

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

POSGRADO EN CIENCIA E INGENIERÍA DE LA COMPUTACIÓN

Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas

**Modelado del crecimiento urbano en la
Zona Metropolitana de Querétaro
mediante Weight of Evidence y Autómatas
Celulares**

TESIS

QUE PARA OPTAR POR EL GRADO DE:

MAESTRO EN CIENCIA E INGENIERÍA DE LA COMPUTACIÓN

PRESENTA:

JOSÉ RODRIGO MORENO LÓPEZ

DIRECTORA DE TESIS:

DRA. MARÍA ELENA LÁRRAGA RAMÍREZ

Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas

Ciudad Universitaria, Cd. Mx., 2026

UNAM – Dirección General de Bibliotecas

Tesis Digitales

Restricciones de uso

DERECHOS RESERVADOS ©

PROHIBIDA SU REPRODUCCIÓN TOTAL O PARCIAL

Todo el material contenido en esta tesis esta protegido por la Ley Federal del Derecho de Autor (LFDA) de los Estados Unidos Mexicanos (México).

El uso de imágenes, fragmentos de videos, y demás material que sea objeto de protección de los derechos de autor, será exclusivamente para fines educativos e informativos y deberá citar la fuente donde la obtuvo mencionando el autor o autores. Cualquier uso distinto como el lucro, reproducción, edición o modificación, será perseguido y sancionado por el respectivo titular de los Derechos de Autor.

*A mi madre, ante todo,
por sostenerme con su ejemplo y su cariño incondicional;
cada página de este trabajo lleva algo suyo.*

*A mi Aurora, raíz y refugio,
cuya fortaleza me acompaña siempre.*

*A Germán,
que me acogió cuando faltaron guía y hogar.*

*A Mau,
por caminar a mi lado sin soltarme
y guiarme con su experiencia.*

*A Donald, que no me dejó rendirme:
sin él, este camino no habría llegado a su fin.*

*Y a Edrei, Ameyalli y Daniela,
hermanos que la vida me dio a elegir.*

Gracias por ser mi lugar seguro.

Agradecimientos

Se agradece a la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (SECIHTI) por el apoyo otorgado a través de la beca para los estudios de maestría que hicieron posible este trabajo.

A la Dra. María Elena Lárraga Ramírez, directora de esta tesis, por su guía rigurosa, su paciencia y su disposición permanente para orientar el trabajo en las direcciones que importan. Sus observaciones precisas mejoraron cada etapa del proceso.

Al Posgrado en Ciencia e Ingeniería de la Computación (PCIC) de la Universidad Nacional Autónoma de México, y en particular a los miembros del comité tutorial, por el acompañamiento académico a lo largo del programa.

A quienes compartieron discusiones técnicas, recursos de cómputo o simplemente tiempo durante el desarrollo de esta investigación.

Resumen

Se presenta una estrategia de integración, calibración y validación para construir un modelo reproducible de crecimiento urbano a partir de imágenes históricas de libre acceso, evaluado mediante un protocolo multitemporal con cinco ventanas quinquenales desplazadas. El modelo combina Pesos de Evidencia (WoE) con un autómata celular (AC) y se aplica como caso de uso a la Zona Metropolitana de Querétaro sobre una serie anual de 37 años (1984–2020).

Las capturas RGB obtenidas con la herramienta de imagen histórica de Google Earth se transformaron en mapas binarios urbano/no-urbano mediante un *pipeline* de clasificación abierto: patrones binarios locales (LBP), agrupamiento K-Means y un clasificador SVM lineal. Los Pesos de Evidencia cuantifican, sin supuestos de linealidad, la influencia espacial de siete variables derivadas del mapa binario histórico, y alimentan junto con la vecindad de Moore una regla de transición probabilística. El modelo se calibró por búsqueda sistemática en el espacio de parámetros y se evaluó sobre cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020), un protocolo que distingue un desempeño estructural de un ajuste puntual.

La aportación no reside en el acoplamiento WoE-AC, documentado en la literatura, sino en el protocolo de evaluación multitemporal, en la interpretabilidad auditable variable por variable y en la reproducibilidad completa sobre CPU, sin GPU ni software propietario. El desempeño promedio alcanza un *Figure of Merit* de 0,317, un coeficiente Kappa de 0,445, una exactitud de 0,722 y un *IoU* de 0,633, valores dentro de la banda intermedia del espectro empírico documentado por Pontius Jr et al. [1] (seis de trece aplicaciones con FoM inferior a 0,15 y una sola por encima de 0,50), sostenidos en las cinco ventanas.

Palabras clave: crecimiento urbano; autómatas celulares; Pesos de Evidencia; validación multitemporal; *Figure of Merit*; Zona Metropolitana de Querétaro.

Abstract

A strategy for the integration, calibration and validation of a reproducible urban growth model is presented. The model is built from freely accessible historical imagery and assessed through a multi-temporal validation protocol with five shifted five-year windows. It couples Weights of Evidence (WoE) with a cellular automaton (CA) and is applied, as a case study, to the Querétaro Metropolitan Area over a 37-year annual series (1984–2020).

RGB captures from Google Earth’s historical imagery tool were converted into binary urban/non-urban maps through an open classification pipeline: local binary patterns (LBP), K-Means clustering and a linear SVM. The Weights of Evidence quantify, without linearity assumptions, the spatial influence of seven variables derived from the historical binary map, feeding alongside the Moore neighborhood a probabilistic transition rule. The model was calibrated via systematic parameter-space search and evaluated over five shifted five-year windows (2011–2016 to 2015–2020), a protocol designed to distinguish stable behavior from overfitting to a single period.

The contribution lies not in the WoE-CA coupling, well documented in the literature, but in the multi-temporal evaluation protocol, the variable-by-variable auditability and the full reproducibility on CPU, without GPU or proprietary software. Average performance reaches a Figure of Merit of 0.317, a Kappa coefficient of 0.445, an accuracy of 0.722 and an IoU of 0.633, values within the intermediate band of the multi-site spectrum documented by Pontius Jr et al. [1] (six of thirteen applications with FoM below 0.15 and only one above 0.50), sustained across all five windows.

Keywords: urban growth; cellular automata; Weights of Evidence; multi-temporal validation; Figure of Merit; Querétaro Metropolitan Area.

Índice general

Agradecimientos	III
Resumen	IV
Abstract	V
Acrónimos y siglas	XVII
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Justificación	3
1.3. Antecedentes	3
1.4. Objetivos	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.5. Preguntas de investigación e hipótesis	5
1.5.1. Preguntas de investigación	5
1.5.2. Hipótesis	6
1.6. Aportaciones del trabajo	6
1.7. Organización del documento	7
2. Marco teórico	8
2.1. Fundamentos del preprocesamiento de imágenes	8

2.1.1.	Percepción remota como fuente de datos geoespaciales	8
2.1.2.	Clasificación de cobertura del suelo	9
2.1.3.	Espacio de color y descriptores cromáticos	10
2.1.4.	Patrones binarios locales	10
2.1.5.	Estandarización y análisis de componentes principales	10
2.1.6.	Agrupamiento K-Means	11
2.1.7.	Máquinas de vectores de soporte	11
2.2.	Autómatas Celulares	12
2.2.1.	Espacio celular y teselaciones	12
2.2.2.	Autómatas celulares probabilísticos	13
2.2.3.	Vecindades	13
2.3.	Pesos de Evidencia	16
2.3.1.	Formulación del método	16
2.3.2.	Information Value y ponderación de variables	18
2.3.3.	Ventajas y limitaciones	18
2.3.4.	Aplicación: del WoE a la regla de transición del autómata	19
2.4.	Métricas de evaluación de modelos predictivos	20
2.4.1.	Matriz de confusión	20
2.4.2.	Métricas de clasificación global	21
2.4.3.	Métricas de cambio	23
2.4.4.	Descomposición del error	24
3.	Estado del arte	26
3.1.	Evolución del modelado urbano computacional	26
3.2.	Problemas metodológicos persistentes	27
3.2.1.	Calibración: equifinalidad y costo computacional	27
3.2.2.	Validación: sobreajuste temporal y métricas no comparables	28
3.2.3.	Interpretabilidad: el problema de la caja negra	29
3.2.4.	Reproducibilidad: software propietario y barreras de acceso	30

3.3.	Pesos de Evidencia y modelos probabilísticos espaciales	30
3.4.	Validación espacial en modelos LUCC	32
3.5.	Vacíos específicos en el contexto mexicano	33
3.6.	Síntesis: posicionamiento del presente trabajo	34
4.	Modelo de crecimiento urbano híbrido	36
4.1.	Consideraciones del modelo	36
4.2.	Arquitectura del modelo	37
4.3.	Área de estudio	37
4.3.1.	Localización y características	39
4.3.2.	Adquisición y conformación del conjunto de imágenes	39
4.4.	Preprocesamiento de datos	42
4.4.1.	Representación de los datos y extracción de características	43
4.4.2.	Pipeline de clasificación: de RGB a mapas binarios	45
4.4.3.	Análisis de datos procesados y transformación binaria	47
4.5.	Definición del modelo	50
4.6.	Validación	54
5.	Resultados y análisis	56
5.1.	Dinámica observada del crecimiento urbano	56
5.1.1.	Evolución temporal 1984–2020	56
5.1.2.	Patrones espaciales de expansión	57
5.2.	Resultados del análisis Weight of Evidence	58
5.2.1.	Transiciones históricas identificadas	58
5.2.2.	Pesos por variable (Information Value)	59
5.2.3.	Interpretación de los pesos WoE	59
5.3.	Calibración del modelo	61
5.3.1.	Configuración del autómatas celular	62
5.3.2.	Proceso de calibración	62

5.4.	Simulación del crecimiento urbano	63
5.4.1.	Protocolo de validación quinquenal múltiple	63
5.5.	Evaluación del modelo	64
5.5.1.	Resumen comparativo – cinco períodos quinquenales	64
5.5.2.	Período 2011–2016	67
5.5.3.	Período 2012–2017	68
5.5.4.	Período 2013–2018	69
5.5.5.	Período 2014–2019	70
5.5.6.	Período 2015–2020	71
5.5.7.	Descomposición del desacuerdo en cantidad y asignación	72
5.6.	Análisis espacial del error del modelo	72
5.6.1.	Fuentes de error identificadas	74
5.6.2.	Análisis morfológico de la predicción	75
5.7.	Fortalezas y debilidades del modelo	75
5.7.1.	Fortalezas identificadas	75
5.7.2.	Debilidades identificadas	76
5.8.	Validación de hipótesis	76
5.9.	Síntesis del desempeño del modelo	77
6.	Conclusiones	79
6.1.	Principales hallazgos	79
6.1.1.	Síntesis de la investigación	79
6.1.2.	Respuestas a las preguntas de investigación	80
6.1.3.	Cumplimiento de los objetivos específicos	81
6.1.4.	Cumplimiento de los requerimientos del modelo	81
6.1.5.	Validación de hipótesis	82
6.1.6.	Aportaciones del trabajo	83
6.2.	Alcances	84
6.2.1.	Accesibilidad computacional	84

6.3.	Limitaciones del modelo	85
6.3.1.	Limitaciones de alcance del estudio	85
6.3.2.	Limitaciones conceptuales	86
6.3.3.	Limitaciones empíricas	86
6.3.4.	Limitaciones de transferibilidad	87
6.4.	Trabajo futuro	87
6.4.1.	Corto plazo (1-2 años)	87
6.4.2.	Mediano plazo (3-5 años)	87
6.4.3.	Largo plazo (5-10 años)	88
6.4.4.	Refinamientos del estimador WoE	88
6.4.5.	Uso en planeación urbana	88
6.5.	Reflexión de cierre	89
A.	Arquitectura e implementación del software	90
A.1.	Procedimiento de adquisición manual de imágenes	92
A.2.	Pseudocódigo del pipeline de clasificación	93
A.3.	Tablas complementarias del conjunto de datos	95
	Bibliografía	98

Índice de figuras

1.1.	Secuencia de capturas RGB (insumo <i>raw</i>) obtenidas con Google Earth en modo imagen histórica sobre la Zona Metropolitana de Querétaro (1984, 2010 y 2020), en orden cronológico y con encuadre homogéneo según el procedimiento manual descrito para la serie temporal. Visualmente se aprecia la expansión periférica y un patrón de ocupación predominantemente disperso.	2
2.1.	Dimensiones y teselaciones del espacio celular, con la celda urbana en azul oscuro y la no urbana en gris. El caso unidimensional (a) es el que Wolfram empleó para clasificar los comportamientos del formalismo. La rejilla cuadrada (b) es la habitual en modelado urbano, porque coincide con la rejilla de la imagen digital. Las teselaciones hexagonal (c) y triangular (d) son alternativas válidas: la hexagonal tiene la ventaja de que los seis vecinos equidistan del centro. . .	13
2.2.	Vecindad de Moore (8 celdas adyacentes) frente a Von Neumann (4 ortogonales). La de Von Neumann propaga el crecimiento solo en las direcciones cardinales; la de Moore admite además frentes diagonales. <i>Imagen elaborada con IA generativa, con base en la definición de Wolfram [28].</i>	14
2.3.	Condiciones de frontera para las celdas del borde, que no tienen vecindad completa. La periódica (a) identifica cada borde con el opuesto y convierte el dominio en un toro. La fija (b) asigna un estado constante al exterior. La reflejante (c) replica hacia fuera el estado de las celdas interiores. El recuadro negro delimita el dominio simulado; las celdas semitransparentes o rayadas son el exterior que cada convención supone.	15

2.4.	Ejemplo del cálculo de WoE: la variable <i>distancia al frente urbano</i> acumula pesos positivos en bins próximos y negativos en bins lejanos. La suma ponderada pasa por la sigmoide y se compara con un umbral de transición θ . <i>Imagen elaborada con IA generativa, con base en la formulación de Bonham-Carter [30].</i>	17
2.5.	Matriz de confusión (a) y componentes del <i>Figure of Merit</i> (b). En el panel (a), <i>FP</i> corresponde a sobre-predicción y <i>FN</i> a sub-predicción. En el panel (b), <i>B</i> es el acierto sobre la transición, <i>A</i> la falsa alarma y <i>C</i> la omisión. La diferencia entre ambos paneles está en el alcance: las permanencias urbanas y no urbanas quedan fuera del FoM, que solo contabiliza celdas en transición.	21
4.1.	Framework operativo del modelo WoE-AC. Para cada una de las seis etapas se indica la entrada que recibe, la operación que realiza y el artefacto que entrega, con ejemplos tomados de la serie y de la ventana 2015–2020. El período 2011–2020 no interviene en la estimación de los pesos de evidencia. <i>Imagen elaborada con IA generativa, con base en la arquitectura propia descrita en este capítulo. . .</i>	38
4.2.	Indicadores auxiliares de calidad por década, derivados del preprocesamiento de las capturas. No equivalen a control de calidad radiométrico de productos satelitales oficiales; sirven como apoyo visual para revisar la continuidad de la serie.	42
4.3.	Representación binaria $U_t(i, j) \in \{0, 1\}$: celdas oscuras urbanas y claras no urbanas. <i>Imagen elaborada con IA generativa, con base en la definición propia de U_t de esta sección.</i>	43
4.4.	Pipeline de preprocesamiento implementado	46
4.5.	Sub-pipeline de clasificación aplicado a un recorte de 8×8 celdas: de la captura RGB al mapa binario. El agrupamiento separa dos clases pero no las nombra; la asignación urbano/no urbano se fija en un paso posterior, con la convención descrita en el texto de esta sección. <i>Imagen elaborada con IA generativa, con base en el pipeline de clasificación propio descrito en esta sección.</i>	48
4.6.	Evolución del crecimiento urbano de la Zona Metropolitana de Querétaro (1984–2020), representada mediante mapas binarios urbano/no-urbano obtenidos a partir de la clasificación LBP+K-Means+SVM aplicada a las capturas RGB de la serie.	49
4.7.	Transición $U_t(i, j) = 0 \rightarrow U_{t+1}(i, j) = 1$: la celda con borde rojo transita a urbana cuando $P_{i,j} > \theta$. <i>Imagen elaborada con IA generativa, con base en la regla de transición propia de la ecuación 2.6.</i>	50

4.8.	Las siete variables espaciales derivadas del mapa binario U_t . Todas se calculan exclusivamente a partir de la configuración urbana histórica, sin capas externas. <i>Imagen elaborada con IA generativa, con base en las siete variables definidas en esta sección.</i> . . .	51
4.9.	Un paso del AC: las celdas candidatas (borde rojo) se evalúan con la regla WoE y transitan a urbanas (relleno rojo) si $P_{i,j} > \theta$. <i>Imagen elaborada con IA generativa, con base en el algoritmo propio del autómata descrito en esta sección.</i>	52
4.10.	Protocolo de validación: separación temporal entre entrenamiento (WoE, 1984–2010) y las cinco ventanas quinquenales de prueba (2011–2020). Ningún dato del período de prueba interviene en el ajuste del modelo. <i>Imagen elaborada con IA generativa, con base en el protocolo propio de validación quinquenal múltiple.</i>	54
4.11.	Componentes del <i>Figure of Merit</i> : acierto (B), falsa alarma (A) y omisión (C). Solo las celdas en transición entran al cálculo. <i>Imagen elaborada con IA generativa, con base en la definición de Pontius Jr et al. [1].</i>	55
5.1.	Evolución de la fracción clasificada como “urbano” en Querétaro (1984–2020). Se observa una tendencia ascendente con fuerte variabilidad interanual, más marcada en el tramo final de la serie.	57
5.2.	<i>Information Value</i> por variable (izquierda) y rango de pesos WoE por variable (derecha), calculados sobre el período de entrenamiento 1984–2010. La distancia al área urbana concentra el IV más alto (3,270, un 28,2 % del total), por encima de la densidad de vecindad 3×3 (2,897, un 24,9 %). El panel derecho muestra que ambas variables son también las de mayor amplitud entre evidencia negativa y positiva.	61
5.3.	Desempeño comparado del modelo WoE-AC en las cinco ventanas quinquenales. Las líneas verticales punteadas señalan el promedio de cada métrica: FoM = 0,317, Kappa = 0,445, IoU = 0,633. El FoM más bajo coincide con la única ventana cuyo crecimiento neto observado es negativo. <i>Figura elaborada con IA generativa a partir de los resultados de validación propios de la Tabla 5.5.</i>	66
5.4.	Validación quinquenal 2011–2016. De izquierda a derecha: estado inicial (2011), mapa observado 2016 (<i>ground truth</i>), mapa predicho 2016 y diferencia (verde=TP, naranja=FP, azul=FN). FoM = 0,222; la anomalía se debe a que el área urbana observada disminuyó levemente por variabilidad en la clasificación binaria RGB año a año.	67

5.5.	Validación quinquenal 2012–2017. FoM = 0,345; período con crecimiento observado positivo (+27,9 %) y FoM superior al de la ventana 2011–2016 bajo el mismo protocolo. Los 602 889 hits (B) corresponden a píxeles donde tanto el modelo como la observación registran transición a urbano en el período, asociados a la expansión perimetral visible en el mapa binario.	68
5.6.	Validación quinquenal 2013–2018. FoM = 0,355; valor cercano al del período 2012–2017 en un contexto análogo de crecimiento observado positivo. El número de omisiones (231 317 píxeles) sugiere que parte de la expansión hacia el norte y el este no queda recogida en la predicción bajo este experimento.	69
5.7.	Validación quinquenal 2014–2019. FoM = 0,287; el crecimiento real modesto (+9,5 %) contrasta con una predicción de expansión más elevada (+68,3 %), lo que se refleja en la proporción de falsas alarmas (1 176 288 píxeles). El Recall alto (0,965) indica que el modelo asigna clase urbana de forma amplia respecto al mapa observado en 2019.	70
5.8.	Validación quinquenal 2015–2020. FoM = 0,378; entre las cinco ventanas es el FoM más alto, en un contexto de fuerte crecimiento observado (+33,5 %). Se registran 704 983 hits y, en términos relativos a este conjunto de corridas, una menor proporción de falsas alarmas que en otras ventanas.	71
5.9.	Mapa de error para la ventana 2015→2020 (FoM = 0,378). Las celdas verdes (B) son aciertos, es decir, transiciones correctamente predichas; las ámbar (A) son falsas alarmas; las rojas (C) son omisiones. Solo las celdas en transición entran al cálculo del FoM; las permanencias urbanas y no urbanas aparecen en gris. <i>Figura elaborada con IA generativa a partir de los mapas predicho y observado propios de la ventana 2015–2020.</i>	73
A.1.	Arquitectura del framework WoE-AC para modelado de crecimiento urbano. Diagrama UML mostrando las clases del sistema organizadas en paquetes: Configuration (configuración), Data/IO (manejo de datos históricos), Feature & Spatial (extracción de características), Weight of Evidence (cálculo de pesos), Cellular Automaton (simulación AC) y Orchestrator (pipeline y calibración de parámetros). El diagrama se genera desde el código fuente usando PlantUML (ver diagramas/architecture.puml).	91

Índice de tablas

1.1.	Requerimientos del modelo de crecimiento urbano para la ZMQ.	3
3.1.	Posicionamiento de la literatura mexicana frente a R1–R4.	34
5.1.	Fracción media de píxeles clasificados como “urbano” por tramo de la serie 1984–2020. Las cifras provienen directamente de los mapas binarios y deben leerse como un indicador grueso de la dinámica, no como superficie construida.	57
5.2.	<i>Information Value</i> y pesos normalizados de las siete variables WoE, calculados sobre el período de entrenamiento (1984–2010).	59
5.3.	Configuración final del Autómata Celular WoE-AC.	62
5.4.	Configuración del experimento de validación quinquenal múltiple.	63
5.5.	Métricas de validación en las cinco ventanas quinquenales (WoE-AC, umbral $\theta = 0,75$).	64
5.6.	Posicionamiento del modelo WoE-AC en el espectro empírico de Figure of Merit (FoM) documentado en la literatura LUCC. La comparación es cualitativa: los sitios, las definiciones temáticas de las clases y los horizontes temporales difieren entre estudios.	65
5.7.	Métricas de validación del período 2011→2016. <i>B</i> (hits del FoM) es el subconjunto de <i>TP</i> que corresponde a transiciones a urbano observadas y predichas simultáneamente; los píxeles permanentes ya urbanizados quedan incluidos en <i>TP</i> pero no en <i>B</i> (véase Ec. 2.24).	67
5.8.	Métricas de validación del período 2012→2017.	68
5.9.	Métricas de validación del período 2013→2018.	69
5.10.	Métricas de validación del período 2014→2019.	70

5.11. Métricas de validación del período 2015→2020.	71
5.12. Descomposición del desacuerdo total en sus componentes de cantidad y de asignación [33], sobre las 5 419 008 celdas de cada ventana. El desacuerdo total es el complemento de la exactitud global de la Tabla 5.5. La última columna es la fracción del desacuerdo atribuible a la cantidad.	72
5.13. Estimación cualitativa de la contribución de fuentes de error (no cuantificada empíricamente)	74
6.1. Validación de hipótesis particulares	82
6.2. Características operativas del enfoque WoE-AC frente a modelos de aprendizaje profundo	85
A.1. Características extraídas por píxel a partir de cada captura RGB.	95
A.2. Estimación cualitativa de las principales fuentes de error del conjunto de imágenes, su efecto sobre los mapas binarios y su mitigación. Los niveles son apreciaciones del autor, no medidas formales de incertidumbre.	96
A.3. Resumen agregado del preprocesamiento aplicado a la serie 1984–2020.	97

Acrónimos y siglas

ABM	Modelos basados en agentes (<i>Agent-Based Models</i>).
AC	Autómata celular (<i>Cellular Automaton</i>).
CLUE-S	<i>Conversion of Land Use and its Effects at Small regional extent.</i>
CONAPO	Consejo Nacional de Población.
CPU	Unidad central de procesamiento (<i>Central Processing Unit</i>).
EPSG	Registro de sistemas de referencia de coordenadas (<i>European Petroleum Survey Group</i>).
ExG	Índice de exceso de verde (<i>Excess Green Index</i>).
ExR	Índice de exceso de rojo (<i>Excess Red Index</i>).
FLUS	<i>Future Land Use Simulation.</i>
FoM	Figura de Mérito (<i>Figure of Merit</i>).
FRAGSTATS	Programa de análisis de métricas del paisaje (<i>Fragmentation Statistics</i>).
GPU	Unidad de procesamiento gráfico (<i>Graphics Processing Unit</i>).
HSV	Espacio de color matiz-saturación-valor (<i>Hue, Saturation, Value</i>).
IIEc	Instituto de Investigaciones Económicas, UNAM.
IIMAS	Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas.
INEGI	Instituto Nacional de Estadística y Geografía.
IoU	Índice de solapamiento (<i>Intersection over Union</i>).
IV	Valor de Información (<i>Information Value</i>).
LAB	Espacio de color CIELAB (luminosidad y dos ejes cromáticos).
LBP	Patrones binarios locales (<i>Local Binary Patterns</i>).
LUCC	Cambio en la cobertura y uso del suelo (<i>Land Use / Land Cover Change</i>).

NDBI	Índice de edificación de diferencia normalizada (<i>Normalized Difference Built-up Index</i>).
NDVI	Índice de vegetación de diferencia normalizada (<i>Normalized Difference Vegetation Index</i>).
NGRDI	Índice verde-rojo normalizado (<i>Normalized Green-Red Difference Index</i>).
NIR	Infrarrojo cercano (<i>Near Infrared</i>).
PCA	Análisis de componentes principales (<i>Principal Component Analysis</i>).
PCIC	Posgrado en Ciencia e Ingeniería de la Computación.
PMOTDU	Programa Municipal de Ordenamiento Territorial y Desarrollo Urbano.
RGB	Modelo de color rojo-verde-azul (<i>Red-Green-Blue</i>).
ROC	Característica operativa del receptor (<i>Receiver Operating Characteristic</i>).
SECIHTI	Secretaría de Ciencia, Humanidades, Tecnología e Innovación.
SEDATU	Secretaría de Desarrollo Agrario, Territorial y Urbano.
SLEUTH	<i>Slope, Land use, Exclusion, Urban, Transportation, Hillshade.</i>
SVM	Máquina de vectores de soporte (<i>Support Vector Machine</i>).
UML	Lenguaje unificado de modelado (<i>Unified Modeling Language</i>).
UNAM	Universidad Nacional Autónoma de México.
WGS84	Sistema geodésico mundial de 1984 (<i>World Geodetic System 1984</i>).
WoE	Pesos de Evidencia (<i>Weight of Evidence</i>).
ZMCM	Zona Metropolitana de la Ciudad de México.
ZMQ	Zona Metropolitana de Querétaro.

Capítulo 1

Introducción

1.1. Planteamiento del problema

Google Earth en escritorio ofrece una línea de tiempo de imagen histórica de acceso libre. Esas capturas muestran cómo ha cambiado una ciudad año con año. No son, sin embargo, un mapa de cobertura: hay que convertirlas en una serie comparable y, a partir de ella, simular dónde puede aparecer lo urbano nuevo.

La urbanización es uno de los procesos que más transforma el territorio en este siglo. Una fracción creciente de la población mundial vive en ciudades, y la superficie urbana suele expandirse más rápido que la población que la habita [2, 3]. El mismo proceso se observa en México, con ritmos e instrumentos distintos a los de otros países.

Anticipar ese crecimiento es, en el fondo, un problema de simulación espacial. Para abordarlo se han desarrollado modelos de cambio de uso y cobertura de suelo (LUCC), entre los que los autómatas celulares ocupan un lugar central por representar la ciudad celda a celda. Su utilidad práctica, sin embargo, depende de tres condiciones que rara vez se cumplen a la vez: que la regla de transición sea interpretable, que el desempeño se valide en más de un horizonte temporal y que el flujo completo sea reproducible con datos abiertos.

Estas tensiones se agudizan en las ciudades intermedias, y en particular en las mexicanas, poco representadas en la literatura de modelado urbano pese a concentrar buena parte del crecimiento reciente del país [4]. La Zona Metropolitana de Querétaro sirve en este trabajo como caso de uso para ejercitar y validar el protocolo: una ciudad intermedia con una dinámica de expansión representativa y una serie de imágenes de archivo lo bastante larga para evaluarlo en varios períodos.

México cuenta con instrumentos de ordenamiento territorial: la Ley General de Asentamientos Humanos, los Programas Municipales de Ordenamiento Territorial y Desarrollo Urbano (PMOTDU), la Secretaría de Desarrollo Agrario, Territorial y Urbano (SEDATU) y acuerdos con ONU-Hábitat. Su cobertura efectiva es incompleta, y una parte de los planes publicados no se ha actualizado [5, 6]. El INEGI documenta que la mayor parte de la población reside en localidades urbanas [7]. El resultado observable es un patrón de crecimiento disperso que supera la capacidad de planificación disponible, con impactos documentados sobre infraestructura, cobertura de suelo y calidad de vida.



Figura 1.1: Secuencia de **capturas RGB** (insumo *raw*) obtenidas con Google Earth en modo imagen histórica sobre la Zona Metropolitana de Querétaro (**1984, 2010 y 2020**), en orden cronológico y con encuadre homogéneo según el procedimiento manual descrito para la serie temporal. Visualmente se aprecia la expansión periférica y un patrón de ocupación predominantemente disperso.

Como se observa en la figura 1.1, la mancha urbana de Querétaro se expandió de forma dispersa entre 1984 y 2020, sobre una zona metropolitana que rebasó el millón y medio de habitantes tras décadas de expansión sostenida [7, 8]. Este patrón, documentado pero no suficientemente modelado para la ZMQ, impide anticipar dónde y a qué velocidad se producirá la siguiente oleada de expansión: información necesaria para el diseño de infraestructura y política territorial. Como instancia concreta de ese problema, el trabajo ejerce el modelo sobre la ZMQ, que reúne una serie histórica larga (37 años), datos de acceso libre y una dinámica de crecimiento propia de las ciudades intermedias del centro del país. Para que un modelo de simulación sea útil como herramienta de apoyo a la planeación, debe satisfacer los cuatro requerimientos de la Tabla 1.1.

Tabla 1.1: Requerimientos del modelo de crecimiento urbano para la ZMQ.

ID	Requerimiento	Descripción y criterio de cumplimiento
R1	Simulación histórica con precisión	Reproducir el patrón de cambio urbano/no-urbano a partir del historial de uso de suelo. El desempeño se evalúa cuantitativamente con <i>Figure of Merit</i> (FoM), Kappa e <i>Intersection over Union</i> (IoU) en ventanas de validación desplazadas respecto del entrenamiento.
R2	Soporte a planeación estratégica	Generar mapas espacialmente explícitos que sirvan para comparar patrones de expansión bajo supuestos declarados, leídos como escenarios y no como planes calibrados.
R3	Replicabilidad y apertura	El flujo completo debe ser documentado, reproducible y ejecutable sin software propietario ni hardware especializado, con calibración sistemática y tiempos de cómputo razonables.
R4	Interpretabilidad de la función de transición	La función que decide la transición de cada celda debe ser auditable: sus pesos deben ser legibles como evidencia espacial cuantificable, no como parámetros opacos de una red neuronal.

1.2. Justificación

En las ciudades intermedias mexicanas es poco frecuente disponer de un modelo de simulación interpretable celda a celda, validado en varios horizontes y reproducible con datos abiertos. Mientras ese vacío persista, no es posible distinguir si el desempeño de los modelos disponibles para el país responde a mecanismos espaciales estables o a un sobreajuste de corto plazo. Los requerimientos R1–R4 de la Tabla 1.1 son la forma operativa de comprobar si un modelo cierra esa brecha.

1.3. Antecedentes

El modelado del crecimiento urbano cuenta con numerosos estudios, agrupables según el tipo de función de transición que emplean. Los modelos de caja negra basados en aprendizaje automático [9] alcanzan concordancia espacial alta en los casos publicados, pero sus pesos internos no son legibles como evidencia espacial, lo que dificulta su uso en contextos que exigen transparencia metodológica. Los híbridos metaheurísticos [10] sustituyen los pesos por cromosomas, con la misma consecuencia para la interpretabilidad. Los modelos de caja blanca más citados [11, 12, 13] atienden la interpretabilidad, pero en la mayoría de los casos se validan

sobre un único período quinquenal, sin que sea posible determinar si el desempeño refleja mecanismos espaciales estables o sobreajuste a esa fase concreta del crecimiento. Los trabajos revisados para ciudades mexicanas [14, 15, 16] satisfacen parcialmente R1 y R2, pero no R3 ni R4. Las aplicaciones basadas en Pesos de Evidencia se han calibrado y validado principalmente en contextos internacionales, con dinámicas de crecimiento y fuentes de datos distintas a las ciudades intermedias del país. El análisis detallado de estos trabajos se desarrolla en el Capítulo 3.

Se desarrolló y validó un modelo que acopla Pesos de Evidencia (WoE) con un autómata celular (AC) y que busca satisfacer R1–R4 de forma conjunta. El WoE produce pesos de evidencia cuantificables por variable (R4). Los parámetros se calibraron por búsqueda sistemática sobre el período de entrenamiento y el desempeño se evaluó después en cinco ventanas quinquenales desplazadas, de modo que se mide la estabilidad temporal y no solo el ajuste a un período (R1). La implementación en Python con datos de acceso libre hace reproducible el flujo sin software propietario (R3). Los mapas simulados se leen como escenarios de expansión, no como planes calibrados (R2). Querétaro es el caso de uso donde se ejerce y se valida el protocolo. La aportación es el protocolo mismo, potencialmente transferible a otras ciudades intermedias previa recalibración, aunque esa transferencia no se verificó empíricamente aquí.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar un modelo basado en autómatas celulares que integre el método Weight of Evidence para simular el crecimiento urbano de la Zona Metropolitana de Querétaro en el período 1984–2020, evaluar su desempeño mediante métricas espaciales cuantitativas y comparar los resultados con valores de referencia reportados en la literatura. Esto es, desarrollar un modelo que cumpla con los requerimientos básicos planteados en la Tabla 1.1 y que sea capaz de simular el crecimiento urbano de la ciudad de Querétaro en el período 1984–2020.

1.4.2. Objetivos específicos

El primer objetivo específico (OE1) consiste en construir una serie histórica anual (1984–2020) de mapas binarios urbano/no-urbano para la ZMQ a partir de imágenes de archivo de Google Earth, empleando clasificación no supervisada para prescindir de etiquetas manuales, de modo que el flujo de adquisición y preprocesamiento sea replicable sin software propietario. Sobre esa serie, el segundo objetivo (OE2) selecciona y calcula las variables espaciales derivadas de los mapas binarios, que sirven de evidencia empírica al modelo WoE. La elección de WoE

como función de transición, frente a alternativas como la regresión logística o las redes neuronales, responde a su capacidad de descomponer la contribución de cada variable mediante el *Information Value* (IV), propiedad que hace auditable la decisión celda a celda y cumple el requerimiento R4 de la Tabla 1.1.

El tercer objetivo (OE3) diseña e implementa el autómatas celular WoE-AC que simula la transición de no urbano a urbano en la ZMQ. La decisión de usar AC sobre enfoques basados en agentes (ABM) o modelos estadísticos puros se fundamenta en que los AC capturan la dinámica de difusión espacial emergente sin requerir la especificación de reglas de comportamiento individual, y mantienen la interpretabilidad del modelo al nivel de la rejilla espacial [11, 12]. El cuarto objetivo (OE4) calibra sistemáticamente los parámetros del WoE-AC (umbral de transición y peso de vecindad) mediante búsqueda en cuadrícula y establece un protocolo de validación multi-período con cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020), evaluadas con FoM, Kappa e IoU. La validación en ventanas desplazadas, en lugar de un único período final, hace posible detectar el sobreajuste a una fase específica del crecimiento urbano [1].

Por último, el quinto objetivo (OE5) analiza la estabilidad temporal del desempeño del modelo a lo largo de los cinco períodos y compara los valores de FoM e IoU obtenidos con los rangos reportados en la literatura para modelos de caja blanca y de caja negra, con el fin de posicionar la contribución del trabajo en el contexto del estado del arte.

1.5. Preguntas de investigación e hipótesis

1.5.1. Preguntas de investigación

La investigación se articula en torno a cuatro preguntas, que se identifican como P1 a P4 para poder rastrear su respuesta en las conclusiones. **P1** indaga si un modelo WoE-AC calibrado puede reproducir el patrón de crecimiento urbano observado en la Zona Metropolitana de Querétaro (ZMQ) con métricas espaciales (Figure of Merit, Kappa e Intersection over Union) comparables a las de la literatura. **P2** interroga qué variables espaciales tienen mayor poder discriminatorio para predecir la transición urbana en la ZMQ. **P3** examina si el modelo mantiene la estabilidad de su desempeño al evaluarse en cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020). Cada ventana queda fuera del entrenamiento; entre sí se solapan. **P4** plantea si el flujo completo, desde la adquisición de imágenes hasta la validación, se ejecuta con herramientas de código abierto en una CPU estándar, sin GPU ni software propietario.

1.5.2. Hipótesis

Hipótesis general. Un modelo híbrido WoE-AC, calibrado y validado mediante un protocolo multitemporal sobre datos de libre acceso, permite simular de forma interpretable y reproducible el crecimiento urbano de una ciudad intermedia mexicana con un desempeño comparable al reportado en la literatura.

De esa hipótesis general se derivan cuatro particulares, cada una falsable con los resultados del Capítulo 5.

H1 (interpretabilidad). La regla de transición basada en WoE ponderada por Information Value produce un modelo en el que cada variable contribuye de forma auditable: la distancia al frente urbano y la densidad de vecindad concentran el mayor IV, por encima de las variables de fragmentación y de gradiente.

H2 (estabilidad temporal). El desempeño del modelo se sostiene en cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020), sin degradación sistemática atribuible al modelo. El valor más bajo se asocia a la ventana de menor crecimiento neto observado, no a un fallo de calibración.

H3 (reproducibilidad). El flujo completo, desde la adquisición de imágenes hasta la validación quinquenal, se ejecuta con herramientas de código abierto en una CPU estándar, sin requerir GPU, software propietario ni hardware especializado.

H4 (desempeño comparable). Aplicado a la Zona Metropolitana de Querétaro, el modelo reproduce el patrón de crecimiento con métricas (FoM, Kappa e IoU) dentro del rango de la literatura LUCC, por encima del subconjunto de modelos con FoM inferior a 0,15 [1], sin recurrir a representaciones de caja negra.

1.6. Aportaciones del trabajo

La combinación de Pesos de Evidencia y autómatas celulares no es, en sí misma, una novedad metodológica: existe una literatura consolidada que la emplea. Lo que distingue a este trabajo no es la técnica, sino la metodología con que se evaluó y las condiciones de reproducibilidad bajo las que se aplicó.

La aportación central es de carácter metodológico: un protocolo de evaluación reproducible y multi-período. En lugar de validar sobre un único horizonte, el modelo se evaluó sobre cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020) con un conjunto de métricas espaciales complementarias (Figure of Merit, Kappa e Intersection over Union) y la descomposición

del error de Pontius entre desacuerdo de cantidad y de asignación, situando el desempeño en el espectro empírico multi-sitio de referencia. Ese protocolo permite distinguir un desempeño estable de un ajuste a una fase concreta del crecimiento, y arrojó métricas dentro del rango reportado en la literatura (FoM promedio 0,317, Kappa promedio 0,445), sostenidas a lo largo de los cinco horizontes y no concentradas en uno solo.

Sobre ese núcleo se apoyan las demás aportaciones. El flujo completo, desde la adquisición de imágenes hasta la validación quinquenal, se implementó con herramientas de código abierto y quedó documentado paso a paso, de modo que otros investigadores puedan reproducirlo, adaptarlo o extenderlo a otras ciudades intermedias. La función de transición WoE aporta, además, pesos de evidencia y valores de información (IV) legibles por variable, lo que mantiene auditable cada decisión del modelo y facilita interpretar los resultados en términos de los mecanismos espaciales que los sustentan.

El protocolo se ejercita, por último, sobre un contexto poco representado en la literatura de modelado urbano: las ciudades intermedias mexicanas, habitualmente analizadas con calibraciones heurísticas y sobre un solo horizonte temporal. Para ello se construyó una serie histórica larga, 37 años continuos (1984–2020), a partir de imágenes de archivo de acceso libre, una base temporal más extensa que la habitual en trabajos comparables para el país. Querétaro es el caso de uso donde el protocolo se ejercita y se valida.

1.7. Organización del documento

El resto de la tesis sigue el hilo que abre este diagnóstico. El Capítulo 2 fija el andamiaje formal mínimo (fundamentos del preprocesamiento de imágenes, autómatas celulares probabilísticos, Pesos de Evidencia y métricas de evaluación espacial) que el modelo necesita para ser especificado y evaluado con precisión. El Capítulo 3 muestra que los problemas metodológicos que motivan el trabajo (calibración heurística, validación en un solo período, dependencia de software propietario y poca presencia de ciudades intermedias mexicanas en la literatura) siguen abiertos y justifican la propuesta. El Capítulo 4 es el núcleo empírico: presenta el área de estudio, los datos y su preprocesamiento, y formaliza el acoplamiento WoE-AC, su calibración por búsqueda sistemática y el protocolo de validación quinquenal múltiple. El Capítulo 5 muestra que el modelo se sostiene en las cinco ventanas (FoM medio 0,317) y lo sitúa frente a la literatura. Por último, el Capítulo 6 contrasta las hipótesis con la evidencia, precisa las aportaciones, define los alcances y acota lo que el modelo sí y no permite afirmar, junto con las líneas de trabajo futuro. El Apéndice A reúne el material de soporte: la arquitectura de software, el pseudocódigo del pipeline de clasificación y las tablas de detalle de las características y del preprocesamiento.

Capítulo 2

Marco teórico

En este capítulo se presentan los conceptos necesarios para comprender la propuesta. Se define primero la cadena que permite convertir una imagen en un mapa de dos clases: la percepción remota como fuente de datos, la clasificación de cobertura del suelo, los descriptores de color y de textura, y los métodos de reducción dimensional, agrupamiento y clasificación. Se define después el autómata celular, con sus dimensiones, vecindades y condiciones de frontera, y su versión probabilística. Se expone enseguida el método de Pesos de Evidencia, con sus ventajas y sus límites, y la razón por la que se articula con la función de transición de un autómata celular. Se cierra con las métricas empleadas para evaluar modelos de cambio de cobertura. La aplicación de estos conceptos al caso estudiado corresponde al Capítulo 4.

2.1. Fundamentos del preprocesamiento de imágenes

Un modelo de crecimiento urbano basado en celdas requiere como entrada un mapa discreto de estados. Obtener ese mapa a partir de una imagen exige una cadena de conceptos que esta sección define en el orden en que intervienen: la fuente de datos, la tarea de clasificación de cobertura, los descriptores que representan cada píxel y los métodos que agrupan y separan esos descriptores en clases. La aplicación concreta de la cadena al conjunto de imágenes del caso de estudio se describe en la Sección 4.4.

2.1.1. Percepción remota como fuente de datos geoespaciales

La percepción remota permite observar la superficie terrestre sin contacto directo, mediante sensores que registran la radiación reflejada o emitida. Un producto de percepción remota queda caracterizado por cuatro resoluciones: la espacial, que fija el tamaño de terreno representado

por cada píxel; la espectral, que determina cuántas bandas del espectro se registran y con qué anchura; la temporal, que indica cada cuánto se vuelve a observar el mismo sitio; y la radiométrica, que describe la finura con que se cuantifica la intensidad. La combinación de estas cuatro resoluciones condiciona qué fenómenos pueden estudiarse: un análisis de la forma de la mancha urbana y de su evolución exige sobre todo continuidad temporal y consistencia geométrica, más que una gran finura espectral [17].

Los programas de observación de larga duración, en particular la familia Landsat, hicieron posible construir series históricas de cobertura del suelo con décadas de profundidad y cartografiarlas a escala global [18], y sobre ellas se apoya buena parte de los estudios de cambio de uso de suelo [19]. El acceso a estos acervos se ha facilitado con plataformas de procesamiento en la nube como Google Earth Engine [20], que permiten consultar y procesar grandes volúmenes sin descargarlos. Conviene distinguir esa plataforma del visor de escritorio Google Earth, que no expone las bandas originales del sensor sino un mosaico cartográfico compuesto en color visible, con una herramienta de imagen histórica que permite recuperar la vista de un mismo sitio en distintas fechas. Esa distinción importa porque determina qué información espectral queda disponible, y con ello qué descriptores pueden calcularse.

2.1.2. Clasificación de cobertura del suelo

La clasificación de cobertura del suelo asigna a cada píxel una etiqueta de una lista predefinida de clases. Los métodos se dividen en dos familias según la información que necesitan. Los **supervisados** requieren un conjunto de píxeles previamente etiquetados, la llamada verdad terreno, a partir del cual se ajusta una frontera de decisión. Los **no supervisados** prescinden de esas etiquetas y agrupan los píxeles por similitud en el espacio de características, de modo que la interpretación de cada grupo queda a cargo del analista. Las arquitecturas de aprendizaje profundo, hoy frecuentes en la disciplina, pertenecen a la primera familia y su desempeño depende de la disponibilidad de grandes volúmenes anotados [21].

El caso binario, que distingue únicamente entre cubierta urbana y no urbana, es el pertinente cuando el objeto de estudio es la extensión de la mancha construida y no la composición interna de usos. Reduce el problema a una frontera de decisión y produce directamente el mapa de estados discretos que consume un autómata celular. Su contrapartida es que agrupa en una sola clase superficies heterogéneas, con lo que la etiqueta resultante debe leerse como cubierta construida en sentido amplio y no como uso de suelo urbano en sentido normativo.

2.1.3. Espacio de color y descriptores cromáticos

Una imagen en color se representa habitualmente en el espacio RGB, donde cada píxel es una terna de intensidades en los canales rojo, verde y azul [22]. Ese espacio es adecuado para la representación en pantalla, pero mezcla en sus tres canales la información de iluminación y la de cromaticidad, lo que dificulta separar clases cuando la escena varía en brillo. Por eso es común transformarlo a espacios que separan ambas componentes. El espacio CIE $L^*a^*b^*$ aísla la luminancia L^* de dos ejes cromáticos, y el espacio HSV descompone el color en matiz, saturación y valor [22]. Ninguna transformación añade información: reorganizan la existente de manera que las diferencias relevantes resulten más separables.

A partir de las bandas visibles pueden construirse índices que realzan la presencia de vegetación, como el índice verde-rojo normalizado (NGRDI, *normalized green-red difference index*) o los índices de exceso de verde y de exceso de rojo [23]. Estos índices no equivalen al NDVI, que requiere la banda del infrarrojo cercano; funcionan como aproximaciones cromáticas y bastan cuando el contraste de interés es el que separa superficies vegetadas de superficies construidas.

2.1.4. Patrones binarios locales

El color por sí solo distingue mal el tejido construido, porque una superficie de concreto y un suelo desnudo pueden compartir tonalidad. Lo que los separa es la textura: la regularidad de bordes y contrastes a escala de unos pocos píxeles. Los patrones binarios locales, propuestos por Ojala et al. [24], describen esa textura comparando la intensidad de cada píxel con la de sus vecinos sobre un círculo de radio r con P puntos de muestreo, y codificando el resultado de las comparaciones como un número binario. El descriptor resultante es invariante a cambios monótonos de iluminación, porque depende de comparaciones relativas y no de valores absolutos, y admite versiones invariantes a la rotación. Esa robustez explica su uso en series de imágenes tomadas en fechas distintas, donde las condiciones de captura no son homogéneas.

2.1.5. Estandarización y análisis de componentes principales

Cuando cada píxel se describe con muchas variables, dos problemas aparecen antes de cualquier clasificación. El primero es de escala: variables medidas en unidades distintas contribuyen de forma desigual a cualquier distancia, de modo que las de mayor rango numérico dominan el resultado. La estandarización lo corrige restando la media y dividiendo entre la desviación estándar de cada variable, con lo que todas quedan centradas y con dispersión comparable. El segundo problema es de redundancia: los descriptores derivados de una misma imagen están

correlacionados entre sí, y esa correlación no aporta información nueva pero sí encarece el cómputo y puede degradar la separación entre clases.

El análisis de componentes principales [25] atiende el segundo problema. Es un método no supervisado que busca las direcciones ortogonales de máxima varianza en los datos y proyecta las observaciones sobre las primeras de ellas, ordenadas de mayor a menor varianza explicada. Conservar unas pocas componentes retiene la mayor parte de la variabilidad con muchas menos dimensiones. La reducción se expresa como una proyección lineal de las variables estandarizadas sobre un subespacio de menor dimensión:

$$\mathbf{z}(x, y) = \mathbf{W}^\top \tilde{\mathbf{f}}(x, y) \quad (2.1)$$

donde $\tilde{\mathbf{f}}$ es el vector de variables estandarizadas, $\mathbf{W}$ es la matriz cuyos k primeros autovectores definen el subespacio retenido y $\mathbf{z}$ es la representación reducida.

El pseudocódigo de la estandarización y de la proyección se recoge en el Apéndice A (Algoritmos 2 y 3).

2.1.6. Agrupamiento K-Means

El agrupamiento K-Means, propuesto por MacQueen [26], es un método no supervisado que particiona un conjunto de observaciones en k grupos, minimizando la suma de distancias cuadradas de cada punto al centroide de su grupo. Procede de forma iterativa: asigna cada observación al centroide más próximo, recalcula los centroides como la media de los puntos asignados y repite hasta que las asignaciones se estabilizan. El resultado depende de la inicialización, por lo que en la práctica se ejecuta varias veces y se conserva la partición de menor inercia. Su utilidad en clasificación de imágenes está en que produce una partición del espacio de características sin necesidad de etiquetas previas; su límite es que esa partición carece de significado semántico, de modo que asociar cada grupo a una clase de cobertura requiere una decisión posterior del analista. El procedimiento completo figura en el Apéndice A (Algoritmo 4).

2.1.7. Máquinas de vectores de soporte

La máquina de vectores de soporte [27] es un clasificador supervisado que busca el hiperplano que separa dos clases con el mayor margen posible, es decir, maximizando la distancia a las observaciones más próximas de cada lado. En su formulación de margen blando admite errores de clasificación penalizados por un parámetro de regularización, lo que la hace tolerante al ruido en las etiquetas. Con núcleo lineal la frontera es un hiperplano en el espacio original,

opción adecuada cuando las clases ya resultan casi separables tras la reducción dimensional y cuando interesa un modelo ligero y reproducible.

Que el método sea supervisado no obliga a disponer de verdad terreno. Las pseudo-etiquetas producidas por un agrupamiento no supervisado pueden emplearse como conjunto de referencia para el ajuste, y el clasificador resultante predice después la etiqueta del resto de las observaciones. Conviene precisar el alcance de ese procedimiento: al entrenarse sobre pseudo-etiquetas, la exactitud que se mida indica la coherencia interna del clasificador respecto del agrupamiento, no su acierto frente a una referencia externa independiente. El Apéndice A recoge el pseudocódigo del clasificador (Algoritmo 5).

2.2. Autómatas Celulares

Un **Autómata Celular** (AC), en el sentido formalizado por Wolfram [28], es un sistema dinámico discreto definido sobre una cuadrícula regular de N celdas. Formalmente, un AC queda definido por la cuádrupla $(Q, \mathcal{N}, \delta, q_0)$. El primer elemento, Q , es el conjunto finito de estados posibles de cada celda; en el modelado urbano binario $Q = \{0, 1\}$ distingue lo no-urbano de lo urbano. El segundo, $\mathcal{N}$, es la vecindad: el conjunto de celdas adyacentes cuyo estado influye en la transición. El tercero, $\delta : Q^{|\mathcal{N}|} \rightarrow Q$, es la función de transición, que determina el nuevo estado de una celda a partir del estado de sus vecinos. El último, $q_0 : \Omega \rightarrow Q$, fija la configuración inicial del sistema.

2.2.1. Espacio celular y teselaciones

El espacio celular puede tener cualquier dimensión. Los autómatas unidimensionales, que Wolfram empleó para clasificar los comportamientos posibles del formalismo, disponen las celdas en una línea; los bidimensionales las organizan en una superficie, y los de dimensión superior generalizan la construcción sin cambiar sus reglas. La geometría de la teselación también admite variantes: además de la rejilla cuadrada, habitual por su correspondencia directa con la estructura de una imagen digital, se emplean teselaciones hexagonales, que tienen la ventaja de que todos los vecinos equidistan del centro, y triangulares. El modelado urbano trabaja casi siempre en dos dimensiones sobre rejilla cuadrada, porque es la forma en que se almacenan los datos de percepción remota y porque cada celda admite entonces una lectura directa como superficie de terreno. La Figura 2.1 contrasta las cuatro configuraciones.

En el contexto del crecimiento urbano, el dominio espacial $\Omega \subset \mathbb{Z}^2$ es una cuadrícula discreta de celdas indexadas por pares (i, j) , donde $i \in \{1, \dots, R\}$ indica la fila y $j \in \{1, \dots, C\}$ la columna, con $N = R \times C$ celdas en total.




Figura 2.1: Dimensiones y teselaciones del espacio celular, con la celda urbana en azul oscuro y la no urbana en gris. El caso unidimensional (a) es el que Wolfram empleó para clasificar los comportamientos del formalismo. La rejilla cuadrada (b) es la habitual en modelado urbano, porque coincide con la rejilla de la imagen digital. Las teselaciones hexagonal (c) y triangular (d) son alternativas válidas: la hexagonal tiene la ventaja de que los seis vecinos equidistan del centro.

2.2.2. Autómatas celulares probabilísticos

En los AC probabilísticos, la función de transición δ asigna probabilidades a cada posible nuevo estado, en lugar de determinar el siguiente estado de forma determinista. Esta extensión, base de los modelos urbanos basados en AC desde White y Engelen [29] y de marcos calibrados como SLEUTH [11], resulta adecuada para el modelado urbano, en el que la transición de no-urbano a urbano no está garantizada incluso cuando las condiciones locales son favorables.

Entre los marcos de autómatas celulares urbanos, SLEUTH [11] es el más difundido. Su nombre resume las capas de entrada que utiliza: *slope* (pendiente), *land use* (uso de suelo), *exclusion* (zonas excluidas del crecimiento), *urban* (mancha urbana histórica), *transportation* (vialidades) e *hillshade* (sombreado del terreno). Su comportamiento queda gobernado por cinco coeficientes de crecimiento (*diffusion*, *breed*, *spread*, *slope resistance* y *road gravity*) que se ajustan mediante búsqueda sobre un espacio discreto de combinaciones, evaluando cada una con simulaciones Monte Carlo. Estas definiciones son las que el Capítulo 3 da por sentadas al discutir las dificultades prácticas de esa calibración.

2.2.3. Vecindades

La vecindad determina qué celdas influyen en la transición de una celda dada, y su elección condiciona la forma de los patrones que el autómata puede generar. Los dos tipos más utilizados en modelado urbano son la vecindad de Von Neumann, formada por las cuatro celdas ortogonalmente adyacentes, y la vecindad de Moore, que añade las cuatro diagonales hasta sumar ocho. La diferencia no es menor en este dominio: la vecindad de Von Neumann propaga el crecimiento solo en las direcciones cardinales, mientras que la de Moore admite frentes diagonales, más próximos a la forma en que se expande una mancha urbana. En ambos casos

el radio de influencia puede extenderse más allá de la celda inmediatamente adyacente, con lo que se representan efectos de proximidad a mayor escala a costa de un cómputo mayor. La Figura 2.2 compara las dos vecindades sobre una misma configuración.




Figura 2.2: Vecindad de Moore (8 celdas adyacentes) frente a Von Neumann (4 ortogonales). La de Von Neumann propaga el crecimiento solo en las direcciones cardinales; la de Moore admite además frentes diagonales. *Imagen elaborada con IA generativa, con base en la definición de Wolfram [28].*

Queda por resolver el tratamiento de las celdas del borde, que no tienen vecindad completa. Las tres convenciones habituales son la frontera periódica, que identifica cada borde con el opuesto y convierte el dominio en un toro; la frontera fija o absorbente, que asigna a las celdas exteriores un estado constante; y la frontera reflejante, que replica hacia fuera el estado de las celdas interiores. La Figura 2.3 ilustra las tres. En aplicaciones urbanas la frontera periódica carece de sentido físico, porque uniría zonas geográficamente distantes, de modo que se prefiere una frontera fija en estado no urbano. La consecuencia es doble: el crecimiento cerca del borde queda subestimado y el dominio debe elegirse con margen suficiente alrededor del área de interés.

La influencia de la vecindad suele cuantificarse mediante la proporción de celdas urbanas en un radio r alrededor de la celda evaluada:




Figura 2.3: Condiciones de frontera para las celdas del borde, que no tienen vecindad completa. La periódica (a) identifica cada borde con el opuesto y convierte el dominio en un toro. La fija (b) asigna un estado constante al exterior. La reflejante (c) replica hacia fuera el estado de las celdas interiores. El recuadro negro delimita el dominio simulado; las celdas semitransparentes o rayadas son el exterior que cada convención supone.

$$\Omega_{i,j}(r) = \frac{1}{|\mathcal{N}_{i,j}(r)|} \sum_{(i',j') \in \mathcal{N}_{i,j}(r)} s_{i',j'} \quad (2.2)$$

donde $s_{i',j'} \in \{0, 1\}$ es el estado urbano de la celda vecina en posición (i', j') y $\mathcal{N}_{i,j}(r)$ es el conjunto de celdas dentro del radio r alrededor de la celda (i, j) . Dicho de otra forma, es la proporción de celdas urbanas en el radio r alrededor de la celda (i, j) , bajo la definición de vecindad.

La probabilidad de que una celda no-urbana en posición (i, j) transite al estado urbano en el paso $t + 1$ se define como una función de tres componentes:

$$P(s_{i,j}^{t+1} = 1 \mid s_{i,j}^t = 0) = f(W_{i,j}, \Omega_{i,j}(r), \varepsilon_{i,j}) \quad (2.3)$$

donde $W_{i,j}$ es la idoneidad espacial asignada por el método WoE (definida a continuación), $\Omega_{i,j}(r)$ es el efecto de vecindad, y $\varepsilon_{i,j}$ es un término estocástico que introduce variabilidad aleatoria en la simulación. La función f combina estos tres factores según parámetros que se fijan en la calibración; los valores adoptados para el caso de estudio se describen en el Capítulo 4. Esta función es la que define la transición de una celda no-urbana a una urbana.

2.3. Pesos de Evidencia

El método de **Pesos de Evidencia** (Weight of Evidence, WoE) es una técnica estadística de origen bayesiano que cuantifica la asociación entre una variable espacial y la ocurrencia de un evento, en este caso la transición de suelo no-urbano a urbano [30]. Fue desarrollado originalmente en el contexto de la predicción de depósitos minerales y posteriormente adaptado al análisis de cambio de uso de suelo.

2.3.1. Formulación del método

Para una variable espacial X discretizada en categorías o intervalos, el peso de evidencia de la categoría b se define como:

$$W^+(b) = \ln \frac{P(X = b \mid \text{transición})}{P(X = b \mid \text{no transición})} \quad (2.4)$$

donde $P(X \in b \mid \text{transición})$ es la proporción de píxeles con transición observada que pertenecen a la categoría b , y $P(X \in b \mid \text{no transición})$ es la proporción equivalente para píxeles sin transición. Los pesos positivos indican que la categoría b favorece la transición; los pesos negativos indican lo contrario. En esta expresión, b no representa la clase urbano/no-urbano, sino una categoría, intervalo o bin de la variable espacial X (por ejemplo, un rango de distancia a la mancha urbana existente o un rango de densidad vecinal). La clase binaria $\{0, 1\}$ corresponde al estado observado o predicho de la celda, mientras que las categorías b pertenecen al espacio de valores de cada variable explicativa.

El peso total para la celda en posición (i, j) se obtiene sumando los pesos de cada variable espacial evaluada en esa celda:

$$W_{i,j} = \sum_{k=1}^V W^+(b_{(i,j)k}) \quad (2.5)$$

donde V es el número de variables espaciales consideradas y $b_{(i,j)k}$ es la categoría o intervalo que toma la variable espacial k en la celda (i, j) . V no es el número de clases del mapa binario; las clases del estado celular siguen siendo dos (0 para no urbano y 1 para urbano). Este valor $W_{i,j}$ se transforma mediante una función sigmoide para obtener una probabilidad de transición acotada en $[0, 1]$:

$$P_{i,j}^{\text{WoE}} = \frac{1}{1 + e^{-W_{i,j}}} \quad (2.6)$$

Concepto de Pesos de Evidencia (WoE): W^+ y W^-




Figura 2.4: Ejemplo del cálculo de WoE: la variable *distancia al frente urbano* acumula pesos positivos en bins próximos y negativos en bins lejanos. La suma ponderada pasa por la sigmoide y se compara con un umbral de transición θ . Imagen elaborada con IA generativa, con base en la formulación de Bonham-Carter [30].

La Figura 2.4 ilustra el procedimiento sobre una variable típica. La distancia al frente urbano se discretiza en intervalos; los intervalos próximos al frente acumulan pesos positivos, porque en ellos la transición se observa con más frecuencia de la que correspondería a su superficie, y los intervalos lejanos acumulan pesos negativos. La lectura relevante de la figura es que la relación entre distancia y probabilidad no es lineal: los pesos caen con rapidez en los primeros intervalos y después se estabilizan, un comportamiento que un modelo con forma funcional impuesta reproduciría mal.

El cálculo de los pesos se realiza sobre datos históricos de transición, lo que hace que las probabilidades resultantes reflejen empíricamente los patrones observados en el área de estudio, en lugar de depender de supuestos teóricos sobre el comportamiento urbano.

2.3.2. Information Value y ponderación de variables

La ecuación 2.5 trata a todas las variables por igual. Eso rara vez es deseable, porque unas discriminan la transición mejor que otras. El **Information Value** (IV) mide esa capacidad discriminante por variable, agregando sobre todos sus bins la diferencia entre la distribución de los casos con transición y la de los casos sin transición, ponderada por el peso de cada bin [30]:

$$IV = \sum_b [P(X = b \mid \text{transición}) - P(X = b \mid \text{no transición})] W^+(b) \quad (2.7)$$

El IV es no negativo y crece cuando las dos distribuciones se separan. La escala convencional de interpretación lo divide en cinco tramos: por debajo de 0,02 la variable no tiene valor predictivo; entre 0,02 y 0,10 es débil; entre 0,10 y 0,30, medio; entre 0,30 y 0,50, fuerte; y por encima de 0,50 se considera muy fuerte, con la advertencia de que valores muy altos suelen indicar sobreajuste o un bin que separa el resultado de forma trivial.

Con el IV se puede sustituir la suma simple por una suma ponderada, en la que cada variable contribuye en proporción a su capacidad discriminante:

$$W_{i,j}^\omega = \sum_{k=1}^V \omega_k W^+(b_{(i,j)k}), \quad \omega_k = \frac{IV_k}{\sum_{l=1}^V IV_l} \quad (2.8)$$

Los pesos ω_k suman uno por construcción y no son parámetros libres: se derivan de los mismos datos históricos que producen los $W^+(b)$. Esta es la forma que adopta el modelo de esta tesis, y la razón por la que el Capítulo 5 reporta el IV de cada variable junto con sus pesos.

2.3.3. Ventajas y limitaciones

La ventaja principal del WoE es su interpretabilidad, y es una interpretabilidad de grano fino: cada peso $W^+(b)$ se traduce en términos geográficos por separado. Si la variable *distancia a manchas urbanas* tiene peso negativo en los bins de distancia grande, la lectura es directa: en esas celdas la transición se observó con menos frecuencia de la que correspondería a su superficie. No hay un coeficiente único por variable que haya que interpretar en promedio, sino un valor por intervalo, de modo que la forma de la relación queda expuesta en lugar de imponerse. A esto se suman dos ventajas prácticas: los pesos se estiman en una sola pasada sobre los datos, sin optimización iterativa, y el IV ordena las variables por aporte con un criterio explícito.

Las limitaciones son cuatro y conviene declararlas para no atribuirle propiedades que no

tiene. Primero, la suma de pesos asume independencia condicional entre variables dado el evento, supuesto que la propia estructura del espacio urbano incumple. Segundo, los pesos dependen de cómo se discretice cada variable: un cambio en el número o en los cortes de los bins cambia los valores. Tercero, cuando dos variables están correlacionadas, su evidencia se cuenta dos veces. Cuarto, el método no corrige por sí solo la autocorrelación espacial, de modo que las celdas vecinas aportan información que no es independiente [30]. El Capítulo 3 discute cada una como antecedente, con la literatura que las documenta.

Hay además una limitación que no es del método sino de su aplicación, y que afecta a la lectura del IV. Si el muestreo incluye celdas que no pueden experimentar el evento, esas celdas forman bins sin transiciones observadas cuyo peso queda determinado por el suavizado y no por los datos. El IV resultante se infla y deja de ser comparable con la escala convencional. El Capítulo 5 documenta el alcance de este efecto en los pesos estimados para la zona de estudio.

2.3.4. Aplicación: del WoE a la regla de transición del autómata

Lo que hace al WoE apropiado para acoplarse a un autómata celular es la naturaleza de su salida. El método estima la influencia de cada factor geográfico sobre la probabilidad de que una celda transite, y esa estimación es por celda, no agregada: la ecuación 2.6 devuelve un valor en $[0, 1]$ para cada posición de la rejilla. Un autómata celular necesita exactamente eso, una función que asigne a cada celda una probabilidad de cambiar de estado a partir de su situación local. El WoE surte esa función y la surte de forma auditable, porque el valor que produce se descompone en las contribuciones de cada variable y de cada bin.

Aquí está la diferencia con las alternativas. Una regresión logística entrega un coeficiente por variable, no un peso por intervalo, de modo que impone la forma de la relación en lugar de estimarla. Una red neuronal puede ajustar mejor, pero sus pesos internos no admiten lectura geográfica: se sabe qué predice y no por qué. Con el WoE se puede reconstruir la decisión de una celda concreta sumando evidencias con significado propio, que es lo que exige un instrumento destinado a la planeación.

Es por ello que diversos estudios han integrado ya el WoE con modelos de autómatas celulares para calibrar sus reglas de transición. El Capítulo 3 revisa esos antecedentes y precisa qué resuelven y qué dejan abierto.

2.4. Métricas de evaluación de modelos predictivos

La evaluación cuantitativa del desempeño de un modelo de cambio de cobertura exige comparar, celda a celda, el mapa predicho con el mapa observado. Esa comparación no se resume bien con una sola cifra: cada métrica alumbra una pregunta distinta y tiene sus propios puntos ciegos. Esta sección define primero el instrumento base, la matriz de confusión, y después organiza las métricas en tres grupos: las que evalúan la clasificación en su conjunto, las que se concentran en las transiciones, y la descomposición del error que separa qué tanto del desacuerdo es de cantidad y qué tanto es de asignación.

La notación es la siguiente. Sea Ω el conjunto de $N = R \times C$ celdas del dominio discretizado. Para cada celda $i \in \Omega$, sea $y_i \in \{0, 1\}$ el estado observado y $\hat{y}_i \in \{0, 1\}$ el estado predicho por el modelo, donde 1 indica urbano y 0 no urbano.

2.4.1. Matriz de confusión

La **matriz de confusión** $C \in \mathbb{N}^{2 \times 2}$ cuantifica la concordancia píxel a píxel entre predicción y observación:

$$C = \begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix} \quad (2.9)$$

donde los elementos se definen mediante la función indicadora $\mathbb{I}[\cdot]$ como sigue:

$$TP = \sum_{i \in \Omega} \mathbb{I}[\hat{y}_i = 1 \wedge y_i = 1] \quad (\text{verdaderos positivos: urbano predicho y observado}) \quad (2.10)$$

$$TN = \sum_{i \in \Omega} \mathbb{I}[\hat{y}_i = 0 \wedge y_i = 0] \quad (\text{verdaderos negativos: no-urbano predicho y observado}) \quad (2.11)$$

$$FP = \sum_{i \in \Omega} \mathbb{I}[\hat{y}_i = 1 \wedge y_i = 0] \quad (\text{falsos positivos: sobre-predicción}) \quad (2.12)$$

$$FN = \sum_{i \in \Omega} \mathbb{I}[\hat{y}_i = 0 \wedge y_i = 1] \quad (\text{falsos negativos: sub-predicción}) \quad (2.13)$$

Los cuatro componentes satisfacen $TP + TN + FP + FN = N$. La magnitud relativa de FP frente a FN revela el sesgo del modelo: si $FP > FN$ hay sobre-predicción; si $FN > FP$ el modelo es conservador. La construcción de la matriz requiere correspondencia espacial exacta entre los

mapas predicho y observado: misma resolución, proyección y extensión. La Figura 2.5 sitúa los cuatro componentes y anticipa cuáles de ellos intervienen en el cálculo del FoM, definido más adelante.




Figura 2.5: Matriz de confusión (a) y componentes del *Figure of Merit* (b). En el panel (a), *FP* corresponde a sobre-predicción y *FN* a sub-predicción. En el panel (b), *B* es el acierto sobre la transición, *A* la falsa alarma y *C* la omisión. La diferencia entre ambos paneles está en el alcance: las permanencias urbanas y no urbanas quedan fuera del FoM, que solo contabiliza celdas en transición.

2.4.2. Métricas de clasificación global

Exactitud global

La **exactitud global** mide la fracción de píxeles correctamente clasificados:

$$\text{Accuracy} = \frac{TP + TN}{N} \quad (2.14)$$

Esta métrica es sensible al desbalance de clases: en contextos urbanos, donde la mayoría de píxeles no experimenta cambio, un modelo que predice siempre “no cambio” obtiene exactitud alta sin capturar ninguna dinámica. Debe complementarse con métricas que evalúen específicamente la clase minoritaria de interés.

Precisión

La **precisión** cuantifica la confiabilidad de las predicciones positivas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.15)$$

Probabilísticamente, Precision estima $P(y_i = 1 \mid \hat{y}_i = 1)$: la probabilidad de que la urbanización haya ocurrido, dado que el modelo la predijo. Precision decrece cuando el modelo genera muchas falsas alarmas (sobre-predicción). Es especialmente relevante cuando el sobre-dimensionamiento de infraestructura tiene costos significativos.

Recall

El **recall** cuantifica la capacidad de detectar píxeles con transición real:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.16)$$

Recall estima $P(\hat{y}_i = 1 \mid y_i = 1)$: la probabilidad de que el modelo detecte un píxel que sí se urbanizó. Recall bajo indica que el modelo omite transiciones reales, subestimando la expansión urbana.

Existe una tensión inherente entre Precision y Recall: aumentar el umbral de decisión tiende a incrementar Precision pero disminuye Recall, y viceversa. Esta dualidad motiva la siguiente métrica.

F1-Score

El **F1-Score** es la media armónica entre Precision y Recall:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (2.17)$$

La media armónica penaliza más los valores bajos que la aritmética: F1 cae cuando cualquiera de las dos métricas es baja.

Coefficiente Kappa de Cohen

El **coeficiente Kappa de Cohen** [31] corrige la concordancia observada por la concordancia esperada por azar:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (2.18)$$

donde p_o = Accuracy es la proporción observada de concordancia, y p_e es la proporción

esperada por azar:

$$p_e = \frac{(TP + FP)(TP + FN) + (TN + FN)(TN + FP)}{N^2} \quad (2.19)$$

El rango es $\kappa \in [-1, 1]$. Conforme a la escala de interpretación de uso común propuesta por Landis y Koch [32], $\kappa > 0,81$ indica acuerdo casi perfecto; 0,61–0,80, acuerdo sustancial; 0,41–0,60, acuerdo moderado; 0,21–0,40, acuerdo justo; y $\kappa < 0,20$, acuerdo pobre. La ventaja del coeficiente κ frente a la exactitud es que descuenta el acuerdo esperado por azar, haciendo la comparación más justa cuando las clases están desbalanceadas. Su limitación, identificada por Pontius Jr et al. [1], es que mezcla en un solo número dos fuentes de error metodológicamente distintas: el desacuerdo de cantidad y el de asignación.

2.4.3. Métricas de cambio

Las métricas del bloque anterior incluyen tanto las transiciones como las permanencias. En modelado de cambio de cobertura lo que interesa evaluar son las transiciones: una celda que sigue siendo urbana o no urbana no revela si el modelo captura la dinámica. Dado que la clase mayoritaria (píxeles sin cambio) infla artificialmente las métricas globales, se necesitan indicadores que la excluyan.

El **Figure of Merit** (FoM), propuesto por Pontius Jr et al. [1] precisamente para hacer comparables los resultados entre estudios, evalúa exclusivamente el subconjunto de píxeles donde ocurre o se predice un cambio. En un sistema donde el 95 % del territorio permanece constante, un modelo que nunca predice cambio obtiene exactitud del 0,95 y Kappa apreciable, pero FoM igual a cero.

Sea $\mathcal{T}_{obs}$ el conjunto de píxeles con cambio observado y $\mathcal{T}_{pred}$ el conjunto con cambio predicho entre t_0 y t_1 . El FoM es el índice de Jaccard aplicado exclusivamente a las transiciones:

$$\text{FoM} = \frac{|\mathcal{T}_{obs} \cap \mathcal{T}_{pred}|}{|\mathcal{T}_{obs} \cup \mathcal{T}_{pred}|} \quad (2.20)$$

Descomponiendo en componentes:

$$B = |\mathcal{T}_{obs} \cap \mathcal{T}_{pred}| \quad (\text{cambio correctamente predicho}) \quad (2.21)$$

$$C = |\mathcal{T}_{obs} \setminus \mathcal{T}_{pred}| \quad (\text{cambio observado no predicho: omisión}) \quad (2.22)$$

$$A = |\mathcal{T}_{pred} \setminus \mathcal{T}_{obs}| \quad (\text{cambio predicho no observado: comisión}) \quad (2.23)$$

$$\boxed{\text{FoM} = \frac{B}{A + B + C}} \quad (2.24)$$

El denominador incluye exactamente $A + B + C$, que son las celdas donde el cambio ocurre, se predice o ambas. Las celdas sin cambio no entran en el cálculo.

La **Intersection over Union** (IoU) sobre la clase urbana complementa al FoM con otra perspectiva: mientras el FoM evalúa qué tan bien se predice el cambio, la IoU evalúa qué tan bien se predice el estado urbano final, incluyendo tanto las celdas que permanecen urbanas como las que transitan. Para la clase urbana, la IoU es la fracción de celdas que el modelo y la observación coinciden en clasificar como urbanas, dividida por la unión de las celdas que al menos uno de los dos clasifica como urbanas. Reportar ambas métricas evita el sesgo de medir solo la dinámica o solo el estado.

2.4.4. Descomposición del error

Saber cuánto error total comete un modelo no dice si ese error proviene de predecir una extensión de cambio equivocada o de localizarlo mal. Pontius Jr et al. [1] propone una descomposición que separa ambas fuentes, formalizada después por Pontius Jr y Millones [33].

El **desacuerdo de cantidad** (*quantity disagreement*) ocurre cuando el modelo predice un total de celdas en transición distinto al observado, sin importar dónde. El **desacuerdo de asignación** (*allocation disagreement*) aparece cuando el total es correcto pero las celdas están en lugares equivocados. Para dos clases, ambos se obtienen de la matriz de confusión:

$$Q = \frac{|FP - FN|}{N} \quad (2.25)$$

$$A = \frac{2 \min(FP, FN)}{N} \quad (2.26)$$

La suma $Q + A$ recupera el desacuerdo total $(FP + FN)/N$, que es el complemento de la

exactitud global. La interpretación se sigue de las expresiones: el exceso neto de una clase sobre la otra es cantidad, y lo que queda tras cancelar ese exceso es asignación, es decir, pares de celdas intercambiadas de lugar. Un modelo puede ser preciso en cantidad y errado en asignación: acertar en cuántos píxeles se urbanizan pero situarlos en el lugar incorrecto. La separación es útil para el diagnóstico: un desacuerdo de cantidad elevado apunta a deficiencias en cómo se estima la demanda de crecimiento, mientras que un desacuerdo de asignación elevado indica que la regla de transición no capta bien la distribución espacial del fenómeno.

El posicionamiento de este trabajo en la literatura especializada es el tema del Capítulo 3, donde se revisan de forma crítica los enfoques previos y se justifica la brecha que la propuesta atiende. La aplicación de todos los conceptos definidos en este capítulo se describe en el Capítulo 4.

Capítulo 3

Estado del arte

El modelado computacional del crecimiento urbano ha producido en treinta años una literatura rica pero metodológicamente heterogénea. Este capítulo no ordena trabajos por autor sino que identifica los cuatro problemas metodológicos que siguen abiertos en el campo: calibración por fuerza bruta, validación sobreajustada a una sola ventana temporal, opacidad de la función de transición en los modelos de aprendizaje profundo, y dependencia de software propietario. Se muestra cómo cada uno justifica una decisión concreta del diseño del modelo propuesto. La discusión concluye con un mapa de la literatura para ciudades mexicanas, donde ningún trabajo publicado satisface simultáneamente los cuatro requerimientos (R1–R4) de simulación histórica con precisión, soporte a planeación estratégica, replicabilidad y apertura, e interpretabilidad de la función de transición que motivaron esta investigación.

3.1. Evolución del modelado urbano computacional

El modelado de la dinámica urbana mediante autómatas celulares empezó con White y Engelen [29], cuyo trabajo mostró que reglas locales basadas en distancia y vecindad podrían reproducir patrones macroscópicos realistas en ciudades. El siguiente nivel del enfoque fue introducido con SLEUTH en [11, 34], que durante dos décadas fue la referencia del campo, y que se aplicó en decenas de ciudades.

Al mismo tiempo, la metodología LUCC (Land Use and Cover Change) introdujo modelos basados en mapas de idoneidad de uso de suelo de base estadística: sistemas como CLUE-S [35], Dinamica EGO [36], CA-Markov y, más recientemente, FLUS [37] brindaron arquitecturas alternativas al autómata celular puro en las que la función de transición emerge de regresiones logísticas o pesos bayesianos sobre datos históricos.

Una generación posterior de trabajos sustituyó la regresión por modelos de aprendizaje automático e híbridos metaheurísticos. Almeida et al. [9] acopló una red neuronal feedforward a un autómata celular estocástico para Piracicaba, Brasil; años más tarde Wang et al. [10] combinó un autómata celular con un algoritmo genético para optimizar la forma urbana de Wuhan, mientras que Hagenauer y Helbich [38] introdujo una red neuronal geográficamente ponderada para relaciones espaciales no lineales en vivienda y calidad del aire, no como modelo de crecimiento urbano. Estos enfoques reportan ganancias cuantitativas en sus métricas, pero sustituyen parámetros legibles por activaciones internas o cromosomas que no admiten una lectura geográfica directa; en esa medida, no son auditables respecto de lo que aprenden.

La disyuntiva de fondo no es autómatas celulares frente a aprendizaje automático. Es una tensión entre dos objetivos que a priori parecen contrapuestos: maximizar la precisión predictiva y mantener la trazabilidad de cada decisión espacial. Las secciones siguientes examinan esa tensión y el margen que deja para replantear la pregunta metodológica.

3.2. Problemas metodológicos persistentes

Los problemas metodológicos más importantes detectados en la literatura fueron equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software no libre.

3.2.1. Calibración: equifinalidad y costo computacional

La calibración de SLEUTH, cuyos componentes se definen en el Capítulo 2, se resuelve mediante búsqueda por fuerza bruta sobre un espacio discreto del orden de 10^9 combinaciones [34, 39], cada una evaluada con simulaciones Monte Carlo de múltiples iteraciones. Silva y Clarke [34] y Clarke [39] estructuraron la búsqueda en tres fases sucesivas (gruesa, fina y final) que estrechan iterativamente el rango de cada coeficiente; aun así, una calibración completa puede tomar más de una semana en un clúster de la época [40]. A esa carga se añaden dos rasgos que agravan la dificultad. Primero, SLEUTH es un autómata *auto-modificable*: los coeficientes de *spread* se reescriben durante la propia corrida en respuesta a la tasa de crecimiento, de modo que el resultado depende de la trayectoria seguida y no solo de los valores iniciales [11]. Segundo, los coeficientes calibrados son sensibles a la resolución espacial de los datos, por lo que un conjunto ajustado a una escala no se transfiere directamente a otra. Sobre esa base aparece el problema metodológico de fondo, que no es solo el costo: es la **equifinalidad**, esto es, la existencia de múltiples combinaciones de coeficientes que producen patrones indistinguibles para la métrica de calibración pero divergen en las proyecciones de largo plazo [39]. Sin un

criterio adicional, la elección entre combinaciones equifinales termina dependiendo de quien realiza la calibración. A ello se suma un riesgo de **sobreajuste de calibración**: como el ajuste se optimiza contra un único intervalo histórico, los coeficientes pueden reproducir muy bien esa ventana y, sin embargo, degradarse al proyectar otro horizonte, sin que la propia métrica de calibración lo advierta [34, 40]. Esta combinación de costo, dependencia de trayectoria y equifinalidad es, precisamente, lo que motiva la estrategia de validación multi-ventana que se adopta más adelante: una sola ventana temporal no basta para distinguir un conjunto de coeficientes estable de uno meramente equifinal.

Esa literatura deja abierto un recorte distinto: calibrar pocos parámetros que combinan evidencia espacial empírica, un umbral de transición y un peso de vecindad, en lugar de un espacio de coeficientes geométricos genéricos. El capítulo siguiente adopta ese recorte; aquí basta registrar que reduce el espacio de búsqueda y que cada configuración candidata produce pesos por variable auditables, lo que acota la ambigüedad asociada a conjuntos de parámetros distintos con el mismo ajuste.

3.2.2. Validación: sobreajuste temporal y métricas no comparables

Pontius Jr et al. [1] analizó trece simulaciones independientes de nueve modelos de cambio de uso de suelo y propuso el Figure of Merit (FoM) como métrica estándar comparable entre estudios. Su resultado es poco alentador para el campo: seis de las trece aplicaciones obtienen FoM inferior a 0,15 y solo una supera 0,50. La dispersión o variabilidad no se explica por la complejidad del modelo sino por la magnitud del cambio neto observado: el FoM tiende a ser mayor cuando el porcentaje de celdas que efectivamente cambian de estado es mayor [1]. Dicho de otra forma, el FoM *excluye* las celdas que no cambian; no las penaliza.

Esto tiene dos implicaciones que la literatura rara vez confronta. La primera, **validar en una sola ventana temporal es estadísticamente insuficiente**: si el FoM depende de la magnitud del cambio, entonces se puede concluir que una validación única no permite distinguir entre un modelo estable y uno sobreajustado a una fase específica del crecimiento en el tiempo. Segundo, **reportar métricas como Kappa o Accuracy sin FoM infla artificialmente la calidad del modelo**: en un sistema urbano consolidado donde el 95 % de las celdas permanece sin cambio, un modelo trivial que predice “no cambio” en todas las celdas obtiene una exactitud de 0,95 sin capturar ninguna dinámica: recoge la estabilidad y no el cambio, que es lo que interesa medir.

De ahí se sigue un criterio de diseño, no un resultado: validar en varias ventanas del mismo sistema, reportando FoM, Kappa e IoU a la vez, distingue un comportamiento que se sostiene de un ajuste a un solo lustro. El protocolo concreto se describe en el Capítulo 4.

Vale la pena confrontar una contradicción que la literatura rara vez coloca lado a lado. Por un lado, los trabajos de aprendizaje automático y profundo reportan mejoras de concordancia espacial frente a los autómatas celulares clásicos [9]; por otro, la comparación multi-sitio de Pontius Jr et al. [1] muestra que la dispersión del FoM entre trece aplicaciones no se explica por la sofisticación del modelo, sino por la magnitud del cambio neto del periodo evaluado. Las dos observaciones no se contradicen en abstracto, pero sí en la práctica con que suelen leerse: un FoM de, por ejemplo, 0,40 obtenido en una ciudad con 20 % de cambio neto no es comparable con un 0,20 obtenido en una con 5 %, y aun así ambos se citan como evidencia directa de que un modelo supera a otro. La consecuencia es incómoda pero ineludible: buena parte de los *rankings* de desempeño publicados confunden la dificultad del caso con la calidad del modelo. Algo análogo ocurre con la calibración de SLEUTH [34, 39]: dos conjuntos de coeficientes que empatan en la métrica de ajuste pueden divergir en la proyección a largo plazo, de modo que reportar un único conjunto de coeficientes sin declarar los demás que alcanzan el mismo ajuste transmite una unicidad que los datos no respaldan. El capítulo siguiente no compara su FoM absoluto contra el de otras ciudades como si fueran intercambiables; evalúa la estabilidad del FoM entre cinco ventanas del mismo sistema urbano y reporta el rango completo en lugar de un único valor favorable.

3.2.3. Interpretabilidad: el problema de la caja negra

Almeida et al. [9] entrenó una red neuronal feedforward con backpropagation sobre variables biofísicas e infraestructurales de Piracicaba (Brasil, 1985–1999); la red aprende pesos sinápticos que alimentan a un CA estocástico. El modelo reporta concordancia espacial superior a los AC clásicos de la época, pero los pesos no son transformables o explicables a una pregunta geográfica, es decir, no se puede afirmar que “la distancia a vialidades contribuyó un X % a la transición de esta celda”. La activación de cada neurona es una combinación no lineal de todas las variables de entrada, sin descomposición legible: no es auditable respecto de lo que aprende.

Trabajos posteriores intensifican esta opacidad por dos vías. La primera es la optimización metaheurística: Wang et al. [10] integra un autómata celular a un algoritmo genético para generar formas urbanas que maximizan un índice de vitalidad en Wuhan, donde cada generación produce cromosomas que carecen de lectura geográfica directa. La segunda es el aprendizaje profundo aplicado a teledetección [21], que suele requerir conjuntos anotados grandes y, en la práctica, hardware gráfico para entrenar redes cuyas representaciones internas no son auditables. La ganancia en exactitud es real, pero el costo epistémico es alto: el modelo clasifica sin justificar, y la justificación es exactamente lo que un instrumento de planeación urbana requiere. Un plan municipal sustentado en “el modelo lo predijo” es jurídica y políticamente más débil que uno

sustentado en “históricamente, la proximidad al frente urbano contribuye con un Information Value de X a la probabilidad de transición”.

El método de Pesos de Evidencia (WoE) provee exactamente esa descomposición. La elección de WoE en este trabajo no responde a una preferencia estética por la transparencia: responde al requerimiento R4 de la Tabla 1.1, que define la auditabilidad como condición de uso del modelo, no como propiedad accesoria.

3.2.4. Reproducibilidad: software propietario y barreras de acceso

Una fracción significativa de los modelos LUCC más citados depende de software propietario, lo que limita en la práctica la reproducibilidad y la transferibilidad de los resultados publicados. Los tres marcos más empleados ilustran el rango de condiciones de acceso, según los términos de distribución que declara cada uno: Dinamica EGO [36] se obtiene bajo registro con licencia de uso académico; IDRISI y su sucesor TerrSet se distribuyen de forma comercial por Clark Labs; y SLEUTH [11] publica su código fuente en C, de modo que es el único de los tres sin barrera de licencia, aunque su compilación en sistemas actuales exige ajustes que la documentación original no cubre. La consecuencia práctica es que la reproducibilidad de los resultados publicados es, en el mejor de los casos, parcial: el lector puede leer el método pero no ejecutarlo sin acceso a infraestructura específica.

Esta dependencia tiene una consecuencia material poco discutida en la literatura metodológica: el acceso a licencias y a hardware especializado introduce una barrera de entrada que condiciona qué grupos académicos pueden reproducir o extender los modelos publicados. En contextos donde estos recursos son limitados, la única alternativa práctica es reescribir el pipeline desde cero o dedicar un esfuerzo considerable a descifrar requerimientos no documentados. Conviene, entonces, una implementación en código abierto sobre imágenes de archivo de acceso libre. En este caso se usan capturas de Google Earth en escritorio, no Google Earth Engine. El Capítulo 4 desarrolla esa implementación.

3.3. Pesos de Evidencia y modelos probabilísticos espaciales

El método de Pesos de Evidencia, desarrollado por Bonham-Carter [30] en el contexto de la prospección mineral, se formaliza en el Capítulo 2 (ecuación 2.4): para cada clase de una variable espacial discretizada se calcula un peso bayesiano que cuantifica la asociación entre dicha clase y la ocurrencia del evento de interés, en este trabajo, la transición de suelo no urbano

a urbano. El peso total por celda es la suma de los pesos de las variables evaluadas en ella, transformada por la función logística para obtener una probabilidad acotada (ecuación 2.6); el Information Value sintetiza el poder discriminatorio de cada variable. La presente sección no repite la derivación matemática, sino que la sitúa en la literatura LUCC.

La adaptación del WoE al modelado de cambio de uso de suelo se consolidó con Soares-Filho et al. [36] y la familia de modelos *Dinamica EGO*, que separan dos preguntas que el campo suele tratar de forma confusa: *cuánto* suelo cambia y *dónde* lo hace. La cantidad de transición se fija con una matriz de transición markoviana estimada del cambio histórico, mientras que la asignación espacial la resuelve un autómata celular de dos operadores (*expander*, que ensancha los parches urbanos existentes, y *patcher*, que siembra parches nuevos), alimentado por un mapa de idoneidad WoE. Ese diseño reproduce con fidelidad la distribución de tamaños de parche observada en frentes de deforestación amazónica y expansión agrícola, y en menor medida en crecimiento urbano.

La misma lógica de *demanda* más *asignación* reaparece en otros marcos LUCC ampliamente citados: CLUE-S [35] acopla una idoneidad derivada de regresión logística con una asignación iterativa gobernada por la demanda sectorial de suelo, y FLUS [37] sustituye esa idoneidad por la probabilidad de una red neuronal y la asigna mediante un autómata celular con inercia auto-adaptativa y competencia por ruleta. Conviene tomar postura sobre la diferencia con el presente trabajo, porque es deliberada: estos marcos descomponen el problema en un módulo de cantidad (Markov o demanda exógena) y un módulo de localización (CA), y la mayoría se distribuye como software con interfaz gráfica o licencia restringida. El esquema de dos módulos ajusta muy bien la cantidad de cambio, y esa es su fortaleza documentada. Paga el ajuste, sin embargo, con una dependencia mayor de software especializado y con una frontera difusa entre lo que decide el modelo de demanda y lo que decide el CA. La alternativa que la literatura deja abierta es una regla única, en la que la evidencia espacial y la vecindad decidan a la vez cuántas y cuáles celdas transitan: se pierde control sobre la cantidad total de cambio, pero se gana la posibilidad de rastrear por qué una celda concreta se urbaniza, que es lo que importa en un instrumento de planeación.

Sin embargo, el WoE tiene cuatro limitaciones estadísticas reconocidas que conviene explicitar para evitar atribuirle propiedades que no posee:

Independencia condicional. La suma de pesos asume que las variables son condicionalmente independientes dada la ocurrencia del evento. Ese supuesto rara vez se cumple en variables espaciales urbanas: la proximidad a vialidades y la proximidad al frente urbano están correlacionadas. El presente trabajo no introduce una corrección formal para esta dependencia; sigue la

práctica estándar de la literatura LUCC, que reporta el sesgo derivado mediante el contraste empírico con el cambio observado. Una validación en varios períodos añade un diagnóstico: si el sesgo fuera dominante, el FoM degradaría sistemáticamente entre ventanas.

Sensibilidad a la discretización. Los pesos dependen de cómo se categorice cada variable continua. Una opción reproducible es discretizar por cuantiles uniformes. No es necesariamente la óptima en términos de IV (Information Value), pero evita que el recorte de clases dependa de un umbral ad hoc.

Multicolinealidad entre drivers. Variables correlacionadas producen pesos redundantes que inflan la magnitud aparente de la evidencia. Conviene no confundir dos reducciones distintas. El PCA del preprocesamiento de imagen, descrito en el Capítulo 2, atenúa la redundancia entre descriptores de píxel; no toca la redundancia entre las variables de evidencia del WoE. Para estas últimas, la práctica habitual es ponderarlas por Information Value en lugar de proyectarlas a componentes, porque un peso por variable sigue siendo legible y una componente no.

Sesgo y sensibilidad espacial. Un problema menos discutido en las aplicaciones urbanas del WoE es la autocorrelación espacial: las celdas vecinas no son observaciones independientes, de modo que el tamaño muestral efectivo es menor que el número de píxeles y los pesos pueden estimarse con una precisión aparente mayor que la real [30]. El efecto se acentúa cuando las variables se derivan de la propia configuración urbana, porque la señal de proximidad y densidad está espacialmente estructurada por construcción. La literatura no ofrece una corrección estándar para este caso, pero sí dos atenuantes: la discretización por cuantiles evita que clases muy pobladas dominen el peso, y la validación en varias ventanas desplazadas funciona como prueba de estabilidad, ya que un sesgo espacial dominante se manifestaría como una degradación sistemática del FoM entre períodos.

3.4. Validación espacial en modelos LUCC

La métrica más reportada en la literatura LUCC sigue siendo el coeficiente Kappa de Cohen, a pesar de las críticas explícitas a su uso en mapas de cambio. Pontius Jr et al. [1] muestra que Kappa mezcla dos fuentes de error conceptualmente distintas, el desacuerdo de cantidad y el de asignación, cuyas definiciones se recogen en el Capítulo 2, lo que dificulta diagnosticar el tipo de fallo que el modelo comete. El FoM, al evaluar exclusivamente las celdas en transición, es sensible exactamente al problema que Kappa oscurece, y la IoU sobre la clase urbana lo complementa al evaluar el estado final en lugar de la dinámica de cambio.

Entre los trabajos recientes que sí reportan FoM conviene destacar uno, porque sirve de referencia cuantitativa en el Capítulo 5. Tang et al. [41] acoplan un autómatas celular con un algoritmo de búsqueda gravitacional para simular la expansión de Urumqi, en el noroeste de China, y reportan FoM de 0,430 en la calibración (2000–2010) y de 0,376 en la validación (2010–2020). La cifra comparable con un esquema de prueba independiente es la segunda. El contexto explica en parte esos valores: se trata de una ciudad en medio árido, donde el relieve y la disponibilidad de agua restringen la expansión de forma nítida, y el modelo incorpora esos *drivers* físicos como capas explícitas. Es el punto de comparación más cercano disponible para un acoplamiento AC con calibración automática, con la salvedad de que el sitio, las clases y el horizonte temporal difieren de los de esta tesis.

Otro patrón crítico de la literatura es la validación sobre un único período: la mayoría de los estudios compara el mapa simulado contra un solo horizonte temporal, lo que impide distinguir entre un desempeño estable y un ajuste puntual a las características de ese lustro. Conviene, entonces, un protocolo con FoM como métrica primaria, IoU y Kappa como complemento, la descomposición de Pontius como diagnóstico y varias ventanas quinquenales desplazadas del mismo sistema urbano. El Capítulo 4 desarrolla esa vía.

3.5. Vacíos específicos en el contexto mexicano

La literatura mexicana sobre modelado de crecimiento urbano es escasa, pero útil como referencia. Suárez y Delgado [14] construyó el primer estudio de predicción espacial sistemática para la Zona Metropolitana de la Ciudad de México: a partir de proyecciones demográficas de CONAPO al 2020, distribuyó hectáreas adicionales en contornos metropolitanos bajo tres escenarios de densidad. El trabajo es relevante por su carácter pionero, pero no es un autómatas celular: no hay reglas de vecindad, no hay calibración sobre datos históricos de cambio celular y la validación se hace a nivel de totales de hectáreas, no a nivel de celda, pues se usan agregados y no datos a nivel grano. R1, R4 y la replicabilidad pública no aplican; la única dimensión satisfecha es R2.

Ramírez Hernández [15], en un libro institucional de II Ec-UNAM, aplica un AC inspirado en SLEUTH a la ZMCM con datos de 1990–2010 y proyecta al 2040. Los parámetros se describen en el texto pero el código no está disponible y la validación no reporta FoM ni Kappa de forma sistemática. La obra es valiosa como referencia conceptual pero no como benchmark cuantitativo, es decir, no es posible comparar su desempeño con el rango de métricas reportadas en Pontius Jr et al. [1].

Así pues, García-Ramírez et al. [16] aplica una cadena SVM + regresión logística + CA-

Markov en TerrSet/IDRISI a núcleos urbanos asentados en cinco cuencas hidrológicas del estado de Chihuahua (Laguna Bustillos y de los Mexicanos; río Conchos–Ojinaga; río Conchos–Presa de la Colina; río Conchos–Presa el Granero; y río San Pedro), con proyecciones a 2030, 2040 y 2050. La clasificación SVM sobre mapas de uso de suelo 2010–2020 es reproducible y la regresión logística aporta interpretabilidad parcial: el resumen reporta pseudo R^2 de McFadden superior a 0,2 y ROC aceptable, aunque el detalle deja tres núcleos por debajo de ese umbral. La asignación CA-Markov ocurre dentro del módulo Land Change Modeler de TerrSet, software no libre, y la validación cuantitativa se reporta sobre la regresión logística, no sobre la simulación CA en sí. R4 se cumple parcialmente; R3 no se cumple.

El cuadrante metodológico que estos trabajos definen es claro, y se resume en la Tabla 3.1:

Tabla 3.1: Posicionamiento de la literatura mexicana frente a R1–R4.

Trabajo	R1	R2	R3	R4
Suárez y Delgado [14]	no	✓	no	no
Ramírez Hernández [15]	no	✓	no	parcial
García-Ramírez et al. [16]	parcial	✓	no	parcial

En la literatura mexicana revisada, hasta donde alcanza esta revisión, ningún trabajo publicado cumple simultáneamente con validación multi-período cuantitativa, reproducibilidad abierta e interpretabilidad auditable a nivel de celda. Esa es la brecha que el capítulo siguiente atiende. Querétaro entra como caso de uso de una ciudad intermedia poco estudiada, no como sustituto de una comparación directa con modelos de caja negra entrenados en otras ciudades.

3.6. Síntesis: posicionamiento del presente trabajo

Los cuatro problemas metodológicos analizados (equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software propietario) se cruzan con la topología espacial del campo. Las revisiones sistemáticas de Santé et al. [12] y Aburas et al. [13] muestran que las aplicaciones documentadas se concentran en China, Europa y Estados Unidos, mientras que la literatura mexicana revisada en la sección anterior avanza con modelos heredados o con herramientas propietarias que limitan la auditoría.

El capítulo siguiente toma tres decisiones que esta revisión deja abiertas. Primera: usar WoE como función de transición, de modo que cada peso sea auditable (R4). Segunda: validar en cinco ventanas quinquenales desplazadas con FoM, Kappa e IoU, para distinguir un comportamiento que se sostiene de un ajuste a un solo lustro (R1). Tercera: implementar el flujo en código

abierto sobre imágenes de archivo, sin software propietario (R3). La lectura de los mapas como escenarios de expansión, no como planes calibrados (R2), se discute en las conclusiones.

El Capítulo 4 presenta el modelo híbrido propuesto: consideraciones, arquitectura, área de estudio, preprocesamiento, definición de la regla de transición y protocolo de validación. Ahí se ponen a prueba, sobre una ciudad intermedia mexicana, las decisiones de diseño que este capítulo justificó: una calibración acotada e interpretable, una validación multi-ventana frente al sobreajuste temporal y una implementación abierta frente a la dependencia de software propietario.

Capítulo 4

Modelo de crecimiento urbano híbrido

Este capítulo presenta el modelo híbrido WoE-AC propuesto: un autómata celular cuya función de transición se construye a partir de Pesos de Evidencia estimados sobre series históricas de cobertura. El capítulo es donde comienza la aportación propia del trabajo. Se presentan el área de estudio y los datos que alimentan al modelo, el pipeline de preprocesamiento que transforma imágenes RGB de Google Earth en mapas binarios urbano/no urbano mediante clasificación LBP+K-Means+SVM, y se formalizan los componentes del modelo: cuantificación de evidencia espacial, regla de transición, vecindad, calibración por búsqueda sistemática y protocolo de validación quinquenal, junto con las decisiones de diseño que los sostienen. La novedad no es el acoplamiento WoE-AC en sí, que cuenta con antecedentes en la literatura, sino su calibración reproducible y su validación sobre cinco ventanas quinquenales desplazadas aplicadas a una ciudad intermedia mexicana con código y datos de libre acceso.

4.1. Consideraciones del modelo

Todo modelo de crecimiento urbano toma decisiones sobre qué incluir y qué dejar fuera. En este trabajo el espacio se representa como una rejilla discreta de celdas iguales, cuya unidad espacial es el píxel de las capturas de Google Earth, con una resolución efectiva del orden de 27 m/píxel. El tiempo avanza en pasos anuales: cada iteración del autómata corresponde a un año de la serie histórica. El dominio tiene condiciones de frontera fijas (las celdas exteriores nunca transitan a urbano), lo que es coherente con el hecho de que la ventana de captura delimita el área de interés. El modelo no incluye capas externas de infraestructura (vialidades, pendientes, uso de suelo oficial) ni un término de decaimiento explícito por distancia a centros de empleo; la atracción ejercida por las zonas ya urbanizadas se captura implícitamente en el campo de evidencia WoE y en la vecindad local del autómata. Estas simplificaciones son

deliberadas: reducen el número de parámetros que deben ser estimados y hacen al modelo más auditable, con el costo de ignorar el rol de la infraestructura en la dirección del crecimiento.

Conviene distinguir, desde aquí, tres planos que en lo que sigue se exponen de forma entrelazada pero que son conceptualmente distintos. El primero es el **modelo conceptual**: las reglas matemáticas generales del acoplamiento WoE-AC (la cuantificación de evidencia, la regla de transición probabilística y la actualización del estado), válidas para cualquier ciudad. El segundo es la **implementación**: el recálculo iterativo del campo de evidencia y de la vecindad sobre el estado actualizado del mapa en cada paso de simulación. El tercero es la **configuración experimental**: los valores concretos fijados para la Zona Metropolitana de Querétaro (el umbral $\theta = 0,75$, el peso de vecindad $\alpha = 0,50$, la ponderación por *Information Value* y las ventanas quinquenales de validación), que son objeto del Capítulo 5. La narración avanza del primero al tercero.

4.2. Arquitectura del modelo

La Figura 4.1 presenta el flujo completo del modelo en seis etapas, con lo que recibe, lo que hace y lo que entrega cada una. La primera adquiere las capturas RGB desde el visor de Google Earth y conforma la serie temporal. La segunda las clasifica: 23 descriptores por píxel, reducción por PCA, agrupamiento K-Means y consolidación con un SVM lineal. La tercera fija la convención de etiquetas, de modo que el valor 1 corresponda siempre a urbano. La cuarta estima los pesos de evidencia sobre los 26 pares históricos anuales (1984–2010): esos pesos quedan fijos. La quinta ejecuta el autómata celular de forma iterativa sobre el horizonte de predicción; en cada paso se recalculan las siete variables espaciales sobre el estado actualizado del mapa y se les aplican los pesos ya estimados. La sexta evalúa el resultado contra los mapas observados mediante cinco ventanas quinquenales desplazadas, cada una con sus propias métricas de desempeño. Las secciones siguientes describen cada etapa en el orden en que intervienen.

El diagrama indica además la ruta del artefacto que produce cada etapa y un ejemplo tomado de la corrida que se reporta en el Capítulo 5. La intención es que el flujo pueda contrastarse contra los archivos del repositorio y no solo leerse como un esquema.

4.3. Área de estudio




Figura 4.1: Framework operativo del modelo WoE-AC. Para cada una de las seis etapas se indica la entrada que recibe, la operación que realiza y el artefacto que entrega, con ejemplos tomados de la serie y de la ventana 2015–2020. El período 2011–2020 no interviene en la estimación de los pesos de evidencia. *Imagen elaborada con IA generativa, con base en la arquitectura propia descrita en este capítulo.*

4.3.1. Localización y características

La Zona Metropolitana de Querétaro se ubica en el centro de México y constituye uno de los polos industriales de mayor crecimiento reciente del país. Según la delimitación oficial de zonas metropolitanas [8], agrupa varios municipios en torno a la capital del estado y, de acuerdo con el Censo de Población y Vivienda 2020 [7], rebasó el millón y medio de habitantes, tras décadas de expansión sostenida que la convierten en un caso representativo de las ciudades intermedias mexicanas. Su delimitación espacial precisa (centro del encuadre, extensión cubierta y sistema de referencia) se detalla más adelante, dentro de la descripción del conjunto de imágenes.

Descripción y fuente de datos

El estudio utiliza una serie anual de **capturas RGB** (1984–2020, 37 años) sobre la Zona Metropolitana de Querétaro. Las imágenes se obtuvieron con **Google Earth** en escritorio, usando la **imagen histórica** (línea de tiempo) para elegir, año a año, una fecha con baja nubosidad visible y buen contraste, manteniendo el mismo encuadre. El fondo cartográfico de Google Earth integra, según época, mosaicos que pueden incluir composiciones basadas en sensores tipo Landsat u otras fuentes; en este trabajo **no** se empleó Google Earth Engine [20] ni descarga masiva por API. La elección de Querétaro se sustenta en su dinámica de crecimiento reciente, bien documentada para la zona metropolitana [42, 43], la posibilidad de cubrir 1984–2020 con la misma ventana de visualización y su relevancia como polo industrial en el centro de México, dentro de la expansión urbana que el país arrastra desde los años setenta [44]. Dado que el objetivo es modelar la expansión urbana a escala macroscópica (la mancha urbana y su frente de crecimiento) y no una caracterización espectral fina, la fuente se eligió privilegiando la consistencia espacial y temporal del encuadre a lo largo de casi cuatro décadas por encima de la calibración radiométrica absoluta. Esta decisión es coherente con la naturaleza binaria (urbano/no urbano) del problema y con el carácter histórico de la serie, para la cual no existe una alternativa con calibración radiométrica homogénea y acceso libre que cubra desde 1984.

Tras el preprocesamiento, cada año queda como matriz RGB de $1\,792 \times 3\,024$ píxeles (del orden de $5,4 \times 10^6$ píxeles por imagen) en formato PNG; los metadatos de cobertura y tamaño se resumen más adelante, al conformar la serie.

4.3.2. Adquisición y conformación del conjunto de imágenes

La adquisición siguió un **protocolo manual replicable** (misma ventana geográfica y criterios visuales de calidad en cada año) orientado a obtener una serie temporal homogénea para estudiar la forma espaciotemporal del crecimiento urbano a partir de percepción remota,

en la línea de trabajos que miden esa dinámica desde imágenes [17]. La herramienta fue **Google Earth** en escritorio, elegida por tres razones prácticas: da acceso a la **imagen histórica** año con año sobre la misma área, ofrece una interfaz visual inmediata para evaluar nubosidad y nitidez antes de capturar, y hace viable construir la serie sin infraestructura de acceso a API ni *scripts* de descarga. La contrapartida es que la repetibilidad depende de mantener la misma escala, orientación y encuadre entre capturas, y de registrar manualmente la fecha elegida en cada año; el procedimiento paso a paso se detalla en el Apéndice A (Algoritmo 1).

La serie se diseñó atendiendo a criterios temporales y de calidad: cobertura completa 1984–2020 (37 años, suficiente para abarcar varios ciclos de crecimiento), una imagen representativa por año sin años omitidos, captura preferente en temporada seca (noviembre–abril) con una meta visual de menos del 10 % de nubes, y consistencia geométrica entre años (mismo zoom, orientación y región de interés, con ajuste fino a la cuadrícula en el preprocesamiento) sin saturación evidente en los canales RGB.

Criterios de selección y parámetros espaciales

Los parámetros espaciales que guiaron la captura pueden describirse de forma compacta. El área de estudio es la Zona Metropolitana de Querétaro, registrada con Google Earth en escritorio de forma manual mediante la imagen histórica, sin recurrir a Google Earth Engine ni a descarga masiva por API. Las capturas son imágenes de pantalla del visor: no llevan georreferencia ni barra de escala, de modo que su extensión y su tamaño de píxel no se pueden leer del archivo. Para fijarlos se registró cada captura contra el mosaico Sentinel-2 *cloudless*, que pertenece a la misma familia de imagen que el visor despliega a ese nivel de zoom, según la atribución «Image Landsat / Copernicus» impresa en las propias capturas. El registro estima una transformación de similitud por emparejamiento de rasgos y arrojó una solución sólida en 17 de las 37 imágenes; en el resto, todas anteriores a 2005, el mosaico histórico no aporta rasgos suficientes. El procedimiento y sus resultados por año quedan documentados en el repositorio.

De ese registro se obtiene la geometría efectiva de la serie. El encuadre se centra en 20,6144° N y 100,3843° W (20°36'52" N, 100°23'03" W) y cubre 80,8 × 47,9 km, unos 3 870 km². Cada píxel mide 26,7 m de lado, es decir unos 713 m². El marco no está orientado al norte: el norte geográfico queda a unos 22° en sentido horario respecto de la vertical de la imagen. Esa rotación no afecta al modelo, porque todas las variables espaciales y la vecindad se calculan sobre la rejilla y son invariantes a la orientación del marco, pero sí importa al interpretar cualquier mapa de la serie. El visor opera sobre el elipsoide WGS84 (EPSG:4326). Las bandas disponibles son únicamente RGB, capturadas desde el visor.

La dispersión entre capturas cuantifica la consistencia geométrica que el protocolo buscaba. El tamaño de píxel varía entre 26,5 y 26,9 m, con una desviación de 0,11 m (0,4 %); el giro del marco tiene una desviación de 0,37°; y el centro se mantiene dentro de 230 m, unas nueve celdas sobre una ventana de 80 km. El protocolo manual conservó, por tanto, la misma ventana a lo largo de los 37 años con una tolerancia del orden de tres milésimas de la extensión.

A partir de estos parámetros puede caracterizarse la resolución espacial efectiva. La ventana de 80,8 × 47,9 km ocupa una rejilla de 1 792 × 3 024 píxeles, de modo que la celda es cuadrada y mide 26,7 m de lado. Esa cifra coincide en orden de magnitud con la resolución nativa de Landsat (30 m) y es consistente con la atribución del mosaico que el visor despliega a ese nivel de zoom. El muestreo de la rejilla no excede, por tanto, el detalle que la fuente contiene, que es la condición para que la resolución declarada sea interpretable. Conviene leerla como distancia de muestreo y no como poder de resolución calibrado: Google Earth remuestrea internamente las teselas y la nitidez varía entre fechas. La resolución resultante basta para discriminar la mancha urbana a escala metropolitana, el objetivo de este trabajo, pero no para distinguir estructuras individuales finas ni para comparaciones submétricas entre años. En términos del autómata, las ventanas de vecindad de 3 × 3, 5 × 5 y 7 × 7 píxeles corresponden a lados de 80, 134 y 187 m.

En conjunto, la serie reúne 37 imágenes, una por año entre 1984 y 2020, capturadas con una meta visual de cobertura nubosa inferior al 10 % evaluada en el momento de la captura. Cada imagen se homogeneizó en el *pipeline* a 1 792 × 3 024 píxeles, y el conjunto completo ocupa del orden de 200 MB.

Control de calidad, limitaciones y mitigación

En la adquisición, el control de calidad fue principalmente **visual** (nubosidad, sombras, nitidez, consistencia del encuadre). Ya conformada la carpeta de imágenes, el **pipeline de preprocesamiento** aplica comprobaciones reproducibles (dimensiones homogéneas, formato RGB, detección de archivos faltantes y reescalado cuando una captura varió en resolución de pantalla) antes de alimentar al clasificador; a ello se suman una validación geométrica (ajuste a la cuadrícula de referencia), una de intensidades (histogramas RGB para detectar anomalías evidentes) y una temporal (continuidad de la serie y sustitución puntual de años claramente anómalos). El conjunto final queda resumido en la descripción anterior del conjunto de imágenes y en la Figura 4.2.

El dataset tiene cuatro limitaciones principales: la resolución y nitidez efectivas dependen del nivel de zoom, del fondo cartográfico de cada fecha y de la compresión al exportar; el operador no controla la corrección atmosférica ni el origen exacto de cada tesela subyacente; la




Figura 4.2: Indicadores auxiliares de calidad por década, derivados del preprocesamiento de las capturas. No equivalen a control de calidad radiométrico de productos satelitales oficiales; sirven como apoyo visual para revisar la continuidad de la serie.

comparabilidad cromática entre años puede variar cuando el proveedor actualiza mosaicos; y el criterio de temporada seca y baja nubosidad es visual, no un filtrado por metadatos de nubes. Para acotar su impacto se fijaron los parámetros de vista (zoom, orientación, región) lo más constantes posible entre años, se homogeneizaron formato y dimensiones en el preprocesamiento, se hizo una revisión cruzada año con año para detectar saltos de contraste o nubosidad residual, y se normalizaron los valores de píxel con vistas a la clasificación binaria, sin pretender una calibración radiométrica entre sensores.

Estas fuentes de error se organizan por tipo, con una estimación cualitativa de su nivel y de su efecto sobre los mapas binarios, en la Tabla A.2 del Apéndice A. Los niveles (bajo, medio, alto) son juicios del autor a partir de la inspección de la serie y no mediciones formales de incertidumbre; sirven para dar prioridad a las estrategias de mitigación y para acotar honestamente el alcance de los resultados.

4.4. Preprocesamiento de datos

El modelo WoE-AC no parte de las imágenes crudas, sino de una serie de mapas binarios urbano/no-urbano $\{U_t\}_{t=1984}^{2020}$. Su construcción (la conversión de cada captura RGB de 1792×3024 píxeles en un mapa $U_t(x, y) \in \{0, 1\}$ mediante la cadena LBP + K-Means + SVM) se detalla en esta sección. Basta adelantar dos restricciones que ese flujo resuelve: la ausencia de banda infrarroja descarta los índices espectrales habituales (NDVI, NDBI) y obliga a apoyarse en descriptores

de textura y color, y la falta de verdad terreno para los 37 años obliga a etiquetar de forma no supervisada.

La Figura 4.3 resume esa representación. De ese flujo conviene rescatar, eso sí, la decisión que condiciona todo lo que sigue: el criterio que separa lo urbano de lo no-urbano es **idéntico para todos los años de la serie**. Esa consistencia inter-anual, y no la exactitud cartográfica frente a una verdad terreno, es lo que vuelve comparables las transiciones entre años consecutivos y permite que alimenten el cálculo de Pesos de Evidencia sin sesgos por cambios de criterio. La representación binaria, por su parte, es la entrada natural de un autómata celular, que opera sobre estados discretos, y captura justo la variable de interés: la expansión de la mancha urbana, no la composición interna de usos. Como respaldo de su fiabilidad interna, el clasificador reprodujo entre el 88 % y el 94 % de las pseudoetiquetas en el reparto de prueba (Sección 4.4.3); su validación externa, de carácter indirecto, se realiza a través del desempeño temporal del propio modelo en el Capítulo 5.




Figura 4.3: Representación binaria $U_t(i, j) \in \{0, 1\}$: celdas oscuras urbanas y claras no urbanas. *Imagen elaborada con IA generativa, con base en la definición propia de U_t de esta sección.*

4.4.1. Representación de los datos y extracción de características

Cada imagen RGB de $1\,792 \times 3\,024$ píxeles se convierte en un mapa binario urbano/no urbano mediante el pipeline LBP + K-Means + SVM. El resultado se almacena en el arreglo tridimensional $M_{t,i,j} \in \{0, 1\}$, donde t identifica el año, e i, j la posición en la cuadrícula; $M_{t,i,j} = 1$ si la celda es urbana ese año y 0 en caso contrario. Para obtener esa etiqueta, cada píxel se mapea a un vector de 23 características. Sea $\mathbf{f}_{i,j} = (f_1, \dots, f_{23})$ ese vector; las definiciones de cada componente se organizan en tres conjuntos que se describen a continuación.

El primer conjunto reúne las ocho **características básicas de color**, derivadas directamente de los canales rojo, verde y azul.

red: $f_1(i, j) = R(i, j)$, canal rojo.

green: $f_2(i, j) = G(i, j)$, canal verde.

blue: $f_3(i, j) = B(i, j)$, canal azul.

intensity: $f_4(i, j) = \frac{R+G+B}{3}$, intensidad media.

brightness: $f_5(i, j) = 0,299 R + 0,587 G + 0,114 B$,

luminancia (Rec. 601).

red_std: $f_6(i, j) = \bar{R}_{5 \times 5}(i, j)$, media local en ventana 5×5 . El nombre *_std es heredado del código y no describe la operación.

green_std: $f_7(i, j) = \bar{G}_{5 \times 5}(i, j)$, equivalente para

el canal verde.

blue_std: $f_8(i, j) = \overline{B_{5 \times 5}}(i, j)$, equivalente para el canal azul.

El segundo conjunto agrupa las seis **características de textura**, calculadas sobre la imagen convertida a escala de grises.

sobel_horizontal: $f_9 = \partial \text{gray} / \partial y$, convolución con kernel Sobel horizontal.

lbp: $f_{12}(i, j) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$, patrón binario local uniforme con $P = 24$, $r = 3$ y $s(x) = \mathbf{1}_{x \geq 0}$.

sobel_vertical: $f_{10} = \partial \text{gray} / \partial x$, convolución con kernel Sobel vertical.

entropy: $f_{13}(i, j) = -\sum_k p_k \log_2 p_k$, entropía local en ventana 9×9 .

gradient_magnitude: $f_{11}(i, j) = \sqrt{f_9^2 + f_{10}^2}$, magnitud del gradiente.

contrast: $f_{14}(i, j) = \overline{\text{gray}_{5 \times 5}}(i, j)$, media local en ventana 5×5 sobre la escala de grises.

El tercer conjunto incluye las nueve **características espectrales y de color**: índices contruidos a partir de las bandas visibles y transformaciones a otros espacios de color.

ngrdi: $f_{15} = \frac{G - R}{G + R + \varepsilon}$ con $\varepsilon = 10^{-8}$; índice verde-rojo normalizado (NGRDI), proxy cromático de vegetación con bandas visibles. No es un NDVI en sentido estricto, pues este requiere la banda del infrarrojo cercano, ausente en las capturas RGB.

lab_l: luminancia $L^* \in [0, 100]$ en el espacio CIE $L^*a^*b^*$.

excess_green: $f_{16} = 2G - R - B$, índice de exceso de verde (ExG).

lab_a: eje verde(-) a rojo(+), $a^* \in [-128, 127]$.

lab_b: eje azul(-) a amarillo(+), $b^* \in [-128, 127]$.

excess_red: $f_{17} = 1,4R - G$, índice de exceso de rojo (ExR), asociado a suelo y zona urbana.

hsv_h: matiz $H \in [0, 1]$.

hsv_s: $S = \frac{\max(R, G, B) - \min(R, G, B)}{\max(R, G, B)}$, saturación.

hsv_v: $V = \max(R, G, B)$, valor.

En conjunto, estas 23 características describen cada píxel por su color, su textura y su comportamiento espectral, y constituyen la entrada del paso de reducción dimensional. La Tabla A.1 del Apéndice A recoge el detalle de implementación de cada una.

Dentro del preprocesamiento esas 23 características se reducen a 8, mediante un StandardScaler y un PCA, cuyo fundamento se dio en el Capítulo 2 y cuyo pseudocódigo está en el Apéndice A (Algoritmos 2 y 3). La proyección retiene en promedio el 96,1 % de la varianza original, con un rango de 95,3 a 96,8 % entre los años muestreados de la serie: una compresión razonable sin pérdida apreciable de información para una clasificación binaria. El preprocesamiento aplicado a toda la serie se resume en la Tabla A.3 del mismo apéndice.

La salida del algoritmo PCA es la entrada del algoritmo de clasificación K-Means (matriz $Z \in \mathbb{R}^{N \times 8}$, Algoritmo 4). El algoritmo de K-Means se emplea con el fin de agrupar los píxeles en 2, 3 o 4 grupos; en este trabajo se usaron 2.

Las pseudo-etiquetas ℓ producidas por K-Means se usan como verdad base para entrenar un clasificador SVM (Algoritmo 5) sobre una muestra de hasta 10 000 píxeles, que luego predice la etiqueta de todos los N píxeles.

La salida del algoritmo SVM es un mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$ donde H es el número de filas y W es el número de columnas de la imagen. Aquí se empleó un procedimiento manual para seleccionar qué clase es la mancha urbana y cuál la no-urbana.

4.4.2. Pipeline de clasificación: de RGB a mapas binarios

El preprocesamiento homogeneiza formato y dimensiones de las capturas RGB y prepara la entrada al clasificador automático (LBP+K-Means+SVM). El *pipeline*, implementado en Python, encadena las etapas que resume la Figura 4.4:

Antes de describirlo conviene justificar por qué se eligió esta cadena y no un enfoque supervisado directo. La razón de fondo es que no se dispone de una verdad terreno etiquetada para los 37 años de la serie: un clasificador supervisado clásico o un *Random Forest* exigiría etiquetar manualmente muestras representativas año por año, y una arquitectura profunda tipo U-Net necesitaría además grandes volúmenes anotados y cómputo en GPU, sin aportar interpretabilidad sobre la decisión urbano/no-urbano. Frente a ello, la cadena combina texturas y color sin verdad terreno etiquetada: los patrones binarios locales (LBP) describen la rugosidad del tejido construido y son robustos a cambios de iluminación, el agrupamiento K-Means genera pseudoetiquetas sin información previa, y un SVM lineal consolida a partir de ellas una frontera de decisión reproducible y ligera. Dado que el problema es binario y que las imágenes son RGB sin banda infrarroja, este contraste de textura y color basta para separar lo construido de lo no construido; la opción elegida es, además, computacionalmente liviana (sin GPU) y replicable, lo que prioriza la reproducibilidad sobre una exactitud marginalmente mayor que las alternativas más pesadas no garantizan en ausencia de etiquetas.

Pipeline de Procesamiento

Clasificación automática de capturas RGB




Figura 4.4: Pipeline de preprocesamiento implementado

Sobre la categoría espectral conviene una aclaración, porque el nombre de los índices se confunde con facilidad. Como las capturas son RGB y no incluyen banda infrarroja, aquí no se calcula un NDVI en sentido estricto: ese índice necesita el infrarrojo cercano, del que estas imágenes carecen. Lo que se usa son índices contruidos únicamente con los canales visibles. El que se reporta como índice verde-rojo normalizado responde a la forma $(G - R)/(G + R)$ y coincide con el NGRDI que la literatura de percepción remota emplea con cámaras RGB; junto con el exceso de verde y de rojo cumple el papel de un proxy cromático de vegetación, suficiente

para separar superficies vegetadas de las construidas a partir del contraste de color, que es lo que requiere la clasificación binaria de este trabajo.

La implementación se organiza en una arquitectura modular (rasterización/clasificación de las capturas, cálculo de Pesos de Evidencia y simulación con autómatas celulares) cuyo diagrama de clases UML y rutas de los módulos del repositorio se documentan en el Apéndice A, para no recargar la descripción metodológica.

En este espacio RGB enriquecido con descriptores de textura (en particular los patrones binarios locales [LBP] de Ojala et al. [24], robustos a cambios de iluminación y útiles para distinguir la rugosidad del tejido construido), los primeros componentes del PCA reflejan el contraste urbano-vegetación y la variabilidad local, de modo que el SVM trabaja sobre representaciones comprimidas y poco redundantes.

El efecto de la cadena sobre un fragmento concreto de la imagen se aprecia en la Figura 4.5. El recorte de 8×8 celdas muestra la fotografía original, los dos grupos que forma el agrupamiento, la decisión del SVM y la rejilla binaria resultante. Cada celda de esa rejilla es la unidad espacial sobre la que opera el autómata y mide unos 27 m de lado.

La salida del SVM no determina por sí sola cuál de los dos grupos es el urbano. El agrupamiento no es supervisado y la etiqueta que asigna a cada clase es arbitraria, de modo que un año puede quedar con los valores invertidos respecto del anterior sin que nada en la clasificación lo advierta. Para resolverlo se aplica una convención sobre el resultado: se toma el 30 % central de la rejilla, que en esta ventana corresponde al núcleo consolidado de la ciudad, y se verifica qué etiqueta domina ahí; si domina el cero, el mapa se invierte. Los 37 mapas quedan así con la misma convención, 1 para urbano y 0 para no urbano, que es la que asume el resto del modelo. El procedimiento está implementado en `src/tesis_ac/historical/standardize_labels.py`.


4.4.3. Análisis de datos procesados y transformación binaria

Esta subsección resume la salida del pipeline: mapas binarios anuales urbano/no-urbano listos para alimentar el modelo WoE-AC que se define más adelante en este mismo capítulo.


Resultados de la transformación binaria

La Figura 4.6 muestra la evolución temporal del crecimiento urbano de Querétaro capturada mediante la clasificación binaria.

E1 — Sub-pipeline de clasificación: de la captura RGB al mapa de celdas



Lo que se ve en un recorte de 8×8 celdas



verde/beige = foto y clusters · navy = urbano (1) · gris = no urbano (0). El nombre urbano/no-urbano se fija en E2.

Figura 4.5: Sub-pipeline de clasificación aplicado a un recorte de 8×8 celdas: de la captura RGB al mapa binario. El agrupamiento separa dos clases pero no las nombra; la asignación urbano/no urbano se fija en un paso posterior, con la convención descrita en el texto de esta sección. *Imagen elaborada con IA generativa, con base en el pipeline de clasificación propio descrito en esta sección.*




Figura 4.6: Evolución del crecimiento urbano de la Zona Metropolitana de Querétaro (1984–2020), representada mediante mapas binarios urbano/no-urbano obtenidos a partir de la clasificación LBP+K-Means+SVM aplicada a las capturas RGB de la serie.

Calidad interna de la clasificación

La calidad del clasificador LBP+K-Means+SVM se evalúa con un reparto interno *train/test* (20 % para prueba por defecto) sobre las pseudoetiquetas generadas por K-Means, conforme a la rutina de entrenamiento documentada en el Apéndice A. En los experimentos sobre Querétaro, la concordancia del SVM con esas pseudoetiquetas (medida como *accuracy* en el reparto interno, no contra una verdad terreno) se situó en el rango 88–94 %.

Este porcentaje mide la coherencia interna del clasificador (es decir, qué tan bien el SVM reproduce las etiquetas generadas por K-Means) y no la exactitud respecto a una verdad terreno externa independiente. La validación externa del *pipeline* se realiza, de manera indirecta, a través de la evaluación temporal del modelo AC en el Capítulo 5.

Justificación de la representación binaria

La simplificación del mapa de cobertura de suelo a dos categorías (urbano/no-urbano) responde a tres consideraciones metodológicas. La primera es la compatibilidad con el AC: los autómatas celulares utilizados operan con estados discretos, de modo que la representación binaria elimina una etapa adicional de discretización y hace que las reglas de transición sean directamente interpretables. La segunda es la disponibilidad de datos: las capturas son RGB, sin bandas térmicas ni radar, lo que acota la discriminación fina de usos intraurbanos y hace razonable condensar la salida en dos clases. La tercera es el objetivo del modelo: el interés está en modelar la *expansión* del área urbana y no la composición interna de usos de suelo, y la clasificación binaria captura precisamente esa variable de salida.

Síntesis del preprocesamiento

La inspección visual de los mapas binarios anuales (Figura 4.6) muestra transiciones graduales y continuas entre años consecutivos, con patrones de expansión congruentes con el crecimiento documentado para la ZMQ, sin artefactos sistemáticos ni discontinuidades espaciales abruptas

en la serie. Con la serie de 37 mapas binarios (1984–2020) construida y verificada, las secciones siguientes definen el modelo de crecimiento que la toma como entrada.

4.5. Definición del modelo




Figura 4.7: Transición $U_t(i, j) = 0 \rightarrow U_{t+1}(i, j) = 1$: la celda con borde rojo transita a urbana cuando $P_{i,j} > \theta$. Imagen elaborada con IA generativa, con base en la regla de transición propia de la ecuación 2.6.

Con la serie de mapas binarios $\{U_t\}_{t=1984}^{2020}$ ya construida, el modelo de crecimiento urbano debe responder a una pregunta distinta de la del preprocesamiento: ya no se trata de decidir qué es urbano, sino de aprender dónde y por qué aparece lo urbano nuevo. El primer paso es, por tanto, definir el objeto de estudio del modelo: la transición (Figura 4.7). Una transición ocurre cuando una celda que era no-urbana en el año t pasa a urbana en $t + 1$, es decir, $U_t(i, j) = 0$ y $U_{t+1}(i, j) = 1$. Estas transiciones son los eventos que el modelo busca primero explicar a partir de la historia y, más adelante, reproducir hacia

La primera decisión del modelo es cómo cuantificar la evidencia que vincula la configuración espacial de una celda con su probabilidad de transición. La vía más común en la literatura es la regresión logística, pero conlleva un supuesto fuerte: que el logit de la probabilidad es una función lineal de las variables explicativas. Las relaciones espaciales del crecimiento urbano no son lineales; la probabilidad de urbanización cae de forma abrupta en los primeros cientos de metros desde el frente urbano y luego se aplanan. Por eso se elige el método de Pesos de Evidencia (WoE, ecuación 2.4 del Capítulo 2), que no impone ninguna forma funcional: discretiza cada variable en intervalos y estima un peso bayesiano independiente para cada uno, capturando la curvatura real de la relación. Como ventaja adicional, cada peso es interpretable en términos geográficos, lo que satisface el requisito de transparencia que motivó este trabajo y que los enfoques de caja negra no ofrecen.

La segunda decisión es qué variables espaciales alimentan el WoE (Figura 4.8). Aquí opera de nuevo una restricción de los datos: no se dispone de capas externas homogéneas (vialidades, pendiente, uso de suelo oficial) para los 37 años de la serie. Por tanto, todas las variables deben derivarse de la propia configuración urbana histórica, sin insumos adicionales. Se definen siete:

la distancia euclidiana a la celda urbana más cercana, la densidad de vecinos urbanos a tres escalas (ventanas 3×3 , 5×5 y 7×7), la fragmentación local, el tamaño del cluster urbano contiguo más cercano y el gradiente de urbanización. Cada una captura un aspecto distinto del proceso: la proximidad al frente consolidado, la presión del vecindario a múltiples escalas y la morfología del borde urbano. El que las siete provengan únicamente del mapa binario reduce los insumos necesarios para aplicar el modelo en otra ciudad a la disponibilidad de esa misma serie binaria, sin bases de datos locales. La transferencia geográfica no se verificó en este trabajo y exigiría recalibrar los pesos WoE con las transiciones del sitio objetivo.

La tercera decisión es sobre qué datos afinar. En lugar de ajustar el WoE a un único par de años, se agregan (*pooling*) las transiciones de los 26 pares consecutivos del período 1984–2010, hasta reunir 8 196 264 transiciones observadas. El motivo es estadístico: las transiciones de un solo año son escasas y ruidosas, y producirían pesos inestables.

Conviene precisar cómo se emparejan los datos, porque la agregación no es simétrica en sus dos lados. Las siete variables espaciales se promedian sobre los 26 períodos y ese mapa promedio se contrasta con el conjunto acumulado de transiciones. Los pesos relacionan, por tanto, la configuración espacial media del período de entrenamiento con las transiciones observadas en él, no cada configuración anual con su transición correspondiente. La consecuencia es que los pesos describen un régimen espacial promedio de 1984 a 2010 y se tratan como constantes del modelo, lo cual es coherente con su uso posterior, pero también significa que el número de valores distintos de cada covariable es el de una sola rejilla, 5 419 008, y no el del conjunto acumulado. Emparejar cada variable anual con su transición es una de las extensiones que se plantean en el Capítulo 6.

El período 2011–2020 se reserva deliberadamente, sin tocarlo durante el ajuste, para la validación posterior.

Con los pesos calculados, surge una cuarta decisión: cómo combinarlos. No todas las variables aportan lo mismo. El peso total por celda no se obtiene como la suma simple de la ecuación 2.5, sino con la suma ponderada de la ecuación 2.8, que pesa cada variable por su *Information Value*




Figura 4.8: Las siete variables espaciales derivadas del mapa binario U_t . Todas se calculan exclusivamente a partir de la configuración urbana histórica, sin capas externas. *Imagen elaborada con IA generativa, con base en las siete variables definidas en esta sección.*

(ecuación 2.7) normalizado, de modo que las variables con mayor poder discriminativo pesen más en la decisión final. En el caso de la Zona Metropolitana de Querétaro, esto hace que la distancia al frente urbano domine la combinación, concentra cerca del 28 % del peso total, el *Information Value* más alto de las siete variables, seguida de la densidad de vecinos inmediatos. La suma ponderada se transforma con la función sigmoide (ecuación 2.6) para obtener una probabilidad de transición acotada en $[0, 1]$.

Llegados a este punto aparece la decisión de acoplar el campo WoE a un autómata celular, en lugar de usar el mapa de probabilidad como predicción estática. Los pesos WoE, estimados en 1984–2010, sí quedan fijos; lo que no es estático es el *campo*: en cada paso anual se recalculan las siete variables espaciales sobre el estado actualizado del mapa y se les aplican esos pesos. Una celda muy apta puede no urbanizarse si ningún frente urbano la alcanza dentro del período, y una celda de idoneidad media puede hacerlo si el crecimiento llega a su vecindad. Se adopta la vecindad de Moore, definida en la Figura 2.2 del Capítulo 2, porque admite frentes diagonales y esa es la forma en que avanza una mancha urbana. El autómata celular (Sección 2.2 del Capítulo 2) aplica la regla de forma iterativa. Así, cuando una celda se urbaniza, incrementa de inmediato la densidad de vecinos de sus celdas contiguas y eleva su probabilidad de transición en el paso siguiente. Este mecanismo de contagio borde a borde es coherente con los patrones de mancha compacta, relleno de huecos y extensión de corredores observados en la ZMQ.




Figura 4.9: Un paso del AC: las celdas candidatas (borde rojo) se evalúan con la regla WoE y transitan a urbanas (relleno rojo) si $P_{i,j} > \theta$. *Imagen elaborada con IA generativa, con base en el algoritmo propio del autómata descrito en esta sección.*

La regla de transición (Figura 4.9) integra, finalmente, tres componentes. A la probabilidad WoE de cada celda se le añade la influencia del vecindario de Moore (ocho celdas adyacentes, ecuación 2.2), ponderada por un peso vecinal; se elige la vecindad de Moore por ser la mínima que captura tanto adyacencias ortogonales como diagonales del frente urbano. La probabilidad combinada se compara contra un umbral de transición: solo las celdas que lo superan pueden urbanizarse. Este umbral se fijó en 0,75 mediante exploración sistemática, tras observar que valores menores producían sobre-predicción masiva; su calibración y la del peso vecinal se detallan en el Capítulo 5.

Por último, la transición no es determinista: una celda apta se urbaniza solo si un sorteo aleatorio lo confirma. Esta componente estocástica refleja que, incluso bajo condiciones favorables, la

urbanización de una parcela depende de factores no modelados (decisiones de propietarios, permisos, mercado), y es lo que hace que distintas corridas del modelo generen escenarios ligeramente distintos en lugar de una única predicción rígida.

Los tres componentes se condensan en una sola expresión, que constituye el núcleo formal del modelo y coincide con la implementación validada. Para una celda no urbana (i, j) , la probabilidad de transición es

$$P_{i,j} = \min\left(1, \sigma\left(\sum_k \omega_k \text{WoE}_k(i, j)\right) + \alpha N_{i,j}\right), \quad \omega_k = \frac{\text{IV}_k}{\sum_l \text{IV}_l}, \quad (4.1)$$

donde $\sigma(\cdot)$ es la función logística; $\text{WoE}_k(i, j)$ es el peso de evidencia de la k -ésima variable espacial, ponderado por su *Information Value* normalizado ω_k (de modo que las variables más discriminativas pesan más); y $N_{i,j} \in [0, 1]$ es la influencia del vecindario, definida como la fracción de vecinos urbanos en la vecindad de Moore (las ocho celdas adyacentes), con peso vecinal α . Nótese que la idoneidad WoE se transforma primero con la sigmoide y la vecindad se suma después, acotando el resultado a $[0, 1]$. La proximidad al frente urbano no aparece como un término separado: la introduce la propia variable de distancia, la de mayor *Information Value*, dentro del campo WoE. En la implementación validada no se incluye un término adicional de decaimiento espacial (por ejemplo, una ponderación por distancia de Chebyshev sobre el vecindario); la distancia al frente urbano actúa únicamente como una variable más dentro del campo WoE, y la vecindad se incorpora como la fracción de vecinos urbanos en la vecindad de Moore. La celda transita a urbana en el paso siguiente solo si $P_{i,j}$ supera el umbral θ y si, además, un sorteo aleatorio $u \sim \mathcal{U}(0, 1)$ lo confirma ($u < P_{i,j}$). La configuración validada en este trabajo fija $\theta = 0,75$ y $\alpha = 0,50$ (Capítulo 5).

Conviene precisar en qué se aparta esta formulación del esquema WoE-AC más habitual. Conviene precisar cómo entra el WoE al autómata, porque de ahí depende su comportamiento. Aquí el WoE se incorpora como un campo probabilístico continuo ponderado por el *Information Value* normalizado de cada variable, que se recompone en cada paso al recalcular las variables espaciales sobre el estado actualizado del mapa, y se acopla a la vecindad mediante una regla deliberadamente sencilla y auditable. Ahora bien, la aportación metodológica central no reside en el uso del WoE y del AC, que la literatura ya documenta ampliamente, sino en el protocolo de evaluación: la calibración y la validación reproducibles sobre cinco ventanas quinquenales desplazadas, con código y datos abiertos, que permiten distinguir un desempeño estable de un ajuste a un único período. A ello se suman el contexto poco estudiado, una ciudad intermedia mexicana, y la serie larga de 37 años.

4.6. Validación

Definido el modelo, queda la pregunta de si sus predicciones son confiables. La primera decisión de la validación ya se tomó al entrenar: el WoE se ajustó únicamente con las transiciones de 1984–2010, dejando intacto el período 2011–2020. Esta separación temporal es lo que hace honesta a la evaluación, pues el modelo se prueba sobre años que nunca vio durante el ajuste, de la misma forma en que tendría que operar al proyectar el futuro. Validar sobre los mismos datos de entrenamiento solo mediría la capacidad de memorizar, no la de predecir.




Figura 4.10: Protocolo de validación: separación temporal entre entrenamiento (WoE, 1984–2010) y las cinco ventanas quinquenales de prueba (2011–2020). Ningún dato del periodo de prueba interviene en el ajuste del modelo. *Imagen elaborada con IA generativa, con base en el protocolo propio de validación quinquenal múltiple.*

La segunda decisión, y la que define el aporte metodológico de este trabajo, es no validar sobre una única ventana sino sobre cinco ventanas quinquenales desplazadas (Figura 4.10): 2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020. Cada ventana es hold-out respecto del entrenamiento 1984–2010; entre sí se solapan cuatro de cinco años. Una sola ventana puede resultar engañosamente favorable o desfavorable según las particularidades de ese lustro; cinco ventanas que se desplazan año con año permiten distinguir entre un acierto puntual y un

comportamiento que se sostiene. Gran parte de la literatura revisada en el Capítulo 3 valida sobre un solo período, lo que impide saber si el desempeño reportado se sostiene en el tiempo.

El procedimiento es el mismo en cada ventana. Se toma el mapa observado del año inicial como estado de partida, se ejecuta el autómata celular durante cinco pasos anuales recalculando las variables espaciales en cada uno, y el mapa predicho para el año final se compara, celda a celda, contra el mapa observado de ese año. De esa comparación se construye la matriz de confusión (ecuación 2.9) y, a partir de ella, todas las métricas.

Aquí aparece una decisión sobre cómo medir el acierto. Las métricas globales como la exactitud o el coeficiente Kappa (ecuación 2.18) son engañosas en este problema: como la mayoría del territorio no cambia de un año a otro, un modelo que se limitara a copiar el mapa inicial obtendría una exactitud alta sin predecir crecimiento alguno. Por eso la métrica central de la validación es el *Figure of Merit* (ecuación 2.24; Figura 4.11), que evalúa exclusivamente las celdas en transición e ignora la clase mayoritaria de permanencia. Se reportan, no obstante, las métricas complementarias (IoU, Precision, Recall, F1 y Kappa) y la descomposición del error en sus componentes de cantidad y de asignación, porque cada una ilumina un aspecto distinto del desempeño.

Las cifras por ventana, la calibración y el contraste con las hipótesis se presentan en el Capítulo 5.




Figura 4.11: Componentes del *Figure of Merit*: acierto (B), falsa alarma (A) y omisión (C). Solo las celdas en transición entran al cálculo. *Imagen elaborada con IA generativa, con base en la definición de Pontius Jr et al. [1].*

Capítulo 5

Resultados y análisis

Este capítulo presenta los resultados obtenidos de la aplicación del modelo WoE-AC para simular el crecimiento urbano de Querétaro. Se analiza la dinámica histórica observada (1984–2020), los resultados del análisis Weight of Evidence, la calibración del modelo, las simulaciones en cinco ventanas quinquenales desplazadas (2011–2016 a 2015–2020) y la evaluación cuantitativa mediante métricas espaciales (Accuracy, Precision, Recall, F1, Kappa, FoM). Finalmente, se realiza un análisis espacial del error para identificar las fuentes de discrepancia entre predicción y observación.

5.1. Dinámica observada del crecimiento urbano

Antes de evaluar el desempeño del modelo, es pertinente caracterizar el proceso que la simulación busca reproducir. Esta sección describe la evolución histórica de la huella urbana de Querétaro y los patrones espaciales de expansión identificados en la serie temporal 1984–2020.

5.1.1. Evolución temporal 1984–2020

Antes de presentar los resultados de la simulación conviene situarlos en el contexto histórico del crecimiento de Querétaro. Aquí hace falta una advertencia: la magnitud absoluta de la clase “urbano” que devuelve el clasificador no equivale a la mancha urbana real, porque arrastra también suelo desnudo y superficies áridas espectralmente parecidas (véase la nota metodológica al final de esta sección). Por eso, en vez de una tasa de crecimiento compuesta, que la serie clasificada no sostiene, la Tabla 5.1 resume la fracción media de píxeles de esa clase en cuatro tramos de la serie.

Sobre el conjunto de la serie, la fracción clasificada pasa de 44,42 % en 1984 a 52,85 % en 2020,

Tabla 5.1: Fracción media de píxeles clasificados como “urbano” por tramo de la serie 1984–2020. Las cifras provienen directamente de los mapas binarios y deben leerse como un indicador grueso de la dinámica, no como superficie construida.

Período	Fracción media clasificada	Característica principal
1984–1995	~43 %	Consolidación del centro urbano
1996–2005	~44 %	Expansión hacia zonas industriales
2006–2015	~45 %	Expansión dispersa (norte y este)
2016–2020	~50 %	Consolidación periférica

un incremento neto de 8,4 puntos porcentuales. La variabilidad interanual es alta: hay mínimos como 33,6 % en 1992 y una desviación estándar cercana a 4 puntos a lo largo del período. Un ajuste lineal de la fracción frente al año arroja una pendiente de apenas 0,15 puntos por año, con $R^2 \approx 0,15$; es decir, la tendencia ascendente existe pero es débil y queda dominada por el ruido del clasificador. El único tramo que se separa con nitidez del resto es 2016–2020. Por eso no se reporta una tasa anual compuesta: la serie no la sostiene.




Figura 5.1: Evolución de la fracción clasificada como “urbano” en Querétaro (1984–2020). Se observa una tendencia ascendente con fuerte variabilidad interanual, más marcada en el tramo final de la serie.

La Figura 5.1 resume esa serie.

5.1.2. Patrones espaciales de expansión

Los mapas binarios generados para cada año revelan tres patrones principales de expansión. El primero es el crecimiento contiguo por difusión, donde la expansión se produce principalmente desde los bordes de áreas urbanas existentes, siguiendo el mecanismo de contagio espacial que los autómatas celulares capturan de manera natural. El segundo corresponde al desarrollo

periurbano a lo largo de corredores de transporte, visible en los ejes norte (autopista a San Luis Potosí) y oeste (autopista a Celaya). El tercero es el desarrollo industrial puntual: la instalación de parques industriales (Aeropuerto Industrial, Querétaro Aerospace) genera núcleos discontinuos en la periferia.

Los mapas binarios muestran crecimiento sostenido de la huella urbana a lo largo del período. Para los años de inicio de los experimentos de validación, los recuentos de píxeles urbanos extraídos directamente de los mapas clasificados son los siguientes: 2011: 2 699 088 px; 2012: 2 140 433 px; 2013: 2 140 627 px; 2014: 2 469 631 px; 2015: 2 145 356 px; 2020 (observado): 2 864 122 px. Estas cifras corresponden directamente a los valores `urban_start` y `urban_end_observed` de los archivos de resultados de validación (`validation_results.json`) y son los insumos directos del Autómata Celular.

Nota metodológica sobre la clase “urbano”: El clasificador K-Means+SVM opera sobre características espectrales y de textura extraídas de las **capturas RGB** de la serie (Google Earth, imagen histórica). En la práctica, el clasificador aprende a separar dos agrupaciones espectrales: *zonas con cubierta vegetal verde y densa* versus *zonas sin cubierta vegetal verde*. Esta segunda clase agrupa el tejido urbano real (edificaciones, vialidades, concreto), pero también suelo desnudo agrícola en temporada seca y superficies áridas periféricas espectralmente similares a las urbanas. Por ello, los recuentos de píxeles de la clase “urbano” son considerablemente mayores que la mancha urbana real de Querétaro.

La validación del modelo se realiza en términos de *consistencia interna*: dado un mapa binario clasificado en el año t (con la definición descrita), el modelo predice qué píxeles habrán cambiado de clase en $t + 5$. La calidad de esa predicción es lo que miden las métricas de la Sección 5.5. Este enfoque es válido mientras la definición de clase se aplique de forma consistente en todos los años de la serie.

5.2. Resultados del análisis Weight of Evidence

Esta sección presenta los resultados del cálculo de Weight of Evidence sobre las transiciones históricas observadas (1984–2010), incluyendo el poder predictivo de cada variable espacial cuantificado mediante el Information Value y la interpretación geográfica de los pesos obtenidos.

5.2.1. Transiciones históricas identificadas

El cálculo de Weight of Evidence se basó en el análisis de 26 períodos anuales consecutivos (1984–2010), identificando los píxeles que cambiaron de estado entre cada par de años, hasta

acumular 8 196 264 transiciones observadas. Las siete variables espaciales se promediaron sobre esos 26 períodos y el mapa promedio se contrastó con el conjunto acumulado de transiciones, según el procedimiento descrito en el Capítulo 4. Los pesos resultantes describen, por tanto, el régimen espacial medio del período de entrenamiento.

5.2.2. Pesos por variable (Information Value)

El modelo utiliza 7 variables espaciales cuya importancia predictiva se cuantifica mediante el Information Value (IV). La Tabla 5.2 presenta los IV calculados sobre el conjunto de entrenamiento 1984–2010 y el peso normalizado que se deriva de ellos, que es el que pondera a cada variable en la probabilidad de transición.

Tabla 5.2: *Information Value* y pesos normalizados de las siete variables WoE, calculados sobre el período de entrenamiento (1984–2010).

Variable	IV	Peso normalizado
Distancia al área urbana (<i>distance_urban</i>)	3,2697	0,2815
Densidad de vecindad 3×3 (<i>neighbor_density_3x3</i>)	2,8973	0,2495
Densidad de vecindad 5×5 (<i>neighbor_density_5x5</i>)	1,6782	0,1445
Densidad de vecindad 7×7 (<i>neighbor_density_7x7</i>)	1,2396	0,1067
Fragmentación local (<i>local_fragmentation</i>)	1,2331	0,1062
Gradiente urbano (<i>urban_gradient</i>)	1,1568	0,0996
Tamaño del <i>cluster</i> más cercano (<i>nearest_cluster_size</i>)	0,1388	0,0120
Total	11,6135	1,000

El peso normalizado de cada variable es su IV dividido entre el IV total de las siete. El patrón muestra que la distancia al área urbana y las tres variables de densidad concentran 0,782 del peso (78,2 %), lo que es coherente con un mecanismo de difusión espacial desde las áreas ya urbanizadas. La variable *nearest_cluster_size* recibe un peso muy bajo (0,012, con un IV de 0,139), lo que sugiere que el tamaño del *cluster* urbano más cercano aporta información marginal una vez controlada la distancia.

5.2.3. Interpretación de los pesos WoE

El patrón observado en los pesos es **coherente** con la teoría de difusión urbana, aunque no de forma monótona. Para las tres variables de densidad de vecindad, los pesos de los *bins* 1–3 son negativos (−5,58 a −0,40 en el radio 3×3): corresponden a celdas con vecindad escasamente urbanizada y, en consecuencia, con menor probabilidad de transición que el promedio. Los *bins* 4–8 son positivos y contienen la evidencia favorable a la transición, con un máximo de +0,93

(3×3) , $+0,87$ (5×5) y $+0,80$ (7×7) en $\rho \approx 0,37-0,55$. El punto de equilibrio ($WoE \approx 0$) se alcanza en $\rho \approx 0,10-0,15$, según el radio.

La relación es, por tanto, unimodal y no monótona. Pasado el máximo, la evidencia decae: el peso del radio 3×3 baja de $+0,93$ en $\rho \approx 0,37-0,55$ a $+0,21$ en el intervalo $\rho \approx 0,74-0,92$, que es el más alto que una celda candidata puede alcanzar. La lectura es directa y refuerza el mecanismo de difusión: la evidencia favorable se concentra en vecindades parcialmente urbanizadas, no en las que ya están próximas a la saturación, donde queda poco suelo disponible alrededor. El crecimiento ocurre en el frente urbano, no dentro de la mancha consolidada. La Figura 5.2 resume la contribución de cada variable y la amplitud de sus pesos.

Alcance de los bins extremos y de la jerarquía entre variables

Los pesos anteriores se estimaron sobre todas las celdas de la rejilla, sin restringir el muestreo a las celdas elegibles, es decir, a las que eran no urbanas en el año inicial. Conviene precisar el alcance de esa decisión, porque afecta a dos bins y a la lectura del *Information Value*.

El efecto se concentra en dos intervalos. El *bin* de distancia nula de `distance_urban` agrupa las celdas que ya eran urbanas, y el *bin* de densidad unitaria del radio 3×3 agrupa las de vecindad completamente urbanizada. Ninguno de los dos registra transiciones observadas, de modo que su peso ($-14,28$ y $-13,78$) queda determinado por el suavizado que evita la división por cero, no por los datos. Lo que ambos codifican es la restricción estructural de que una celda urbana no vuelve a urbanizarse, no un gradiente de evidencia espacial.

Ninguno de los dos pesos interviene en la simulación, y no por una precaución añadida sino por la propia construcción de las variables. El autómata evalúa como candidatas únicamente las celdas no urbanas. Una celda no urbana tiene distancia al frente urbano mayor o igual que uno, mientras que el *bin* degenerado de `distance_urban` cubre el intervalo $[0; 0,0385]$: es inalcanzable. Y la densidad de vecindad se calcula con una ventana 3×3 que incluye la celda central, de modo que si el centro es no urbano la densidad no puede exceder $8/9 \approx 0,889$, mientras que el *bin* degenerado exige densidad exactamente unitaria: también es inalcanzable. La comprobación sobre las diez rejillas del período de validación confirma el argumento sin excepciones: de 28 917 357 celdas candidatas, ninguna cae en ninguno de los dos *bins*. El detalle está en `data/processed/woe_bin_reachability.json`.

Queda entonces acotado dónde sí influyen. Los IV de la Tabla 5.2 superan con holgura el umbral de 0,50 que la escala convencional de la Sección 2.3.2 marca como muy fuerte, y esa magnitud no debe leerse como capacidad predictiva excepcional, porque proviene en buena parte de esos dos *bins*: en `distance_urban` el degenerado aporta 2,786 de sus 3,270 de IV, un

85,2 %, y en el radio 3×3 , 1,617 de 2,897, un 55,8 %. Las otras cinco variables no tienen *bins* degenerados. Como el IV determina la ponderación ω_k de la ecuación 2.8, el efecto real es sobre el peso relativo entre variables: descontando esos *bins*, la densidad de vecindad 5×5 pasaría al primer lugar (1,678) y *distance_urban* caería al sexto (0,484).

De ahí se sigue qué afirmar y qué no. La ponderación de la Tabla 5.2 concede a la distancia más influencia que la que le correspondería con los *bins* descontados, y es la ponderación con la que se obtuvieron todos los resultados de este capítulo: se validó fuera de muestra en cinco ventanas que no intervinieron en su estimación, con los valores de FoM, Kappa e IoU ya reportados. Lo que se sostiene en cualquiera de las dos lecturas es que la señal que gobierna la simulación es la difusión por contigüidad, porque las cuatro variables de densidad y fragmentación conservan su posición relativa. Lo que no se sostiene sin esta salvedad es la primacía de la distancia sobre la densidad como jerarquía de capacidad discriminante. Restringir el muestreo a celdas elegibles depuraría la interpretación de los IV sin alterar la mecánica de la simulación, y por eso figura entre las extensiones del Capítulo 6 y no entre las correcciones pendientes.




Figura 5.2: *Information Value* por variable (izquierda) y rango de pesos WoE por variable (derecha), calculados sobre el período de entrenamiento 1984–2010. La distancia al área urbana concentra el IV más alto (3,270, un 28,2 % del total), por encima de la densidad de vecindad 3×3 (2,897, un 24,9 %). El panel derecho muestra que ambas variables son también las de mayor amplitud entre evidencia negativa y positiva.

5.3. Calibración del modelo

A partir de los pesos WoE derivados de los datos históricos, esta sección describe la configuración final del Autómata Celular y el proceso de calibración sistemática de sus parámetros mediante búsqueda en cuadrícula (*grid search*). El marco metodológico que justifica esta elección se discute en el Capítulo 4 (Sección 4.5).

5.3.1. Configuración del autómata celular

El Autómata Celular se configuró con los parámetros especificados en la Tabla 5.3, resultado de la calibración sobre el conjunto de entrenamiento (1984–2010).

Tabla 5.3: Configuración final del Autómata Celular WoE-AC.

Parámetro	Valor
Espacio celular	1 792 × 3 024 píxeles.
Estados	{0 : no-urbano, 1 : urbano}.
Vecindario	Moore (8 vecinos, radio = 1).
Variables WoE	Siete variables espaciales: distancia al área urbana, densidades de vecindad 3 × 3, 5 × 5 y 7 × 7, fragmentación local, gradiente urbano y tamaño del <i>cluster</i> más cercano.
Ponderación de variables	Proporcional al <i>Information Value</i> (IV) normalizado.
Umbral de urbanización	$\theta = 0,75$ (calibrado sobre la probabilidad combinada).
Peso de vecindad	$\alpha = 0,50$.
Paso temporal	1 año.
Períodos de simulación	5 iteraciones por experimento.

5.3.2. Proceso de calibración

La calibración se centró en el umbral de urbanización (θ) y en la ponderación de las siete variables WoE, y se realizó sobre el período de entrenamiento (1984–2010). El umbral final $\theta = 0,75$ se adoptó porque los valores ensayados en la exploración inicial ($\approx 0,40$ – $0,60$) producían una sobre-predicción excesiva del crecimiento urbano: la mejor configuración de ese rango, con $\theta = 0,400$, simuló 2 203 593 transiciones frente a las 391 095 observadas y alcanzó un FoM de 0,172, muy por debajo del que se obtiene con el umbral adoptado. Ya en la fase de validación, y como resultado y no como criterio de ajuste, esa configuración reduce la sobre-predicción y mantiene el Recall por encima de 0,91 en las cinco ventanas evaluadas. La ponderación de las siete variables WoE se hizo proporcional al *Information Value* (IV) de cada variable, calculado sobre el conjunto de entrenamiento (1984–2010). La configuración resultante (umbral, peso de vecindad y ponderación por IV) queda documentada en el repositorio, junto con los scripts que reproducen el barrido. El detalle de rutas se recoge en el Apéndice A.

La probabilidad de urbanización para la celda (i, j) en el paso t es la misma regla de transición definida en el Capítulo 4 (ecuación 4.1): el campo WoE, suma de las siete evidencias ponderadas por su *Information Value* normalizado, se transforma con la sigmoide y se le suma después la

influencia del vecindario, acotando el resultado a $[0, 1]$:

$$P_{\text{trans}}(i, j, t) = \min\left(1, \sigma\left(\sum_{k=1}^7 \frac{IV_k}{\sum_l IV_l} \cdot \text{WoE}_k(i, j, t)\right) + \alpha \cdot I_{\text{neigh}}(i, j, t)\right), \quad (5.1)$$

donde $\sigma(\cdot)$ es la función sigmoide; IV_k , el *Information Value* de la k -ésima variable; $\text{WoE}_k(i, j, t)$, el valor de evidencia en la celda; $\alpha = 0,50$, el peso de vecindad; e $I_{\text{neigh}}(i, j, t) \in [0, 1]$, la fracción de vecinos urbanos en la vecindad de Moore. Una celda se urbaniza cuando P_{trans} supera el umbral $\theta = 0,75$ y un sorteo aleatorio lo confirma.

5.4. Simulación del crecimiento urbano

Esta sección describe el protocolo de validación quinquenal múltiple implementado para evaluar el desempeño del modelo en régimen de *hold-out* respecto del período de entrenamiento, y presenta los resultados individuales de las simulaciones en cada uno de los cinco períodos evaluados.

5.4.1. Protocolo de validación quinquenal múltiple

Para evaluar el modelo de forma independiente del entrenamiento, se adoptó un esquema de **validación quinquenal múltiple**: el WoE se entrenó exclusivamente con datos del período 1984–2010 y, con esos pesos, el Autómata Celular se simuló en cinco ventanas temporales solapadas de cinco años, con años de inicio sucesivos (2011, 2012, 2013, 2014 y 2015). El diseño separa entrenamiento y prueba: ningún dato del período de validación interviene en el entrenamiento (*hold-out* temporal) y permite evaluar la estabilidad del modelo bajo distintas condiciones de partida. La Tabla 5.4 reúne la configuración con la que se ejecutaron las cinco simulaciones.

Tabla 5.4: Configuración del experimento de validación quinquenal múltiple.

Parámetro	Valor
WoE entrenado con	1984–2010 (26 transiciones anuales agregadas por <i>pooling</i>)
Umbral de urbanización	$\theta = 0,75$
Peso de vecindad	$\alpha = 0,50$
Pasos por validación	5 iteraciones (1 año por paso)
Períodos evaluados	2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020

5.5. Evaluación del modelo

A continuación se presentan las métricas de evaluación cuantitativa del modelo en los cinco períodos quinquenales y se contextualizan los resultados frente a valores de referencia reportados en la literatura internacional.

5.5.1. Resumen comparativo – cinco períodos quinquenales

La Tabla 5.5 resume las métricas obtenidas en los cinco períodos evaluados. El **FoM promedio es de 0,317** (equivalente a 31,7 % en escala porcentual), calculado conforme a la Ecuación 2.24 del marco teórico. Esta magnitud se sitúa en una **banda intermedia** del espectro empírico documentado por Pontius Jr et al. [1]: por encima del subconjunto de aplicaciones con FoM inferior a 0,15 y muy por debajo del único caso que supera 0,50 en esa muestra multi-sitio (Capítulo 3). El Kappa promedio de 0,445 corresponde a un acuerdo moderado según la escala de Landis y Koch [32], en la parte baja de ese rango (0,41–0,60). El Recall alto ($> 0,91$ en todos los períodos) indica que el modelo captura la mayor parte de la urbanización observada, bajo la misma definición operativa de la clase urbana, aunque con sobre-predicción sistemática de la magnitud del crecimiento.

Tabla 5.5: Métricas de validación en las cinco ventanas quinquenales (WoE-AC, umbral $\theta = 0,75$).

Período	Acc	IoU	Prec	Recall	F1	κ	FoM
2011–2016	0,665	0,581	0,590	0,975	0,735	0,349	0,222
2012–2017	0,750	0,652	0,688	0,925	0,789	0,499	0,345
2013–2018	0,744	0,648	0,689	0,917	0,787	0,482	0,355
2014–2019	0,697	0,614	0,628	0,965	0,761	0,396	0,287
2015–2020	0,755	0,669	0,701	0,936	0,802	0,498	0,378
Promedio	0,722	0,633	0,659	0,944	0,775	0,445	0,317

La variación entre períodos refleja diferencias en la dinámica observada. El período 2011–2016 muestra el FoM más bajo (0,222): el área urbana clasificada en 2016 *decreció* levemente respecto a 2011, una anomalía atribuible a la variabilidad de la clasificación binaria RGB año a año, más que a una contracción urbana real. Los períodos 2012–2017, 2013–2018 y 2015–2020,

en los que el crecimiento neto observado es positivo, exhiben FoM entre 0,345 y 0,378, con mayor concordancia entre el modelo y los mapas observados. La Tabla 5.6 sitúa estos valores frente al espectro documentado en la literatura.

Tabla 5.6: Posicionamiento del modelo WoE-AC en el espectro empírico de Figure of Merit (FoM) documentado en la literatura LUCC. La comparación es cualitativa: los sitios, las definiciones temáticas de las clases y los horizontes temporales difieren entre estudios.

Referencia	Método	FoM reportado / observado
Estudio comparativo multi-sitio [1]	Trece aplicaciones de nueve modelos	Espectro empírico amplio: seis aplicaciones con FoM inferior a 0,15 y una sola por encima de 0,50; el FoM puede variar entre 0 y 1.
GSA-CA en Urumqi [41]	AC con búsqueda gravitacional	FoM = 0,430 en calibración y 0,376 en validación; contexto árido con <i>drivers</i> físicos explícitos.
Este trabajo (ZMQ, promedio cinco ventanas)	WoE-AC con <i>grid search</i>	FoM promedio = 0,317 (i.e., 31,7 %); Kappa promedio = 0,445.

Comparado con el estudio de Tang et al. [41] sobre Urumqi, presentado en el Capítulo 3, donde el aprovechamiento explícito de *drivers* físicos asociados a la aridez eleva el FoM por encima de 0,37, el modelo WoE-AC propuesto queda por debajo, lo que es coherente con el hecho de que en este trabajo se emplean exclusivamente variables derivadas del propio mapa binario, sin incorporar restricciones topográficas, socioeconómicas ni de infraestructura.

La Figura 5.3 presenta esas mismas cifras en forma gráfica y admite dos lecturas que la tabla no hace evidentes. La primera es que las tres métricas coinciden en señalar las dos ventanas de menor desempeño, 2011–2016 y 2014–2019, que son también las de menor crecimiento neto observado; entre las tres restantes el orden cambia según la métrica que se privilegie, de modo que la jerarquía fina entre ellas no es robusta. La segunda es que la dispersión entre ventanas depende de la métrica: el FoM varía en un factor de 1,70 entre el valor mínimo y el máximo, el Kappa en 1,43 y el IoU en 1,15. La razón está en el alcance de cada una. El IoU se calcula sobre la clase urbana completa e incorpora las celdas que ya eran urbanas al inicio del período, mientras que el FoM excluye por construcción el acierto sobre la permanencia y contabiliza solo celdas en transición (ecuación 2.24). El FoM es, por tanto, la métrica que discrimina con mayor amplitud entre ventanas, y es la que se privilegia al situar el modelo frente a la literatura.




Figura 5.3: Desempeño comparado del modelo WoE-AC en las cinco ventanas quinquenales. Las líneas verticales punteadas señalan el promedio de cada métrica: FoM = 0,317, Kappa = 0,445, IoU = 0,633. El FoM más bajo coincide con la única ventana cuyo crecimiento neto observado es negativo. *Figura elaborada con IA generativa a partir de los resultados de validación propios de la Tabla 5.5.*

5.5.2. Período 2011–2016

La Tabla 5.7 reúne las métricas de esta ventana y la Figura 5.4 compara el mapa observado con el predicho. Es el período con el FoM más bajo de la serie (0,222), por la razón ya anticipada: el área urbana clasificada en 2016 quedó por debajo de la de 2011.

Tabla 5.7: Métricas de validación del período 2011→2016. B (hits del FoM) es el subconjunto de TP que corresponde a transiciones a urbano observadas y predichas simultáneamente; los píxeles permanentes ya urbanizados quedan incluidos en TP pero no en B (véase Ec. 2.24).

Métricas de píxel		Figure of Merit	
Accuracy	0,665	FoM	0,222
IoU	0,581	Hits (B)	361 614
Precision	0,590	Falsas alarmas (A)	1 203 567
Recall	0,975	Omisiones (C)	64 208
F1	0,735	TP / FP / FN	2 514 806 / 1 749 463 / 64 208
κ	0,349	Crec. obs. / pred.	−4,4 % / +58,0 %




Figura 5.4: Validación quinquenal 2011–2016. De izquierda a derecha: estado inicial (2011), mapa observado 2016 (*ground truth*), mapa predicho 2016 y diferencia (verde=TP, naranja=FP, azul=FN). FoM = 0,222; la anomalía se debe a que el área urbana observada disminuyó levemente por variabilidad en la clasificación binaria RGB año a año.

5.5.3. Período 2012–2017

En esta ventana el desempeño mejora respecto a la anterior. La Tabla 5.8 detalla las métricas y la Figura 5.5 ilustra el resultado espacial, con un FoM de 0,345 sobre un crecimiento observado positivo.

Tabla 5.8: Métricas de validación del período 2012→2017.

Métricas de píxel		Figure of Merit	
Accuracy	0,750	FoM	0,345
IoU	0,652	Hits (<i>B</i>)	602 889
Precision	0,688	Falsas alarmas (<i>A</i>)	937 345
Recall	0,925	Omisiones (<i>C</i>)	205 308
F1	0,789	TP / FP / FN	2 532 942 / 1 147 725 / 205 308
κ	0,499	Crec. obs. / pred.	+27,9 % / +72,0 %




Figura 5.5: Validación quinquenal 2012–2017. FoM = 0,345; período con crecimiento observado positivo (+27,9 %) y FoM superior al de la ventana 2011–2016 bajo el mismo protocolo. Los 602 889 hits (*B*) corresponden a píxeles donde tanto el modelo como la observación registran transición a urbano en el período, asociados a la expansión perimetral visible en el mapa binario.

5.5.4. Período 2013–2018

La Tabla 5.9 y la Figura 5.6 resumen el período, que alcanza un FoM de 0,355, el más alto hasta aquí, en un contexto de expansión sostenida hacia el norte y el este.

Tabla 5.9: Métricas de validación del período 2013→2018.

Métricas de píxel			Figure of Merit
Accuracy	0,744	FoM	0,355
IoU	0,648	Hits (<i>B</i>)	641 089
Precision	0,689	Falsas alarmas (<i>A</i>)	934 924
Recall	0,917	Omisiones (<i>C</i>)	231 317
F1	0,787	TP / FP / FN	2 559 805 / 1 156 835 / 231 317
κ	0,482	Crec. obs. / pred.	+30,4 % / +73,6 %




Figura 5.6: Validación quinquenal 2013–2018. FoM = 0,355; valor cercano al del período 2012–2017 en un contexto análogo de crecimiento observado positivo. El número de omisiones (231 317 píxeles) sugiere que parte de la expansión hacia el norte y el este no queda recogida en la predicción bajo este experimento.

5.5.5. Período 2014–2019

Este período se aparta de la tendencia: la Tabla 5.10 registra un FoM de 0,287 y la Figura 5.7 deja ver el desajuste entre un crecimiento real modesto y una predicción de expansión más amplia.

Tabla 5.10: Métricas de validación del período 2014→2019.

Métricas de píxel		Figure of Merit	
Accuracy	0,697	FoM	0,287
IoU	0,614	Hits (<i>B</i>)	511 475
Precision	0,628	Falsas alarmas (<i>A</i>)	1 176 288
Recall	0,965	Omisiones (<i>C</i>)	93 486
F1	0,761	TP / FP / FN	2 611 594 / 1 545 800 / 93 486
κ	0,396	Crec. obs. / pred.	+9,5 % / +68,3 %




Figura 5.7: Validación quinquenal 2014–2019. FoM = 0,287; el crecimiento real modesto (+9,5 %) contrasta con una predicción de expansión más elevada (+68,3 %), lo que se refleja en la proporción de falsas alarmas (1 176 288 píxeles). El Recall alto (0,965) indica que el modelo asigna clase urbana de forma amplia respecto al mapa observado en 2019.

5.5.6. Período 2015–2020

La última ventana es la de FoM más alto de las cinco. La Tabla 5.11 consigna un FoM de 0,378 y la Figura 5.8 muestra el mayor número de aciertos de toda la serie, en un año de fuerte crecimiento observado.

Tabla 5.11: Métricas de validación del período 2015→2020.

Métricas de píxel		Figure of Merit	
Accuracy	0,755	FoM	0,378
IoU	0,669	Hits (<i>B</i>)	704 983
Precision	0,701	Falsas alarmas (<i>A</i>)	977 214
Recall	0,936	Omisiones (<i>C</i>)	181 887
F1	0,802	TP / FP / FN	2 682 235 / 1 145 318 / 181 887
κ	0,498	Crec. obs. / pred.	+33,5 % / +78,4 %




Figura 5.8: Validación quinquenal 2015–2020. FoM = 0,378; entre las cinco ventanas es el FoM más alto, en un contexto de fuerte crecimiento observado (+33,5 %). Se registran 704 983 hits y, en términos relativos a este conjunto de corridas, una menor proporción de falsas alarmas que en otras ventanas.

5.5.7. Descomposición del desacuerdo en cantidad y asignación

Las métricas anteriores dicen cuánto se equivoca el modelo, no de qué se equivoca. La descomposición de Pontius Jr y Millones [33], definida en las ecuaciones 2.25 y 2.26 del marco teórico, separa las dos fuentes: predecir una extensión de cambio equivocada es desacuerdo de cantidad, y localizar mal un total correcto es desacuerdo de asignación. La Tabla 5.12 recoge ambos componentes en las cinco ventanas.

Tabla 5.12: Descomposición del desacuerdo total en sus componentes de cantidad y de asignación [33], sobre las 5 419 008 celdas de cada ventana. El desacuerdo total es el complemento de la exactitud global de la Tabla 5.5. La última columna es la fracción del desacuerdo atribuible a la cantidad.

Período	FoM	Cantidad	Asignación	Cantidad / total
2011–2016	0,222	31,1 %	2,4 %	92,9 %
2012–2017	0,345	17,4 %	7,6 %	69,7 %
2013–2018	0,355	17,1 %	8,5 %	66,7 %
2014–2019	0,287	26,8 %	3,5 %	88,6 %
2015–2020	0,378	17,8 %	6,7 %	72,6 %
Promedio	0,317	22,0 %	5,7 %	79,4 %

El desacuerdo de cantidad domina en las cinco ventanas y concentra el 79,4 % del desacuerdo total en promedio. El modelo urbaniza demasiadas celdas, pero las coloca en su mayoría donde corresponde. Ese diagnóstico es consistente con el Recall alto frente a la Precisión moderada de la Tabla 5.5, y con el factor de sobre-predicción que se documenta más adelante.

La lectura por ventana afina el resultado. Las dos ventanas de peor FoM son las de mayor desacuerdo de cantidad: 2011–2016 concentra en cantidad el 92,9 % de su desacuerdo, algo esperable porque es la única ventana con crecimiento neto observado negativo, de modo que cualquier crecimiento simulado es exceso por definición; en 2014–2019 la proporción llega al 88,6 %. Las tres ventanas de mejor FoM descienden al rango 66,7–72,6 %, y es ahí donde el desacuerdo de asignación alcanza su nivel más alto. La implicación metodológica es directa: el margen de mejora está en la estimación de la magnitud del crecimiento, no en la regla que decide dónde ocurre.

5.6. Análisis espacial del error del modelo

La Figura 5.9 localiza esos componentes para la ventana 2015–2020. Complementando la evaluación cuantitativa, esta sección examina las fuentes de error identificadas en el proceso de




Figura 5.9: Mapa de error para la ventana 2015→2020 (FoM = 0,378). Las celdas verdes (B) son aciertos, es decir, transiciones correctamente predichas; las ámbar (A) son falsas alarmas; las rojas (C) son omisiones. Solo las celdas en transición entran al cálculo del FoM; las permanencias urbanas y no urbanas aparecen en gris. *Figura elaborada con IA generativa a partir de los mapas predicho y observado propios de la ventana 2015–2020.*

simulación y analiza cualitativamente los patrones morfológicos de las predicciones, con el fin de orientar las extensiones metodológicas propuestas en las conclusiones.

5.6.1. Fuentes de error identificadas

El análisis conjunto de los cinco períodos revela tres fuentes principales de error que se propagan desde la clasificación de imágenes hasta la simulación:

Error de clasificación de imágenes

El pipeline de clasificación no supervisada (K-Means + SVM) reporta una concordancia interna de 88–94 % con las pseudoetiquetas en el conjunto de prueba holdout (20 % de los píxeles), según se describe en el Capítulo 4. Con una imagen de 5,4 millones de píxeles, un error nominal del 6 al 12 % equivale a unos 325 000–650 000 píxeles mal clasificados por imagen. Estos errores se manifiestan como confusión espectral (suelo desnudo o techos claros clasificados como urbano) e inconsistencias temporales que introducen “transiciones” espurias en el historial WoE.

Propagación en transiciones históricas

El cálculo de WoE se basa en las transiciones históricas observadas. Los errores de clasificación distorsionan las probabilidades WoE, y el efecto se acumula a lo largo de los 26 años de datos de entrenamiento.

Amplificación en el autómata celular

El AC amplifica errores iniciales: una celda mal clasificada como urbana actúa como “semilla” de crecimiento y genera falsas alarmas en cascada mediante el efecto de vecindad. La Tabla 5.13 ordena estas tres fuentes por su contribución estimada, con la advertencia de que se trata de una estimación cualitativa y no de una descomposición medida.

Tabla 5.13: Estimación cualitativa de la contribución de fuentes de error (no cuantificada empíricamente)

Fuente de error	Contribución relativa estimada
Error de clasificación directa (K-Means+SVM)	Alta
Propagación de errores en el historial WoE	Moderada
Amplificación AC (efecto de vecindad cascada)	Alta

Nota metodológica: la tabla anterior refleja una estimación *cualitativa* basada en el análisis del comportamiento del modelo y no un desglose cuantificado de forma empírica. Una cuantificación precisa de la contribución de cada fuente de error requeriría mapas de referencia externos (verdad terreno) para cada año, los cuales no están disponibles para la serie completa

1984–2020.

5.6.2. Análisis morfológico de la predicción

El análisis morfológico cualitativo de los mapas generados muestra que el modelo reproduce patrones estructurales del crecimiento urbano coherentes con el observado: la expansión se concentra en los bordes de áreas ya urbanizadas (mecanismo de difusión), con presencia de fragmentación periférica. El mapa predicho para 2020 tiene un número de celdas urbanizadas mayor al observado (sobre-predicción sistemática), pero la distribución espacial del crecimiento sigue el mismo patrón de contigüidad que el real.

El cálculo formal de métricas de paisaje (FRAGSTATS, Moran's I) requeriría la ejecución de análisis específicos sobre los mapas predicho y observado. Los archivos de mapa predicho están disponibles, por ejemplo, en `data/processed/validation_quinquenal_2015_2020_v3_weighted/predicted_2020.npy`, para verificación independiente.

Conviene señalar el límite de esta lectura: la evaluación de este trabajo es píxel a píxel sobre las transiciones, que es lo que mide el FoM y donde el promedio alcanzado es 0,317. La similitud morfológica se aprecia de forma visual, sin una métrica de configuración espacial que la cuantifique, de modo que no compensa ni sustituye la concordancia píxel a píxel. Incorporar métricas de patrón de paisaje para medirla es una de las extensiones que se plantean en las conclusiones.

5.7. Fortalezas y debilidades del modelo

5.7.1. Fortalezas identificadas

El modelo exhibe consistencia espacial: las predicciones concentran el crecimiento en los bordes de las áreas urbanas existentes, de forma coherente con el patrón de difusión observado. Su FoM promedio de 0,317 se interpreta frente al espectro multi-sitio documentado por Pontius Jr et al. [1] (Capítulo 3). El Recall se mantiene superior a 0,91 en todos los períodos, de modo que el modelo recoge la mayor parte de las transiciones observadas bajo la definición operativa de la clase urbana. A esa cobertura se suma su fidelidad morfológica: las comparaciones visuales entre mapas predichos y observados (Figuras 5.4 a 5.8) muestran que el crecimiento predicho se concentra consistentemente en los bordes del área urbana existente y reproduce el patrón de difusión contigua observado en los cinco períodos. El enfoque es, además, parsimonioso: siete variables espaciales derivadas del mapa binario –distancia a área urbana, densidades de vecindad 3×3/5×5/7×7, fragmentación local, gradiente urbano y tamaño de *cluster*– bastan para

alcanzar estas métricas sin recurrir a datos socioeconómicos externos.

5.7.2. Debilidades identificadas

Las debilidades parten de una sobre-predicción sistemática: en las cuatro ventanas con crecimiento neto positivo el crecimiento predicho supera al observado por un factor de entre 2,3 y 7,2 veces, y en 2011–2016 el crecimiento observado es negativo, de modo que el cociente no está definido. Asociada a ella, la *Precision* se mantiene moderada, entre 0,59 y 0,70, lo que indica que muchas predicciones de transición son falsas alarmas. El crecimiento disperso queda sin modelar: el mecanismo de vecindad no captura el desarrollo tipo *leapfrog*. A ello se añade el peso de las variables externas, pues la omisión de factores socioeconómicos o de infraestructura (p. ej. distancia a empleo, precio del suelo) limita la precisión más allá de las siete variables derivadas del mapa binario.

5.8. Validación de hipótesis

A continuación se contrastan la hipótesis general y las cuatro particulares enunciadas en el Capítulo 1 con la evidencia de las cinco ventanas. El cuadro resumen se presenta en el Capítulo 6.

H1 (apoyada por la evidencia, con una salvedad). La regla de transición WoE ponderada por Information Value produce un modelo auditable: la distancia al frente urbano y la densidad de vecindad concentran el mayor IV, por encima de fragmentación y gradiente. La Tabla 5.2 lo sostiene: distancia 0,282 y las tres densidades suman 0,782 del peso normalizado; fragmentación y gradiente quedan por debajo. La salvedad es la de la Sección 5.2.3 y afecta al orden entre las dos primeras variables, no al enunciado: la primacía de la distancia sobre la densidad depende de un *bin* sin transiciones observadas que, por construcción, ninguna celda candidata puede alcanzar. Lo que la hipótesis afirma queda en pie en cualquiera de las dos lecturas: la difusión por contigüidad gobierna la simulación y cada peso admite lectura geográfica, que es el sentido en que el modelo es auditable. Que la salvedad pueda enunciarse y cuantificarse con esta precisión es, de hecho, una consecuencia de esa auditabilidad.

H2 (apoyada de forma parcial). El desempeño se sostiene en las cinco ventanas desplazadas, pero el FoM varía entre 0,222 y 0,378 (Tabla 5.5). El valor mínimo (2011–2016) coincide con la única ventana cuyo crecimiento neto observado es negativo. El comportamiento morfológico (expansión perimetral) se reproduce en todas las ventanas; las métricas píxel a píxel sí dependen de la señal de cambio. No hay degradación sistemática atribuible a un fallo de calibración, pero tampoco una estabilidad numérica estricta.

H3 (apoyada por la evidencia). El flujo completo se ejecutó en Python (NumPy, SciPy, scikit-learn) sobre capturas de Google Earth en escritorio, sin GPU ni software propietario, en un cómputo del orden de tres horas en CPU estándar.

H4 (apoyada por la evidencia). El FoM promedio de 0,317, el Kappa de 0,445 y el IoU de 0,633 se ubican en la banda intermedia del espectro multi-sitio de Pontius Jr et al. [1], en los términos precisados en la Sección 5.5. El contraste con modelos de caja negra es cualitativo: sitios, clases y horizontes distintos.

5.9. Síntesis del desempeño del modelo

Vistas en conjunto, las cinco ventanas dibujan un comportamiento consistente más que un resultado aislado. El FoM se mantiene en una banda intermedia (promedio 0,317, entre 0,222 y 0,378) y el Recall alto en todos los períodos indica que el modelo rara vez deja fuera la urbanización que sí ocurre. El costo de esa cobertura es una sobre-predicción sistemática: el crecimiento simulado supera al observado y la *Precision* se queda en un rango moderado. En otras palabras, el modelo opera en un régimen de alta cobertura predictiva y baja especificidad relativa: acierta dónde crece la ciudad, pero tiende a hacerla crecer de más. Este comportamiento es propagación conservadora en términos de omisión y expansiva en términos de falsos positivos, consecuencia de un campo de probabilidad WoE que favorece la expansión continua del estado urbano ante vecindades parcialmente urbanizadas.

Ese patrón es coherente con la lectura de los pesos WoE. La distancia al área urbana y la densidad de vecindad concentran 78,2 % del *Information Value*, de modo que la señal que gobierna la simulación es la difusión por contigüidad. Ahí está, a la vez, la fortaleza y el límite del enfoque: como es un modelo de caja blanca, se puede leer qué lo mueve; pero al apoyarse solo en variables derivadas del propio mapa binario, no captura el desarrollo disperso ni los factores socioeconómicos que explican parte del crecimiento real. La validación multi-período, más que un número único, es lo que da solidez a esta lectura, porque muestra que el comportamiento se sostiene bajo distintas dinámicas observadas. Las cinco corridas concentran el crecimiento en los mismos núcleos urbanos consolidados y corredores, de modo que el patrón espacial predicho depende sobre todo del estado inicial de cada ventana. Conviene precisar el alcance de esa observación: es una regularidad de las cinco simulaciones, no un resultado de convergencia, porque este trabajo no analizó el comportamiento asintótico del autómata ni su sensibilidad al estado inicial.

Estos resultados son el insumo del capítulo siguiente, donde se consolidan las hipótesis en un cuadro único, se precisan las contribuciones del trabajo y se discuten las líneas para

corregir las debilidades aquí identificadas, en particular la sobre-predicción y el crecimiento tipo *leapfrog*.

Capítulo 6

Conclusiones

Este capítulo sintetiza los hallazgos de la investigación, delimita sus alcances, identifica las limitaciones del modelo y propone direcciones de trabajo futuro, entre ellas el uso del modelo como apoyo a la planeación. Se presentan las respuestas a las preguntas de investigación, la validación de hipótesis y las aportaciones del trabajo al campo del modelado urbano, a la luz de los resultados de la validación quinquenal múltiple (cinco períodos, 2011–2020).

6.1. Principales hallazgos

Esta sección sintetiza los resultados centrales de la investigación, presenta las respuestas a las preguntas formuladas en el Capítulo 1 y evalúa el estado de cada hipótesis a la luz de la validación quinquenal múltiple sobre cinco períodos desplazados.

6.1.1. Síntesis de la investigación

Esta investigación abordó el problema de modelar el crecimiento urbano de Querétaro (1984–2020) mediante la integración de tres metodologías complementarias: **Weight of Evidence (WoE)** para cuantificar empíricamente la evidencia espacial, **Autómatas Celulares (AC)** para simular dinámicas espaciales locales y una estrategia de **calibración sistemática** para el ajuste de parámetros. La validación quinquenal múltiple sobre cinco períodos desplazados (2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020) sugiere que la metodología WoE-AC, bajo las condiciones de datos y calibración descritas en los capítulos anteriores, presenta varios rasgos consistentes. El *pipeline* LBP+K-Means+SVM clasificó de manera automática las 37 capturas RGB anuales (1984–2020) en mapas binarios urbano/no-urbano, con coherencia interna de 88–94 % respecto de las pseudoetiquetas de K-Means en el conjunto de prueba, no frente a una

verdad terreno. Sobre esa base, el WoE cuantificó empíricamente la evidencia espacial a partir de las transiciones históricas observadas en 26 años de datos (1984–2010). El modelo obtuvo un **FoM promedio de 0,317** sobre cinco períodos de validación desplazados, equivalente a aproximadamente 31,7 % en la escala porcentual usada por Pontius Jr et al. [1]; interpretado frente al espectro empírico multi-sitio de ese estudio (seis aplicaciones con FoM inferior a 0,15 y una sola por encima de 0,50), el resultado se ubica en una **banda intermedia** de dicho marco (Capítulo 3), utilizando únicamente siete variables espaciales derivadas del mapa binario. En conjunto, reprodujo los patrones de expansión urbana con *Accuracy* promedio de 0,722, Kappa promedio de 0,445 y FoM promedio de 0,317, y capturó el mecanismo de difusión por contagio espacial perimetral de forma coherente con los patrones observados.

6.1.2. Respuestas a las preguntas de investigación

P1: ¿Métricas comparables a la literatura?

El FoM promedio de 0,317, el Kappa de 0,445 y el IoU de 0,633 (Tabla 5.5) se sitúan en la banda intermedia del espectro multi-sitio de Pontius Jr et al. [1]: por encima del subconjunto con FoM inferior a 0,15 y por debajo del único caso que supera 0,50. El umbral $\theta = 0,75$ y el peso de vecindad $\alpha = 0,50$ son la configuración usada en las cinco ventanas; ensayos preliminares con umbrales menores produjeron sobre-predicción masiva, con un FoM que no es directamente comparable porque se midió bajo otro protocolo de conteo (Capítulo 5).

P2: ¿Qué variables discriminan?

El *Information Value* muestra que la **distancia al área urbana** y la **densidad de vecindad** (tres radios) concentran 0,782 del peso normalizado (78,2 %), por encima de fragmentación y gradiente. La lectura es coherente con un mecanismo de difusión por contagio espacial.

P3: ¿Se sostiene el desempeño en las cinco ventanas?

El FoM varía entre 0,222 y 0,378 según la dinámica observada. El valor más bajo (2011–2016) coincide con la única ventana con crecimiento neto observado negativo. El comportamiento morfológico (expansión perimetral) se reproduce en las cinco ventanas; las métricas píxel a píxel sí dependen de la señal de cambio. Las ventanas son hold-out respecto de 1984–2010 y se solapan entre sí.

P4: ¿El flujo corre en código abierto y CPU?

El pipeline completo se ejecutó en Python (NumPy, SciPy, scikit-learn) sobre capturas de Google Earth en escritorio, sin GPU ni software propietario, en un cómputo del orden de tres

horas en CPU estándar. No se ensayó una réplica geográfica en otra ciudad; H3 afirma la reproducibilidad de *este* flujo, no su transferibilidad ya medida.

6.1.3. Cumplimiento de los objetivos específicos

Los cinco objetivos específicos planteados en el Capítulo 1 se cumplieron del modo que se describe a continuación. El primero (OE1) condujo a la **serie histórica binaria**: se construyó la serie anual 1984–2020 (37 mapas urbano/no-urbano) a partir de imágenes de archivo de Google Earth, con una cadena de clasificación LBP+K-Means+SVM que no requiere verdad terreno etiquetada, y sin software propietario (Sección 4.4). El segundo (OE2) abordó las **variables espaciales y el WoE**: se calcularon las siete variables derivadas del mapa binario y se adoptó el WoE como función de transición por su descomposición auditable mediante el *Information Value* (Capítulos 4 y 5). El tercero (OE3) corresponde al **diseño e implementación del WoE-AC**: se implementó el autómata celular que simula la transición no urbano → urbano sobre la ZMQ (Capítulo 4). El cuarto (OE4) cubrió la **calibración y el protocolo de validación**: se calibraron umbral y peso de vecindad por búsqueda en cuadrícula y se validó el modelo en cinco ventanas quinquenales desplazadas con FoM, Kappa e IoU (Capítulo 5). El quinto (OE5) atendió la **estabilidad temporal y el posicionamiento**: se analizó la estabilidad del desempeño a lo largo de los cinco períodos y se contrastaron los valores de FoM e IoU con los rangos de la literatura de modelos de caja blanca y de caja negra (Capítulos 5 y 3).

6.1.4. Cumplimiento de los requerimientos del modelo

El Capítulo 1 fijó cuatro requerimientos (Tabla 1.1) y el Capítulo 3 los usó para calificar la literatura. Corresponde aplicarlos al propio modelo, con el mismo criterio y sin concesiones.

R1, simulación histórica con precisión: cumplido de forma parcial. El modelo reproduce el patrón de cambio con FoM promedio de 0,317, Kappa de 0,445 e IoU de 0,633 en cinco ventanas desplazadas del período de entrenamiento. La reserva es de magnitud, no de localización: el desacuerdo de cantidad concentra el 79,4 % del desacuerdo total (Sección 5.5.7), de modo que el modelo acierta mayormente en dónde crece la ciudad y sobre-predice cuánto.

R2, soporte a planeación estratégica: cumplido en su formulación mínima. El modelo produce mapas espacialmente explícitos que admiten lectura comparativa bajo supuestos declarados. No se calibraron escenarios contrafactuales de política ni se cuantificó su efecto, de modo que esos mapas se leen como escenarios y no como planes calibrados, tal como el propio requerimiento acota.

R3, replicabilidad y apertura: cumplido. El flujo completo se ejecuta en Python con

bibliotecas de código abierto sobre CPU estándar, en un cómputo del orden de tres horas, con calibración sistemática documentada y sin software propietario ni hardware especializado.

R4, interpretabilidad de la función de transición: cumplido. Los pesos de la función de transición son valores WoE por bin, legibles como evidencia espacial, y su contribución relativa queda ordenada por el *Information Value* de cada variable (Tabla 5.2). Ninguna decisión del modelo depende de parámetros opacos.

El balance es que tres de los cuatro requerimientos se cumplen y el primero lo hace con una reserva localizada y medida. Esa reserva, la sobre-predicción de la magnitud, es la que orienta las extensiones de la Sección 6.4.

6.1.5. Validación de hipótesis

La hipótesis general y sus cuatro particulares, formuladas en el Capítulo 1, se contrastan a continuación con los resultados del Capítulo 5.

Hipótesis general. Un modelo híbrido WoE-AC, calibrado y validado mediante un protocolo multitemporal sobre datos de libre acceso, permite simular de forma interpretable y reproducible el crecimiento urbano de una ciudad intermedia mexicana con un desempeño comparable al reportado en la literatura. **Estado: apoyada por la evidencia.** El modelo alcanzó un FoM promedio de 0,317 y un Kappa promedio de 0,445 en las cinco ventanas quinquenales desplazadas, valores en la banda intermedia documentada por Pontius Jr et al. [1], con implementación íntegra en Python y datos de acceso libre. La Tabla 6.1 recoge el veredicto de las cuatro hipótesis particulares.

Tabla 6.1: Validación de hipótesis particulares

Hip.	Enunciado (Cap. 1)	Estado	Evidencia
H1	<i>Interpretabilidad.</i> La regla de transición WoE ponderada por IV produce un modelo auditable: la distancia al frente urbano y la densidad de vecindad concentran el mayor IV, por encima de fragmentación y gradiente.	Apoyada	IV concentrado en distancia al área urbana y densidad de vecindad (0,782 del peso normalizado), por encima de fragmentación y gradiente. El orden entre distancia y densidad depende del tratamiento de las celdas no elegibles (Cap. 5).

Hip.	Enunciado (Cap. 1)	Estado	Evidencia
H2	<i>Estabilidad temporal.</i> El desempeño se sostiene en las cinco ventanas quinquenales desplazadas; el valor más bajo se asocia a la única ventana con crecimiento neto observado negativo, no a un fallo de calibración.	Parcial	FoM entre 0,222 y 0,378; el mínimo (2011–2016) coincide con crecimiento neto observado negativo. El patrón morfológico se sostiene; las métricas píxel a píxel varían.
H3	<i>Reproducibilidad.</i> El flujo completo se ejecuta con herramientas de código abierto en CPU estándar, sin GPU ni software propietario.	Apoyada	Implementación íntegra en Python (NumPy, SciPy, scikit-learn) con capturas de Google Earth en escritorio; cómputo del orden de tres horas en CPU (Sección 6.2.1).
H4	<i>Desempeño comparable.</i> Aplicado a la ZMQ, el modelo reproduce el patrón de crecimiento con FoM, Kappa e IoU en la banda intermedia del espectro de Pontius Jr et al. [1].	Apoyada	FoM promedio 0,317, Kappa 0,445 e IoU 0,633. El contraste con caja negra es cualitativo (sitios y horizontes distintos).

6.1.6. Aportaciones del trabajo

El uso del Weight of Evidence y del autómatas celular no constituye, por sí mismo, una novedad metodológica, pues ambos están ampliamente documentados en la literatura. La aportación central de esta investigación reside en el **protocolo de evaluación**: el acoplamiento WoE-AC **calibrado y validado de forma reproducible sobre cinco ventanas temporales desplazadas**, con código y datos de acceso libre, aplicado a una ciudad intermedia mexicana poco estudiada. El WoE se incorpora como un campo probabilístico continuo ponderado por el *Information Value*, pero el valor diferenciador está en poder distinguir un desempeño estable de un ajuste a un único período. De esa aportación principal se derivan varias contribuciones específicas. La primera es el **protocolo de validación quinquenal múltiple**, de carácter *metodológico*: la evaluación sobre cinco períodos desplazados (2011–2020) con métricas píxel a píxel (FoM, Kappa, IoU), la descomposición del error de Pontius entre desacuerdo de cantidad y de asignación y un análisis visual comparativo de patrones morfológicos evalúa la estabilidad temporal del modelo con mayor rigor que la validación en un único período, y es la aportación que sostiene las demás. La segunda, de orden *práctico*, es la **reproducibilidad abierta del pipeline**: un sistema modular en Python que transforma capturas RGB en mapas binarios y en

proyecciones de crecimiento urbano (clasificación híbrida, WoE, AC y evaluación), ejecutable con herramientas de código abierto y datos de acceso libre, documentado y publicado. La tercera, de orden *instrumental* y subordinada al protocolo, es el **campo WoE continuo ponderado por Information Value**: la implementación concreta que hace auditable la regla de transición, donde la idoneidad WoE no es un mapa estático, sino un campo probabilístico ponderado por el *Information Value* normalizado de cada variable, que se recalcula en cada paso sobre el estado actualizado del mapa y se acopla a la vecindad de Moore. La cuarta, de naturaleza *aplicada*, es la **aplicación a una ciudad intermedia mexicana**: la adaptación del enfoque WoE-AC al contexto de la Zona Metropolitana de Querétaro, un caso poco estudiado y sin un *benchmark* comparable previo. La quinta, de carácter *empírico*, es la **serie temporal de Querétaro**: un conjunto de datos procesado de 37 años (1984–2020) de mapas binarios urbano/no-urbano, que puede utilizarse como base para investigaciones futuras en la región. La sexta, igualmente *empírica*, es el **posicionamiento frente a la literatura**: el contraste del modelo WoE-AC con estudios internacionales mediante métricas estandarizadas (FoM, IoU), que contextualiza los resultados en el espectro empírico multi-sitio de Pontius Jr et al. [1].

6.2. Alcances

El modelo se aplicó a la Zona Metropolitana de Querétaro sobre una serie anual de 37 años (1984–2020), período que concentra la mayor expansión urbana documentada para esta ciudad y para el cual fue posible construir una serie histórica completa a partir de imágenes de archivo de Google Earth. En su dimensión temporal, el alcance abarca esa serie procesada hasta mapas binarios urbano/no urbano compatibles con el autómata celular. En su dimensión espacial, cada año se representa como una rejilla de $1\,792 \times 3\,024$ píxeles derivada del preprocesamiento de las capturas RGB. El modelo no reemplaza los instrumentos de planeación urbana ni produce predicciones normativas: es una herramienta de análisis retrospectivo y prospectivo con la que se exploran escenarios de crecimiento bajo supuestos explícitos y reproducibles. La metodología fue diseñada para ser replicable en otras ciudades intermedias mexicanas con datos equivalentes, previa recalibración de parámetros.

6.2.1. Accesibilidad computacional

El pipeline completo (clasificación + WoE + simulación + validación) se ejecuta en aproximadamente 3 horas en CPU estándar, sin requerir GPU. Los enfoques de aprendizaje profundo en teledetección suelen exigir conjuntos anotados grandes y, en la práctica, hardware gráfico [21]; esta tesis no midió horas de GPU de terceros. La Tabla 6.2 resume las características operativas

del enfoque adoptado.

Tabla 6.2: Características operativas del enfoque WoE-AC frente a modelos de aprendizaje profundo

Característica	WoE-AC (este trabajo)	Aprendizaje profundo
Datos de entrenamiento requeridos	Series multitemporales locales (en este trabajo, 26 transiciones anuales agregadas por <i>pooling</i>).	Conjuntos de datos etiquetados a gran escala, habitualmente con decenas de imágenes anotadas.
Hardware mínimo	CPU estándar.	GPU recomendada.
Interpretabilidad de resultados	Alta (pesos WoE explicables).	Baja (modelo de caja negra).
Tiempo de ejecución	Del orden de tres horas en CPU.	Depende del conjunto y de la arquitectura; suele requerir GPU.
Transferibilidad	Requiere recalibración WoE.	Requiere reentrenamiento.

6.3. Limitaciones del modelo

El rigor académico exige reconocer los límites del enfoque adoptado. Esta sección describe las limitaciones conceptuales, empíricas y de transferibilidad del modelo, e identifica las extensiones metodológicas que permitirían superarlas en investigaciones futuras.

6.3.1. Limitaciones de alcance del estudio

El modelo opera sobre imágenes RGB sin bandas infrarrojas, lo que restringe la clasificación binaria a información espectral visible. Esta decisión fue deliberada: reducir la barrera de entrada a datos de acceso libre y procesamiento reproducible, a costa de la precisión espectral que ofrece la teledetección multispectral. La representación binaria urbano/no urbano simplifica la complejidad interna de la ciudad; como consecuencia, el modelo captura la dinámica de expansión de la mancha urbana, pero no su estructura interna.

El enfoque es puramente espacial: factores como políticas públicas, incentivos económicos o decisiones de inversión influyeron en el crecimiento real de Querétaro y no están representados en las variables de entrada. Esta limitación es compartida por la mayoría de los modelos CA-WoE de la literatura y acota la interpretación de los resultados al patrón morfológico observado, no a sus causas socioeconómicas.

La elección de caja blanca implica una concesión de desempeño frente a modelos de aprendizaje profundo, cuya magnitud este trabajo no midió. Los resultados del Capítulo 5 ubican

al modelo WoE-AC en la banda intermedia del espectro multi-sitio de Pontius Jr et al. [1]; el contraste con modelos de caja negra es cualitativo, porque se refiere a sitios, clases y horizontes distintos, de modo que no permite cuantificar el costo de la interpretabilidad.

6.3.2. Limitaciones conceptuales

En el plano conceptual, la primera limitación atañe a la **definición operativa de “urbano”**. El clasificador K-Means+SVM, al operar sobre imágenes RGB sin banda infrarroja, aprende a separar zonas con cubierta vegetal verde de zonas sin ella. La clase “urbano” incluye, por tanto, tejido urbano real pero también suelo desnudo agrícola en temporada seca y superficies áridas. Una clasificación más precisa requeriría imágenes con banda NIR para calcular NDVI real, o muestras de campo geolocalizadas como ground truth. Esta limitación no invalida la validación interna del modelo (que evalúa la consistencia predictiva dentro de la misma clasificación), pero sí acota la interpretación de los resultados en términos de área urbana absoluta. Una segunda limitación es el **radio de vecindad**: Moore (3×3) captura interacciones locales pero no influencias de largo alcance (empleo, transporte). Los pesos WoE, estimados en 1984–2010, quedan fijos; las siete variables espaciales sí se recalculan en cada paso sobre el estado actualizado del mapa. Por último, la **asunción de estacionariedad**: las relaciones WoE calibradas con 1984–2010 se asumen válidas en las cinco ventanas posteriores, supuesto que puede no sostenerse ante transformaciones económicas o políticas disruptivas.

6.3.3. Limitaciones empíricas

En el plano empírico, la primera limitación se relaciona con la **calidad de los datos**: la clasificación sin verdad terreno (K-Means + SVM sobre pseudoetiquetas) tiene una *accuracy* interna del 88 al 94 %, lo que equivale a un error nominal del 6 al 12 % por imagen (del orden de 325 000 a 650 000 píxeles sobre $5,4 \times 10^6$). Estos errores se propagan al cálculo WoE y pueden amplificarse en la simulación del AC mediante el efecto de vecindad. La segunda es la **resolución espectral**: las imágenes contienen únicamente bandas RGB, sin información infrarroja, y el índice verde-rojo normalizado (NGRDI), $(G - R)/(G + R)$, es un proxy cromático menos discriminativo que el NDVI real $(NIR - R)/(NIR + R)$. La tercera concierne a las **variables internas**: el modelo usa 7 variables espaciales derivadas del propio mapa binario (densidades, distancias, fragmentación, gradiente) y no incorpora variables externas potencialmente relevantes como distancia a vialidades, pendiente topográfica, zonificación oficial o variables socioeconómicas. La cuarta es el **crecimiento disperso no modelado**: el mecanismo de difusión por vecindad no captura el desarrollo tipo leapfrog (saltos discontinuos de urbanización), que representa una fracción significativa del crecimiento real observado.

6.3.4. Limitaciones de transferibilidad

En cuanto a la transferibilidad, una primera limitación es la **especificidad contextual**: los pesos WoE son específicos al patrón histórico de Querétaro y requieren recalibración para su aplicación en otras ciudades. La segunda es la **dependencia de la resolución**: los resultados están ligados a la grilla de los mapas binarios derivada de las capturas homogeneizadas ($1\,792 \times 3\,024$ píxeles), de modo que modificar la extensión, el tamaño de celda o la fuente de imágenes implica reentrenar el WoE y recalibrar los parámetros del AC. La tercera es el **horizonte temporal**: la aplicabilidad del modelo para horizontes mayores a 15 años es incierta sin recalibración periódica, dado que las dinámicas urbanas pueden cambiar estructuralmente.

6.4. Trabajo futuro

Con base en las limitaciones identificadas, se proponen las siguientes extensiones prioritarias:

6.4.1. Corto plazo (1-2 años)

A corto plazo destacan tres líneas. La primera es la incorporación de **variables adicionales**: distancia a vialidades principales, distancia a centros de empleo y pendiente topográfica mediante análisis WoE multi-variable. La segunda es la **optimización metaheurística**, esto es, explorar metaheurísticas alternativas al grid exhaustivo (p. ej. optimización por enjambre de partículas o procedimientos bayesianos de búsqueda) para la calibración de parámetros, comparando su desempeño con el procedimiento empleado en esta investigación. La tercera es la **validación en más ciudades**: aplicar la metodología a Aguascalientes, León y San Luis Potosí para evaluar la transferibilidad geográfica.

6.4.2. Mediano plazo (3-5 años)

A mediano plazo se perfilan cuatro extensiones. El **WoE temporal** consistiría en desarrollar pesos que evolucionan dinámicamente para capturar cambios en las dinámicas de crecimiento a lo largo del tiempo. La **integración multi-escala** acoplaría el modelo AC con modelos económicos regionales que proporcionen demanda agregada de urbanización. Los **datos de movilidad** permitirían incorporar patrones de origen-destino de viajes (disponibles vía telefonía móvil) como variable explicativa. La **calibración multiobjetivo**, por su parte, extendería el grid search para optimizar simultáneamente FoM, similitud morfológica y compacidad urbana como criterios de sostenibilidad.

6.4.3. Largo plazo (5-10 años)

A largo plazo, la **integración con cambio climático** adaptaría el modelo para incorporar escenarios de cambio climático (temperatura, precipitación) como restricciones o drivers de urbanización. El **transfer learning** buscaría desarrollar pre-entrenamiento en múltiples ciudades para reducir los datos requeridos en nuevas aplicaciones. Finalmente, las **métricas complementarias de validación** pasarían por adoptar de forma sistemática métricas espaciales adicionales (FRAGSTATS, índice de Moran, *Fuzzy Accuracy*) para complementar las métricas píxel a píxel ya empleadas, en línea con buenas prácticas reconocidas en la literatura LUCC.

6.4.4. Refinamientos del estimador WoE

Dos ajustes del procedimiento de estimación son de implementación inmediata. Ninguno corrige un error de los resultados reportados, porque los pesos afectados no intervienen en la simulación; ambos depuran la interpretación de los *Information Value*. El primero es restringir el muestreo a las celdas elegibles, es decir, a las no urbanas en el año inicial de cada par: con ello desaparecen los *bins* sin transiciones observadas, los IV vuelven a la escala convencional de interpretación y la jerarquía entre variables queda libre del efecto trivial que hoy la condiciona (Sección 5.2.3). El segundo es emparejar cada configuración espacial anual con su transición correspondiente, en lugar de promediar las variables sobre el período de entrenamiento. Ese cambio mostraría además si los pesos son estables entre décadas o si el régimen espacial de la zona cambió a lo largo de los 26 períodos.

6.4.5. Uso en planeación urbana

Cualquier uso instrumental exige antes recalibración y validación local. Cumplida esa condición, las líneas de aplicación son acotadas: anticipar dónde extender redes de agua, drenaje y electricidad; reservar suelo para espacio público y amortiguamiento ambiental antes de que la presión inmobiliaria lo encarezca; y detectar áreas ecológicamente sensibles situadas en la trayectoria de expansión proyectada. En los tres casos el producto es una lectura de tendencia, no un plan.

La estructura del modelo también admite explorar escenarios de política ajustando parámetros o aplicando máscaras de probabilidad, por ejemplo densificación intraurbana, contención del borde o concentración a lo largo de corredores de transporte. Conviene ser explícito en el alcance: este trabajo no calibró corridas contrafactuales por política ni cuantificó su efecto sobre métricas de dispersión para Querétaro. Ese ejercicio queda como extensión, y su primer requisito es definir cómo se traduce cada instrumento de política en un parámetro del autómata.

6.5. Reflexión de cierre

El aporte concreto de este trabajo es un protocolo de validación quinquenal múltiple, reproducible sobre datos de acceso libre, ejercitado en un modelo WoE-AC de la Zona Metropolitana de Querétaro construido sobre 37 años de imágenes de archivo (1984–2020). Ese protocolo, más que un valor de desempeño aislado, es lo que distingue la propuesta: separa un comportamiento espacial estable de un ajuste a un único período, en un contexto, las ciudades intermedias mexicanas, donde rara vez se documenta esa distinción.

Un modelo parsimonioso e interpretable, validado empíricamente en varios períodos desplazados, puede reproducir de forma razonable la dinámica morfológica del crecimiento urbano y servir como herramienta de exploración. Con siete variables derivadas del propio mapa binario, el FoM promedio de 0,317 sobre cinco ventanas quinquenales desplazadas se ubica en una banda intermedia del espectro multi-sitio documentado en la literatura [1]. El mecanismo de difusión por contagio espacial se reproduce con razonable fidelidad sin requerir variables socioeconómicas ni hardware especializado.

La metodología no es un fin en sí misma, sino una base reproducible: código abierto, datos libres y validación multitemporal. Sobre esa base, trabajos futuros pueden mejorar la clasificación, incorporar variables socioeconómicas y extender la evaluación a otras ciudades intermedias mexicanas. Su utilidad para la planificación es indirecta: ofrece una primera lectura de hacia dónde tiende a expandirse la ciudad, no una predicción operativa, que exigiría recalibración local y validación adicional antes de cualquier uso instrumental.

Apéndice A

Arquitectura e implementación del software

Este apéndice reúne los detalles de implementación del *framework* WoE-AC: el diagrama de clases y las rutas de los módulos en el repositorio. Complementan la descripción metodológica del Capítulo 4 sin recargar su narrativa. El repositorio organiza el trabajo en una arquitectura modular que integra la rasterización/clasificación de las capturas, el cálculo de Pesos de Evidencia y la simulación con autómatas celulares; la Figura A.1 muestra el diagrama de clases UML (generado con PlantUML; véase `diagramas/architecture.puml`).




Figura A.1: Arquitectura del framework WoE-AC para modelado de crecimiento urbano. Diagrama UML mostrando las clases del sistema organizadas en paquetes: Configuración (configuración), Data/IO (manejo de datos históricos), Feature & Spatial (extracción de características), Weight of Evidence (cálculo de pesos), Cellular Automaton (simulación AC) y Orchestrator (pipeline y calibración de parámetros). El diagrama se genera desde el código fuente usando PlantUML (ver diagramas/architecture.puml).

En la rama de **imágenes**, el flujo opera sobre matrices RGB ya homogeneizadas. El módulo FeatureExtractor (paquete tesis_ac/pipeline/feature_extraction) construye las 23 variables resumidas en la Tabla A.1. La clase FeaturePreprocessor aplica StandardScaler y PCA (ocho componentes por defecto). El componente SatelliteImageProcessor (nombre

heredado en el código; procesa matrices RGB de las capturas, véase `tesis_ac/pipeline/clustering.py`) agrupa `ImageClusterer` e `ImageClassifier`: K-means para $k \in \{2, 3, 4\}$ y SVM lineal entrenado con pseudoetiquetas. La varianza acumulada explicada por PCA se consulta con `get_variance_explained` del preprocesador. La orquestación de alto nivel está en `SatelliteImagePipeline` (`tesis_ac/pipeline/main\_pipeline.py`).

En la cadena **WoE-AC** usada en la validación quinquenal de la tesis intervienen `WoE Calculator`, `WoECellularAutomaton` y la simulación implementada en los módulos `tesis_ac/woe/` y `tesis_ac/ca/`. La configuración efectiva, es decir, umbral, peso de vecindad y ponderación por IV, se encuentra registrada en `data/processed/quinquenal\_best\_config.json`. Los experimentos son reproducibles desde la raíz del repositorio con los scripts `validate\_quinquenal\_*.py`, que leen los mapas en `data/processed/standardized\_maps/` y el modelo WoE entrenado `data/processed/woe\_pooled\_1984\_2010.pkl`; el entrenamiento agregado del WoE se obtiene con `train\_woe\_pooled.py`. El repositorio conserva, además, un pipeline experimental más amplio en `tesis_ac/run\_classify\_and\_grid.py`, que no forma parte de la narrativa defendida en esta tesis (la cual se centra en la búsqueda en cuadrícula y el ajuste manual del umbral descritos en el Capítulo 4).

A.1. Procedimiento de adquisición manual de imágenes

El conjunto de imágenes descrito en la Sección 4.3 se construyó con el procedimiento manual reproducible que resume el Algoritmo 1, sobre Google Earth en escritorio y su herramienta de imagen histórica.

Como las capturas no llevan georreferencia, su extensión, tamaño de píxel y orientación se recuperaron a posteriori registrando cada imagen contra el mosaico Sentinel-2 *cloudless*. El script `tools/registrar_s2.py` realiza el registro y `tools/verificar_encuadre.py` rehace la escena con los parámetros estimados para comprobarlos visualmente; los resultados por año se guardan en `data/processed/georreferencia\_capturas.json`.

Algoritmo 1 Procedimiento de adquisición manual con Google Earth

- 1: Centrar el visor en la Zona Metropolitana de Querétaro y ajustar zoom, orientación y ángulo que se mantendrán fijos para toda la serie
 - 2: Para cada año y de 1984 a 2020:
 - 3: Abrir la herramienta de *imagen histórica* y seleccionar el año y
 - 4: Desplazarse dentro del año hasta una fecha con cobertura nubosa baja (criterio visual)
 - 5: Verificar que el encuadre coincide con el resto de la serie (sin desplazamientos accidentales)
 - 6: Exportar o capturar la imagen y guardarla con nomenclatura estandarizada (p. ej. YYYY.png)
 - 7: Revisar visualmente la continuidad de la serie (saltos bruscos, años atípicos) y repetir la captura solo cuando una escena resulte claramente inutilizable
-

A.2. Pseudocódigo del pipeline de clasificación

Los cuatro algoritmos que traducen una captura RGB en un mapa binario urbano/no urbano se recogen aquí, en el orden en que se ejecutan. Su fundamento conceptual está en el Capítulo 2 y su configuración efectiva en el Capítulo 4; lo que sigue es el detalle procedimental.

Algoritmo 2 StandardScaler: estandarización por z-score

Entrada: Matriz de features $X \in \mathbb{R}^{N \times F}$ (N píxeles, F features)

Salida: Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$

- 1: **Fase de ajuste** (sobre los datos de entrenamiento)
 - 2: **para** $j = 1$ **hasta** F **hacer**
 - 3: $\mu_j \leftarrow \frac{1}{N} \sum_{i=1}^N X_{ij}$
 - 4: $\sigma_j \leftarrow \sqrt{\frac{1}{N} \sum_{i=1}^N (X_{ij} - \mu_j)^2}$
 - 5: **fin para**
 - 6: **Fase de transformación**
 - 7: **para** $i = 1$ **hasta** N **hacer**
 - 8: **para** $j = 1$ **hasta** F **hacer**
 - 9: $\tilde{X}_{ij} \leftarrow \frac{X_{ij} - \mu_j}{\sigma_j + \varepsilon}$ ▷ ε evita división por cero
 - 10: **fin para**
 - 11: **fin para**
 - 12: **devolver** $\tilde{X}$
-

Algoritmo 3 PCA: reducción de dimensionalidad

Entrada: Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$, número de componentes $k < F$

Salida: Representación reducida $Z \in \mathbb{R}^{N \times k}$

- 1: Calcular la matriz de covarianza: $\Sigma \leftarrow \frac{1}{N-1} \tilde{X}^\top \tilde{X}$
 - 2: Obtener descomposición espectral: $\Sigma \mathbf{w}_j = \lambda_j \mathbf{w}_j, \quad j = 1, \dots, F$
 - 3: Ordenar autovalores de forma descendente: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_F$
 - 4: Seleccionar los k autovectores de mayor varianza: $\mathbf{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \dots \ \mathbf{w}_k] \in \mathbb{R}^{F \times k}$
 - 5: Proyectar los datos: $Z \leftarrow \tilde{X} \mathbf{W}$
 - 6: **devolver** Z
-

Algoritmo 4 K-Means: agrupamiento no supervisado

Entrada: Matriz reducida $Z \in \mathbb{R}^{N \times k}$, número de clústeres k , número de inicializaciones n_{init}

Salida: Vector de etiquetas $\ell \in \{1, \dots, k\}^N$

- 1: **para** cada inicialización $r = 1, \dots, n_{\text{init}}$ **hacer**
 - 2: Inicializar centroides $\{\mu_1, \dots, \mu_k\} \subset Z$ (selección aleatoria)
 - 3: **repetir**
 - 4: **Asignación:** $\ell_i \leftarrow \arg \min_{c \in \{1, \dots, k\}} \|z_i - \mu_c\|_2^2 \quad \forall i$
 - 5: **Actualización:** $\mu_c \leftarrow \frac{1}{|C_c|} \sum_{i \in C_c} z_i \quad \forall c$, donde $C_c = \{i : \ell_i = c\}$
 - 6: **hasta que** los centroides no cambien
 - 7: Registrar inercia $\mathcal{J}_r = \sum_{i=1}^N \|z_i - \mu_{\ell_i}\|_2^2$
 - 8: **fin para**
 - 9: Seleccionar la solución con menor $\mathcal{J}_r$
 - 10: **devolver** ℓ
-

Algoritmo 5 SVM lineal: clasificación sobre pseudo-etiquetas K-Means

Entrada: Matriz reducida $Z \in \mathbb{R}^{N \times k}$, pseudo-etiquetas $\ell \in \{0, 1\}^N$, tamaño de muestra $n_s \leq N$

Salida: Mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$

- 1: Seleccionar submuestra aleatoria $\mathcal{S} \subset \{1, \dots, N\}$, $|\mathcal{S}| = n_s$
- 2: Entrenar SVM lineal minimizando:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i \in \mathcal{S}} \max(0, 1 - \ell_i^* (\mathbf{w}^\top z_i + b))$$

donde $\ell_i^* \in \{-1, +1\}$ es la pseudo-etiqueta recodificada

- 3: **Predicción sobre todos los píxeles:** $\hat{y}_i \leftarrow \text{sign}(\mathbf{w}^\top z_i + b) \quad \forall i \in \{1, \dots, N\}$
 - 4: Recodificar a binario: $\hat{y}_i \leftarrow 1[\hat{y}_i > 0]$
 - 5: Reorganizar en mapa $H \times W$
 - 6: **devolver** $\hat{y}$
-

A.3. Tablas complementarias del conjunto de datos

El conjunto de imágenes descrito en la Sección 4.3 se complementa con tres cuadros de referencia: el detalle de las 23 características extraídas por píxel (Tabla A.1), la estimación cualitativa de las principales fuentes de error y su mitigación (Tabla A.2) y el resumen agregado del preprocesamiento aplicado a toda la serie (Tabla A.3).

Tabla A.1: Características extraídas por píxel a partir de cada captura RGB.

Categoría	Cantidad	Características específicas
Básicas	8	Canales R, G, B; intensidad; brillo; media local en ventana 5×5 de R, G y B (los nombres <code>red_std</code> , <code>green_std</code> y <code>blue_std</code> del código son heredados y no describen la operación).
Texturales	6	Sobel horizontal y vertical; magnitud del gradiente; LBP uniforme ($R = 3$, $P = 24$) sobre escala de grises; entropía local; media local en escala de grises (nombrada <code>contrast</code> en el código).
Espectrales / color	9	Índice verde-rojo normalizado $(G - R) / (G + R)$; exceso de verde y exceso de rojo; componentes L, a, b (LAB); H, S, V (HSV).
Total	23	

Tabla A.2: Estimación cualitativa de las principales fuentes de error del conjunto de imágenes, su efecto sobre los mapas binarios y su mitigación. Los niveles son apreciaciones del autor, no medidas formales de incertidumbre.

Tipo de error	Nivel	Efecto sobre los mapas	Mitigación aplicada
Georreferenciación / encuadre	Bajo	Pequeños desplazamientos entre capturas por reposicionamiento manual del visor; desalineación píxel a píxel entre años.	Mismo zoom, orientación y región; ajuste a la cuadrícula de referencia en el preprocesamiento. Verificado a posteriori por registro contra Sentinel-2: el tamaño de píxel varía un 0,4 % y el centro se mantiene dentro de 230 m (Sección 4.3).
Temporal (fecha intra-anual)	Medio	La fecha exacta varía dentro de cada año; cambios fenológicos y estacionales alteran la respuesta de la vegetación.	Captura preferente en temporada seca (nov.–abr.) y revisión de continuidad de la serie.
Mosaico / composición del proveedor	Medio–alto	Google Earth actualiza mosaicos y mezcla fuentes y fechas; discontinuidades de textura y color no atribuibles a cambio real.	Revisión cruzada año con año y sustitución puntual de escenas claramente anómalas.
Cromático / radiométrico	Medio	Sin corrección atmosférica; diferencias de balance de color e iluminación que sesgan los índices de color (NGRDI).	Normalización y estandarización por imagen; descriptores de textura (LBP) robustos a la iluminación.
Compresión / exportación	Bajo–medio	Las capturas se exportan como imágenes comprimidas (JPEG/PNG); aparecen artefactos de bloque y suavizado de bordes que pueden alterar píxeles de frontera urbano/no-urbano.	Exportación a la máxima resolución disponible del visor y descriptores de textura locales menos sensibles al artefacto puntual.
Clasificación (LBP+K-Means+SVM)	Medio	Pseudoetiquetas no supervisadas, sin verdad terreno; ruido binario y sobre o subestimación local de lo urbano.	Validación interna <i>train/test</i> y evaluación temporal indirecta del modelo AC (Capítulo 5).

Tabla A.3: Resumen agregado del preprocesamiento aplicado a la serie 1984–2020.

Métrica	Valor
Varianza retenida por PCA (promedio de la serie)	96,1 % (rango 95,3–96,8 %).
Componentes finales por píxel	8 (a partir de los 23 descriptores originales).
Características válidas por imagen	23 de 23 (ningún descriptor se descarta).
Píxeles procesados por imagen	5 419 008 ($1\,792 \times 3\,024$).

Bibliografía

- [1] R. G. Pontius Jr et al., «Comparing the input, output, and validation maps for several models of land change», *The Annals of Regional Science*, vol. 42, n.º 1, págs. 11-37, 2008. DOI: [10.1007/s00168-007-0138-2](https://doi.org/10.1007/s00168-007-0138-2).
- [2] K. C. Seto, B. Güneralp y L. R. Hutyrá, «Global forecasts of urban expansion to 2030 and direct impacts on biodiversity and carbon pools», *Proceedings of the National Academy of Sciences*, vol. 109, n.º 40, págs. 16 083-16 088, 2012. DOI: [10.1073/pnas.1211658109](https://doi.org/10.1073/pnas.1211658109).
- [3] UN-Habitat, *World Cities Report 2020: The Value of Sustainable Urbanization*, Informe completo en PDF, 2020. dirección: https://unhabitat.org/sites/default/files/2020/10/wcr_2020_report.pdf.
- [4] A. G. Aguilar, «Urbanization, population growth, and employment in México», *Cities*, vol. 20, n.º 1, págs. 3-19, 2003.
- [5] Secretaría de Desarrollo Agrario, Territorial y Urbano, *Norma Oficial Mexicana NOM-005-SEDATU-2024: Contenidos generales para planes o programas municipales de ordenamiento territorial y/o desarrollo urbano*, Diario Oficial de la Federación, Homologación de contenidos para PMOTDU; inscrita en el Programa Nacional de Infraestructura de la Calidad (DOF, 1 de junio de 2023), 2024. visitado 24 de mayo de 2026. dirección: https://www.dof.gob.mx/nota_detalle.php?codigo=5732738&fecha=09/07/2024.
- [6] Programa de las Naciones Unidas para los Asentamientos Humanos (ONU-Hábitat). «Tendencias del desarrollo urbano en México». Basado en el Programa Nacional de Desarrollo Urbano 2013–2018 (SEDATU) y el Índice de prosperidad urbana en la República Mexicana (ONU-Hábitat México, 2016), visitado 24 de mayo de 2026. dirección: <https://onu-habitat.org/index.php/tendencias-del-desarrollo-urbano-en-mexico>.
- [7] Instituto Nacional de Estadística y Geografía (INEGI). «Censo de Población y Vivienda 2020», visitado 7 de jun. de 2026. dirección: <https://www.inegi.org.mx/programas/ccpv/2020/>.

- [8] Consejo Nacional de Población (CONAPO) and SEDATU and INEGI. «Delimitación de las zonas metropolitanas de México 2015», visitado 7 de jun. de 2026. dirección: <https://www.gob.mx/conapo/documentos/delimitacion-de-las-zonas-metropolitanas-de-mexico-2015>.
- [9] C. M. Almeida, J. M. Gleriani, E. F. Castejon y B. S. Soares-Filho, «Using neural networks and cellular automata for modelling intra-urban land-use dynamics», *International Journal of Geographical Information Science*, vol. 22, n.º 9, págs. 943-963, 2008. DOI: [10.1080/13658810701731168](https://doi.org/10.1080/13658810701731168).
- [10] R. Wang, Q. He, L. Zhang y H. Wang, «Coupling Cellular Automata and a Genetic Algorithm to Generate a Vibrant Urban Form—A Case Study of Wuhan, China», *International Journal of Environmental Research and Public Health*, vol. 18, n.º 21, pág. 11 013, 2021. DOI: [10.3390/ijerph182111013](https://doi.org/10.3390/ijerph182111013).
- [11] K. C. Clarke y L. J. Gaydos, «Loose-coupling a Cellular Automaton Model and GIS: Long-term Urban Growth Prediction for San Francisco and Washington/Baltimore», *International Journal of Geographical Information Science*, vol. 12, n.º 7, págs. 699-714, 1998. DOI: [10.1080/136588198241617](https://doi.org/10.1080/136588198241617).
- [12] I. Santé, A. M. García, D. Miranda y R. Crecente, «Cellular automata models for the simulation of real-world urban processes: A review and analysis», *Landscape and Urban Planning*, vol. 96, n.º 2, págs. 108-122, 2010. DOI: [10.1016/j.landurbplan.2010.03.001](https://doi.org/10.1016/j.landurbplan.2010.03.001).
- [13] M. M. Aburas, Y. M. Ho, M. F. Ramli y Z. H. Ash'aari, «The simulation and prediction of spatio-temporal urban growth trends using cellular automata models: A review», *International Journal of Applied Earth Observation and Geoinformation*, vol. 52, págs. 380-389, 2016. DOI: [10.1016/j.jag.2016.07.007](https://doi.org/10.1016/j.jag.2016.07.007).
- [14] M. Suárez y J. Delgado, «La expansión urbana probable de la Ciudad de México. Un escenario pesimista y dos alternativos para el año 2020», *Estudios Demográficos y Urbanos*, vol. 22, n.º 1, págs. 101-142, 2007. DOI: [10.24201/edu.v22i1.1295](https://doi.org/10.24201/edu.v22i1.1295).
- [15] R. Ramírez Hernández, *Zona Metropolitana de la Ciudad de México: crecimiento y expansión al 2040. Prospectiva territorial usando modelos de simulación urbana*. Universidad Nacional Autónoma de México, Instituto de Investigaciones Económicas, 2021. DOI: [10.22201/iiec.9786073044349e.2021](https://doi.org/10.22201/iiec.9786073044349e.2021).
- [16] P. García-Ramírez, L. C. Alatorre-Cejudo y L. C. Bravo-Peña, «Detección, modelización y proyección del crecimiento urbano de núcleos de población en diferentes cuencas hidrológicas de Chihuahua, México», *Investigación y Ciencia de la Universidad Autónoma de Aguascalientes*, vol. 31, n.º 90, págs. 1-19, 2023. DOI: [10.33064/iycuaa2023904103](https://doi.org/10.33064/iycuaa2023904103).

- [17] M. Herold, N. C. Goldstein y K. C. Clarke, «The Spatiotemporal Form of Urban Growth: Measurement, Analysis and Modeling», *Remote Sensing of Environment*, vol. 86, n.º 3, págs. 286-302, 2003. DOI: [10.1016/S0034-4257\(03\)00075-0](https://doi.org/10.1016/S0034-4257(03)00075-0). dirección: <https://www.sciencedirect.com/science/article/abs/pii/S0034425703000750>.
- [18] P. Gong et al., «Finer resolution observation and monitoring of global land cover: First mapping results with Landsat TM and ETM+ data», *International Journal of Remote Sensing*, vol. 34, n.º 7, págs. 2607-2654, 2013. DOI: [10.1080/01431161.2012.748992](https://doi.org/10.1080/01431161.2012.748992).
- [19] Q. Weng, «Land Use Change Analysis in the Zhujiang Delta of China using Satellite Remote Sensing, GIS and Stochastic Modelling», *Journal of Environmental Management*, vol. 64, n.º 3, págs. 273-284, 2002. DOI: [10.1006/jema.2001.0509](https://doi.org/10.1006/jema.2001.0509).
- [20] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau y R. Moore, «Google Earth Engine: Planetary-scale geospatial analysis for everyone», *Remote Sensing of Environment*, vol. 202, págs. 18-27, 2017. DOI: [10.1016/j.rse.2017.06.031](https://doi.org/10.1016/j.rse.2017.06.031).
- [21] L. Ma, Y. Liu, X. Zhang, Y. Ye, G. Yin y B. A. Johnson, «Deep learning in remote sensing applications: A meta-analysis and review», *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 152, págs. 166-177, 2019. DOI: [10.1016/j.isprsjprs.2019.04.015](https://doi.org/10.1016/j.isprsjprs.2019.04.015).
- [22] R. C. Gonzalez y R. E. Woods, *Digital Image Processing*, 4.^a ed. New York: Pearson, 2018.
- [23] C. J. Tucker, «Red and photographic infrared linear combinations for monitoring vegetation», *Remote Sensing of Environment*, vol. 8, n.º 2, págs. 127-150, 1979. DOI: [10.1016/0034-4257\(79\)90013-0](https://doi.org/10.1016/0034-4257(79)90013-0).
- [24] T. Ojala, M. Pietikäinen y T. Mäenpää, «Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 24, n.º 7, págs. 971-987, 2002. DOI: [10.1109/TPAMI.2002.1017623](https://doi.org/10.1109/TPAMI.2002.1017623).
- [25] I. T. Jolliffe, *Principal Component Analysis*, 2.^a ed. New York: Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835).
- [26] J. B. MacQueen, «Some Methods for Classification and Analysis of Multivariate Observations», en *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, L. M. Le Cam y J. Neyman, eds., vol. 1, Berkeley, CA: University of California Press, 1967, págs. 281-297.
- [27] C. Cortes y V. Vapnik, «Support-vector networks», *Machine Learning*, vol. 20, n.º 3, págs. 273-297, 1995. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [28] S. Wolfram, «Cellular Automata as Models of Complexity», *Nature*, vol. 311, n.º 5985, págs. 419-424, 1984. DOI: [10.1038/311419a0](https://doi.org/10.1038/311419a0).

- [29] R. White y G. Engelen, «Cellular Automata as the Basis of Integrated Dynamic Regional Modelling», *Environment and Planning B: Planning and Design*, vol. 24, págs. 235-246, 1997. DOI: [10.1068/b240235](https://doi.org/10.1068/b240235).
- [30] G. F. Bonham-Carter, *Geographic Information Systems for Geoscientists: Modelling with GIS* (Computer Methods in the Geosciences). Pergamon, 1994, vol. 13, pág. 398.
- [31] J. Cohen, «A Coefficient of Agreement for Nominal Scales», *Educational and Psychological Measurement*, vol. 20, n.º 1, págs. 37-46, 1960. DOI: [10.1177/001316446002000104](https://doi.org/10.1177/001316446002000104).
- [32] J. R. Landis y G. G. Koch, «The Measurement of Observer Agreement for Categorical Data», *Biometrics*, vol. 33, n.º 1, págs. 159-174, 1977. DOI: [10.2307/2529310](https://doi.org/10.2307/2529310).
- [33] R. G. Pontius Jr y M. Millones, «Death to Kappa: birth of quantity disagreement and allocation disagreement for accuracy assessment», *International Journal of Remote Sensing*, vol. 32, n.º 15, págs. 4407-4429, 2011. DOI: [10.1080/01431161.2011.552923](https://doi.org/10.1080/01431161.2011.552923).
- [34] E. A. Silva y K. C. Clarke, «Calibration of the SLEUTH urban growth model for Lisbon and Porto, Portugal», *Computers, Environment and Urban Systems*, vol. 26, n.º 6, págs. 525-552, 2002. DOI: [10.1016/S0198-9715\(01\)00014-X](https://doi.org/10.1016/S0198-9715(01)00014-X).
- [35] P. H. Verburg, W. Soepboer, A. Veldkamp, R. Limpiada, V. Espaldon y S. S. A. Mastura, «Modeling the spatial dynamics of regional land use: the CLUE-S model», *Environmental Management*, vol. 30, n.º 3, págs. 391-405, 2002. DOI: [10.1007/s00267-002-2630-x](https://doi.org/10.1007/s00267-002-2630-x).
- [36] B. S. Soares-Filho, G. C. Cerqueira y C. L. Pennachin, «DINAMICA—a stochastic cellular automata model designed to simulate the landscape dynamics in an Amazonian colonization frontier», *Ecological Modelling*, vol. 154, n.º 3, págs. 217-235, 2002. DOI: [10.1016/S0304-3800\(02\)00059-5](https://doi.org/10.1016/S0304-3800(02)00059-5).
- [37] X. Liu et al., «A future land use simulation model (FLUS) for simulating multiple land use scenarios by coupling human and natural effects», *Landscape and Urban Planning*, vol. 168, págs. 94-116, 2017. DOI: [10.1016/j.landurbplan.2017.09.019](https://doi.org/10.1016/j.landurbplan.2017.09.019).
- [38] J. Hagenauer y M. Helbich, «A geographically weighted artificial neural network», *International Journal of Geographical Information Science*, vol. 36, n.º 2, págs. 215-235, 2022. DOI: [10.1080/13658816.2021.1871618](https://doi.org/10.1080/13658816.2021.1871618).
- [39] K. C. Clarke, «A Decade of Cellular Urban Modeling with SLEUTH: Unresolved Issues and Problems», en *Planning Support Systems for Cities and Regions*, R. K. Brail, ed., Cambridge, MA: Lincoln Institute of Land Policy, 2008, cap. 3, págs. 47-60.
- [40] C. A. Jantz, S. J. Goetz y M. K. Shelley, «Using the SLEUTH Urban Growth Model to Simulate the Impacts of Future Policy Scenarios on Urban Land Use in the Baltimore-

Washington Metropolitan Area», *Environment and Planning B: Planning and Design*, vol. 30, n.º 2, págs. 251-271, 2003. DOI: [10.1068/b2983](https://doi.org/10.1068/b2983).

- [41] X. Tang, F. Liu y X. Hu, «Urban growth simulation and scenario projection for the arid regions using heuristic cellular automata», *Scientific Reports*, vol. 14, n.º 1, pág. 21 106, 2024. DOI: [10.1038/s41598-024-71709-4](https://doi.org/10.1038/s41598-024-71709-4).
- [42] R. d. J. Huacuz Elías y R. d. R. Vázquez Cruz, «El proceso de metropolización en Querétaro 1990–2010», *Contexto. Revista de la Facultad de Arquitectura de la Universidad Autónoma de Nuevo León*, vol. 12, n.º 16, págs. 79-91, 2018. DOI: [10.29105/contexto12.16-6](https://doi.org/10.29105/contexto12.16-6). dirección: <https://www.redalyc.org/articulo.oa?id=353667618006>.
- [43] J. Delgado y A. López, «Tendencias recientes del crecimiento urbano en la Zona Metropolitana de Querétaro», *Estudios Demográficos y Urbanos*, vol. 33, n.º 1, págs. 173-205, 2018, DOI no localizado en el repositorio de Estudios Demográficos y Urbanos (El Colegio de México). dirección: <https://estudiosdemograficosyurbanos.colmex.mx/index.php/edu/issue/view/EDU.v33i1>.
- [44] J. A. Montejano-Escamilla, C. A. Caudillo-Cos, F. G. Ávila-Jiménez, R. Tapia-McClung e I. G. Barrera-Alarcón, «Expansión y crecimiento urbanos en México, 1975–2020», *Región y Sociedad*, vol. 35, n.º e1734, 2023. DOI: [10.22198/rys2023/35/1734](https://doi.org/10.22198/rys2023/35/1734). dirección: https://www.scielo.org.mx/scielo.php?pid=S1870-39252023000100118&script=sci_arttext.