

Capítulo 2

Marco teórico

Este marco teórico sigue el orden del flujo descrito en el Cap. ??: primero los algoritmos de preprocesamiento de imágenes (StandardScaler, PCA, K-Means y SVM), después la definición formal del autómata celular probabilístico y el método de Pesos de Evidencia como función de transición, y al final las métricas espaciales de evaluación. Cada sección incluye únicamente los conceptos que el modelo del Cap. ?? efectivamente utiliza.

2.1. Preprocesamiento de datos

El primer paso del flujo de trabajo fue obtener las capturas RGB de la Zona Metropolitana de Querétaro. Para ello, se utilizó el software Google Earth Engine (GEE) para descargar las capturas RGB de la zona de estudio.

El preprocesamiento de dichos datos consiste en la conversión de las capturas RGB en mapas binarios urbano/no-urbano mediante el pipeline LBP+K-Means+SVM. Se define pues un arreglo tridimensional $M_{t,i,j} \in \{0, 1\}$ donde t es el año de la captura, i es la fila y j es la columna de la celda en la cuadrícula. $M_{t,i,j} = 1$ si la celda (i, j) es urbana en el año t , y $M_{t,i,j} = 0$ si la celda (i, j) es no-urbana en el año t .

Cada una de las imágenes RGB está representada por una matriz de $1,792 \times 3,024$ píxeles, en formato PNG. Cada píxel tiene tres canales de color (RGB), de modo que cada imagen es un tensor de $1,792 \times 3,024 \times 3$. Para obtener una conversión precisa, cada píxel se mapea a un vector de 23 características. Sea f_i la i -ésima característica del píxel; el vector de características es $f = (f_1, f_2, \dots, f_{23})_{(i,j)}$. Las definiciones rigurosas de cada característica se muestran en las Tablas 2.1, 2.2 y 2.3.

Cuadro 2.1: Features básicas de canal RGB extraídas por píxel.

#	Nombre	Definición
1	red	$f_1(i, j) = R(i, j)$
2	green	$f_2(i, j) = G(i, j)$
3	blue	$f_3(i, j) = B(i, j)$
4	intensity	$f_4(i, j) = \frac{R+G+B}{3}$
5	brightness	$f_5(i, j) = 0,299 R + 0,587 G + 0,114 B$ (luminancia Rec. 601)
6	red_std	$f_6(i, j) = \overline{R}_{5 \times 5}(i, j)$, media de rango local ventana 5×5
7	green_std	$f_7(i, j) = \overline{G}_{5 \times 5}(i, j)$
8	blue_std	$f_8(i, j) = \overline{B}_{5 \times 5}(i, j)$

Cuadro 2.2: Features de textura extraídas sobre la imagen en escala de grises.

#	Nombre	Definición
9	sobel_horizontal	$f_9 = \partial \text{gray} / \partial y$, convolución con kernel Sobel horizontal
10	sobel_vertical	$f_{10} = \partial \text{gray} / \partial x$, convolución con kernel Sobel vertical
11	gradient_magnitude	$f_{11}(i, j) = \sqrt{f_9^2 + f_{10}^2}$
12	lbp	LBP uniforme: $f_{12}(i, j) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$, $P = 24$, $r = 3$, $s(x) = \mathbf{1}_{x \geq 0}$
13	entropy	$f_{13}(i, j) = -\sum_k p_k \log_2 p_k$ en ventana 9×9
14	contrast	$f_{14}(i, j) = \overline{\text{gray}}_{5 \times 5}(i, j)$, media de rango local

Cuadro 2.3: Índices espectrales y transformaciones de espacio de color.

#	Nombre	Definición
15	ndvi_approx	$f_{15} = \frac{G - R}{G + R + \varepsilon}$, $\varepsilon = 10^{-8}$ (proxy NDVI con bandas visibles)
16	excess_green	$f_{16} = 2G - R - B$ (índice ExG de vegetación)
17	excess_red	$f_{17} = 1,4 R - G$ (índice ExR, suelo/urbano)
18	lab_l	Luminancia $L^* \in [0, 100]$ en espacio CIE $L^*a^*b^*$
19	lab_a	Eje verde(-) - rojo(+), $a^* \in [-128, 127]$
20	lab_b	Eje azul(-) - amarillo(+), $b^* \in [-128, 127]$
21	hsv_h	Matiz $H \in [0, 1]$
22	hsv_s	$S = \frac{\max(R, G, B) - \min(R, G, B)}{\max(R, G, B)}$
23	hsv_v	$V = \max(R, G, B)$

Los cuadros 2.1, 2.2 y 2.3 muestran las características extraídas por píxel para cada una de las bandas RGB, las características de textura y las características espectrales y de color, respectivamente.

Sin embargo dentro del preprocesamiento se reducen las características a 8, mediante un StandardScaler y un PCA.

$$\mathbf{f}(x, y) = \mathbf{W}\mathbf{f}(x, y) \quad (2.1)$$

donde $\mathbf{W}$ es la matriz de pesos PCA.

A continuación se define el algoritmo de StandardScaler y PCA.

Algorithm 1 StandardScaler: estandarización por z-score**Require:** Matriz de features $X \in \mathbb{R}^{N \times F}$ (N píxeles, F features)**Ensure:** Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$

```

1: Fase de ajuste (sobre los datos de entrenamiento)
2: for  $j = 1$  to  $F$  do
3:    $\mu_j \leftarrow \frac{1}{N} \sum_{i=1}^N X_{ij}$ 
4:    $\sigma_j \leftarrow \sqrt{\frac{1}{N} \sum_{i=1}^N (X_{ij} - \mu_j)^2}$ 
5: end for
6: Fase de transformación
7: for  $i = 1$  to  $N$  do
8:   for  $j = 1$  to  $F$  do
9:      $\tilde{X}_{ij} \leftarrow \frac{X_{ij} - \mu_j}{\sigma_j + \varepsilon}$  ▷  $\varepsilon$  evita división por cero
10:   end for
11: end for
12: return  $\tilde{X}$ 

```

Algorithm 2 PCA: reducción de dimensionalidad**Require:** Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$, número de componentes $k = 8$ **Ensure:** Representación reducida $Z \in \mathbb{R}^{N \times k}$

```

1: Calcular la matriz de covarianza:  $\Sigma \leftarrow \frac{1}{N-1} \tilde{X}^\top \tilde{X}$ 
2: Obtener descomposición espectral:  $\Sigma \mathbf{w}_j = \lambda_j \mathbf{w}_j, \quad j = 1, \dots, F$ 
3: Ordenar autovalores de forma descendente:  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_F$ 
4: Seleccionar los  $k$  autovectores de mayor varianza:  $\mathbf{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \dots \ \mathbf{w}_k] \in \mathbb{R}^{F \times k}$ 
5: Proyectar los datos:  $Z \leftarrow \tilde{X} \mathbf{W}$ 
6: return  $Z$ 

```

La salida del algoritmo PCA es la entrada del algoritmo de clasificación K-Means. (matrix $Z \in \mathbb{R}^{N \times 8}$) El algoritmo de K-Means es utilizado con el fin de agrupar los píxeles en 2, 3 o 4 grupos. En este caso 2, su definición es la siguiente:

Algorithm 3 K-Means: agrupamiento no supervisado ($k = 2$)**Require:** Matriz PCA $Z \in \mathbb{R}^{N \times 8}$, número de clústeres $k = 2$, inicializaciones $n_{\text{init}} = 10$ **Ensure:** Vector de etiquetas $\ell \in \{0, 1\}^N$

- 1: **for** cada inicialización $r = 1, \dots, n_{\text{init}}$ **do**
- 2: Inicializar centroides $\{\mu_1, \mu_2\} \subset Z$ (selección aleatoria)
- 3: **repeat**
- 4: **Asignación:** $\ell_i \leftarrow \arg \min_{c \in \{1, 2\}} \|z_i - \mu_c\|_2^2 \quad \forall i$
- 5: **Actualización:** $\mu_c \leftarrow \frac{1}{|C_c|} \sum_{i \in C_c} z_i \quad \forall c$, donde $C_c = \{i : \ell_i = c\}$
- 6: **until** los centroides no cambien
- 7: Registrar inercia $\mathcal{J}_r = \sum_{i=1}^N \|z_i - \mu_{\ell_i}\|_2^2$
- 8: **end for**
- 9: Seleccionar la solución con menor $\mathcal{J}_r$
- 10: **return** ℓ

Las pseudo-etiquetas ℓ producidas por K-Means se usan como verdad base para entrenar un clasificador SVM sobre una muestra de hasta 10 000 píxeles, que luego predice la etiqueta de todos los N píxeles.

Algorithm 4 SVM lineal: clasificación sobre pseudo-etiquetas K-Means**Require:** Matriz PCA $Z \in \mathbb{R}^{N \times 8}$, pseudo-etiquetas $\ell \in \{0, 1\}^N$, tamaño de muestra $n_s = \min(N, 10\,000)$ **Ensure:** Mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$

- 1: Seleccionar submuestra aleatoria $\mathcal{S} \subset \{1, \dots, N\}$, $|\mathcal{S}| = n_s$
- 2: Entrenar SVM lineal minimizando:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i \in \mathcal{S}} \max(0, 1 - \ell_i^* (\mathbf{w}^\top z_i + b))$$

donde $\ell_i^* \in \{-1, +1\}$ es la pseudo-etiqueta recodificada

- 3: **Predicción sobre todos los píxeles:** $\hat{y}_i \leftarrow \text{sign}(\mathbf{w}^\top z_i + b) \quad \forall i \in \{1, \dots, N\}$
- 4: Recodificar a binario: $\hat{y}_i \leftarrow \mathbf{1}[\hat{y}_i > 0]$
- 5: Reorganizar en mapa $H \times W$
- 6: **return** $\hat{y}$

La salida del algoritmo SVM es un mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$ donde H es el número de filas y W es el número de columnas de la imagen. Aquí se empleó un procedimiento manual para seleccionar que clase es la mancha urbana y que es la no-urbana. La imagen 2.1 muestra el flujo de preprocesamiento de datos.




Figura 2.1: Flujo de preprocesamiento de datos.

2.2. Autómatas Celulares

Un **Autómata Celular** (AC), en el sentido formalizado por Wolfram (1984), es un sistema dinámico discreto definido sobre una cuadrícula regular de N celdas. Formalmente, un AC queda definido por la cuádrupla $(Q, \mathcal{N}, \delta, q_0)$, donde:

- Q es el conjunto finito de estados posibles de cada celda (por ejemplo, $Q = \{0, 1\}$ para no-urbano y urbano).
- $\mathcal{N}$ es la vecindad de cada celda, es decir, el conjunto de celdas adyacentes cuyo estado influye en la transición.
- $\delta : Q^{|\mathcal{N}|} \rightarrow Q$ es la función de transición que determina el nuevo estado de una celda a partir del estado de sus vecinos. Es decir de n estados posibles, determina el nuevo estado de la celda.
- $q_0 : \Omega \rightarrow Q$ es la configuración inicial del sistema.

En el contexto del crecimiento urbano, el dominio espacial $\Omega \subset \mathbb{Z}^2$ es una cuadrícula discreta de celdas indexadas por pares (i, j) , donde $i \in \{1, \dots, R\}$ indica la fila y $j \in \{1, \dots, C\}$ la columna, con $N = R \times C$ celdas en total.

En los AC probabilísticos, la función de transición δ asigna probabilidades a cada posible

nuevo estado, en lugar de determinar el siguiente estado de forma determinista. Esta extensión, base de los modelos urbanos basados en AC desde White y Engelen (1997) y de marcos calibrados como SLEUTH (Clarke & Gaydos, 1998), resulta adecuada para el modelado urbano, en el que la transición de no-urbano a urbano no está garantizada incluso cuando las condiciones locales son favorables.

Los dos tipos de vecindad más utilizados en modelado urbano son la vecindad de Von Neumann (cuatro celdas ortogonales) y la vecindad de Moore (ocho celdas incluyendo diagonales). En ambos casos, el radio de influencia puede extenderse más allá de la celda inmediatamente adyacente, permitiendo capturar efectos de accesibilidad y proximidad a zonas urbanas existentes.

Para el presente modelo, la influencia de la vecindad se cuantifica mediante la proporción de celdas urbanas en un radio r alrededor de la celda evaluada:

$$\Omega_{i,j}(r) = \frac{1}{|\mathcal{N}_{i,j}(r)|} \sum_{(i',j') \in \mathcal{N}_{i,j}(r)} s_{i',j'} \quad (2.2)$$

donde $s_{i',j'} \in \{0, 1\}$ es el estado urbano de la celda vecina en posición (i', j') y $\mathcal{N}_{i,j}(r)$ es el conjunto de celdas dentro del radio r alrededor de la celda (i, j) . Dicho de otra forma, es la proporción de celdas urbanas en el radio r alrededor de la celda (i, j) , bajo la definición de vecindad.

La probabilidad de que una celda no-urbana en posición (i, j) transite al estado urbano en el paso $t + 1$ se define como una función de tres componentes:

$$P(s_{i,j}^{t+1} = 1 \mid s_{i,j}^t = 0) = f(W_{i,j}, \Omega_{i,j}(r), \varepsilon_{i,j}) \quad (2.3)$$

donde $W_{i,j}$ es la idoneidad espacial asignada por el método WoE (definida a continuación), $\Omega_{i,j}(r)$ es el efecto de vecindad, y $\varepsilon_{i,j}$ es un término estocástico que introduce variabilidad aleatoria en la simulación. La función f combina estos tres factores según parámetros que, en este trabajo, se ajustan mediante el procedimiento de calibración descrito en el Capítulo ?? y en la Sección ?. Esta función es la que define la transición de una celda no-urbana a una urbana.

El método de **Pesos de Evidencia** (Weight of Evidence, WoE) es una técnica estadística de origen bayesiano que cuantifica la asociación entre una variable espacial y la ocurrencia de un evento, en este caso la transición de suelo no-urbano a urbano (Bonham-Carter, 1994). Fue desarrollado originalmente en el contexto de la predicción de depósitos minerales y posteriormente adaptado al análisis de cambio de uso de suelo.

Para una variable espacial X discretizada en categorías o intervalos, el peso de evidencia de la categoría b se define como:

$$W^+(b) = \ln \frac{P(X = b \mid \text{transición})}{P(X = b \mid \text{no transición})} \quad (2.4)$$

donde $P(X \in b \mid \text{transición})$ es la proporción de píxeles con transición observada que pertenecen a la categoría b , y $P(X \in b \mid \text{no transición})$ es la proporción equivalente para píxeles sin transición. Los pesos positivos indican que la categoría b favorece la transición; los pesos negativos indican lo contrario. En esta expresión, b no representa la clase urbano/no-urbano, sino una categoría, intervalo o bin de la variable espacial X (por ejemplo, un rango de distancia a la mancha urbana existente o un rango de densidad vecinal). La clase binaria $\{0, 1\}$ corresponde al estado observado o predicho de la celda, mientras que las categorías b pertenecen al espacio de valores de cada variable explicativa.

El peso total para la celda en posición (i, j) se obtiene sumando los pesos de cada variable espacial evaluada en esa celda:

$$W_{i,j} = \sum_{k=1}^V W^+(b_{(i,j)k}) \quad (2.5)$$

donde V es el número de variables espaciales consideradas y $b_{(i,j)k}$ es la categoría o intervalo que toma la variable espacial k en la celda (i, j) . En la implementación de este trabajo, $V = 7$, porque se consideran siete variables espaciales derivadas de la configuración urbana histórica. Por tanto, V no es el número de clases del mapa binario; las clases del estado celular siguen siendo dos (0 para no urbano y 1 para urbano). Este valor $W_{i,j}$ se transforma mediante una función sigmoide para obtener una probabilidad de transición acotada en $[0, 1]$:

$$P_{i,j}^{\text{WoE}} = \frac{1}{1 + e^{-W_{i,j}}} \quad (2.6)$$

Una propiedad relevante del WoE es su interpretabilidad: cada peso $W^+(b)$ puede traducirse en términos geográficos. Por ejemplo, si la variable *distancia a manchas urbanas* tiene un peso negativo para distancias grandes, ello sugiere menor probabilidad de urbanización en celdas alejadas de vías de comunicación.




Figura 2.2: Ejemplo del cálculo de WoE: la variable *distancia al frente urbano* acumula pesos positivos en bins próximos y negativos en bins lejanos. La suma ponderada pasa por la sigmoide y se compara con

Dicha transparencia puede apoyar la comunicación de resultados a planificadores urbanos, sin sustituir el juicio experto ni las políticas públicas aplicables en cada contexto.

El cálculo de los pesos se realiza sobre datos históricos de transición, lo que hace que las probabilidades resultantes reflejen empíricamente los patrones observados en el área de estudio, en lugar de depender de supuestos teóricos sobre el comportamiento urbano.

2.3. Métricas de evaluación de modelos predictivos

La evaluación cuantitativa del desempeño del modelo requiere métricas que comparen el mapa predicho con el mapa observado a nivel de píxel y a nivel global. A continuación se presentan las métricas utilizadas en este trabajo, derivadas de la matriz de confusión espacial. La matriz de confusión es una tabla que muestra el número de píxeles correctamente clasificados y los errores de clasificación.

Sea $\Omega \subset \mathbb{R}^2$ el dominio espacial de estudio discretizado en $N = |\Omega|$ píxeles. Para cada píxel $i \in \Omega$, sea $y_i \in \{0, 1\}$ el estado observado real (donde 0 denota no-urbano y 1 denota urbano), y sea $\hat{y}_i \in \{0, 1\}$ el estado predicho por el modelo. En esta notación, i es un índice lineal sobre las $N = R \times C$ celdas de la cuadrícula; cada valor i corresponde a la celda en posición (r, c) con $r \in \{1, \dots, R\}$ filas y $c \in \{1, \dots, C\}$ columnas. Se emplea el índice lineal por claridad en la notación de conjuntos; la equivalencia con la indexación bidimensional (i, j) de las secciones anteriores es $i \leftrightarrow (r, c)$.

La **matriz de confusión** $C \in \mathbb{N}^{2 \times 2}$ cuantifica la concordancia píxel a píxel entre predicción y observación:

$$C = \begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix} \quad (2.7)$$

donde los elementos se definen mediante la función indicadora $\mathbb{I}[\cdot]$ como sigue:

$$TP = \sum_{i \in \Omega} \mathbb{1}[\hat{y}_i = 1 \wedge y_i = 1] \quad (\text{verdaderos positivos: urbano predicho y observado}) \quad (2.8)$$

$$TN = \sum_{i \in \Omega} \mathbb{1}[\hat{y}_i = 0 \wedge y_i = 0] \quad (\text{verdaderos negativos: no-urbano predicho y observado}) \quad (2.9)$$

$$FP = \sum_{i \in \Omega} \mathbb{1}[\hat{y}_i = 1 \wedge y_i = 0] \quad (\text{falsos positivos: sobre-predicción}) \quad (2.10)$$

$$FN = \sum_{i \in \Omega} \mathbb{1}[\hat{y}_i = 0 \wedge y_i = 1] \quad (\text{falsos negativos: sub-predicción}) \quad (2.11)$$

Estos cuatro componentes satisfacen $TP + TN + FP + FN = N$. La magnitud relativa de FP frente a FN revela el sesgo sistemático del modelo: si $FP > FN$, el modelo sobre-predice urbanización; si $FN > FP$, el modelo es conservador.

La construcción de la matriz requiere correspondencia espacial exacta entre los mapas predicho y observado: idéntica resolución espacial, sistema de proyección cartográfica y extensión geográfica. Los píxeles se clasifican evaluando las condiciones lógicas anteriores sobre todos los píxeles del dominio. La **exactitud global** mide la fracción de píxeles correctamente clasificados:

$$\text{Accuracy} = \frac{TP + TN}{N} \quad (2.12)$$

Esta métrica es sensible al desbalance de clases. En contextos urbanos, donde la mayoría de píxeles no experimenta cambio, un modelo que predice “no cambio” en todos los píxeles obtiene Accuracy muy alta sin capturar ninguna dinámica. Por esta razón, Accuracy debe complementarse con métricas específicas para las transiciones. La **precisión** cuantifica la confiabilidad de las predicciones positivas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.13)$$

Probabilísticamente, Precision estima $P(y_i = 1 \mid \hat{y}_i = 1)$: dado que el modelo predijo urbanización, ¿cuál es la probabilidad de que realmente ocurrió? Precision decrece cuando el modelo genera muchas falsas alarmas (sobre-predicción). Es especialmente relevante cuando el sobre-dimensionamiento de infraestructura tiene costos significativos. El **recall** cuantifica la capacidad de detectar píxeles con transición real:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.14)$$

Recall estima $P(\hat{y}_i = 1 \mid y_i = 1)$: dado que un píxel se urbanizó, ¿cuál es la probabilidad de que el modelo lo detectó? Recall bajo indica que el modelo omite transiciones reales, subestimando la expansión urbana.

Existe una tensión inherente entre Precision y Recall: aumentar el umbral de decisión tiende a incrementar Precision pero disminuye Recall, y viceversa. Esta dualidad motiva la siguiente métrica. El **F1-Score** es la media armónica entre Precision y Recall:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (2.15)$$

La media armónica penaliza más severamente los valores bajos que la media aritmética, de modo que F1 es bajo cuando cualquiera de las dos métricas es baja, exigiendo buen desempeño en ambas dimensiones simultáneamente. El **coeficiente Kappa de Cohen** (Cohen, 1960) corrige la concordancia observada por la concordancia esperada por azar:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (2.16)$$

donde p_o = Accuracy es la proporción observada de concordancia, y p_e es la proporción esperada por azar:

$$p_e = \frac{(TP + FP)(TP + FN) + (TN + FN)(TN + FP)}{N^2} \quad (2.17)$$

El rango es $\kappa \in [-1, 1]$. Conforme a la escala de interpretación de uso común propuesta por Landis y Koch (1977), $\kappa > 0,81$ indica acuerdo casi perfecto; 0,61–0,80, acuerdo sustancial; 0,41–0,60, acuerdo moderado; 0,21–0,40, acuerdo justo; y $\kappa < 0,20$, acuerdo pobre. La ventaja del coeficiente κ frente a la *Accuracy* es que proporciona una evaluación más realista ante desbalance de clases, al descontar el acuerdo esperado por azar.

Las métricas anteriores evalúan la concordancia global píxel a píxel, incluyendo tanto las transiciones como las permanencias. Sin embargo, en modelación de cambio de uso de suelo interesa específicamente predecir las **transiciones**, no las permanencias. Dado que la clase mayoritaria (píxeles sin cambio) puede inflar artificialmente las métricas globales, el **Figure of Merit** (FoM), propuesto como métrica comparable entre estudios de cambio de uso de suelo por Pontius Jr et al. (2008), aborda esta limitación evaluando exclusivamente la predicción de

cambio.

En un sistema urbano consolidado con 95 % de territorio permanente y 5 % con transición, un modelo trivial que predice “no cambio” obtiene $Accuracy = 0,95$ sin capturar ninguna dinámica urbana. El FoM evalúa únicamente el subconjunto de píxeles donde ocurren transiciones, ignorando la clase mayoritaria.

Sea $\mathcal{T}_{obs}$ el conjunto de píxeles con cambio observado y $\mathcal{T}_{pred}$ el conjunto con cambio predicho entre t_0 y t_1 . El FoM es el índice de Jaccard aplicado exclusivamente a las transiciones:

$$FoM = \frac{|\mathcal{T}_{obs} \cap \mathcal{T}_{pred}|}{|\mathcal{T}_{obs} \cup \mathcal{T}_{pred}|} \quad (2.18)$$

Descomponiendo en componentes:

$$B = |\mathcal{T}_{obs} \cap \mathcal{T}_{pred}| \quad (\text{cambio correctamente predicho}) \quad (2.19)$$

$$C = |\mathcal{T}_{obs} \setminus \mathcal{T}_{pred}| \quad (\text{cambio observado no predicho: omisión}) \quad (2.20)$$

$$A = |\mathcal{T}_{pred} \setminus \mathcal{T}_{obs}| \quad (\text{cambio predicho no observado: comisión}) \quad (2.21)$$

$$\boxed{FoM = \frac{B}{A + B + C}} \quad (2.22)$$

El denominador contiene exactamente tres términos. No incluye el término D (píxeles sin cambio) porque FoM evalúa exclusivamente las transiciones.

Con esto queda definido el marco teórico necesario para el desarrollo del modelo propuesto en el Cap. ???. El posicionamiento de este trabajo en la literatura especializada es el tema del Cap. ??, donde se realiza una revisión crítica de los enfoques previos y se contrasta el modelo propuesto con ellos.

Bibliografía

- Bonham-Carter, G. F. (1994). *Geographic Information Systems for Geoscientists: Modelling with GIS* (Vol. 13). Pergamon.
- Clarke, K. C., & Gaydos, L. J. (1998). Loose-coupling a Cellular Automaton Model and GIS: Long-term Urban Growth Prediction for San Francisco and Washington/Baltimore. *International Journal of Geographical Information Science*, 12(7), 699-714. <https://doi.org/10.1080/136588198241617>
- Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37-46. <https://doi.org/10.1177/001316446002000104>
- Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, 33(1), 159-174. <https://doi.org/10.2307/2529310>
- Pontius Jr, R. G., Boersma, W., Castella, J.-C., Clarke, K., de Nijs, T., Dietzel, C., Duan, Z., Fotsing, E., Goldstein, N., Kok, K., Koomen, E., Lippitt, C. D., McConnell, W., Mohd Sood, A., Pijanowski, B., Pithadia, S., Sweeney, S., Trung, T. N., Veldkamp, A. T., & Verburg, P. H. (2008). Comparing the input, output, and validation maps for several models of land change. *The Annals of Regional Science*, 42(1), 11-37. <https://doi.org/10.1007/s00168-007-0138-2>
- White, R., & Engelen, G. (1997). Cellular Automata as the Basis of Integrated Dynamic Regional Modelling. *Environment and Planning B: Planning and Design*, 24, 235-246. <https://doi.org/10.1068/b240235>
- Wolfram, S. (1984). Cellular Automata as Models of Complexity. *Nature*, 311(5985), 419-424. <https://doi.org/10.1038/311419a0>