

Capítulo 3

Estado del arte

El modelado computacional del crecimiento urbano ha producido en treinta años una literatura rica pero metodológicamente diferente. Este capítulo no busca ordenar trabajos por autor sino que busca identificar los cuatro problemas metodológicos que siguen abiertos en el campo —calibración por fuerza bruta, validación sobreajustada a una sola ventana temporal, opacidad de la función de transición en los modelos de aprendizaje profundo y dependencia de software propietario— y muestra cómo cada uno justifica una decisión concreta del diseño del modelo WoE-AC propuesto. La discusión concluye con un mapa de la literatura para ciudades mexicanas, donde ningún trabajo publicado satisface simultáneamente los requerimientos R1–R4 de la Tabla ??.

3.1. Evolución del modelado urbano computacional

El modelado de la dinámica urbana mediante autómatas celulares empezó con White y Engelen (1997), cuyo trabajo mostró que reglas locales basadas en distancia y vecindad podrían reproducir patrones macroscópicos realistas en ciudades. El siguiente nivel del enfoque fue introducido con SLEUTH en (Clarke & Gaydos, 1998; Silva & Clarke, 2002), que durante dos décadas fue vanguardia y considerado como referencia, y que se aplicó en decenas de ciudades.

Al mismo tiempo, la metodología LUCC (Land Use and Cover Change) introdujo modelos basados en mapas de idoneidad de uso de suelo de base estadística: sistemas como CLUE-S, Dinamica EGO, CA-Markov y, más recientemente, FLUS, GeoSOS y MOLUSCE, brindaron arquitecturas alternativas al autómata celular puro en las que la función de transición emerge de regresiones logísticas o pesos bayesianos sobre datos históricos.

Una generación posterior de trabajos sustituyó la regresión por modelos de aprendizaje

automático e híbridos metaheurísticos. Almeida et al. (2008) acopló una red neuronal feedforward a un autómata celular estocástico para Piracicaba, Brasil; años más tarde Wang et al. (2021) combinó un autómata celular con un algoritmo genético para optimizar la forma urbana de Wuhan, a un costo computacional elevado, mientras que Hagenauer y Helbich (2022) introdujo una red neuronal geográficamente ponderada para capturar relaciones espaciales no lineales. Estos enfoques reportan ganancias cuantitativas en precisión, pero sustituyen parámetros legibles por activaciones internas o cromosomas que no admiten una lectura geográfica directa; en esa medida, no son auditables respecto de lo que aprenden.

La decisión central del campo no es en torno a AC y aprendizaje automático, sino entre dos directivas que a priori parecen contrapuestos: maximizar precisión predictiva y mantener la trazabilidad de cada decisión espacial. Las secciones siguientes muestran que esta tensión es resoluble si se cambia la pregunta metodológica.

3.2. Problemas metodológicos persistentes

Los problemas metodológicos mas importantes detectados en la literatura fueron equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software no libre.

3.2.1. Calibración: equifinalidad y costo computacional

SLEUTH calibra cinco coeficientes de crecimiento —*diffusion, breed, spread, slope resistance* y *road gravity*— mediante búsqueda por fuerza bruta sobre un espacio discreto del orden de 10^9 combinaciones, cada una evaluada con simulaciones Monte Carlo de múltiples iteraciones. Clarke y Gaydos (1998) estructuró la búsqueda en tres fases sucesivas —gruesa, fina y final— que estrechan iterativamente el rango de cada coeficiente; aun así, una calibración completa toma días en hardware contemporáneo (Jantz et al., 2003). A esa carga se añaden dos rasgos que agravan la dificultad. Primero, SLEUTH es un autómata *auto-modificable*: los coeficientes de *spread* se reescriben durante la propia corrida en respuesta a la tasa de crecimiento, de modo que el resultado depende de la trayectoria seguida y no solo de los valores iniciales (Clarke & Gaydos, 1998). Segundo, los coeficientes calibrados son sensibles a la resolución espacial de los datos, por lo que un conjunto ajustado a una escala no se transfiere directamente a otra. Sobre esa base aparece el problema metodológico de fondo, que no es solo el costo: es la **equifinalidad**, esto es, la existencia de múltiples combinaciones de coeficientes que producen patrones indistinguibles para la métrica de calibración pero divergen en las proyecciones de largo plazo (Clarke, 2008). Sin un criterio adicional, la elección entre combinaciones equifinales

termina dependiendo de quien realiza la calibración. Esta combinación de costo, dependencia de trayectoria y equifinalidad es, precisamente, lo que motiva la estrategia de validación multi-ventana que se adopta más adelante: una sola ventana temporal no basta para distinguir un conjunto de coeficientes robusto de uno meramente equifinal.

El presente trabajo evita el problema redefiniéndolo: en lugar de calibrar coeficientes que controlan reglas geométricas genéricas (diffusion, breed, spread), calibra dos parámetros que controlan la combinación de evidencia espacial empírica (umbral de transición y peso de vecindad). El espacio de búsqueda es de dos dimensiones y la calibración termina en minutos. Más importante aún: cada configuración candidata produce mapas de idoneidad cuyos pesos por variable son directamente auditables, de modo que es posible explicar por qué una celda recibió una probabilidad de transición dada, lo que reduce la ambigüedad asociada a la equifinalidad.

3.2.2. Validación: sobreajuste temporal y métricas no comparables

Pontius Jr et al. (2008) analizó trece simulaciones independientes de nueve modelos de cambio de uso de suelo y propuso el Figure of Merit (FoM) como métrica estándar comparable entre estudios. Su hallazgo es un tanto desmotivante: seis de las trece aplicaciones obtienen FoM inferior al 15 % y solo una supera el 50 %. La dispersión o variabilidad no se explica por la complejidad del modelo sino por la magnitud del cambio neto observado: el FoM crece monótonicamente con el porcentaje de celdas que efectivamente cambian de estado. O dicho de una forma mas sencilla, el FoM es una métrica que penaliza la cantidad de celdas que no cambian de estado.

Esto tiene dos implicaciones que la literatura rara vez confronta. La primera, **validar en una sola ventana temporal es estadísticamente insuficiente**: si el FoM depende de la magnitud del cambio, entonces se puede concluir que una validación única no permite distinguir entre un modelo robusto y uno sobreajustado a una fase específica del crecimiento en el tiempo. Segundo, **reportar métricas como Kappa o Accuracy sin FoM infla artificialmente la calidad del modelo**: en un sistema urbano consolidado donde el 90 % de las celdas permanece sin cambio, un modelo trivial que predice “no cambio” en todas las celdas obtiene Accuracy de 0.90 sin capturar ninguna dinámica. Queremos capturar la dinámica, no la estabilidad.

En consecuencia, la validación del WoE-AC, para el presente trabajo, se realizó en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020), reportando FoM, Kappa e IoU simultáneamente. La estabilidad del FoM a través de las cinco ventanas, no su valor absoluto en una sola, es lo que permite denotar un modelo que generaliza bien de uno que no lo hace tan bien.

Vale la pena confrontar una contradicción que la literatura rara vez coloca lado a lado. Por un lado, los trabajos de aprendizaje automático y profundo reportan mejoras de exactitud frente a los autómatas celulares clásicos (Almeida et al., 2008; Hagenauer & Helbich, 2022); por otro, el meta-análisis de Pontius Jr et al. (2008) muestra que la dispersión del FoM entre trece aplicaciones no se explica por la sofisticación del modelo, sino por la magnitud del cambio neto del periodo evaluado. Las dos observaciones no se contradicen en abstracto, pero sí en la práctica con que suelen leerse: un FoM de, por ejemplo, 0,40 obtenido en una ciudad con 20 % de cambio neto no es comparable con un 0,20 obtenido en una con 5 %, y aun así ambos se citan como evidencia directa de que un modelo supera a otro. La consecuencia es incómoda pero ineludible: buena parte de los *rankings* de desempeño publicados confunden la dificultad del caso con la calidad del modelo. Algo análogo ocurre con la equifinalidad de SLEUTH (Clarke, 2008): dos calibraciones que empatan en la métrica de ajuste pueden divergir por completo en la proyección a largo plazo, de modo que reportar “el mejor conjunto de coeficientes” sin declarar el conjunto de los equifinales transmite una unicidad que los datos no respaldan. Este trabajo toma postura frente a ese punto: no compara su FoM absoluto contra el de otras ciudades como si fueran intercambiables, sino que evalúa la estabilidad del FoM entre cinco ventanas del mismo sistema urbano —la única comparación que mantiene constante la magnitud del cambio— y reporta el rango completo en lugar de un único valor favorable.

3.2.3. Interpretabilidad: el problema de la caja negra

Almeida et al. (2008) entrenó una red neuronal feedforward con backpropagation sobre variables biofísicas e infraestructurales de Piracicaba (Brasil, 1985–1999); la red aprende pesos sinápticos que alimentan a un CA estocástico. El modelo reporta concordancia espacial superior a los AC clásicos de la época, pero los pesos no son transformables o explicables a una pregunta geográfica, es decir, no se puede afirmar que “la distancia a vialidades contribuyó un X % a la transición de esta celda”. La activación de cada neurona es una combinación no lineal de todas las variables de entrada, sin descomposición legible o dicho de otra forma, no es auditable en cuestión de lo que aprenden.

Trabajos posteriores intensifican esta opacidad por dos vías. La primera es la optimización metaheurística: Wang et al. (2021) integra un autómata celular a un algoritmo genético para generar formas urbanas que maximizan un índice de vitalidad en Wuhan, donde cada generación produce cromosomas que carecen de lectura geográfica directa. La segunda es el aprendizaje profundo aplicado a teledetección y modelado espacial (Hagenauer & Helbich, 2022; Ma et al., 2019), que requiere GPU y conjuntos de datos masivos para entrenar redes cuyas representaciones internas no son auditables, una vez más. La ganancia en exactitud es real, pero

el costo epistémico es alto: el modelo clasifica sin justificar, y la justificación es exactamente lo que un instrumento de planeación urbana requiere. Un plan municipal sustentado en “el modelo lo predijo” es jurídica y políticamente más débil que uno sustentado en “históricamente, la proximidad al frente urbano contribuye con un Information Value de X a la probabilidad de transición”.

El método de Pesos de Evidencia (WoE) provee exactamente esa descomposición. La elección de WoE en este trabajo no responde a una preferencia estética por la transparencia: responde al requerimiento R4 de la Tabla ??, que define la auditabilidad como condición de uso del modelo, no como propiedad accesoria.

3.2.4. Transferibilidad: software propietario y reproducibilidad

Una fracción significativa de los modelos LUCC más citados depende de software propietario, lo que limita en la práctica la reproducibilidad y la transferibilidad de los resultados publicados. Por ejemplo, Dinamica EGO opera bajo licencia académica restringida; IDRISI y TerrSet son comerciales; SLEUTH se distribuye como código en C, pero su instalación en sistemas modernos requiere ajustes no documentados que no son triviales para el usuario. La consecuencia práctica es que la reproducibilidad de los resultados publicados es, en el mejor de los casos, parcial: el lector puede leer el método pero no ejecutarlo sin acceso a infraestructura específica.

Esta dependencia tiene una consecuencia material poco discutida en la literatura metodológica: el acceso a licencias y a hardware especializado introduce una barrera de entrada que condiciona qué grupos académicos pueden reproducir o extender los modelos publicados. En contextos donde estos recursos son limitados, la única alternativa práctica es reescribir el pipeline desde cero o dedicar un esfuerzo considerable a descifrar requerimientos no documentados. El presente trabajo opta por esta vía: se implementa íntegramente en Python con dependencias de código abierto (NumPy, SciPy, scikit-learn) sobre datos públicos (Google Earth Engine), satisfaciendo R3 sin problemas.

3.3. Pesos de Evidencia y modelos probabilísticos espaciales

El método de Pesos de Evidencia, desarrollado por Bonham-Carter (1994) en el contexto de la prospección mineral, se formaliza en el Capítulo ?? (ecuación ??): para cada clase de una variable espacial discretizada se calcula un peso bayesiano que cuantifica la asociación entre dicha clase y la ocurrencia del evento de interés, en este trabajo, la transición de suelo no urbano

a urbano. El peso total por celda es la suma de los pesos de las variables evaluadas en ella, transformada por la función logística para obtener una probabilidad acotada (ecuación ??); el Information Value sintetiza el poder discriminatorio de cada variable. La presente sección no repite la derivación matemática, sino que la sitúa en la literatura LUCC.

La adaptación del WoE al modelado de cambio de uso de suelo se consolidó con Soares-Filho et al. (2002) y la familia de modelos *Dinamica EGO*, que separan dos preguntas que el campo suele tratar de forma confusa: *cuánto* suelo cambia y *dónde* lo hace. La cantidad de transición se fija con una matriz de transición markoviana estimada del cambio histórico, mientras que la asignación espacial la resuelve un autómata celular de dos operadores —*expander*, que ensancha los parches urbanos existentes, y *patcher*, que siembra parches nuevos— alimentado por un mapa de idoneidad WoE. Ese diseño reproduce con fidelidad la distribución de tamaños de parche observada en frentes de deforestación amazónica y expansión agrícola, y en menor medida en crecimiento urbano.

La misma lógica de *demanda* más *asignación* reaparece en otros marcos LUCC ampliamente citados: CLUE-S (Verburg et al., 2002) acopla una idoneidad derivada de regresión logística con una asignación iterativa gobernada por la demanda sectorial de suelo, y FLUS (Liu et al., 2017) sustituye esa idoneidad por la probabilidad de una red neuronal y la asigna mediante un autómata celular con inercia auto-adaptativa y competencia por ruleta. Conviene tomar postura sobre la diferencia con el presente trabajo, porque es deliberada: estos marcos descomponen el problema en un módulo de cantidad (Markov o demanda exógena) y un módulo de localización (CA), y la mayoría se distribuye como software con interfaz gráfica o licencia restringida. Aquí, en cambio, la cantidad no se impone desde fuera, sino que emerge de la propia regla de transición, donde el campo WoE ponderado por IV y la influencia del vecindario de Moore deciden conjuntamente cuántas y cuáles celdas transitan. El esquema de dos módulos ajusta muy bien la cantidad de cambio —esa es su fortaleza documentada—, pero paga ese ajuste con una dependencia mayor de software especializado y con una frontera difusa entre lo que decide el modelo de demanda y lo que decide el CA; para un instrumento de planeación, donde importa poder rastrear por qué una celda concreta se urbaniza, la integración transparente y reproducible que se adopta en este trabajo resulta preferible.

Sin embargo, el WoE tiene tres limitaciones estadísticas reconocidas que conviene explicitar para evitar atribuirle propiedades que no posee:

Independencia condicional. La suma de pesos asume que las variables son condicionalmente independientes dada la ocurrencia del evento. Este supuesto claramente rara vez sucede en variables espaciales urbanas, debido a que es un sistema complejo, donde proximidad a vialidades

y proximidad al frente urbano están correlacionadas, por mencionar un ejemplo. El presente trabajo no introduce una corrección formal para esta dependencia; sigue la práctica estándar de la literatura LUCC, que reporta el sesgo derivado mediante el contraste empírico con el cambio observado. Sin embargo, la validación multi-período mitiga parcialmente el problema, esto ya que si el sesgo fuera dominante, el FoM degradaría sistemáticamente entre ventanas.

Sensibilidad a la discretización. Los pesos dependen de cómo se categorice cada variable continua. El presente trabajo adopta una discretización basada en cuantiles uniformes, que es la convención más reproducible aunque no necesariamente la óptima en términos de IV (Information Value).

Multicolinealidad entre drivers. Variables correlacionadas producen pesos redundantes que inflan la magnitud aparente de la evidencia. Este trabajo aplica un análisis de componentes principales sobre el conjunto de variables espaciales antes del cálculo de IV, lo que reduce la redundancia sin sacrificar interpretabilidad.

3.4. Validación espacial en modelos LUCC

La métrica más reportada en LUCC sigue siendo el coeficiente Kappa de Cohen, a pesar de las críticas explícitas a su uso en mapas de cambio. Kappa mezcla dos fuentes de error: desacuerdo en cantidad y desacuerdo en asignación, que tienen significados metodológicos distintos (Pontius Jr et al., 2008). Esta descomposición separa:

- **Quantity disagreement:** el modelo predice un total de celdas de cambio distinto al observado, sin importar dónde.
- **Allocation disagreement:** el modelo predice el total correcto de cambio pero lo asigna a celdas incorrectas.

Un modelo puede ser perfecto en *quantity* y catastrófico en *allocation*: predice exactamente el área urbana total pero en lugares equivocados. El FoM, definido como el índice de Jaccard restringido a las celdas de cambio, es sensible exactamente a este problema.

La Intersection over Union (IoU) sobre la clase urbana provee información complementaria: mientras el FoM evalúa la calidad de la predicción del cambio, la IoU evalúa la calidad de la predicción del estado urbano final. Reportar ambas evita el sesgo de evaluar solo la dinámica o solo el estado. Dicho de forma sencilla: FoM es una métrica que penaliza la cantidad de celdas que no cambian de estado, mientras que IoU es una métrica que penaliza la cantidad de celdas que se clasifican incorrectamente.

El presente trabajo adopta este protocolo de evaluación: FoM como métrica primaria para el cambio, IoU para el estado, Kappa por compatibilidad con la literatura previa y un análisis explícito de la descomposición quantity vs. allocation cuando el FoM es bajo.

3.5. Vacíos específicos en el contexto mexicano

La literatura mexicana sobre modelado de crecimiento urbano es escasa pero útil y de vanguardia. Suárez y Delgado (2007) construyó el primer estudio de predicción espacial sistemática para la Zona Metropolitana de la Ciudad de México: a partir de proyecciones demográficas de CONAPO al 2020, éste distribuyó hectáreas adicionales en contornos metropolitanos bajo tres escenarios de densidad. El trabajo es relevante por su pionería pero no es un modelo Autómatas Celulares: no hay reglas de vecindad, no hay calibración sobre datos históricos de cambio celular y la validación se hace a nivel de totales de hectáreas, no a nivel de celda, pues se usan agregados y no datos a nivel grano. R1, R4 y la replicabilidad pública no aplican; la única dimensión satisfecha es R2.

Ramírez Hernández (2021), en un libro institucional de IIEc-UNAM, aplica un AC inspirado en SLEUTH a la ZMCM con datos de 1990–2010 y proyecta al 2040. Los parámetros se describen en el texto pero el código no está disponible y la validación no reporta FoM ni Kappa de forma sistemática. La obra es valiosa como referencia conceptual pero no como benchmark cuantitativo, es decir, no es posible comparar su desempeño con el rango de métricas reportadas en Pontius Jr et al. (2008).

Así pues, García-Ramírez et al. (2023) aplica una cadena SVM + regresión logística + CA-Markov en TerrSet/IDRISI a núcleos urbanos asentados en cinco cuencas hidrológicas del estado de Chihuahua (Laguna Bustillos y de los Mexicanos, río Conchos, Ojinaga, río Conchos, Presa de la Colina, río Conchos, Presa el Granero y río San Pedro), con proyecciones a 2030, 2040 y 2050. La clasificación SVM sobre mapas de uso de suelo 2010–2020 es reproducible y la regresión logística aporta interpretabilidad parcial (pseudo R^2 de McFadden superior a 0.2, ROC aceptable), pero la asignación CA-Markov ocurre dentro del módulo Land Change Modeler de TerrSet, software no libre, y la validación cuantitativa se reporta sobre la regresión logística, no sobre la simulación CA en sí. R4 se cumple parcialmente; R3 no se cumple.

El cuadrante metodológico que estos tres trabajos definen es claro:

Cuadro 3.1: Posicionamiento de la literatura mexicana frente a R1–R4.

Trabajo	R1	R2	R3	R4
Suárez y Delgado (2007)	—	✓	—	—
Ramírez Hernández (2021)	—	✓	—	parcial
García-Ramírez et al. (2023)	parcial	✓	—	parcial
Presente trabajo	✓	✓	✓	✓

Ningún trabajo publicado para una ciudad mexicana cumple simultáneamente con validación multi-período cuantitativa, reproducibilidad abierta e interpretabilidad auditable a nivel de celda. Esa es la brecha que el presente trabajo atiende, y es la razón por la cual la elección de Querétaro como caso de estudio no es sustituible: aplicar el método sobre una ciudad ya estudiada por modelos de caja negra no generaría comparación válida con la literatura existente; aplicarlo sobre una ciudad intermedia sin estudios previos abre el espacio metodológico.

3.6. Síntesis: posicionamiento del presente trabajo

Los cuatro problemas metodológicos analizados (equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software propietario) se cruzan con la topología espacial del campo. Las revisiones sistemáticas de Santé et al. (2010) y Aburas et al. (2016) muestran que las aplicaciones documentadas se concentran en China, Europa y Estados Unidos, mientras que la literatura mexicana revisada en la sección anterior avanza con modelos heredados o con herramientas propietarias que limitan la auditoría.

El presente trabajo se ubica en la intersección de tres decisiones: (i) usar WoE como función de transición, lo que satisface R4 sin renunciar a la rigurosidad estadística; (ii) validar en cinco ventanas quinquenales independientes con FoM, Kappa e IoU, lo que satisface R1 y permite distinguir robustez de sobreajuste; (iii) implementar el flujo completo en Python con datos abiertos, lo que satisface R3 y abre la posibilidad de replicación en otras ciudades intermedias mexicanas. R2, la utilidad para planeación urbana, se cumple por construcción: los mapas resultantes son raster celda a celda con probabilidades de transición auditables.

El Capítulo ?? describe el área de estudio —la Zona Metropolitana de Querétaro— y la construcción de la serie histórica de mapas urbano/no-urbano que alimenta el modelo. Ese insumo es el que permite poner a prueba, sobre una ciudad intermedia mexicana aún no modelada con estas herramientas, las decisiones de diseño que este capítulo justificó: una calibración acotada e interpretable frente a la equifinalidad, una validación multi-ventana frente

al sobreajuste temporal y una implementación abierta frente a la dependencia de software propietario.

Bibliografía

- Aburas, M. M., Ho, Y. M., Ramli, M. F., & Ash'aari, Z. H. (2016). The simulation and prediction of spatio-temporal urban growth trends using cellular automata models: A review. *International Journal of Applied Earth Observation and Geoinformation*, 52, 380-389. <https://doi.org/10.1016/j.jag.2016.07.007>
- Almeida, C. M., Gleriani, J. M., Castejon, E. F., & Soares-Filho, B. S. (2008). Using neural networks and cellular automata for modelling intra-urban land-use dynamics. *International Journal of Geographical Information Science*, 22(9), 943-963. <https://doi.org/10.1080/13658810701731168>
- Bonham-Carter, G. F. (1994). *Geographic Information Systems for Geoscientists: Modelling with GIS* (Vol. 13). Pergamon.
- Clarke, K. C. (2008). A Decade of Cellular Urban Modeling with SLEUTH: Unresolved Issues and Problems. En R. K. Brail (Ed.), *Planning Support Systems for Cities and Regions* (pp. 47-60). Lincoln Institute of Land Policy.
- Clarke, K. C., & Gaydos, L. J. (1998). Loose-coupling a Cellular Automaton Model and GIS: Long-term Urban Growth Prediction for San Francisco and Washington/Baltimore. *International Journal of Geographical Information Science*, 12(7), 699-714. <https://doi.org/10.1080/136588198241617>
- García-Ramírez, P., Alatorre-Cejudo, L. C., & Bravo-Peña, L. C. (2023). Detección, modelización y proyección del crecimiento urbano de núcleos de población en diferentes cuencas hidrológicas de Chihuahua, México. *Investigación y Ciencia de la Universidad Autónoma de Aguascalientes*, 31(90), 1-19. <https://doi.org/10.33064/iycuaa2023904103>
- Hagenauer, J., & Helbich, M. (2022). A geographically weighted artificial neural network. *International Journal of Geographical Information Science*, 36(2), 215-235. <https://doi.org/10.1080/13658816.2021.1871618>
- Jantz, C. A., Goetz, S. J., & Shelley, M. K. (2003). Using the SLEUTH Urban Growth Model to Simulate the Impacts of Future Policy Scenarios on Urban Land Use in the Baltimore-

- Washington Metropolitan Area. *Environment and Planning B: Planning and Design*, 30(2), 251-271. <https://doi.org/10.1068/b2983>
- Liu, X., Liang, X., Li, X., Xu, X., Ou, J., Chen, Y., Li, S., Wang, S., & Pei, F. (2017). A future land use simulation model (FLUS) for simulating multiple land use scenarios by coupling human and natural effects. *Landscape and Urban Planning*, 168, 94-116. <https://doi.org/10.1016/j.landurbplan.2017.09.019>
- Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. (2019). Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166-177.
- Pontius Jr, R. G., Boersma, W., Castella, J.-C., Clarke, K., de Nijs, T., Dietzel, C., Duan, Z., Fotsing, E., Goldstein, N., Kok, K., Koomen, E., Lippitt, C. D., McConnell, W., Mohd Sood, A., Pijanowski, B., Pithadia, S., Sweeney, S., Trung, T. N., Veldkamp, A. T., & Verburg, P. H. (2008). Comparing the input, output, and validation maps for several models of land change. *The Annals of Regional Science*, 42(1), 11-37. <https://doi.org/10.1007/s00168-007-0138-2>
- Ramírez Hernández, R. (2021). *Zona Metropolitana de la Ciudad de México: crecimiento y expansión al 2040. Prospectiva territorial usando modelos de simulación urbana*. Universidad Nacional Autónoma de México, Instituto de Investigaciones Económicas. <https://doi.org/10.22201/iiec.9786073044349e.2021>
- Santé, I., García, A. M., Miranda, D., & Crecente, R. (2010). Cellular automata models for the simulation of real-world urban processes: A review and analysis. *Landscape and Urban Planning*, 96(2), 108-122. <https://doi.org/10.1016/j.landurbplan.2010.03.001>
- Silva, E. A., & Clarke, K. C. (2002). Calibration of the SLEUTH urban growth model for Lisbon and Porto, Portugal. *Computers, Environment and Urban Systems*, 26(6), 525-552. [https://doi.org/10.1016/S0198-9715\(01\)00014-X](https://doi.org/10.1016/S0198-9715(01)00014-X)
- Soares-Filho, B. S., Cerqueira, G. C., & Pennachin, C. L. (2002). DINAMICA—a stochastic cellular automata model designed to simulate the landscape dynamics in an Amazonian colonization frontier. *Ecological Modelling*, 154(3), 217-235. [https://doi.org/10.1016/S0304-3800\(02\)00059-5](https://doi.org/10.1016/S0304-3800(02)00059-5)
- Suárez, M., & Delgado, J. (2007). La expansión urbana probable de la Ciudad de México. Un escenario pesimista y dos alternativos para el año 2020. *Estudios Demográficos y Urbanos*, 22(1), 101-142. <https://doi.org/10.24201/edu.v22i1.1295>
- Verburg, P. H., Soepboer, W., Veldkamp, A., Limpiada, R., Espaldon, V., & Mastura, S. S. A. (2002). Modeling the spatial dynamics of regional land use: the CLUE-S model. *Environmental Management*, 30(3), 391-405. <https://doi.org/10.1007/s00267-002-2630-x>

- Wang, R., He, Q., Zhang, L., & Wang, H. (2021). Coupling Cellular Automata and a Genetic Algorithm to Generate a Vibrant Urban Form—A Case Study of Wuhan, China. *International Journal of Environmental Research and Public Health*, 18(21), 11013. <https://doi.org/10.3390/ijerph182111013>
- White, R., & Engelen, G. (1997). Cellular Automata as the Basis of Integrated Dynamic Regional Modelling. *Environment and Planning B: Planning and Design*, 24, 235-246. <https://doi.org/10.1068/b240235>