

Capítulo 3

Estado del arte

El modelado computacional del crecimiento urbano ha producido en treinta años una literatura abundante pero metodológicamente desigual. Este capítulo no cataloga trabajos por autor sino que identifica los cuatro problemas metodológicos que siguen abiertos en el campo, calibración por fuerza bruta, validación sobreajustada a una sola ventana temporal, opacidad de la función de transición en modelos de aprendizaje profundo y dependencia de software propietario, y muestra cómo cada uno justifica una decisión concreta del diseño del modelo WoE-AC propuesto. La discusión cierra con un mapa de la literatura para ciudades mexicanas, donde ningún trabajo publicado satisface simultáneamente los requerimientos R1–R4 de la Tabla ??.

3.1. Evolución del modelado urbano computacional

El modelado de la dinámica urbana mediante autómatas celulares se consolidó con White y Engelen (1997), que mostró que reglas locales basadas en distancia y vecindad podían reproducir patrones metropolitanos realistas. La generalización del enfoque vino con SLEUTH (Clarke & Gaydos, 1998; Silva & Clarke, 2002), que durante dos décadas funcionó como referencia y se aplicó en decenas de ciudades. Paralelamente, la tradición LUCC (Land Use and Cover Change) introdujo modelos basados en mapas de idoneidad estadística: familias como CLUE-S, Dinamica EGO, CA-Markov y, más recientemente, FLUS, GeoSOS y MOLUSCE, ofrecieron arquitecturas alternativas al CA puro en las que la función de transición emerge de regresiones logísticas o pesos bayesianos sobre datos históricos.

Una corriente posterior sustituyó la regresión por modelos de aprendizaje automático e híbridos metaheurísticos. Almeida et al. (2008) acopló una red neuronal feedforward a un CA estocástico para Piracicaba, Brasil; años más tarde Wang et al. (2021) combinó un autómata

celular con un algoritmo genético para optimizar la forma urbana de Wuhan, mientras Hagenauer y Helbich (2022) introdujo una red neuronal geográficamente ponderada para capturar relaciones espaciales no lineales. Estos enfoques reportan ganancias cuantitativas, pero sustituyen pesos legibles por activaciones internas o cromosomas que no admiten una lectura geográfica directa.

La tensión central del campo no es entonces entre AC y aprendizaje automático, sino entre dos objetivos que parecen contrapuestos: maximizar precisión predictiva y mantener la trazabilidad de cada decisión espacial. Las secciones siguientes muestran que esta tensión es resoluble si se cambia la pregunta metodológica.

3.2. Problemas metodológicos persistentes

3.2.1. Calibración: equifinalidad y costo computacional

SLEUTH calibra cinco coeficientes enteros mediante búsqueda en cuadrícula sobre el espacio discreto $[0, 100]^4 \times [0, 20]$, es decir, en el orden de 10^9 combinaciones evaluadas con simulaciones Monte Carlo de 100 iteraciones cada una. Clarke y Gaydos (1998) resolvió el problema con tres fases: coarse, fine, final, que reducen el espacio iterativamente; aun así, una calibración completa toma días en hardware contemporáneo (Jantz et al., 2003). El problema metodológico no es solo el costo: es la **equifinalidad**, esto es, la existencia de múltiples combinaciones de coeficientes que producen patrones indistinguibles a la métrica de calibración pero divergen en proyecciones de largo plazo (Clarke, 2008). Sin un criterio adicional, la elección entre combinaciones equifinales termina dependiendo del operador.

El presente trabajo evita el problema redefiniéndolo: en lugar de calibrar coeficientes que controlan reglas geométricas genéricas (diffusion, breed, spread), calibra dos parámetros que controlan la combinación de evidencia espacial empírica (umbral de transición y peso de vecindad). El espacio de búsqueda es de dos dimensiones y la calibración termina en minutos. Más importante: cada configuración candidata produce mapas de idoneidad cuyos pesos por variable son directamente auditables, eliminando la ambigüedad asociada a la equifinalidad.

3.2.2. Validación: sobreajuste temporal y métricas no comparables

Pontius Jr et al. (2008) analizó trece aplicaciones independientes de nueve modelos de cambio de uso de suelo y propuso el Figure of Merit (FoM) como métrica estándar comparable entre estudios. Su hallazgo es incómodo: seis de las trece aplicaciones obtienen FoM inferior al 15 % y solo una supera el 50 %. La dispersión no se explica por la sofisticación del modelo sino por la magnitud del cambio neto observado: el FoM crece monotónicamente con el porcentaje de

celdas que efectivamente cambian de estado.

Esto tiene dos implicaciones que la literatura rara vez confronta. Primero, **validar en una sola ventana temporal es estadísticamente insuficiente**: si el FoM depende de la magnitud del cambio, una validación única no permite distinguir entre un modelo robusto y uno ajustado a una fase específica del crecimiento. Santé et al. (2010) y Aburas et al. (2016) confirman, en sus respectivas revisiones sistemáticas, que la validación en un único período es la norma, no la excepción, en la literatura de Autómatas Celulares. Segundo, **reportar Kappa o Accuracy sin FoM infla artificialmente la calidad del modelo**: en un sistema urbano consolidado donde el 90 % de las celdas permanece sin cambio, un modelo trivial que predice “no cambio” en todas las celdas obtiene Accuracy de 0.90 sin capturar ninguna dinámica.

La consecuencia metodológica es directa: la validación del WoE-AC se realiza en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020), reportando FoM, Kappa e IoU simultáneamente. La estabilidad del FoM a través de las cinco ventanas, no su valor absoluto en una sola, es lo que permite distinguir mecanismos espaciales reales de sobreajuste.

3.2.3. Interpretabilidad: el problema de la caja negra

Almeida et al. (2008) entrenó una red neuronal feedforward con backpropagation sobre variables biofísicas e infraestructurales de Piracicaba (Brasil, 1985–1999); la red aprende pesos sinápticos que alimentan a un CA estocástico. El modelo reporta concordancia espacial superior a los AC clásicos de la época, pero los pesos no son traducibles a una pregunta geográfica: no se puede afirmar que “la distancia a vialidades contribuyó un X % a la transición de esta celda”. La activación de cada neurona es una combinación no lineal de todas las variables de entrada, sin descomposición legible.

Trabajos posteriores intensifican esta opacidad por dos vías. La primera es la optimización metaheurística: Wang et al. (2021) acopla un autómata celular a un algoritmo genético para generar formas urbanas que maximizan un índice de vitalidad en Wuhan, donde cada generación produce cromosomas que carecen de lectura geográfica directa. La segunda es el aprendizaje profundo aplicado a teledetección y modelado espacial (Hagenauer & Helbich, 2022; Ma et al., 2019), que requiere GPU y conjuntos de datos masivos para entrenar redes cuyas representaciones internas no son auditables. La ganancia en exactitud es real, pero el costo metodológico es alto: el modelo clasifica sin justificar, y la justificación es exactamente lo que un instrumento de planeación urbana requiere. Un plan municipal sustentado en “el modelo lo predijo” es jurídica y políticamente más débil que uno sustentado en “históricamente, la proximidad al frente urbano contribuye con un Information Value de X a la probabilidad de transición”.

El método de Pesos de Evidencia provee exactamente esa descomposición. La elección de WoE en este trabajo no responde a una preferencia estética por la transparencia: responde al requerimiento R4 de la Tabla ??, que define la auditabilidad como condición de uso del modelo, no como propiedad accesoria.

3.2.4. Transferibilidad: software propietario y reproducibilidad

Una fracción significativa de los modelos LUCC más citados depende de software propietario. Dinamica EGO opera bajo licencia académica restringida; IDRISI y TerrSet son comerciales; SLEUTH funciona con un código en C disponible pero cuya instalación en sistemas modernos requiere ajustes no documentados. La consecuencia práctica es que la reproducibilidad de los resultados publicados es, en el mejor de los casos, parcial: el lector puede leer el método pero no ejecutarlo sin acceso a infraestructura específica.

Esta dependencia tiene una consecuencia material poco discutida en la literatura metodológica: el acceso a licencias y a hardware especializado introduce una barrera de entrada que condiciona qué grupos académicos pueden reproducir o extender los modelos publicados. En contextos donde estos recursos son limitados, la única alternativa práctica es reescribir el pipeline desde cero. El presente trabajo opta por esta vía: se implementa íntegramente en Python con dependencias de código abierto (NumPy, SciPy, scikit-learn) sobre datos públicos (Google Earth Engine, INEGI), satisfaciendo R3 sin concesiones.

3.3. Pesos de Evidencia y modelos probabilísticos espaciales

El método de Pesos de Evidencia, desarrollado por Bonham-Carter (1994) en el contexto de la prospección mineral, se formaliza en el Capítulo ?? (ecuación ??): para cada clase de una variable espacial discretizada se calcula un peso bayesiano que cuantifica la asociación entre dicha clase y la ocurrencia del evento de interés en este trabajo, la transición de suelo no urbano a urbano. El peso total por celda es la suma de los pesos de las variables evaluadas en ella, transformada por la función logística para obtener una probabilidad acotada (ecuación ??); el Information Value sintetiza el poder discriminatorio de cada variable. La presente sección no repite la derivación matemática, sino que la sitúa en la literatura LUCC.

La adaptación al modelado LUCC se consolidó con herramientas como Dinamica EGO, que combinan mapas de idoneidad WoE con un autómata celular de dos pasos, *expander* y *patcher*, que reproduce la geometría del cambio observado. La literatura derivada documenta

aplicaciones a deforestación amazónica, expansión agrícola y, en menor medida, crecimiento urbano.

El WoE tiene tres limitaciones estadísticas reconocidas que es necesario explicitar para evitar atribuirle propiedades que no posee:

Independencia condicional. La suma de pesos asume que las variables son condicionalmente independientes dada la ocurrencia del evento. Este supuesto rara vez se satisface en variables espaciales urbanas, donde proximidad a vialidades y proximidad al frente urbano están correlacionadas. El presente trabajo no introduce una corrección formal para esta dependencia; sigue la práctica estándar de la literatura LUCC, que reporta el sesgo derivado mediante el contraste empírico con el cambio observado. La validación multi-período mitiga parcialmente el problema: si el sesgo fuera dominante, el FoM degradaría sistemáticamente entre ventanas.

Sensibilidad a la discretización. Los pesos dependen de cómo se categorice cada variable continua. El presente trabajo adopta una discretización basada en cuantiles uniformes, que es la convención más reproducible aunque no necesariamente la óptima en términos de IV.

Multicolinealidad entre drivers. Variables fuertemente correlacionadas producen pesos redundantes que inflan la magnitud aparente de la evidencia. Este trabajo aplica un análisis de componentes principales sobre el conjunto de variables espaciales antes del cálculo de IV, lo que reduce la redundancia sin sacrificar interpretabilidad.

3.4. Validación espacial en modelos LUCC

La métrica más reportada en LUCC sigue siendo el coeficiente Kappa de Cohen, a pesar de las críticas explícitas a su uso en mapas de cambio. Kappa mezcla dos fuentes de error: desacuerdo en cantidad y desacuerdo en asignación, que tienen significados metodológicos distintos (Pontius Jr et al., 2008). Esta descomposición separa:

- **Quantity disagreement:** el modelo predice un total de celdas de cambio distinto al observado, sin importar dónde.
- **Allocation disagreement:** el modelo predice el total correcto de cambio pero lo asigna a celdas incorrectas.

Un modelo puede ser perfecto en *quantity* y catastrófico en *allocation*: predice exactamente el área urbana total pero en lugares equivocados. El FoM, definido como el índice de Jaccard restringido a las celdas de cambio, es sensible exactamente a este problema.

La Intersection over Union (IoU) sobre la clase urbana provee información complementaria: mientras el FoM evalúa la calidad de la predicción del cambio, la IoU evalúa la calidad de la predicción del estado urbano final. Reportar ambas evita el sesgo de evaluar solo la dinámica o solo el estado.

El presente trabajo adopta este protocolo de evaluación: FoM como métrica primaria para el cambio, IoU para el estado, Kappa por compatibilidad con la literatura previa y un análisis explícito de la descomposición quantity vs. allocation cuando el FoM es bajo.

3.5. Vacíos específicos en el contexto mexicano

La literatura mexicana sobre modelado de crecimiento urbano es escasa pero reveladora. Suárez y Delgado (2007) construyó el primer estudio de prospección espacial sistemática para la Zona Metropolitana de la Ciudad de México: a partir de proyecciones demográficas de CONAPO al 2020, distribuyó hectáreas adicionales en contornos metropolitanos bajo tres escenarios de densidad. El trabajo es relevante por su pionería pero no es un modelo CA: no hay reglas de vecindad, no hay calibración sobre datos históricos de cambio celular y la validación se hace a nivel de totales de hectáreas, no a nivel de celda. R1, R4 y la replicabilidad pública no aplican; la única dimensión satisfecha es R2.

Ramírez Hernández (2021), en un libro institucional de IIEc-UNAM, aplica un AC inspirado en SLEUTH a la ZMCM con datos de 1990–2010 y proyecta al 2040. Los parámetros se describen en el texto pero el código no está disponible y la validación no reporta FoM ni Kappa de forma sistemática. La obra es valiosa como referencia conceptual pero no como benchmark cuantitativo: no es posible comparar su desempeño con el rango de Pontius Jr et al. (2008).

García-Ramírez et al. (2023) aplica una cadena SVM + regresión logística + CA-Markov en TerrSet/IDRISI a núcleos urbanos asentados en cinco cuencas hidrológicas del estado de Chihuahua (Laguna Bustillos y de los Mexicanos, río Conchos, Ojinaga, río Conchos, Presa de la Colina, río Conchos, Presa el Granero y río San Pedro), con proyecciones a 2030, 2040 y 2050. La clasificación SVM sobre mapas de uso de suelo 2010–2020 es reproducible y la regresión logística aporta interpretabilidad parcial (pseudo R^2 de McFadden superior a 0.2, ROC aceptable), pero la asignación CA-Markov ocurre dentro del módulo Land Change Modeler de TerrSet, software propietario, y la validación cuantitativa se reporta sobre la regresión logística, no sobre la simulación CA en sí. R4 se cumple parcialmente; R3 no se cumple.

El cuadrante metodológico que estos tres trabajos definen es claro:

Cuadro 3.1: Posicionamiento de la literatura mexicana frente a R1–R4.

Trabajo	R1	R2	R3	R4
Suárez y Delgado (2007)	—	✓	—	—
Ramírez Hernández (2021)	—	✓	—	parcial
García-Ramírez et al. (2023)	parcial	✓	—	parcial
Presente trabajo	✓	✓	✓	✓

Ningún trabajo publicado para una ciudad mexicana cumple simultáneamente con validación multi-período cuantitativa, reproducibilidad abierta e interpretabilidad auditable a nivel de celda. Esa es la brecha que el presente trabajo atiende, y es la razón por la cual la elección de Querétaro como caso de estudio no es sustituible: aplicar el método sobre una ciudad ya estudiada por modelos de caja negra no generaría comparación válida con la literatura existente; aplicarlo sobre una ciudad intermedia sin estudios previos abre el espacio metodológico.

3.6. Síntesis: posicionamiento del presente trabajo

Los cuatro problemas metodológicos analizados (equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software propietario) se cruzan con la geografía del campo. Las revisiones sistemáticas de Santé et al. (2010) y Aburas et al. (2016) muestran que las aplicaciones documentadas se concentran en China, Europa y Estados Unidos, mientras que la literatura mexicana revisada en la sección anterior avanza con modelos heredados o con herramientas propietarias que limitan la auditoría.

El presente trabajo se ubica en la intersección de tres decisiones: (i) usar WoE como función de transición, lo que satisface R4 sin renunciar a la rigurosidad estadística; (ii) validar en cinco ventanas quinquenales independientes con FoM, Kappa e IoU, lo que satisface R1 y permite distinguir robustez de sobreajuste; (iii) implementar el pipeline completo en Python con datos abiertos, lo que satisface R3 y abre la posibilidad de replicación en otras ciudades intermedias mexicanas. R2, la utilidad para planeación urbana, se cumple por construcción: los mapas resultantes son raster celda a celda con probabilidades de transición auditables.

El siguiente capítulo describe el área de estudio y la construcción de la serie histórica de mapas urbano/no-urbano que alimenta el modelo.

Bibliografía

- Aburas, M. M., Ho, Y. M., Ramli, M. F., & Ash'aari, Z. H. (2016). The simulation and prediction of spatio-temporal urban growth trends using cellular automata models: A review. *International Journal of Applied Earth Observation and Geoinformation*, 52, 380-389. <https://doi.org/10.1016/j.jag.2016.07.007>
- Almeida, C. M., Gleriani, J. M., Castejon, E. F., & Soares-Filho, B. S. (2008). Using neural networks and cellular automata for modelling intra-urban land-use dynamics. *International Journal of Geographical Information Science*, 22(9), 943-963. <https://doi.org/10.1080/13658810701731168>
- Bonham-Carter, G. F. (1994). *Geographic Information Systems for Geoscientists: Modelling with GIS* (Vol. 13). Pergamon.
- Clarke, K. C. (2008). A Decade of Cellular Urban Modeling with SLEUTH: Unresolved Issues and Problems. En R. K. Brail (Ed.), *Planning Support Systems for Cities and Regions* (pp. 47-60). Lincoln Institute of Land Policy.
- Clarke, K. C., & Gaydos, L. J. (1998). Loose-coupling a Cellular Automaton Model and GIS: Long-term Urban Growth Prediction for San Francisco and Washington/Baltimore. *International Journal of Geographical Information Science*, 12(7), 699-714. <https://doi.org/10.1080/136588198241617>
- García-Ramírez, P., Alatorre-Cejudo, L. C., & Bravo-Peña, L. C. (2023). Detección, modelización y proyección del crecimiento urbano de núcleos de población en diferentes cuencas hidrológicas de Chihuahua, México. *Investigación y Ciencia de la Universidad Autónoma de Aguascalientes*, 31(90), 1-19. <https://doi.org/10.33064/iycuaa2023904103>
- Hagenauer, J., & Helbich, M. (2022). A geographically weighted artificial neural network. *International Journal of Geographical Information Science*, 36(2), 215-235. <https://doi.org/10.1080/13658816.2021.1871618>
- Jantz, C. A., Goetz, S. J., & Shelley, M. K. (2003). Using the SLEUTH Urban Growth Model to Simulate the Impacts of Future Policy Scenarios on Urban Land Use in the Baltimore-

- Washington Metropolitan Area. *Environment and Planning B: Planning and Design*, 30(2), 251-271. <https://doi.org/10.1068/b2983>
- Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. (2019). Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166-177.
- Pontius Jr, R. G., Boersma, W., Castella, J.-C., Clarke, K., de Nijs, T., Dietzel, C., Duan, Z., Fotsing, E., Goldstein, N., Kok, K., Koomen, E., Lippitt, C. D., McConnell, W., Mohd Sood, A., Pijanowski, B., Pithadia, S., Sweeney, S., Trung, T. N., Veldkamp, A. T., & Verburg, P. H. (2008). Comparing the input, output, and validation maps for several models of land change. *The Annals of Regional Science*, 42(1), 11-37. <https://doi.org/10.1007/s00168-007-0138-2>
- Ramírez Hernández, R. (2021). *Zona Metropolitana de la Ciudad de México: crecimiento y expansión al 2040. Prospectiva territorial usando modelos de simulación urbana*. Universidad Nacional Autónoma de México, Instituto de Investigaciones Económicas. <https://doi.org/10.22201/iiec.9786073044349e.2021>
- Santé, I., García, A. M., Miranda, D., & Crecente, R. (2010). Cellular automata models for the simulation of real-world urban processes: A review and analysis. *Landscape and Urban Planning*, 96(2), 108-122. <https://doi.org/10.1016/j.landurbplan.2010.03.001>
- Silva, E. A., & Clarke, K. C. (2002). Calibration of the SLEUTH urban growth model for Lisbon and Porto, Portugal. *Computers, Environment and Urban Systems*, 26(6), 525-552. [https://doi.org/10.1016/S0198-9715\(01\)00014-X](https://doi.org/10.1016/S0198-9715(01)00014-X)
- Suárez, M., & Delgado, J. (2007). La expansión urbana probable de la Ciudad de México. Un escenario pesimista y dos alternativos para el año 2020. *Estudios Demográficos y Urbanos*, 22(1), 101-142. <https://doi.org/10.24201/edu.v22i1.1295>
- Wang, R., He, Q., Zhang, L., & Wang, H. (2021). Coupling Cellular Automata and a Genetic Algorithm to Generate a Vibrant Urban Form—A Case Study of Wuhan, China. *International Journal of Environmental Research and Public Health*, 18(21), 11013. <https://doi.org/10.3390/ijerph182111013>
- White, R., & Engelen, G. (1997). Cellular Automata as the Basis of Integrated Dynamic Regional Modelling. *Environment and Planning B: Planning and Design*, 24, 235-246. <https://doi.org/10.1068/b240235>