

Capítulo 5

Modelo de crecimiento urbano

Este capítulo muestra una visión exhaustiva del modelo citado a lo largo de todo este trabajo como WoE-A, se presentan las decisiones explícitas de cada componente del modelo, preprocesamiento y validación. Si bien el segundo capítulo del presente trabajo da una definición a cada concepto utilizado, no hay una argumentación de por qué se utiliza cada una de las componentes del flujo completo que al trabajo presente le compete. Se inicia, como ya el lector debe saber, con la definición del flujo de preprocesamiento de datos, seguido por el modelo que consume los datos preprocesados para calcular la matriz de transiciones históricas, seguido por la definición del autómata celular probabilístico y finalmente la validación del modelo.

5.1. Preprocesamiento de datos.

El preprocesamiento de datos, para este trabajo sienta la verdad que el modelo WoE-AC utiliza para predecir la dinámica urban. Por ende, se debe entender el preprocesamiento de datos como el proceso que convierte las capturas RGB en mapas binarios urbano/no-urbano (pipeline LBP + K-Means + SVM); en el capítulo ?? en particular en la figura ?? se muestra el flujo completo de preprocesamiento de datos, primero: se obtiene un tensor RGB de $1,792 \times 3,024 \times 3$ píxeles, esto constituye la información cruda de entrada al flujo.

En el siguiente paso, se realiza una transformación de este arreglo de $1,792 \times 3,024 \times 3$ píxeles a un arreglo de $1,792 \times 3,024 \times 23$ píxeles. Este paso conlleva la primer decisión crítica en la definición del flujo, pues en vez de utilizar índices espectrales, se decide obtener 23 features por celda. Esto tiene una razón de ser: las capturas disponibles son RGB, de tres bandas visibles, NDVI requiere NIR; NDWI requiere NIR o SWIR; NDBI requiere SWIR. Ninguno de esos índices es computable a partir de RGB puro, eso elimina la clase mas común de clasificadores

de cobertura de suelo que usa la literatura. Esto tiene una consecuencia directa, con solo bandas visibles, los píxeles urbanos (techo gris, asfalto) y los de suelo desnudo (arcilla, tierra agrícola seca) tienen un parecido espectral RGB prácticamente indistinguibles. La solución a este problema consiste en extender la representación por píxel con 23 features definidas en las tablas ??, ?? y ?. El objetivo es codificar la textura (LBP, Sobel, entropía, contraste) y espacios de color perceptuales (LAB, HSV). El tejido urbano tiene un patrón espacial regular, cuadrícula de calles, alineación de techados; que la vegetación y el suelo agrícola no tienen. LBP captura exactamente esa regularidad; es un descriptor diseñado para distinguir texturas y ha sido validado en clasificación de imágenes de satélite de baja resolución espectral.

Sin embargo, al ser 23 features o características, esto conlleva un problema de explosión de parámetros a clasificar, es decir, en vez de trabajar sobre un espacio de $\mathbb{R}^3$, se debe trabajar sobre un espacio de $\mathbb{R}^{23}$, lo cual es computacionalmente muy demandante. La solución a este problema consiste en reducir la dimensionalidad de las features mediante PCA.

Antes de aplicar el PCA hay un paso intermedio que no puede omitirse: las 23 características viven en escalas muy distintas. Un canal RGB está acotado entre 0 y 255, mientras que el índice de exceso de verde o las componentes del espacio LAB toman valores en rangos completamente diferentes. Si se aplicara PCA directamente sobre esas escalas, las features de mayor magnitud dominarían artificialmente las primeras componentes, no porque contengan más información, sino simplemente por tener números más grandes. Por ello cada característica se estandariza primero con un StandardScaler (Algoritmo ??), que centra cada columna en media cero y varianza unitaria; con esto las 23 features quedan en condiciones comparables y el PCA puede operar sobre la varianza real de cada una.

Sobre la matriz ya estandarizada se aplica entonces el PCA (Algoritmo ??), que proyecta las 23 dimensiones a un espacio de 8 componentes ortogonales. La elección de 8 componentes no es arbitraria: durante el desarrollo del modelo se observó que estas 8 componentes retienen alrededor del 96 % de la varianza total de la serie. Este número revela además un hecho importante sobre los datos: si las features de textura y color fueran meras combinaciones del RGB crudo, bastarían 3 o 4 componentes para alcanzar ese mismo 96 %; el que se necesiten 8 confirma que la textura y el color sí aportan información complementaria y no redundante. La ortogonalidad de las componentes resuelve, de paso, un problema que de otro modo afectaría al siguiente paso del flujo: la fuerte correlación entre R, G, B, intensidad y brillo distorsionaría la distancia euclidiana con la que K-Means agrupa, al contar varias veces la misma información espectral. Tras el PCA se obtiene una matriz $Z \in \mathbb{R}^{N \times 8}$ que es la entrada del clasificador.

La siguiente decisión es cómo etiquetar cada píxel como urbano o no-urbano. La vía más

directa sería una clasificación supervisada con etiquetas manuales, pero aquí aparece una restricción propia del problema: la serie cubre 37 años (1984–2020). Etiquetar manualmente exigiría entre 500 y 1,000 píxeles por imagen, coherentes entre años, lo que suma decenas de miles de decisiones manuales. Por eso se opta por una vía no supervisada: K-Means con $k = 2$ (Algoritmo ??). Su valor en este contexto no es la exactitud cartográfica frente a una verdad terreno, sino la consistencia interna de la serie, minimizar la inercia intra-cluster, es decir, es idéntica para todos los años, el criterio que separa lo urbano de lo no-urbano en 1990 es el mismo que en 2010. Esa consistencia es justamente lo que hace que las transiciones entre años sean comparables y puedan, más adelante, alimentar el cálculo WoE sin introducir sesgos por cambios de criterio.

K-Means por sí solo, sin embargo, deja una frontera de decisión frágil: al separar el espacio por la mediatriz entre los dos centroides, los píxeles de valor intermedio, zonas periurbanas, sombras, cobertura mixta, pueden desplazar esos centroides hacia regiones ambiguas. Para corregir esto, las etiquetas de K-Means no se usan como resultado final, sino como pseudo-etiquetas para entrenar un SVM lineal (Algoritmo ??). El SVM busca el hiperplano de máximo margen en el espacio PCA, lo que regulariza la frontera y la vuelve robusta frente a esos píxeles atípicos; el kernel lineal es suficiente porque el PCA ya proyectó los datos en un espacio donde las dos clases son aproximadamente separables. El efecto de este refinamiento es medible: a lo largo de la serie el SVM alcanzó entre el 88 % y el 94 % de exactitud sobre el 20 % de píxeles reservados para prueba, por encima de lo que produce una umbralización simple sobre las mismas imágenes.

El último paso es operativo, pero necesario para cerrar el flujo: el SVM entrega dos clases, pero no sabe cuál de ellas corresponde a la mancha urbana. Esa asignación se realiza de forma manual, fijando la convención urbano = 1 / no-urbano = 0. Con ello, cada captura RGB queda convertida en un mapa binario $U_t(x, y) \in \{0, 1\}$, y la repetición del procedimiento sobre los 37 años produce la serie $\{U_t\}_{t=1984}^{2020}$, que es el insumo del que parte todo el modelo WoE-AC: a partir de ella se calculan las transiciones históricas, se derivan las siete variables espaciales y se entrena el Weight of Evidence.

La elección de K-Means sobre otros algoritmos no supervisados, como los modelos de mezclas gaussianas (GMM), el agrupamiento jerárquico o el basado en densidad (DBSCAN), responde a la escala del problema: cada imagen contiene del orden de 5,4 millones de píxeles, y métodos como el agrupamiento jerárquico o el espectral exigen matrices de afinidad de tamaño $N \times N$, inviables en memoria a esa escala. K-Means, en cambio, escala de forma lineal con el número de píxeles y, fijada la semilla y el número de inicializaciones, produce una partición

estable y reproducible. GMM y DBSCAN añadirían supuestos sobre la forma o la densidad de los grupos que no se justifican aquí, donde lo que se busca no es descubrir estructura compleja sino una separación binaria estable y consistente a lo largo de los 37 años de la serie.

5.2. Modelo de crecimiento urbano.

Con la serie de mapas binarios $\{U_t\}_{t=1984}^{2020}$ ya construida, el modelo de crecimiento urbano debe responder a una pregunta distinta de la del preprocesamiento: ya no se trata de decidir qué es urbano, sino de aprender dónde y por qué aparece lo urbano nuevo. El primer paso es, por tanto, definir el objeto de estudio del modelo: la transición. Una transición ocurre cuando una celda que era no-urbana en el año t pasa a urbana en $t + 1$, es decir, $U_t(i, j) = 0$ y $U_{t+1}(i, j) = 1$. Estas transiciones son los eventos que el modelo busca primero explicar a partir de la historia y, más adelante, reproducir hacia el futuro.

La primera decisión del modelo es cómo cuantificar la evidencia que vincula la configuración espacial de una celda con su probabilidad de transición. La vía más común en la literatura es la regresión logística, pero conlleva un supuesto fuerte: que el logit de la probabilidad es una función lineal de las variables explicativas. Las relaciones espaciales del crecimiento urbano no son lineales; la probabilidad de urbanización cae de forma abrupta en los primeros cientos de metros desde el frente urbano y luego se aplanan. Por eso se elige el método de Pesos de Evidencia (WoE, ecuación ?? del Capítulo ??), que no impone ninguna forma funcional: discretiza cada variable en intervalos y estima un peso bayesiano independiente para cada uno, capturando la curvatura real de la relación. Como ventaja adicional, cada peso es interpretable en términos geográficos, lo que satisface el requisito de transparencia que motivó este trabajo y que los enfoques de caja negra no ofrecen.

La segunda decisión es qué variables espaciales alimentan el WoE. Aquí opera de nuevo una restricción de los datos: no se dispone de capas externas homogéneas (vialidades, pendiente, uso de suelo oficial) para los 37 años de la serie. Por tanto, todas las variables deben derivarse de la propia configuración urbana histórica, sin insumos adicionales. Se definen siete: la distancia euclidiana a la celda urbana más cercana, la densidad de vecinos urbanos a tres escalas (ventanas 3×3 , 5×5 y 7×7), la fragmentación local, el tamaño del cluster urbano contiguo más cercano y el gradiente de urbanización. Cada una captura un aspecto distinto del proceso: la proximidad al frente consolidado, la presión del vecindario a múltiples escalas y la morfología del borde urbano. El que las siete provengan únicamente del mapa binario es lo que hace al modelo transferible a cualquier ciudad para la que exista esa serie, sin depender de bases de datos locales.

La tercera decisión es sobre qué datos afinar. En lugar de ajustar el WoE a un único par de años, se agregan (*pooling*) las transiciones de los 26 pares consecutivos del período 1984–2010. El motivo es estadístico: las transiciones de un solo año son escasas y ruidosas, y producirían pesos inestables. Al acumular los 26 períodos se reúnen 8,196,264 transiciones observadas, lo que reduce el error de estimación de cada bin a un nivel en el que los pesos pueden tratarse como constantes del modelo. El período 2011–2020 se reserva deliberadamente, sin tocarlo durante el ajuste, para la validación posterior.

Con los pesos calculados, surge una cuarta decisión: cómo combinarlos. No todas las variables aportan lo mismo. El peso total por celda (ecuación ??) no se obtiene como una suma simple, sino ponderando cada variable por su *Information Value* normalizado, de modo que las variables con mayor poder discriminativo pesen más en la decisión final. En el caso de la Zona Metropolitana de Querétaro, esto hace que la distancia al frente urbano domine la combinación, concentra cerca del 28 % del peso total, el *Information Value* más alto de las siete variables, seguida de la densidad de vecinos inmediatos. La suma ponderada se transforma con la función sigmoide (ecuación ??) para obtener una probabilidad de transición acotada en $[0, 1]$.

Llegados a este punto aparece la decisión central del modelo, la que lo distingue de una simple regresión espacial: por qué un autómata celular y no usar directamente el mapa de probabilidad WoE como predicción. La razón es que el mapa WoE es estático; describe la idoneidad de cada celda dada la configuración del año inicial, pero no simula cómo el crecimiento se propaga en el tiempo. Una celda muy apta puede no urbanizarse si ningún frente urbano la alcanza dentro del período, y una celda de idoneidad media puede hacerlo si el crecimiento llega a su vecindad. El autómata celular (Sección ?? del Capítulo ??) resuelve esto aplicando la regla de transición de forma iterativa: en cada paso anual se recalculan las siete variables espaciales sobre el estado actualizado del mapa. Así, cuando una celda se urbaniza, incrementa de inmediato la densidad de vecinos de sus celdas contiguas y eleva su probabilidad de transición en el paso siguiente. Este mecanismo de contagio borde a borde es el que genera los patrones de mancha compacta, relleno de huecos y extensión de corredores que se observan empíricamente en la ZMQ; que las dos variables más predictivas sean de proximidad local confirma que el crecimiento de la zona es de tipo contagio y no difusión aleatoria, y por tanto que un autómata celular es su representación natural.

La regla de transición integra, finalmente, tres componentes. A la probabilidad WoE de cada celda se le añade la influencia del vecindario de Moore (ocho celdas adyacentes, ecuación ??), ponderada por un peso vecinal; se elige la vecindad de Moore por ser la mínima que captura tanto adyacencias ortogonales como diagonales del frente urbano. La probabilidad combinada

se compara contra un umbral de transición: solo las celdas que lo superan pueden urbanizarse. Este umbral se fijó en 0,75 mediante exploración sistemática, tras observar que valores menores producían sobre-predicción masiva; su calibración y la del peso vecinal se detallan en el Capítulo ???. Por último, la transición no es determinista: una celda apta se urbaniza solo si un sorteo aleatorio lo confirma. Esta componente estocástica refleja que, incluso bajo condiciones favorables, la urbanización de una parcela depende de factores no modelados (decisiones de propietarios, permisos, mercado), y es lo que permite que distintas corridas del modelo generen escenarios ligeramente distintos en lugar de una única predicción rígida.

5.3. Validación.

Definido el modelo, queda la pregunta de si sus predicciones son confiables. La primera decisión de la validación ya se tomó al entrenar: el WoE se ajustó únicamente con las transiciones de 1984–2010, dejando intacto el período 2011–2020. Esta separación temporal es lo que hace honesta a la evaluación, pues el modelo se prueba sobre años que nunca vio durante el ajuste, de la misma forma en que tendría que operar al proyectar el futuro. Validar sobre los mismos datos de entrenamiento solo mediría la capacidad de memorizar, no la de predecir.

La segunda decisión, y la que define el aporte metodológico de este trabajo, es no validar sobre una única ventana sino sobre cinco ventanas quinquenales independientes: 2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020. La razón es que una sola ventana puede resultar engañosamente favorable o desfavorable según las particularidades de ese lustro; cinco ventanas que se desplazan año con año permiten distinguir entre un acierto puntual y un comportamiento estable del modelo. Gran parte de la literatura revisada en el Capítulo ??? valida sobre un solo período, lo que impide saber si el desempeño reportado se sostiene en el tiempo.

El procedimiento es el mismo en cada ventana. Se toma el mapa observado del año inicial como estado de partida, se ejecuta el autómata celular durante cinco pasos anuales recalculando las variables espaciales en cada uno, y el mapa predicho para el año final se compara, celda a celda, contra el mapa observado de ese año. De esa comparación se construye la matriz de confusión (ecuación ??) y, a partir de ella, todas las métricas.

Aquí aparece una decisión sobre cómo medir el acierto. Las métricas globales como la exactitud o el coeficiente Kappa (ecuación ??) son engañosas en este problema: como la mayoría del territorio no cambia de un año a otro, un modelo que se limitara a copiar el mapa inicial obtendría una exactitud altísima sin predecir crecimiento alguno. Por eso la métrica central de la validación es el *Figure of Merit* (ecuación ??), que evalúa exclusivamente las celdas en transición e ignora la clase mayoritaria de permanencia. Se reportan, no obstante, las métricas

complementarias (IoU, Precision, Recall, F1 y Kappa) y la descomposición del error en sus componentes de cantidad y de asignación, porque cada una ilumina un aspecto distinto del desempeño.

El resultado sostiene la hipótesis de estabilidad. A lo largo de las cinco ventanas, el *Figure of Merit* se mantiene en el intervalo $[0,222, 0,378]$, con un valor medio cercano a 0,317, un Kappa medio de 0,445 y un IoU medio de 0,633. Ninguna ventana se desploma ni dispara su desempeño respecto de las demás, lo que indica que el modelo captura una dinámica estructural del crecimiento de la Zona Metropolitana de Querétaro y no un patrón sobreajustado a un período concreto. La presentación detallada de estas métricas, ventana por ventana, junto con la discusión de la calibración, se desarrolla en el Capítulo ??.