

Capítulo 5

Modelo de crecimiento urbano

Este capítulo muestra una visión exhaustiva del modelo citado a lo largo de todo este trabajo como WoE-AC, se presentan las decisiones explícitas de cada componente del modelo, preprocesamiento y validación. Si bien el segundo capítulo del presente trabajo da una definición a cada concepto utilizado, no hay una argumentación de por qué se utiliza cada una de las componentes del flujo completo que al trabajo presente le compete. Se inicia con un recordatorio breve del preprocesamiento que produce la serie binaria de entrada —cuyo detalle queda en el Capítulo ??—, seguido por el modelo que consume esos mapas para calcular la matriz de transiciones históricas, la definición del autómata celular probabilístico y, finalmente, la validación del modelo.

5.1. Del preprocesamiento a la serie binaria de entrada

El modelo WoE-AC no parte de las imágenes crudas, sino de una serie de mapas binarios urbano/no-urbano $\{U_t\}_{t=1984}^{2020}$. Su construcción —la conversión de cada captura RGB de $1,792 \times 3,024$ píxeles en un mapa $U_t(x, y) \in \{0, 1\}$ mediante la cadena LBP + K-Means + SVM— se describe en detalle en el Capítulo ?? y no se reproduce aquí. Basta recordar dos restricciones que ese flujo resuelve: la ausencia de banda infrarroja descarta los índices espectrales habituales (NDVI, NDBI) y obliga a apoyarse en descriptores de textura y color, y la falta de verdad terreno para los 37 años obliga a etiquetar de forma no supervisada.

De ese flujo conviene rescatar, eso sí, la decisión que condiciona todo lo que sigue: el criterio que separa lo urbano de lo no-urbano es **idéntico para todos los años de la serie**. Esa consistencia inter-anual —y no la exactitud cartográfica frente a una verdad terreno— es lo que vuelve comparables las transiciones entre años consecutivos y permite que alimenten el cálculo

de Pesos de Evidencia sin sesgos por cambios de criterio. La representación binaria, por su parte, es la entrada natural de un autómata celular, que opera sobre estados discretos, y captura justo la variable de interés: la expansión de la mancha urbana, no la composición interna de usos. Como respaldo de su fiabilidad interna, el clasificador reprodujo entre el 88 % y el 94 % de las pseudoetiquetas en el reparto de prueba (Capítulo ??); su validación externa, de carácter indirecto, se realiza a través del desempeño temporal del propio modelo en el Capítulo ??.

5.2. Modelo de crecimiento urbano.

Con la serie de mapas binarios $\{U_t\}_{t=1984}^{2020}$ ya construida, el modelo de crecimiento urbano debe responder a una pregunta distinta de la del preprocesamiento: ya no se trata de decidir qué es urbano, sino de aprender dónde y por qué aparece lo urbano nuevo. El primer paso es, por tanto, definir el objeto de estudio del modelo: la transición. Una transición ocurre cuando una celda que era no-urbana en el año t pasa a urbana en $t + 1$, es decir, $U_t(i, j) = 0$ y $U_{t+1}(i, j) = 1$. Estas transiciones son los eventos que el modelo busca primero explicar a partir de la historia y, más adelante, reproducir hacia el futuro.

La primera decisión del modelo es cómo cuantificar la evidencia que vincula la configuración espacial de una celda con su probabilidad de transición. La vía más común en la literatura es la regresión logística, pero conlleva un supuesto fuerte: que el logit de la probabilidad es una función lineal de las variables explicativas. Las relaciones espaciales del crecimiento urbano no son lineales; la probabilidad de urbanización cae de forma abrupta en los primeros cientos de metros desde el frente urbano y luego se aplanan. Por eso se elige el método de Pesos de Evidencia (WoE, ecuación ?? del Capítulo ??), que no impone ninguna forma funcional: discretiza cada variable en intervalos y estima un peso bayesiano independiente para cada uno, capturando la curvatura real de la relación. Como ventaja adicional, cada peso es interpretable en términos geográficos, lo que satisface el requisito de transparencia que motivó este trabajo y que los enfoques de caja negra no ofrecen.

La segunda decisión es qué variables espaciales alimentan el WoE. Aquí opera de nuevo una restricción de los datos: no se dispone de capas externas homogéneas (vialidades, pendiente, uso de suelo oficial) para los 37 años de la serie. Por tanto, todas las variables deben derivarse de la propia configuración urbana histórica, sin insumos adicionales. Se definen siete: la distancia euclidiana a la celda urbana más cercana, la densidad de vecinos urbanos a tres escalas (ventanas 3×3 , 5×5 y 7×7), la fragmentación local, el tamaño del cluster urbano contiguo más cercano y el gradiente de urbanización. Cada una captura un aspecto distinto del proceso: la proximidad al frente consolidado, la presión del vecindario a múltiples escalas y la morfología del borde urbano.

El que las siete provengan únicamente del mapa binario es lo que hace al modelo transferible a cualquier ciudad para la que exista esa serie, sin depender de bases de datos locales.

La tercera decisión es sobre qué datos afinar. En lugar de ajustar el WoE a un único par de años, se agregan (*pooling*) las transiciones de los 26 pares consecutivos del período 1984–2010. El motivo es estadístico: las transiciones de un solo año son escasas y ruidosas, y producirían pesos inestables. Al acumular los 26 períodos se reúnen 8,196,264 transiciones observadas, lo que reduce el error de estimación de cada bin a un nivel en el que los pesos pueden tratarse como constantes del modelo. El período 2011–2020 se reserva deliberadamente, sin tocarlo durante el ajuste, para la validación posterior.

Con los pesos calculados, surge una cuarta decisión: cómo combinarlos. No todas las variables aportan lo mismo. El peso total por celda (ecuación ??) no se obtiene como una suma simple, sino ponderando cada variable por su *Information Value* normalizado, de modo que las variables con mayor poder discriminativo pesen más en la decisión final. En el caso de la Zona Metropolitana de Querétaro, esto hace que la distancia al frente urbano domine la combinación, concentra cerca del 28 % del peso total, el *Information Value* más alto de las siete variables, seguida de la densidad de vecinos inmediatos. La suma ponderada se transforma con la función sigmoide (ecuación ??) para obtener una probabilidad de transición acotada en $[0, 1]$.

Llegados a este punto aparece la decisión central del modelo, la que lo distingue de una simple regresión espacial: por qué un autómata celular y no usar directamente el mapa de probabilidad WoE como predicción. La razón es que el mapa WoE es estático; describe la idoneidad de cada celda dada la configuración del año inicial, pero no simula cómo el crecimiento se propaga en el tiempo. Una celda muy apta puede no urbanizarse si ningún frente urbano la alcanza dentro del período, y una celda de idoneidad media puede hacerlo si el crecimiento llega a su vecindad. El autómata celular (Sección ?? del Capítulo ??) resuelve esto aplicando la regla de transición de forma iterativa: en cada paso anual se recalculan las siete variables espaciales sobre el estado actualizado del mapa. Así, cuando una celda se urbaniza, incrementa de inmediato la densidad de vecinos de sus celdas contiguas y eleva su probabilidad de transición en el paso siguiente. Este mecanismo de contagio borde a borde es el que genera los patrones de mancha compacta, relleno de huecos y extensión de corredores que se observan empíricamente en la ZMQ; que las dos variables más predictivas sean de proximidad local confirma que el crecimiento de la zona es de tipo contagio y no difusión aleatoria, y por tanto que un autómata celular es su representación natural.

La regla de transición integra, finalmente, tres componentes. A la probabilidad WoE de cada celda se le añade la influencia del vecindario de Moore (ocho celdas adyacentes, ecuación ??),

ponderada por un peso vecinal; se elige la vecindad de Moore por ser la mínima que captura tanto adyacencias ortogonales como diagonales del frente urbano. La probabilidad combinada se compara contra un umbral de transición: solo las celdas que lo superan pueden urbanizarse. Este umbral se fijó en 0,75 mediante exploración sistemática, tras observar que valores menores producían sobre-predicción masiva; su calibración y la del peso vecinal se detallan en el Capítulo ?? . Por último, la transición no es determinista: una celda apta se urbaniza solo si un sorteo aleatorio lo confirma. Esta componente estocástica refleja que, incluso bajo condiciones favorables, la urbanización de una parcela depende de factores no modelados (decisiones de propietarios, permisos, mercado), y es lo que hace que distintas corridas del modelo generen escenarios ligeramente distintos en lugar de una única predicción rígida.

Los tres componentes se condensan en una sola expresión, que constituye el núcleo formal del modelo. Para una celda no urbana (i, j) , la probabilidad de transición es

$$P_{i,j} = \sigma \left(e^{-\lambda D_{i,j}} \left[\alpha N_{i,j} + \underbrace{\sum_v \omega_v \text{WoE}_v(i, j)}_{\text{evidencia espacial}} \right] \right), \quad \omega_v = \frac{IV_v}{\sum_k IV_k}, \quad (5.1)$$

donde $\sigma(\cdot)$ es la función logística; $\text{WoE}_v(i, j)$ es el peso de evidencia de la variable espacial v , ponderado por su *Information Value* normalizado ω_v (de modo que las variables más discriminativas pesan más); $N_{i,j} \in [0, 1]$ es la influencia del vecindario de Moore —la fracción de vecinos urbanos ponderada por el inverso de la distancia de Chebyshev— con peso vecinal α ; y $e^{-\lambda D_{i,j}}$ es el factor de decaimiento exponencial con la distancia $D_{i,j}$ al frente urbano más cercano, que atenúa de forma conjunta la evidencia y el vecindario en las celdas alejadas. La celda transita a urbana en el paso siguiente solo si $P_{i,j}$ supera el umbral θ —las probabilidades por debajo se penalizan drásticamente— y si, además, un sorteo aleatorio $u \sim \mathcal{U}(0, 1)$ lo confirma ($u < P_{i,j}$). La configuración validada en este trabajo fija $\theta = 0,75$ y $\alpha = 0,50$ (Capítulo ??).

Conviene precisar en qué se aparta esta formulación del esquema WoE-AC más habitual. En buena parte de la literatura el WoE entra al autómata como un mapa de idoneidad estático y la vecindad se trata como un conteo binario uniforme. Aquí, en cambio, el WoE se incorpora como un campo probabilístico continuo ponderado por el *Information Value* de cada variable, la influencia del vecindario decae con la distancia (ponderación por separación de Chebyshev) en lugar de contarse de forma plana, y todo el acoplamiento se calibra y se valida de manera reproducible sobre cinco ventanas temporales. Esa combinación —campo WoE ponderado por IV, vecindario con decaimiento y validación multi-ventana— es la aportación metodológica del

trabajo, más que el uso del WoE y del AC por separado, que la literatura ya documenta.

5.3. Validación.

Definido el modelo, queda la pregunta de si sus predicciones son confiables. La primera decisión de la validación ya se tomó al entrenar: el WoE se ajustó únicamente con las transiciones de 1984–2010, dejando intacto el período 2011–2020. Esta separación temporal es lo que hace honesta a la evaluación, pues el modelo se prueba sobre años que nunca vio durante el ajuste, de la misma forma en que tendría que operar al proyectar el futuro. Validar sobre los mismos datos de entrenamiento solo mediría la capacidad de memorizar, no la de predecir.

La segunda decisión, y la que define el aporte metodológico de este trabajo, es no validar sobre una única ventana sino sobre cinco ventanas quinquenales independientes: 2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020. La razón es que una sola ventana puede resultar engañosamente favorable o desfavorable según las particularidades de ese lustro; cinco ventanas que se desplazan año con año permiten distinguir entre un acierto puntual y un comportamiento estable del modelo. Gran parte de la literatura revisada en el Capítulo ?? valida sobre un solo período, lo que impide saber si el desempeño reportado se sostiene en el tiempo.

El procedimiento es el mismo en cada ventana. Se toma el mapa observado del año inicial como estado de partida, se ejecuta el autómata celular durante cinco pasos anuales recalculando las variables espaciales en cada uno, y el mapa predicho para el año final se compara, celda a celda, contra el mapa observado de ese año. De esa comparación se construye la matriz de confusión (ecuación ??) y, a partir de ella, todas las métricas.

Aquí aparece una decisión sobre cómo medir el acierto. Las métricas globales como la exactitud o el coeficiente Kappa (ecuación ??) son engañosas en este problema: como la mayoría del territorio no cambia de un año a otro, un modelo que se limitara a copiar el mapa inicial obtendría una exactitud altísima sin predecir crecimiento alguno. Por eso la métrica central de la validación es el *Figure of Merit* (ecuación ??), que evalúa exclusivamente las celdas en transición e ignora la clase mayoritaria de permanencia. Se reportan, no obstante, las métricas complementarias (IoU, Precision, Recall, F1 y Kappa) y la descomposición del error en sus componentes de cantidad y de asignación, porque cada una ilumina un aspecto distinto del desempeño.

El resultado sostiene la hipótesis de estabilidad. A lo largo de las cinco ventanas, el *Figure of Merit* se mantiene en el intervalo $[0,222, 0,378]$, con un valor medio cercano a 0,317, un Kappa medio de 0,445 y un IoU medio de 0,633. Ninguna ventana se desploma ni dispara su

desempeño respecto de las demás, lo que indica que el modelo captura una dinámica estructural del crecimiento de la Zona Metropolitana de Querétaro y no un patrón sobreajustado a un período concreto. La presentación detallada de estas métricas, ventana por ventana, junto con la discusión de la calibración, se desarrolla en el Capítulo ??.