

Capítulo 6

Resultados y análisis

Este capítulo presenta los resultados obtenidos de la aplicación del modelo WoE-AC para simular el crecimiento urbano de Querétaro. Se analiza la dinámica histórica observada (1984–2020), los resultados del análisis Weight of Evidence, la calibración del modelo, las simulaciones en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020) y la evaluación cuantitativa mediante métricas espaciales (Accuracy, Precision, Recall, F1, Kappa, FoM). Finalmente, se realiza un análisis espacial del error para identificar las fuentes de discrepancia entre predicción y observación.

6.1. Dinámica observada del crecimiento urbano

Antes de evaluar el desempeño del modelo, es pertinente caracterizar el proceso que la simulación busca reproducir. Esta sección describe la evolución histórica de la huella urbana de Querétaro y los patrones espaciales de expansión identificados en la serie temporal 1984–2020.

6.1.1. Evolución temporal 1984–2020

Antes de presentar los resultados de la simulación conviene situarlos en el contexto histórico del crecimiento de Querétaro. Aquí hace falta una advertencia: la magnitud absoluta de la clase “urbano” que devuelve el clasificador no equivale a la mancha urbana real, porque arrastra también suelo desnudo y superficies áridas espectralmente parecidas (véase la nota metodológica al final de esta sección). Por eso, en vez de una tasa de crecimiento compuesta, que la serie clasificada no sostiene, la Tabla 6.1 resume la fracción media de píxeles de esa clase en cuatro tramos de la serie.

Sobre el conjunto de la serie, la fracción clasificada pasa de 44,4 % en 1984 a 52,9 % en 2020,

Cuadro 6.1: Fracción media de píxeles clasificados como “urbano” por tramo de la serie 1984–2020. Las cifras provienen directamente de los mapas binarios y deben leerse como un indicador grueso de la dinámica, no como superficie construida.

Período	Fracción media clasificada	Característica principal
1984–1995	~43 %	Consolidación del centro urbano
1996–2005	~44 %	Expansión hacia zonas industriales
2006–2015	~45 %	Expansión dispersa (norte y este)
2016–2020	~51 %	Consolidación periférica

un incremento neto de 8,4 puntos porcentuales. La variabilidad interanual es alta: hay mínimos como 33,6 % en 1992 y una desviación estándar cercana a 4 puntos a lo largo del período. Un ajuste lineal de la fracción frente al año arroja una pendiente de apenas 0,15 puntos por año, con $R^2 \approx 0,15$; es decir, la tendencia ascendente existe pero es débil y queda dominada por el ruido del clasificador. El único tramo que se separa con nitidez del resto es 2016–2020. Por eso no se reporta una tasa anual compuesta: la serie no la sostiene.




Figura 6.1: Evolución de la fracción clasificada como “urbano” en Querétaro (1984–2020). Se observa una tendencia ascendente con fuerte variabilidad interanual, más marcada en el tramo final de la serie.

6.1.2. Patrones espaciales de expansión

Los mapas binarios generados para cada año revelan tres patrones principales de expansión. El primero es el crecimiento contiguo por difusión, donde la expansión se produce principalmente desde los bordes de áreas urbanas existentes, siguiendo el mecanismo de contagio espacial que los autómatas celulares capturan de manera natural. El segundo corresponde al desarrollo periurbano a lo largo de corredores de transporte, visible en los ejes norte (autopista a San Luis

Potosí) y oeste (autopista a Celaya). El tercero es el desarrollo industrial puntual: la instalación de parques industriales (Aeropuerto Industrial, Querétaro Aerospace) genera núcleos discontinuos en la periferia.

Los mapas binarios muestran crecimiento sostenido de la huella urbana a lo largo del período. Para los años de inicio de los experimentos de validación, los recuentos de píxeles urbanos extraídos directamente de los mapas clasificados son los siguientes: 2011: 2,699,088 px; 2012: 2,140,433 px; 2013: 2,140,627 px; 2014: 2,469,631 px; 2015: 2,145,356 px; 2020 (observado): 2,864,122 px. Estas cifras corresponden directamente a los valores `urban_start` y `urban_end_observed` de los archivos de resultados de validación (`validation_results.json`) y son los insumos directos del Autómata Celular.

Nota metodológica sobre la clase “urbano”: El clasificador K-Means+SVM opera sobre características espectrales y de textura extraídas de las **capturas RGB** de la serie (Google Earth, imagen histórica). En la práctica, el clasificador aprende a separar dos agrupaciones espectrales: *zonas con cubierta vegetal verde y densa* versus *zonas sin cubierta vegetal verde*. Esta segunda clase agrupa el tejido urbano real (edificaciones, vialidades, concreto), pero también suelo desnudo agrícola en temporada seca y superficies áridas periféricas espectralmente similares a las urbanas. Por ello, los recuentos de píxeles de la clase “urbano” son considerablemente mayores que la mancha urbana real de Querétaro.

La validación del modelo se realiza en términos de *consistencia interna*: dado un mapa binario clasificado en el año t (con la definición descrita), el modelo predice qué píxeles habrán cambiado de clase en $t + 5$. La calidad de esa predicción es lo que miden las métricas de la Sección 6.5. Este enfoque es válido mientras la definición de clase se aplique de forma consistente en todos los años de la serie.

6.2. Resultados del análisis Weight of Evidence

Esta sección presenta los resultados del cálculo de Weight of Evidence sobre las transiciones históricas observadas (1984–2010), incluyendo el poder predictivo de cada variable espacial cuantificado mediante el Information Value y la interpretación geográfica de los pesos obtenidos.

6.2.1. Transiciones históricas identificadas

El cálculo de Weight of Evidence se basó en el análisis de 26 períodos anuales consecutivos (1984–2010), identificando los píxeles que cambiaron de estado entre cada par de años. El modelo WoE consolidado está almacenado en `data/processed/woe_pooled_1984_2010.pkl`

y utiliza un total de 8,196,264 píxeles de transición observados a lo largo de los 26 períodos.

6.2.2. Pesos por variable (Information Value)

El modelo utiliza 7 variables espaciales cuya importancia predictiva se cuantifica mediante el Information Value (IV). La Tabla 6.2 presenta los IV calculados sobre el conjunto de entrenamiento 1984–2010, que determinan directamente la ponderación de cada variable en la probabilidad de transición.

Cuadro 6.2: *Information Value* y pesos normalizados de las siete variables WoE, calculados sobre el período de entrenamiento (1984–2010).

Variable	IV	Peso normalizado
Distancia al área urbana (distance_urban)	0,2817	0,2817
Densidad de vecindad 3 × 3 (neighbor_density_3x3)	0,2495	0,2495
Densidad de vecindad 5 × 5 (neighbor_density_5x5)	0,1445	0,1445
Densidad de vecindad 7 × 7 (neighbor_density_7x7)	0,1068	0,1068
Fragmentación local (local_fragmentation)	0,1062	0,1062
Gradiente urbano (urban_gradient)	0,0996	0,0996
Tamaño del <i>cluster</i> más cercano (nearest_cluster_size)	0,0120	0,0120
Total	1,0003	1,000

Estos valores provienen directamente de data/processed/quinquenal_best_config.json. El patrón muestra que la distancia al área urbana y las tres variables de densidad concentran cerca del 75 % del poder predictivo, lo que es **coherente** con un mecanismo de difusión espacial desde las áreas ya urbanizadas, ampliamente documentado en la literatura de expansión urbana. La variable nearest_cluster_size presenta un IV muy bajo (0,012), lo que sugiere que el tamaño del *cluster* urbano más cercano aporta información marginal una vez controlada la distancia.

6.2.3. Interpretación de los pesos WoE

El patrón observado en los pesos es **coherente** con la teoría de difusión urbana: la probabilidad de urbanización de una celda crece con la fracción de vecinos ya urbanizados. Los valores de WoE negativos (*bins* 1–2) corresponden a celdas con vecindad escasamente urbanizada y, en consecuencia, con menor probabilidad de transición que el promedio. Los valores positivos (*bins* 4–8) corresponden a celdas rodeadas por áreas urbanas y, por tanto, con probabilidad de transición varias veces mayor al promedio. El punto de equilibrio (WoE $\approx$ 0) se alcanza en $\rho \approx 0,35$ –0,40.




Figura 6.2: Pesos WoE por bin de densidad de vecindad urbana. La relación monótonica creciente es coherente con un mecanismo de difusión espacial y sitúa a la densidad de vecindad como el predictor de mayor peso entre las variables del modelo, sin que ello implique que sea la única causa del crecimiento.

6.3. Calibración del modelo

A partir de los pesos WoE derivados de los datos históricos, esta sección describe la configuración final del Autómata Celular y el proceso de calibración sistemática de sus parámetros mediante búsqueda en cuadrícula (*grid search*). El marco metodológico que justifica esta elección se discute en el Capítulo ?? (Sección ??).

6.3.1. Configuración del autómata celular

El Autómata Celular se configuró con los parámetros especificados en la Tabla 6.3, resultado de la calibración sobre el conjunto de entrenamiento (1984–2010).

Cuadro 6.3: Configuración final del Autómata Celular WoE-AC.

Parámetro	Valor
Espacio celular	1,792 × 3,024 píxeles.
Estados	{0 : no-urbano, 1 : urbano}.
Vecindario	Moore (8 vecinos, radio = 1).
Variables WoE	Siete variables espaciales: distancia al área urbana, densidades de vecindad 3 × 3, 5 × 5 y 7 × 7, fragmentación local, gradiente urbano y tamaño del <i>cluster</i> más cercano.
Ponderación de variables	Proporcional al <i>Information Value</i> (IV) normalizado.
Umbral de urbanización	$\theta = 0,75$ (calibrado sobre la probabilidad combinada).
Peso de vecindad	$\alpha = 0,50$.
Paso temporal	1 año.
Períodos de simulación	5 iteraciones por experimento.

6.3.2. Proceso de calibración

La calibración se centró en el umbral de urbanización (θ) y en la ponderación de las siete variables WoE. El umbral final $\theta = 0,75$ se adoptó porque los valores ensayados en la exploración inicial ($\approx 0,40-0,60$) producían una sobre-predicción excesiva del crecimiento urbano; al fijar $\theta = 0,75$, la sobre-predicción se reduce de manera notable y el Recall se mantiene por encima de 0,91 en las cinco ventanas evaluadas. La ponderación de las siete variables WoE se hizo proporcional al *Information Value* (IV) de cada variable, calculado sobre el conjunto de entrenamiento (1984–2010). La configuración resultante de esta búsqueda (umbral, peso de vecindad y ponderación por IV) queda registrada de forma verificable en el archivo `data/processed/quinquenal_best_config.json` del repositorio, junto con los scripts de calibración que reproducen el barrido.

La probabilidad de urbanización para la celda (i, j) en el paso t es la misma regla de transición definida en el Capítulo ?? (ecuación ??): el campo WoE, suma de las siete evidencias ponderadas por su *Information Value* normalizado, se transforma con la sigmoide y se le suma después la influencia del vecindario, acotando el resultado a $[0, 1]$:

$$P_{\text{trans}}(i, j, t) = \min\left(1, \sigma\left(\sum_{k=1}^7 \frac{IV_k}{\sum_l IV_l} \cdot \text{WoE}_k(i, j, t)\right) + \alpha \cdot I_{\text{neigh}}(i, j, t)\right), \quad (6.1)$$

donde $\sigma(\cdot)$ es la función sigmoide; IV_k , el *Information Value* de la k -ésima variable; $\text{WoE}_k(i, j, t)$, el valor de evidencia en la celda; $\alpha = 0,50$, el peso de vecindad; e $I_{\text{neigh}}(i, j, t) \in [0, 1]$, la fracción de vecinos urbanos en la vecindad de Moore. Una celda se urbaniza cuando P_{trans} supera el umbral $\theta = 0,75$ y un sorteo aleatorio lo confirma.

6.4. Simulación del crecimiento urbano

Esta sección describe el protocolo de validación quinquenal múltiple implementado para evaluar el desempeño del modelo de forma independiente al entrenamiento, y presenta los resultados individuales de las simulaciones en cada uno de los cinco períodos evaluados.

6.4.1. Protocolo de validación quinquenal múltiple

Para evaluar el modelo de forma independiente del entrenamiento, se adoptó un esquema de **validación quinquenal múltiple**: el WoE se entrenó exclusivamente con datos del período 1984–2010 y, con esos pesos, el Autómata Celular se simuló en cinco ventanas temporales solapadas de cinco años, con años de inicio sucesivos (2011, 2012, 2013, 2014 y 2015). El diseño garantiza que ningún dato del período de validación interviene en el entrenamiento (*hold-out*

temporal) y permite evaluar la estabilidad del modelo bajo distintas condiciones de partida.

Cuadro 6.4: Configuración del experimento de validación quinquenal múltiple.

Parámetro	Valor
WoE entrenado con	1984–2010 (26 transiciones anuales agregadas por <i>pooling</i>)
Umbral de urbanización	$\theta = 0,75$
Peso de vecindad	$\alpha = 0,50$
Pasos por validación	5 iteraciones (1 año por paso)
Períodos evaluados	2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020

6.5. Evaluación del modelo

A continuación se presentan las métricas de evaluación cuantitativa del modelo en los cinco períodos quinquenales y se contextualizan los resultados frente a valores de referencia reportados en la literatura internacional.

6.5.1. Resumen comparativo – cinco períodos quinquenales

La Tabla 6.5 resume las métricas obtenidas en los cinco períodos evaluados, con los valores tomados directamente de cada archivo `validation_results.json` en las carpetas `data/processed/validation_quinquenal*_v3_weighted/`. El **FoM promedio es de 0,317** (equivalente a 31,7 % en escala porcentual), calculado conforme a la Ecuación ?? del marco teórico. Esta magnitud se sitúa en una **banda intermedia** del espectro empírico documentado por Pontius Jr et al. (2008): por encima del subconjunto de aplicaciones con FoM inferior al 15 % y muy por debajo del único caso que supera el 50 % en esa muestra multi-sitio (Capítulo ??). El Kappa promedio de 0,445 corresponde a un acuerdo moderado según la escala de Landis y Koch (cercano al límite superior de ese rango). El Recall alto ($> 0,91$ en todos los períodos) indica que el modelo captura la mayor parte de la urbanización observada, bajo la misma definición operativa de la clase urbana, aunque con sobre-predicción sistemática de la magnitud del crecimiento.

La variación entre períodos refleja diferencias en la dinámica observada. El período 2011–2016 muestra el FoM más bajo (0,222): el área urbana clasificada en 2016 *decreció* levemente respecto a 2011, una anomalía atribuible a la variabilidad de la clasificación binaria RGB año a año, más que a una contracción urbana real. Los períodos 2012–2017, 2013–2018 y 2015–2020, en los que el crecimiento neto observado es positivo, exhiben FoM entre 0,35 y 0,38, con mayor concordancia entre el modelo y los mapas observados.

El FoM promedio obtenido se ubica en una banda intermedia del espectro empírico do-

Cuadro 6.5: Métricas de validación en las cinco ventanas quinquenales (WoE-AC, umbral $\theta = 0,75$).

Período	Acc	IoU	Prec	Recall	F1	κ	FoM
2011–2016	0,665	0,581	0,590	0,975	0,735	0,349	0,222
2012–2017	0,750	0,652	0,688	0,925	0,789	0,499	0,345
2013–2018	0,744	0,648	0,689	0,917	0,787	0,482	0,355
2014–2019	0,697	0,614	0,628	0,965	0,761	0,396	0,287
2015–2020	0,755	0,669	0,701	0,936	0,802	0,498	0,378
Promedio	0,722	0,633	0,659	0,944	0,775	0,445	0,317

Cuadro 6.6: Posicionamiento del modelo WoE-AC en el espectro empírico de Figure of Merit (FoM) documentado en la literatura LUCC. La comparación es cualitativa: los sitios, las definiciones temáticas de las clases y los horizontes temporales difieren entre estudios.

Referencia	Método	FoM reportado / observado
Estudio comparativo multi-sitio (Pontius Jr et al., 2008)	Trece aplicaciones de nueve modelos	Espectro empírico amplio: seis aplicaciones con $\text{FoM} < 15\%$ y una sola ($> 50\%$); el FoM puede variar entre 0% y 100% .
GSA-CA en Urumqi (Tang et al., 2024)	AC con búsqueda gravitacional	$\text{FoM} = 43,03\%$ (2010) y $37,64\%$ (2020); contexto árido con <i>drivers</i> físicos explícitos.
Este trabajo (ZMQ, promedio cinco ventanas)	WoE-AC con <i>grid search</i>	FoM promedio = 0,317 (i.e., 31,7 %); Kappa promedio = 0,445.

cumentado por Pontius Jr et al. (2008): por encima del subconjunto de aplicaciones con FoM inferior al 15 % y por debajo del único caso que supera el 50 % en esa muestra. Comparado con el estudio reciente de Tang et al. (2024) sobre Urumqi, donde el aprovechamiento explícito de *drivers* físicos asociados a la aridez eleva el FoM por encima del 35 %, el modelo WoE-AC propuesto queda por debajo, lo que es coherente con el hecho de que en este trabajo se emplean exclusivamente variables derivadas del propio mapa binario, sin incorporar restricciones topográficas, socioeconómicas ni de infraestructura.




Figura 6.3: Desempeño comparado del modelo WoE-AC en las cinco ventanas quinquenales. Las líneas verticales punteadas señalan el promedio de cada métrica: FoM = 0,317, Kappa = 0,445, IoU = 0,633. La estabilidad entre ventanas indica que el modelo captura una dinámica estructural del crecimiento y no un patrón sobreajustado.

6.5.2. Período 2011–2016

La Tabla 6.7 reúne las métricas de esta ventana y la Figura 6.3 compara el mapa observado con el predicho. Es el período con el FoM más bajo de la serie (0,222), por la razón ya anticipada: el área urbana clasificada en 2016 quedó por debajo de la de 2011.

Cuadro 6.7: Métricas de validación del período 2011→2016. B (hits del FoM) es el subconjunto de TP que corresponde a transiciones a urbano observadas y predichas simultáneamente; los píxeles permanentes ya urbanizados quedan incluidos en TP pero no en B (véase Ec. ??).

Métricas de píxel		Figure of Merit	
Accuracy	0,665	FoM	0,222
IoU	0,581	Hits (B)	361,614
Precision	0,590	Falsas alarmas (A)	1,203,567
Recall	0,975	Omisiones (C)	64,208
F1	0,735	TP / FP / FN	2,514,806 / 1,749,463 / 64,208
κ	0,349	Crec. obs. / pred.	−4,4 % / +58,0 %




Figura 6.4: Validación quinquenal 2011–2016. De izquierda a derecha: estado inicial (2011), mapa observado 2016 (*ground truth*), mapa predicho 2016 y diferencia (verde=TP, naranja=FP, azul=FN). FoM = 0,222; la anomalía se debe a que el área urbana observada disminuyó levemente por variabilidad en la clasificación binaria RGB año a año.

6.5.3. Período 2012–2017

En esta ventana el desempeño mejora respecto a la anterior. La Tabla 6.8 detalla las métricas y la Figura 6.4 ilustra el resultado espacial, con un FoM de 0,345 sobre un crecimiento observado positivo.

Cuadro 6.8: Métricas de validación del período 2012→2017.

Métricas de píxel		Figure of Merit	
Accuracy	0,750	FoM	0,345
IoU	0,652	Hits (<i>B</i>)	602,889
Precision	0,688	Falsas alarmas (<i>A</i>)	937,345
Recall	0,925	Omisiones (<i>C</i>)	205,308
F1	0,789	TP / FP / FN	2,532,942 / 1,147,725 / 205,308
κ	0,499	Crec. obs. / pred.	+27,9 % / +71,9 %




Figura 6.5: Validación quinquenal 2012–2017. FoM = 0,345; período con crecimiento observado positivo (+27,9 %) y FoM numéricamente superior al de la ventana 2011–2016 bajo el mismo protocolo. Los 602,889 hits (*B*) corresponden a píxeles donde tanto el modelo como la observación registran transición a urbano en el período, asociados a la expansión perimetral visible en el mapa binario.

6.5.4. Período 2013–2018

La Tabla 6.9 y la Figura 6.5 resumen el período, que alcanza un FoM de 0,355, el más alto hasta aquí, en un contexto de expansión sostenida hacia el norte y el este.

Cuadro 6.9: Métricas de validación del período 2013→2018.

Métricas de píxel		Figure of Merit	
Accuracy	0,744	FoM	0,355
IoU	0,648	Hits (<i>B</i>)	641,089
Precision	0,689	Falsas alarmas (<i>A</i>)	934,924
Recall	0,917	Omisiones (<i>C</i>)	231,317
F1	0,787	TP / FP / FN	2,559,805 / 1,156,835 / 231,317
κ	0,482	Crec. obs. / pred.	+30,4 % / +73,6 %




Figura 6.6: Validación quinquenal 2013–2018. FoM = 0,355; valor numéricamente cercano al del período 2012–2017 en un contexto análogo de crecimiento observado positivo. El número de omisiones (231,317 píxeles) sugiere que parte de la expansión hacia el norte y el este no queda recogida en la predicción bajo este experimento.

6.5.5. Período 2014–2019

Este período se aparta de la tendencia: la Tabla 6.10 registra un FoM de 0,287 y la Figura 6.6 deja ver el desajuste entre un crecimiento real modesto y una predicción de expansión más amplia.

Cuadro 6.10: Métricas de validación del período 2014→2019.

Métricas de píxel		Figure of Merit	
Accuracy	0,697	FoM	0,287
IoU	0,614	Hits (<i>B</i>)	511,475
Precision	0,628	Falsas alarmas (<i>A</i>)	1,176,288
Recall	0,965	Omisiones (<i>C</i>)	93,486
F1	0,761	TP / FP / FN	2,611,594 / 1,545,800 / 93,486
κ	0,396	Crec. obs. / pred.	+9,5 % / +68,3 %




Figura 6.7: Validación quinquenal 2014–2019. FoM = 0,287; el crecimiento real modesto (+9,5 %) contrasta con una predicción de expansión más elevada (+68,3 %), lo que se refleja en la proporción de falsas alarmas (1,176,288 píxeles). El Recall alto (0,965) indica que el modelo asigna clase urbana de forma amplia respecto al mapa observado en 2019.

6.5.6. Período 2015–2020

La última ventana es la de mejor desempeño. La Tabla 6.11 consigna un FoM de 0,378 y la Figura 6.7 muestra el mayor número de aciertos de toda la serie, en un año de fuerte crecimiento observado.

Cuadro 6.11: Métricas de validación del período 2015→2020.

Métricas de píxel		Figure of Merit	
Accuracy	0,755	FoM	0,378
IoU	0,669	Hits (<i>B</i>)	704,983
Precision	0,701	Falsas alarmas (<i>A</i>)	977,214
Recall	0,936	Omisiones (<i>C</i>)	181,887
F1	0,802	TP / FP / FN	2,682,235 / 1,145,318 / 181,887
κ	0,498	Crec. obs. / pred.	+33,5 % / +78,4 %




Figura 6.8: Validación quinquenal 2015–2020. FoM = 0,378; entre las cinco ventanas es el valor de FoM numéricamente más alto, en un contexto de fuerte crecimiento observado (+33,5 %). Se registran 704,983 hits y, en términos relativos a este conjunto de corridas, una menor proporción de falsas alarmas que en otras ventanas.

6.6. Análisis espacial del error del modelo




Figura 6.9: Mapa de error para la ventana 2015→2020 (mejor desempeño, $FoM = 0,378$). Las celdas verdes (B) son aciertos —transiciones correctamente predichas—; las ámbar (A) son falsas alarmas; las rojas (C) son omisiones. Solo las celdas en transición entran al cálculo del FoM; las permanencias urbanas y no urbanas aparecen en gris.

Complementando la evaluación cuantitativa, esta sección examina las fuentes de error identificadas en el proceso de simulación y analiza cualitativamente los patrones morfológicos de las predicciones, con el fin de orientar las extensiones metodológicas propuestas en las conclusiones.

6.6.1. Fuentes de error identificadas

El análisis conjunto de los cinco períodos revela tres fuentes principales de error que se propagan desde la clasificación de imágenes hasta la simulación:

Error de clasificación de imágenes

El pipeline de clasificación no supervisada (K-Means + SVM) reporta una concordancia interna de 88–94 % con las pseudoetiquetas en el conjunto de prueba holdout (20 % de los píxeles),

según se describe en el Capítulo ???. Con una imagen de 5,4 millones de píxeles, incluso un 5–10 % de error equivale a 270,000–540,000 píxeles mal clasificados por imagen. Estos errores se manifiestan como confusión espectral (suelo desnudo o techos claros clasificados como urbano) e inconsistencias temporales que introducen “transiciones” espurias en el historial WoE.

Propagación en transiciones históricas

El cálculo de WoE se basa en las transiciones históricas observadas. Los errores de clasificación distorsionan las probabilidades WoE, y el efecto se acumula a lo largo de los 26 años de datos de entrenamiento.

Amplificación en el autómata celular

El AC amplifica errores iniciales: una celda mal clasificada como urbana actúa como “semilla” de crecimiento y genera falsas alarmas en cascada mediante el efecto de vecindad.

Cuadro 6.12: Estimación cualitativa de la contribución de fuentes de error (no cuantificada empíricamente)

Fuente de error	Contribución relativa estimada
Error de clasificación directa (K-Means+SVM)	Alta
Propagación de errores en el historial WoE	Moderada
Amplificación AC (efecto de vecindad cascada)	Alta

Nota metodológica: la tabla anterior refleja una estimación *cualitativa* basada en el análisis del comportamiento del modelo y no un desglose cuantificado de forma empírica. Una cuantificación precisa de la contribución de cada fuente de error requeriría mapas de referencia externos (verdad terreno) para cada año, los cuales no están disponibles para la serie completa 1984–2020.

6.6.2. Análisis morfológico de la predicción

El análisis morfológico cualitativo de los mapas generados muestra que el modelo reproduce patrones estructurales del crecimiento urbano coherentes con el observado: la expansión se concentra en los bordes de áreas ya urbanizadas (mecanismo de difusión), con presencia de fragmentación periférica. El mapa predicho para 2020 tiene un número de celdas urbanizadas mayor al observado (sobre-predicción sistemática), pero la distribución espacial del crecimiento sigue el mismo patrón de contigüidad que el real.

El cálculo formal de métricas de paisaje (FRAGSTATS, Moran’s I) requeriría la ejecución de análisis específicos sobre los mapas predicho y observado. Los archivos de mapa predicho están

disponibles, por ejemplo, en `data/processed/validation_quinquenal_2015_2020_v3_weighted/predicted_2020.npy`, para verificación independiente.

Para la planificación urbana a escala metropolitana, la reproducción cualitativa de los patrones de difusión contigua puede ser tan relevante como la concordancia píxel a píxel en las transiciones, que es lo que el FoM evalúa específicamente y que en este trabajo alcanza un promedio de 0,317.

6.6.3. Fortalezas y debilidades del modelo

Fortalezas identificadas

1. **Consistencia espacial:** Las predicciones concentran el crecimiento en bordes de áreas urbanas existentes, coherente con el patrón de difusión observado.
2. **FoM promedio** de 0,317 (promedio de los cinco archivos `validation_results.json`), interpretado frente al espectro multi-sitio documentado por Pontius Jr et al. (2008) (Capítulo ??).
3. **Recall alto:** superior a 0,91 en todos los períodos; el modelo captura la mayor parte de la urbanización real.
4. **Fidelidad morfológica:** Las comparaciones visuales entre mapas predichos y observados (figuras `summary_XXXX_to_XXXX.png` de cada período) muestran que el crecimiento predicho se concentra consistentemente en los bordes del área urbana existente, reproduciendo el patrón de difusión contigua observado en los cinco períodos.
5. **Parsimonia:** Siete variables espaciales derivadas del mapa binario (distancia a área urbana, densidades de vecindad $3\times3/5\times5/7\times7$, fragmentación local, gradiente urbano y tamaño de cluster) logran estas métricas sin requerir datos socioeconómicos externos.

Debilidades identificadas

1. **Sobre-predicción sistemática:** En todos los períodos el crecimiento predicho supera al observado por un factor de entre 2 y 8 veces.
2. **Precision moderada:** entre 0,59 y 0,70; muchas predicciones de transición son falsas alarmas.
3. **Crecimiento disperso no modelado:** El mecanismo de vecindad no captura el desarrollo tipo *leapfrog*.
4. **Variables externas:** La omisión de variables socioeconómicas o de infraestructura (p. ej. distancia a empleo, precio del suelo) limita la precisión más allá de las siete variables

derivadas del mapa binario.

6.6.4. Validación de hipótesis

A continuación se contrasta cada una de las seis hipótesis enunciadas en el Capítulo ?? con la evidencia empírica obtenida en los cinco períodos de validación. Cada hipótesis se reproduce de forma literal (entre comillas) antes de su contraste. El cuadro resumen consolidado se presenta en el Capítulo ??.

- **H1 (apoyada por la evidencia):** *«La integración de WoE como función de transición empírica del AC produce simulaciones con FoM superior a 0,15 en las cinco ventanas de validación quinquenal.»* El criterio se cumple: el FoM se mantiene en el intervalo [0,222, 0,378] en los cinco períodos (Tabla 6.5), con un promedio de 0,317, Accuracy promedio de 0,722 y Kappa promedio de 0,445. Esa magnitud se ubica en una **banda intermedia** respecto al espectro empírico multi-sitio resumido en el Capítulo ?? con base en Pontius Jr et al. (2008).
- **H2 (apoyada por la evidencia):** *«En el espacio de parámetros (umbral de transición, peso de vecindad) existe un óptimo no trivial: la configuración calibrada por búsqueda sistemática supera a una configuración por omisión sin calibrar en el FoM medio de las cinco ventanas, y los umbrales por debajo del calibrado degradan el desempeño por sobre-predicción.»* La configuración calibrada (umbral 0,75, peso de vecindad 0,50 y ponderación por IV) produjo FoM en el intervalo [0,222, 0,378] a lo largo de las cinco ventanas, sin reentrenar el WoE por período. El contraste documentado en el repositorio con configuraciones preliminares, en particular un experimento exploratorio con umbral cercano a 0,60 que generaba sobre-predicción masiva (FoM del orden de 0,17), sostiene la mejora atribuida a la calibración adoptada.
- **H3 (apoyada por la evidencia):** *«Entre las siete variables espaciales evaluadas, las que cuantifican la proximidad al frente urbano y la densidad de vecindad concentran el mayor Information Value (IV), por encima de las variables de fragmentación y de gradiente.»* Las variables de distancia al área urbana y de densidad de vecindad concentran cerca del 75 % del Information Value (Tabla 6.2), por encima de la fragmentación local y del gradiente. La relación monotónica creciente entre el WoE y la densidad de vecindad (Figura 6.2) reproduce sobre los datos de Querétaro el patrón de difusión por contagio espacial descrito en la literatura.
- **H4 (apoyada de forma parcial):** *«El modelo mantiene FoM y Kappa estables a lo largo de las cinco ventanas quinquenales, con mayor variación en los períodos donde la extensión de*

nueva área urbana observada es pequeña.» El comportamiento morfológico es estable (los patrones de expansión perimetral se reproducen en todos los períodos), pero las métricas pixel-exactas muestran sensibilidad a la dinámica observada: el FoM varía entre 0,222 y 0,378 según el crecimiento neto del período, y el valor más bajo (2011–2016) coincide con la ventana de menor crecimiento neto observado. La omisión del crecimiento disperso (*leapfrog*), reconocida más adelante como debilidad del modelo, es la principal fuente de degradación pixel-exacta detectada.

- **H5 (apoyada por la evidencia):** *«Restringir la función de transición a siete variables auditables (un modelo de caja blanca) mantiene el FoM medio dentro de la banda intermedia del espectro multi-sitio de Pontius Jr et al. (2008), por encima del subconjunto de aplicaciones con FoM inferior a 0,15, sin recurrir a las representaciones no interpretables propias de los modelos de caja negra (Almeida et al., 2008; García-Ramírez et al., 2023).»* El FoM promedio de 0,317 y el IoU promedio de 0,633 se ubican en esa banda intermedia, por encima del subconjunto con FoM inferior a 0,15, manteniendo pesos auditables (vía *Information Value*) con solo siete variables derivadas del mapa binario. La restricción a un modelo interpretable no hundió el desempeño por debajo de la banda, por lo que la hipótesis se considera apoyada; el contraste con los modelos de caja negra es, eso sí, cualitativo (sitios, clases y horizontes temporales distintos) y no un experimento directo sobre el mismo conjunto de datos.
- **H6 (apoyada por la evidencia):** *«El pipeline completo, desde la adquisición de imágenes hasta la validación quinquenal, se ejecuta en una CPU estándar en un tiempo del orden de horas, sin requerir GPU, software propietario ni hardware especializado.»* Todo el flujo se implementó en Python (NumPy, SciPy, scikit-learn) sobre imágenes de archivo de Google Earth, sin software propietario ni GPU, con un cómputo del orden de horas en una CPU estándar.

6.6.5. Síntesis del desempeño del modelo

Vistas en conjunto, las cinco ventanas dibujan un comportamiento consistente más que un resultado aislado. El FoM se mantiene en una banda intermedia (promedio 0,317, entre 0,222 y 0,378) y el Recall alto en todos los períodos indica que el modelo rara vez deja fuera la urbanización que sí ocurre. El costo de esa cobertura es una sobre-predicción sistemática: el crecimiento simulado supera al observado y la *Precision* se queda en un rango moderado. En otras palabras, el modelo opera en un régimen de alta cobertura predictiva y baja especificidad relativa: acierta dónde crece la ciudad, pero tiende a hacerla crecer de más. Este comportamiento es propagación conservadora en términos de omisión y expansiva en términos de falsos positivos,

consecuencia de un campo de probabilidad WoE que favorece la expansión continua del estado urbano ante vecindades parcialmente urbanizadas.

Ese patrón es coherente con la lectura de los pesos WoE. La distancia al área urbana y la densidad de vecindad concentran cerca del 75 % del *Information Value*, de modo que la señal que gobierna la simulación es la difusión por contigüidad. Ahí está, a la vez, la fortaleza y el límite del enfoque: como es un modelo de caja blanca, se puede leer qué lo mueve; pero al apoyarse solo en variables derivadas del propio mapa binario, no captura el desarrollo disperso ni los factores socioeconómicos que explican parte del crecimiento real. La validación multi-período, más que un número único, es lo que da solidez a esta lectura, porque muestra que el comportamiento se sostiene bajo distintas dinámicas observadas. En términos dinámicos, el sistema no converge a un estado estacionario único, sino que sus trayectorias dependen del estado inicial y se organizan en torno a atractores espaciales locales (los núcleos urbanos consolidados y los corredores de crecimiento) que persisten a lo largo de las cinco simulaciones quinquenales.

Estos resultados son el insumo del capítulo siguiente, donde se consolidan las hipótesis en un cuadro único, se precisan las contribuciones del trabajo y se discuten las líneas para corregir las debilidades aquí identificadas, en particular la sobre-predicción y el crecimiento tipo *leapfrog*.

Bibliografía

- Almeida, C. M., Gleriani, J. M., Castejon, E. F., & Soares-Filho, B. S. (2008). Using neural networks and cellular automata for modelling intra-urban land-use dynamics. *International Journal of Geographical Information Science*, 22(9), 943-963. <https://doi.org/10.1080/13658810701731168>
- García-Ramírez, P., Alatorre-Cejudo, L. C., & Bravo-Peña, L. C. (2023). Detección, modelización y proyección del crecimiento urbano de núcleos de población en diferentes cuencas hidrológicas de Chihuahua, México. *Investigación y Ciencia de la Universidad Autónoma de Aguascalientes*, 31(90), 1-19. <https://doi.org/10.33064/iycuaa2023904103>
- Pontius Jr, R. G., Boersma, W., Castella, J.-C., Clarke, K., de Nijs, T., Dietzel, C., Duan, Z., Fotsing, E., Goldstein, N., Kok, K., Koomen, E., Lippitt, C. D., McConnell, W., Mohd Sood, A., Pijanowski, B., Pithadia, S., Sweeney, S., Trung, T. N., Veldkamp, A. T., & Verburg, P. H. (2008). Comparing the input, output, and validation maps for several models of land change. *The Annals of Regional Science*, 42(1), 11-37. <https://doi.org/10.1007/s00168-007-0138-2>
- Tang, X., Liu, F., & Hu, X. (2024). Urban growth simulation and scenario projection for the arid regions using heuristic cellular automata. *Scientific Reports*, 14(1), 21106. <https://doi.org/10.1038/s41598-024-71709-4>