

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

POSGRADO EN CIENCIA E INGENIERÍA DE LA COMPUTACIÓN

Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas

**Modelado del crecimiento urbano de la
Zona Metropolitana de Querétaro (1984–2020)
mediante Pesos de Evidencia y autómatas
celulares**

TESIS

QUE PARA OPTAR POR EL GRADO DE:

MAESTRO EN CIENCIA E INGENIERÍA DE LA COMPUTACIÓN

PRESENTA:

JOSÉ RODRIGO MORENO LÓPEZ

DIRECTORA DE TESIS:

DRA. MARÍA ELENA LÁRRAGA RAMÍREZ

Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas

*A mi madre, ante todo,
por sostenerme con su ejemplo y su cariño incondicional;
cada página de este trabajo lleva algo suyo.*

*A mi abuela, raíz y refugio,
cuya fortaleza me acompaña siempre.*

A mi tío Germán, por su guía y su confianza.

*A Donaldo, mi mejor amigo,
y a Mau,
por caminar a mi lado en cada etapa.*

Gracias por ser mi lugar seguro.

Resumen

Esta tesis presenta un modelo reproducible de crecimiento urbano para la Zona Metropolitana de Querétaro, construido a partir de una serie anual de imágenes de 37 años (1984–2020) y del acoplamiento entre Pesos de Evidencia (WoE) y autómatas celulares (AC). Las capturas RGB obtenidas con la herramienta de imagen histórica de Google Earth se transformaron en mapas binarios urbano/no-urbano mediante un *pipeline* de clasificación basado en patrones binarios locales, agrupamiento K-Means y un clasificador SVM lineal. Sobre esos mapas, los Pesos de Evidencia cuantifican la influencia espacial de un conjunto reducido de variables auditables y alimentan, junto con la vecindad de Moore, una regla de transición probabilística que el autómata celular aplica celda a celda.

El modelo se calibró mediante búsqueda sistemática sobre el umbral de transición, el peso de la vecindad y la ponderación por *Information Value*, y se evaluó con un protocolo de validación en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020). El desempeño promedio alcanza un *Figure of Merit* de 0,317, un coeficiente Kappa de 0,445, una exactitud de 0,722 y un *IoU* de 0,633, con la descomposición de error de Pontius como marco de interpretación. La contribución central no es el acoplamiento WoE-AC en sí, sino un protocolo de validación multitemporal reproducible, aplicado a un contexto mexicano poco documentado, con una implementación de caja blanca que corre íntegramente en CPU, sin GPU ni software propietario, a partir de datos de acceso libre.

Palabras clave: crecimiento urbano; autómatas celulares; Pesos de Evidencia; validación multitemporal; *Figure of Merit*; Zona Metropolitana de Querétaro.

Abstract

This thesis presents a reproducible urban growth model for the Querétaro Metropolitan Area, built from a 37-year annual image series (1984–2020) and the coupling of Weights of Evidence (WoE) with cellular automata (CA). RGB captures obtained through Google Earth’s historical imagery tool were turned into binary urban/non-urban maps via a classification pipeline based on local binary patterns, K-Means clustering and a linear SVM classifier. On these maps, the Weights of Evidence quantify the spatial influence of a small set of auditable variables and feed, together with the Moore neighborhood, a probabilistic transition rule that the cellular automaton applies cell by cell.

The model was calibrated through a systematic search over the transition threshold, the neighborhood weight and the *Information Value* weighting, and was assessed with a validation protocol across five independent five-year windows (2011–2016 to 2015–2020). Average performance reaches a Figure of Merit of 0.317, a Kappa coefficient of 0.445, an accuracy of 0.722 and an IoU of 0.633, using the Pontius error decomposition as the interpretation framework. The central contribution is not the WoE-CA coupling itself, but a reproducible multi-temporal validation protocol, applied to a scarcely documented Mexican context, with a white-box implementation that runs entirely on CPU, without GPU or proprietary software, from openly accessible data.

Keywords: urban growth; cellular automata; Weights of Evidence; multi-temporal validation; Figure of Merit; Querétaro Metropolitan Area.

Índice general

Resumen	II
Abstract	III
Acrónimos y siglas	XIII
1. Introducción	1
1.1. Contexto y problema	1
1.2. Literatura existente y brecha metodológica	3
1.3. Objetivos	4
1.3.1. Objetivo general	4
1.3.2. Objetivos específicos	4
1.4. Preguntas de investigación e hipótesis	5
1.4.1. Preguntas de investigación	5
1.4.2. Hipótesis	5
1.5. Alcances y limitaciones	6
1.5.1. Alcances	6
1.5.2. Limitaciones	6
1.6. Aportaciones del trabajo	7
1.7. Organización del documento	8
2. Marco teórico	9

2.1.	Preprocesamiento de datos	9
2.2.	Autómatas Celulares	13
2.3.	Métricas de evaluación de modelos predictivos	17
3.	Estado del arte	21
3.1.	Evolución del modelado urbano computacional	21
3.2.	Problemas metodológicos persistentes	22
3.2.1.	Calibración: equifinalidad y costo computacional	22
3.2.2.	Validación: sobreajuste temporal y métricas no comparables	23
3.2.3.	Interpretabilidad: el problema de la caja negra	24
3.2.4.	Transferibilidad: software propietario y reproducibilidad	25
3.3.	Pesos de Evidencia y modelos probabilísticos espaciales	26
3.4.	Validación espacial en modelos LUCC	28
3.5.	Vacíos específicos en el contexto mexicano	28
3.6.	Síntesis: posicionamiento del presente trabajo	29
4.	Área de estudio	31
4.1.	Localización y características del área de estudio	31
4.1.1.	Descripción y fuente de datos	31
4.2.	Adquisición y conformación del conjunto de imágenes	32
4.2.1.	Criterios de selección y parámetros espaciales	33
4.2.2.	Control de calidad, limitaciones y mitigación	33
4.3.	Pipeline de clasificación: de RGB a mapas binarios	35
4.3.1.	Extracción de características	36
4.3.2.	Normalización y reducción dimensional	37
4.4.	Análisis de datos procesados y transformación binaria	37
4.4.1.	Resultados de la transformación binaria	38
4.4.2.	Calidad interna de la clasificación	38
4.4.3.	Justificación de la representación binaria	38

4.4.4.	Síntesis del capítulo	39
5.	Modelo de crecimiento urbano	40
5.1.	Del preprocesamiento a la serie binaria de entrada	40
5.2.	Modelo de crecimiento urbano.	41
5.3.	Validación.	46
6.	Resultados y análisis	49
6.1.	Dinámica observada del crecimiento urbano	49
6.1.1.	Evolución temporal 1984–2020	49
6.1.2.	Patrones espaciales de expansión	50
6.2.	Resultados del análisis Weight of Evidence	51
6.2.1.	Transiciones históricas identificadas	51
6.2.2.	Pesos por variable (Information Value)	52
6.2.3.	Interpretación de los pesos WoE	52
6.3.	Calibración del modelo	53
6.3.1.	Configuración del autómata celular	53
6.3.2.	Proceso de calibración	54
6.4.	Simulación del crecimiento urbano	54
6.4.1.	Protocolo de validación quinquenal múltiple	54
6.5.	Evaluación del modelo	55
6.5.1.	Resumen comparativo – cinco períodos quinquenales	55
6.5.2.	Período 2011–2016	58
6.5.3.	Período 2012–2017	59
6.5.4.	Período 2013–2018	60
6.5.5.	Período 2014–2019	61
6.5.6.	Período 2015–2020	62
6.6.	Análisis espacial del error del modelo	63
6.6.1.	Fuentes de error identificadas	63

6.6.2.	Análisis morfológico de la predicción	64
6.6.3.	Fortalezas y debilidades del modelo	65
6.6.4.	Validación de hipótesis	66
6.6.5.	Síntesis del desempeño del modelo	67
7.	Conclusiones	69
7.1.	Principales hallazgos	69
7.1.1.	Síntesis de la investigación	69
7.1.2.	Respuestas a las preguntas de investigación	70
7.1.3.	Cumplimiento de los objetivos específicos	71
7.1.4.	Validación de hipótesis	72
7.1.5.	Aportaciones del trabajo	73
7.2.	Implicaciones para la planificación urbana	74
7.2.1.	Herramientas para decisión informada	75
7.2.2.	Escenarios de política pública	75
7.2.3.	Accesibilidad computacional	76
7.2.4.	Relevancia para ciudades intermedias mexicanas	76
7.3.	Limitaciones del modelo	77
7.3.1.	Limitaciones conceptuales	77
7.3.2.	Limitaciones empíricas	77
7.3.3.	Limitaciones de transferibilidad	78
7.3.4.	Trabajo futuro	78
7.4.	Mensaje central	79
7.5.	Palabras finales	80
A.	Arquitectura e implementación del software	81
A.1.	Procedimiento de adquisición manual de imágenes	83
A.2.	Cuadros complementarios del conjunto de datos	84
	Bibliografía	87

Índice de figuras

1.1.	Secuencia de capturas RGB (insumo <i>raw</i>) obtenidas con Google Earth en modo imagen histórica sobre la Zona Metropolitana de Querétaro (1984, 2010 y 2020), en orden cronológico y con encuadre homogéneo según el procedimiento manual descrito para la serie temporal. Visualmente se aprecia la expansión periférica y un patrón de ocupación predominantemente disperso.	2
2.1.	Flujo de preprocesamiento de datos.	13
2.2.	Ejemplo del cálculo de WoE: la variable <i>distancia al frente urbano</i> acumula pesos positivos en bins próximos y negativos en bins lejanos. La suma ponderada pasa por la sigmoide y se compara con $\theta = 0,75$	16
4.1.	Indicadores auxiliares de calidad por década, derivados del preprocesamiento de las capturas. No equivalen a control de calidad radiométrico de productos satelitales oficiales; sirven como apoyo visual para revisar la continuidad de la serie.	34
4.2.	Pipeline de preprocesamiento implementado	36
4.3.	Evolución del crecimiento urbano de la Zona Metropolitana de Querétaro (1984–2020), representada mediante mapas binarios urbano/no-urbano obtenidos a partir de la clasificación LBP+K-Means+SVM aplicada a las capturas RGB de la serie.	38
5.1.	Representación binaria $U_t(i, j) \in \{0, 1\}$: celdas oscuras urbanas y claras no urbanas. .	41
5.3.	Transición $U_t(i, j) = 0 \rightarrow U_{t+1}(i, j) = 1$: la celda con borde rojo transita a urbana cuando $P_{i,j} > \theta$	41

5.2.	Pipeline completo del modelo WoE-AC: del dato satelital a la validación quinquenal. Las etapas 1–2 producen la serie binaria; la etapa 3 estima los pesos de evidencia sobre 26 pares históricos; la etapa 4 ejecuta el autómata celular de forma iterativa; la etapa 5 evalúa con cinco ventanas temporales independientes.	42
5.4.	Las siete variables espaciales derivadas del mapa binario U_t . Todas se calculan exclusivamente a partir de la configuración urbana histórica, sin capas externas.	43
5.5.	Vecindad de Moore (8 celdas) frente a Von Neumann (4 ortogonales). Moore captura frentes diagonales de crecimiento.	44
5.6.	Un paso del AC: las celdas candidatas (borde rojo) se evalúan con la regla WoE y transitan a urbanas (relleno rojo) si $P_{i,j} > \theta$	45
5.7.	Protocolo de validación: separación temporal entre entrenamiento (WoE, 1984–2010) y las cinco ventanas quinquenales de prueba (2011–2020). Ningún dato del período de prueba interviene en el ajuste del modelo.	47
5.8.	Componentes del <i>Figure of Merit</i> : acierto (B), falsa alarma (A) y omisión (C). Solo las celdas en transición entran al cálculo.	48
6.1.	Evolución de la fracción clasificada como “urbano” en Querétaro (1984–2020). Se observa una tendencia ascendente con fuerte variabilidad interanual, más marcada en el tramo final de la serie.	50
6.2.	Pesos WoE por bin de densidad de vecindad urbana. La relación monotonía creciente es coherente con un mecanismo de difusión espacial y sitúa a la densidad de vecindad como el predictor de mayor peso entre las variables del modelo, sin que ello implique que sea la única causa del crecimiento.	53
6.3.	Desempeño comparado del modelo WoE-AC en las cinco ventanas quinquenales. Las líneas verticales punteadas señalan el promedio de cada métrica: FoM = 0,317, Kappa = 0,445, IoU = 0,633. La estabilidad entre ventanas indica que el modelo captura una dinámica estructural del crecimiento y no un patrón sobreajustado.	57
6.4.	Validación quinquenal 2011–2016. De izquierda a derecha: estado inicial (2011), mapa observado 2016 (<i>ground truth</i>), mapa predicho 2016 y diferencia (verde=TP, naranja=FP, azul=FN). FoM = 0,222; la anomalía se debe a que el área urbana observada disminuyó levemente por variabilidad en la clasificación binaria RGB año a año.	58

6.5.	Validación quinquenal 2012–2017. FoM = 0,345; período con crecimiento observado positivo (+27,9 %) y FoM numéricamente superior al de la ventana 2011–2016 bajo el mismo protocolo. Los 602,889 hits (B) corresponden a píxeles donde tanto el modelo como la observación registran transición a urbano en el período, asociados a la expansión perimetral visible en el mapa binario.	59
6.6.	Validación quinquenal 2013–2018. FoM = 0,355; valor numéricamente cercano al del período 2012–2017 en un contexto análogo de crecimiento observado positivo. El número de omisiones (231,317 píxeles) sugiere que parte de la expansión hacia el norte y el este no queda recogida en la predicción bajo este experimento.	60
6.7.	Validación quinquenal 2014–2019. FoM = 0,287; el crecimiento real modesto (+9,5 %) contrasta con una predicción de expansión más elevada (+68,3 %), lo que se refleja en la proporción de falsas alarmas (1,176,288 píxeles). El Recall alto (0,965) indica que el modelo asigna clase urbana de forma amplia respecto al mapa observado en 2019.	61
6.8.	Validación quinquenal 2015–2020. FoM = 0,378; entre las cinco ventanas es el valor de FoM numéricamente más alto, en un contexto de fuerte crecimiento observado (+33,5 %). Se registran 704,983 hits y, en términos relativos a este conjunto de corridas, una menor proporción de falsas alarmas que en otras ventanas.	62
6.9.	Mapa de error para la ventana 2015→2020 (mejor desempeño, FoM = 0,378). Las celdas verdes (B) son aciertos —transiciones correctamente predichas—; las ámbar (A) son falsas alarmas; las rojas (C) son omisiones. Solo las celdas en transición entran al cálculo del FoM; las permanencias urbanas y no urbanas aparecen en gris.	63
A.1.	Arquitectura del framework WoE-AC para modelado de crecimiento urbano. Diagrama UML mostrando las clases del sistema organizadas en paquetes: Configuration (configuración), Data/IO (manejo de datos históricos), Feature & Spatial (extracción de características), Weight of Evidence (cálculo de pesos), Cellular Automaton (simulación AC) y Orchestrator (pipeline y calibración de parámetros). El diagrama se genera desde el código fuente usando PlantUML (ver <code>diagramas/architecture.puml</code>).	82

Índice de cuadros

1.1.	Requerimientos del modelo de crecimiento urbano para la ZMQ.	2
3.1.	Posicionamiento de la literatura mexicana frente a R1–R4.	29
6.1.	Fracción media de píxeles clasificados como “urbano” por tramo de la serie 1984–2020. Las cifras provienen directamente de los mapas binarios y deben leerse como un indicador grueso de la dinámica, no como superficie construida.	50
6.2.	<i>Information Value</i> y pesos normalizados de las siete variables WoE, calculados sobre el período de entrenamiento (1984–2010).	52
6.3.	Configuración final del Autómata Celular WoE-AC.	53
6.4.	Configuración del experimento de validación quinquenal múltiple.	55
6.5.	Métricas de validación en las cinco ventanas quinquenales (WoE-AC, umbral $\theta = 0,75$).	56
6.6.	Posicionamiento del modelo WoE-AC en el espectro empírico de Figure of Merit (FoM) documentado en la literatura LUCC. La comparación es cualitativa: los sitios, las definiciones temáticas de las clases y los horizontes temporales difieren entre estudios.	56
6.7.	Métricas de validación del período 2011→2016. <i>B</i> (hits del FoM) es el subconjunto de <i>TP</i> que corresponde a transiciones a urbano observadas y predichas simultáneamente; los píxeles permanentes ya urbanizados quedan incluidos en <i>TP</i> pero no en <i>B</i> (véase Ec. 2.22).	58
6.8.	Métricas de validación del período 2012→2017.	59
6.9.	Métricas de validación del período 2013→2018.	60
6.10.	Métricas de validación del período 2014→2019.	61

6.11. Métricas de validación del período 2015→2020.	62
6.12. Estimación cualitativa de la contribución de fuentes de error (no cuantificada empíricamente)	64
7.1. Resumen de validación de hipótesis	72
7.2. Escenarios de política pública <i>conceptualmente</i> simulables con el modelo WoE-AC mediante ajuste de parámetros o máscaras de probabilidad. Las direcciones de efecto son cualitativas; este trabajo no calibró corridas contrafactuales por política ni cuantificó impactos en métricas de dispersión para Querétaro.	75
7.3. Características operativas del enfoque WoE-AC frente a modelos de aprendizaje profundo	76
A.1. Características extraídas por píxel a partir de cada captura RGB.	84
A.2. Estimación cualitativa de las principales fuentes de error del conjunto de imágenes, su efecto sobre los mapas binarios y su mitigación. Los niveles son apreciaciones del autor, no medidas formales de incertidumbre.	85
A.3. Resumen agregado del preprocesamiento aplicado a la serie 1984–2020.	86

Acrónimos y siglas

AC	Autómata celular (<i>Cellular Automaton</i>).
WoE	Pesos de Evidencia (<i>Weight of Evidence</i>).
IV	Valor de Información (<i>Information Value</i>).
FoM	Figura de Mérito (<i>Figure of Merit</i>).
IoU	Índice de solapamiento (<i>Intersection over Union</i>).
LULC	Cobertura y uso del suelo (<i>Land Use / Land Cover</i>).
LUCC	Cambio en la cobertura y uso del suelo (<i>Land Use / Land Cover Change</i>).
PCA	Análisis de componentes principales (<i>Principal Component Analysis</i>).
LBP	Patrones binarios locales (<i>Local Binary Patterns</i>).
SVM	Máquina de vectores de soporte (<i>Support Vector Machine</i>).
RGB	Modelo de color rojo-verde-azul (<i>Red-Green-Blue</i>).
NGRDI	Índice verde-rojo normalizado (<i>Normalized Green-Red Difference Index</i>).
NDVI	Índice de vegetación de diferencia normalizada (<i>Normalized Difference Vegetation Index</i>).
ZMQ	Zona Metropolitana de Querétaro.
GPU	Unidad de procesamiento gráfico (<i>Graphics Processing Unit</i>).
CPU	Unidad central de procesamiento (<i>Central Processing Unit</i>).
UNAM	Universidad Nacional Autónoma de México.
PCIC	Posgrado en Ciencia e Ingeniería de la Computación.
IIMAS	Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas.

Capítulo 1

Introducción

El crecimiento urbano disperso de las ciudades intermedias mexicanas, y de la Zona Metropolitana de Querétaro en particular, ha rebasado la capacidad de los instrumentos de planeación, sin que exista para ese contexto un modelo de simulación que sea, a la vez, interpretable celda a celda, validado en varios horizontes temporales y reproducible con datos abiertos. Para atender ese vacío, este trabajo desarrolló y validó un modelo de autómatas celulares con función de transición basada en Pesos de Evidencia (WoE-AC), calibrado por búsqueda sistemática y evaluado sobre cinco ventanas quinquenales independientes dentro de la serie 1984–2020. El diagnóstico que abre el capítulo delimita esa brecha científica concreta y la traduce en los requerimientos, las preguntas de investigación y las hipótesis falsables que estructuran el resto de la tesis; la aportación del trabajo no radica en el acoplamiento WoE-AC en sí, sino en su evaluación reproducible y multi-período para una ciudad intermedia mexicana.

1.1. Contexto y problema

México cuenta con instrumentos de ordenamiento territorial (la Ley General de Asentamientos Humanos, los Programas Municipales de Ordenamiento Territorial y Desarrollo Urbano [PMOTDU], la SEDATU y acuerdos con ONU-Hábitat), pero su cobertura efectiva es limitada: solo el 20,5 % de los municipios dispone de un instrumento vigente, casi dos tercios de los planes publicados no han sido actualizados y, según el INEGI, entre el 43 % y el 80 % de la población mexicana reside en zonas urbanas. El resultado observable es un patrón de crecimiento disperso que supera la capacidad de planificación disponible, con impactos documentados sobre infraestructura, cobertura de suelo y calidad de vida.

Como se observa en la figura 1.1, la mancha urbana de Querétaro se expandió de forma




Figura 1.1: Secuencia de **capturas RGB** (insumo *raw*) obtenidas con Google Earth en modo imagen histórica sobre la Zona Metropolitana de Querétaro (**1984, 2010 y 2020**), en orden cronológico y con encuadre homogéneo según el procedimiento manual descrito para la serie temporal. Visualmente se aprecia la expansión periférica y un patrón de ocupación predominantemente disperso.

dispersa entre 1984 y 2020, con una tasa de crecimiento que la posiciona entre las ciudades intermedias de mayor dinamismo en México durante ese período. Este patrón, documentado pero no suficientemente modelado para la ZMQ, impide anticipar dónde y a qué velocidad se producirá la siguiente oleada de expansión: información necesaria para el diseño de infraestructura y política territorial. Querétaro fue seleccionada como caso de estudio por combinar una serie histórica larga (37 años), datos de acceso libre y una dinámica de crecimiento representativa de las ciudades intermedias del centro del país. Para que un modelo de simulación sea útil como herramienta de apoyo a la planeación, debe satisfacer los cuatro requerimientos de la Tabla 1.1.

Cuadro 1.1: Requerimientos del modelo de crecimiento urbano para la ZMQ.

ID	Requerimiento	Descripción y criterio de cumplimiento
R1	Simulación histórica con precisión	Reproducir el patrón de cambio urbano/no-urbano a partir del historial de uso de suelo. El desempeño se evalúa cuantitativamente con FoM, Kappa e IoU en ventanas de validación independientes.
R2	Soporte a planeación estratégica	Generar mapas y escenarios espacialmente explícitos que permitan comparar patrones de expansión y evaluar alternativas de ocupación del suelo.
R3	Replicabilidad y apertura	El flujo completo debe ser documentado, reproducible y ejecutable sin software propietario ni hardware especializado, con calibración sistemática y tiempos de cómputo razonables.
R4	Interpretabilidad de la función de transición	La función que decide la transición de cada celda debe ser auditable: sus pesos deben ser legibles como evidencia espacial cuantificable, no como parámetros opacos de una red neuronal.

1.2. Literatura existente y brecha metodológica

Se revisaron trece trabajos representativos del campo, tanto de escala global como de ciudades mexicanas, para determinar cuáles satisfacen R1–R4 de forma simultánea. R4, la interpretabilidad de la función de transición, resultó ser la condición más restrictiva: los modelos con mejor desempeño cuantitativo en el espacio de aprendizaje automático aplicado a problemas espaciales (Almeida et al. (2008); Hagenauer y Helbich (2022); Ma et al. (2019)) emplean redes neuronales cuyas activaciones internas no son legibles como evidencia espacial; el híbrido metaheurístico de Wang et al. (2021) sustituye los pesos por cromosomas, con la misma consecuencia para la interpretabilidad. Los modelos de caja blanca más citados (Clarke y Gaydos (1998); Santé et al. (2010); Aburas et al. (2016)) atienden R1 pero no validan sobre más de un período quinquenal independiente, por lo que no es posible determinar si su desempeño refleja mecanismos espaciales estables o sobreajuste a una fase particular del crecimiento. Los tres trabajos para ciudades mexicanas revisados (Suárez y Delgado (2007); Ramírez Hernández (2021); García-Ramírez et al. (2023)) se alinean parcialmente con R1 y R2, pero no con R3 ni con R4. En el Cap. 3 se documentan dichas evaluaciones.

Leídas en conjunto, estas limitaciones no son cuatro vacíos independientes sino una sola brecha científica: para las ciudades intermedias mexicanas no se dispone de un modelo de simulación del crecimiento urbano cuya función de transición sea auditable celda a celda y cuya capacidad predictiva haya sido evaluada en varias ventanas temporales independientes con código y datos abiertos. Mientras esa brecha persista, no es posible distinguir si el desempeño que reportan los modelos disponibles para el país corresponde a mecanismos espaciales estables o a un sobreajuste de corto plazo a una fase concreta del crecimiento. Los requerimientos R1–R4 de la Tabla 1.1 son la forma operativa de comprobar si un modelo cierra esa brecha: descomponen esa única pregunta (¿es el modelo, a la vez, interpretable, temporalmente robusto y reproducible?) en criterios verificables. Esa es la brecha que el presente trabajo atiende.

El presente trabajo desarrolló y validó un modelo WoE-AC que satisface R1–R4 de forma conjunta: WoE como función de transición produce pesos de evidencia (IV) cuantificables por variable y clase espacial (R4); la calibración mediante búsqueda sistemática en cuadrícula sobre cinco ventanas quinquenales independientes evalúa robustez temporal y no solo ajuste a un único período (R1); la implementación íntegra en Python con datos de acceso libre garantiza reproducibilidad sin software propietario (R3); y los mapas simulados son directamente interpretables como escenarios de expansión para planeación territorial (R2). El análisis detallado de los trabajos revisados y su posicionamiento respecto a estos requerimientos se desarrolla en el Cap. 3.

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar un modelo basado en autómatas celulares que integre el método Weight of Evidence para simular el crecimiento urbano de la Zona Metropolitana de Querétaro en el período 1984–2020, evaluar su desempeño mediante métricas espaciales cuantitativas y comparar los resultados con valores de referencia reportados en la literatura. Esto es, desarrollar un modelo que cumpla con los requerimientos básicos planteados en la Tabla 1.1 y que sea capaz de simular el crecimiento urbano de la ciudad de Querétaro en el período 1984–2020.

1.3.2. Objetivos específicos

El primer objetivo específico consiste en construir una serie histórica anual (1984–2020) de mapas binarios urbano/no-urbano para la ZMQ a partir de imágenes de archivo de Google Earth, empleando clasificación no supervisada para prescindir de etiquetas manuales y garantizar que el flujo de adquisición y preprocesamiento sea replicable sin software propietario. Sobre esa serie, el segundo objetivo selecciona y calcula las variables espaciales derivadas de los mapas binarios, que sirven de evidencia empírica al modelo WoE. La elección de WoE como función de transición, frente a alternativas como la regresión logística o las redes neuronales, responde a su capacidad de descomponer la contribución de cada variable mediante el Valor de Información (IV), propiedad que hace auditable la decisión celda a celda y cumple el requerimiento R4 de la Tabla 1.1.

El tercer objetivo diseña e implementa el autómata celular WoE-AC que simula la transición de no urbano a urbano en la ZMQ. La decisión de usar AC sobre enfoques basados en agentes (ABM) o modelos estadísticos puros se fundamenta en que los AC capturan la dinámica de difusión espacial emergente sin requerir la especificación de reglas de comportamiento individual, y mantienen la interpretabilidad del modelo al nivel de la rejilla espacial (Clarke & Gaydos, 1998; Santé et al., 2010). El cuarto objetivo calibra sistemáticamente los parámetros del WoE-AC (umbral de transición y peso de vecindad) mediante búsqueda en cuadrícula y establece un protocolo de validación multi-período con cinco ventanas quinquenales independientes (2011–2016 a 2015–2020), evaluadas con FoM, Kappa e IoU. La validación en ventanas desplazadas, en lugar de un único período final, hace posible detectar el sobreajuste a una fase específica del crecimiento urbano (Pontius Jr et al., 2008).

Por último, el quinto objetivo analiza la estabilidad temporal del desempeño del modelo a lo largo de los cinco períodos y compara los valores de FoM e IoU obtenidos con los rangos

reportados en la literatura para modelos de caja blanca y de caja negra, con el fin de posicionar la contribución del trabajo en el contexto del estado del arte.

1.4. Preguntas de investigación e hipótesis

1.4.1. Preguntas de investigación

La investigación se articula en torno a cuatro preguntas. La primera indaga si un modelo WoE-AC calibrado puede reproducir el patrón de crecimiento urbano observado en Querétaro con métricas espaciales comparables a las de la literatura. La segunda interroga qué variables espaciales tienen mayor poder discriminatorio para predecir la transición urbana en la ZMQ. La tercera examina si el modelo mantiene la estabilidad de su desempeño al evaluarse en cinco ventanas quinquenales independientes. La cuarta plantea si es posible replicar el pipeline completo en otra ciudad intermedia con datos equivalentes y sin software propietario.

1.4.2. Hipótesis

El trabajo se guía por seis hipótesis falsables. La primera, **H1**, sostiene que la integración de WoE como función de transición empírica del AC produce simulaciones con FoM superior a 0,15 en las cinco ventanas de validación quinquenal. El umbral no es arbitrario: Pontius Jr et al. (2008) documenta que una fracción importante de los modelos LUCC publicados no lo alcanza, de modo que superarlo de forma sostenida, y no en una sola ventana, indicaría que la evidencia espacial histórica contiene información predictiva relevante y no un acierto puntual.

La segunda, **H2**, plantea que en el espacio de parámetros (umbral de transición, peso de vecindad) existe un óptimo no trivial: la configuración calibrada por búsqueda sistemática supera a una configuración por omisión sin calibrar en el FoM medio de las cinco ventanas, y los umbrales por debajo del calibrado degradan el desempeño por sobre-predicción. De no observarse esa mejora, la calibración sería un refinamiento marginal; que se observe implica que es necesaria para este enfoque.

La tercera, **H3**, afirma que entre las siete variables espaciales evaluadas, las que cuantifican la proximidad al frente urbano y la densidad de vecindad concentran el mayor Information Value (IV), por encima de las variables de fragmentación y de gradiente. La hipótesis es falsable: si el ordenamiento del IV estuviera dominado por estas últimas, el crecimiento de la ZMQ no respondería principalmente a la difusión por contigüidad descrita en la literatura (Bonham-Carter, 1994; Clarke & Gaydos, 1998).

La cuarta, **H4**, supone que el modelo mantiene FoM y Kappa estables a lo largo de las cinco

ventanas quinquenales, con mayor variación en los períodos donde la extensión de nueva área urbana observada es pequeña.

La quinta, **H5**, propone que restringir la función de transición a siete variables auditables (un modelo de caja blanca) mantiene el FoM medio dentro de la banda intermedia del espectro multi-sitio de Pontius Jr et al. (2008), por encima del subconjunto de aplicaciones con FoM inferior a 0,15, sin recurrir a las representaciones no interpretables propias de los modelos de caja negra (Almeida et al., 2008; García-Ramírez et al., 2023). La hipótesis es falsable: si la interpretabilidad tuviera un costo grande en desempeño, el FoM medio caería por debajo de esa banda.

Por último, la sexta, **H6**, afirma que el pipeline completo, desde la adquisición de imágenes hasta la validación quinquenal, se ejecuta en una CPU estándar en un tiempo del orden de horas, sin requerir GPU, software propietario ni hardware especializado.

1.5. Alcances y limitaciones

1.5.1. Alcances

El modelo se aplicó a la Zona Metropolitana de Querétaro sobre una serie anual de 37 años (1984–2020), período que concentra la mayor expansión urbana documentada para esta ciudad y para el cual fue posible construir una serie histórica completa a partir de imágenes de archivo de Google Earth. En su dimensión temporal, el alcance abarca esa serie procesada hasta mapas binarios urbano/no-urbano compatibles con el autómata celular; en su dimensión espacial, cada año se representa como una rejilla digital de $1,792 \times 3,024$ píxeles por imagen, derivada del preprocesamiento de las capturas RGB. La metodología fue diseñada para ser replicable en otras ciudades intermedias mexicanas con datos equivalentes, previa recalibración de parámetros.

1.5.2. Limitaciones

El modelo opera sobre imágenes RGB de archivo sin bandas infrarrojas, lo que restringe la clasificación binaria a información espectral visible. Esta decisión fue deliberada: reducir la barrera de entrada a datos de acceso libre y procesamiento reproducible (R3), a costa de la precisión espectral que ofrece la teledetección multispectral. La representación binaria urbano/no-urbano simplifica adicionalmente la complejidad urbana al omitir densidades variables y usos mixtos del suelo; como consecuencia, el modelo captura la dinámica de expansión de la mancha urbana, pero no su estructura interna.

El enfoque es puramente espacial: factores no modelados explícitamente, como políticas

públicas, incentivos económicos o decisiones de inversión, influyeron en el crecimiento real de Querétaro y no están representados en las variables de entrada. Esta limitación es compartida por la mayoría de los modelos CA-WoE de la literatura y acota la interpretación de los resultados al patrón morfológico observado, no a sus causas socioeconómicas.

Finalmente, la elección de caja blanca implica una concesión de desempeño frente a modelos de aprendizaje profundo. Los resultados del Cap. 6 muestran que esta concesión es moderada: el modelo WoE-AC alcanzó FoM y Kappa comparables a los rangos reportados en la literatura para modelos más complejos, lo que sugiere que la pérdida de precisión asociada a la interpretabilidad no es prohibitiva para el caso de uso estudiado.

1.6. Aportaciones del trabajo

La combinación de Pesos de Evidencia y autómatas celulares no es, en sí misma, una novedad metodológica: existe una literatura consolidada que la emplea. Lo que distingue a este trabajo no es la técnica, sino el conjunto de condiciones bajo las cuales se aplicó y evaluó.

En primer lugar, el caso de estudio aborda un contexto poco representado en la literatura de modelado urbano: las ciudades intermedias mexicanas, habitualmente analizadas con calibraciones heurísticas y sobre un solo horizonte temporal. Frente a esa práctica, el modelo se evaluó con un protocolo de validación multi-período sobre cinco ventanas quinquenales independientes (2011–2016 a 2015–2020), lo que permitió examinar la estabilidad temporal del desempeño y no únicamente el ajuste a un período final. Sobre esas ventanas el modelo simuló el crecimiento de la ZMQ con métricas dentro del rango reportado en la literatura (FoM promedio 0,317, Kappa promedio 0,445), un resultado sostenido a lo largo de los cinco horizontes y no concentrado en uno solo.

En segundo lugar, el estudio se apoya en una serie histórica larga, 37 años continuos (1984–2020), construida a partir de imágenes de archivo de acceso libre, lo que ofrece una base temporal más extensa que la habitual en trabajos comparables para el país.

Por último, el flujo completo, desde la adquisición de imágenes hasta la validación quinquenal, se implementó con herramientas de código abierto y quedó documentado paso a paso, de modo que otros investigadores puedan reproducirlo, adaptarlo o extenderlo a otras ciudades intermedias. En este enfoque, la función de transición WoE aporta además pesos de evidencia (IV) legibles por variable, lo que mantiene auditable cada decisión del modelo y facilita interpretar los resultados en términos de los mecanismos espaciales que los sustentan.

1.7. Organización del documento

El resto de la tesis sigue el hilo que abre este diagnóstico. El Capítulo 2 fija el andamiaje formal mínimo (autómatas celulares probabilísticos, Pesos de Evidencia y métricas de evaluación espacial) que el modelo necesita. El Capítulo 3 muestra que los problemas metodológicos que motivan el trabajo (calibración heurística, validación de un solo período, opacidad de la caja negra y dependencia de software propietario) siguen abiertos en la literatura LUCC, y que el caso de las ciudades intermedias mexicanas es donde más se acumulan. El Capítulo 4 justifica la Zona Metropolitana de Querétaro y la fuente de datos abierta, y documenta cómo se construyó la serie binaria 1984–2020. El Capítulo 5 formaliza el acoplamiento WoE-AC, su calibración por búsqueda en cuadrícula y el protocolo de validación quinquenal múltiple. El Capítulo 6 muestra que el modelo se sostiene en las cinco ventanas (FoM medio 0,317) y lo sitúa frente a la literatura. Por último, el Capítulo 7 contrasta las hipótesis con la evidencia, precisa las aportaciones y acota lo que el modelo sí y no permite afirmar.

Capítulo 2

Marco teórico

Este marco teórico sigue el orden del flujo descrito en el Cap. 1: primero los algoritmos de preprocesamiento de imágenes (StandardScaler, PCA, K-Means y SVM), después la definición formal del autómata celular probabilístico y el método de Pesos de Evidencia como función de transición, y al final las métricas espaciales de evaluación. Cada sección incluye únicamente los conceptos que el modelo del Cap. 5 efectivamente utiliza.

2.1. Preprocesamiento de datos

El primer paso del flujo de trabajo fue obtener las capturas RGB de la Zona Metropolitana de Querétaro. Para ello se utilizó Google Earth en su versión de escritorio, a través de la herramienta de imagen histórica, capturando una imagen por año sobre un mismo encuadre. El procedimiento de adquisición se detalla en el Capítulo 4.

El preprocesamiento de dichos datos consiste en la conversión de las capturas RGB en mapas binarios urbano/no-urbano mediante el pipeline LBP+K-Means+SVM. Se define pues un arreglo tridimensional $M_{t,i,j} \in \{0, 1\}$ donde t es el año de la captura, i es la fila y j es la columna de la celda en la cuadrícula. $M_{t,i,j} = 1$ si la celda (i, j) es urbana en el año t , y $M_{t,i,j} = 0$ si la celda (i, j) es no-urbana en el año t .

Cada una de las imágenes RGB está representada por una matriz de $1,792 \times 3,024$ píxeles, en formato PNG. Cada píxel tiene tres canales de color (RGB), de modo que cada imagen es un tensor de $1,792 \times 3,024 \times 3$. Para obtener una conversión precisa, cada píxel se mapea a un vector de 23 características. Sea f_i la i -ésima característica del píxel; el vector de características es $f = (f_1, f_2, \dots, f_{23})_{(i,j)}$. Las definiciones rigurosas de cada característica se organizan en tres conjuntos que se describen a continuación: las características básicas de color, las de textura y

las espectrales (índices y transformaciones de espacio de color).

El primer conjunto reúne las ocho **características básicas de color**, derivadas directamente de los canales rojo, verde y azul.

red: $f_1(i, j) = R(i, j)$, canal rojo.

green: $f_2(i, j) = G(i, j)$, canal verde.

blue: $f_3(i, j) = B(i, j)$, canal azul.

intensity: $f_4(i, j) = \frac{R+G+B}{3}$, intensidad media.

brightness: $f_5(i, j) = 0,299 R + 0,587 G + 0,114 B$, luminancia (Rec. 601).

red_std: $f_6(i, j) = \bar{R}_{5 \times 5}(i, j)$, media de rango local en ventana 5×5 .

green_std: $f_7(i, j) = \bar{G}_{5 \times 5}(i, j)$, equivalente para el canal verde.

blue_std: $f_8(i, j) = \bar{B}_{5 \times 5}(i, j)$, equivalente para el canal azul.

El segundo conjunto agrupa las seis **características de textura**, calculadas sobre la imagen convertida a escala de grises.

sobel_horizontal: $f_9 = \partial \text{gray} / \partial y$, convolución con kernel Sobel horizontal.

sobel_vertical: $f_{10} = \partial \text{gray} / \partial x$, convolución con kernel Sobel vertical.

gradient_magnitude: $f_{11}(i, j) = \sqrt{f_9^2 + f_{10}^2}$, magnitud del gradiente.

lbp: $f_{12}(i, j) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$, patrón binario local uniforme con $P = 24$, $r = 3$ y $s(x) = 1_{x \geq 0}$.

entropy: $f_{13}(i, j) = -\sum_k p_k \log_2 p_k$, entropía local en ventana 9×9 .

contrast: $f_{14}(i, j) = \overline{\text{gray}}_{5 \times 5}(i, j)$, media de rango local.

El tercer conjunto incluye las nueve **características espectrales y de color**: índices contruidos a partir de las bandas visibles y transformaciones a otros espacios de color.

ndvi_approx: $f_{15} = \frac{G - R}{G + R + \varepsilon}$ con $\varepsilon = 10^{-8}$; índice verde-rojo normalizado (NGRDI), proxy cromático de vegetación con bandas visibles. No es un NDVI en sentido estricto, pues este requiere la banda del infrarrojo cercano, ausente en las capturas RGB.

excess_green: $f_{16} = 2G - R - B$, índice de exceso de verde (ExG).

excess_red: $f_{17} = 1,4 R - G$, índice de exceso de rojo (ExR), asociado a suelo y zona urbana.

lab_l: luminancia $L^* \in [0, 100]$ en el espacio CIE $L^* a^* b^*$.

lab_a: eje verde(-) a rojo(+), $a^* \in [-128, 127]$.

lab_b: eje azul(-) a amarillo(+), $b^* \in [-128, 127]$.

hsv_h: matiz $H \in [0, 1]$.

hsv_s: $S = \frac{\max(R, G, B) - \min(R, G, B)}{\max(R, G, B)}$, saturación.

hsv_v: $V = \max(R, G, B)$, valor.

En conjunto, estas 23 características describen cada píxel por su color, su textura y su comportamiento espectral, y constituyen la entrada del paso de reducción dimensional.

Sin embargo dentro del preprocesamiento se reducen las características a 8, mediante un StandardScaler y un PCA.

$$\mathbf{f}(x, y) = \mathbf{W}\mathbf{f}(x, y) \quad (2.1)$$

donde $\mathbf{W}$ es la matriz de pesos PCA.

A continuación se define el algoritmo de StandardScaler y PCA.

Algorithm 1 StandardScaler: estandarización por z-score

Require: Matriz de features $X \in \mathbb{R}^{N \times F}$ (N píxeles, F features)

Ensure: Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$

```

1: Fase de ajuste (sobre los datos de entrenamiento)
2: for  $j = 1$  to  $F$  do
3:    $\mu_j \leftarrow \frac{1}{N} \sum_{i=1}^N X_{ij}$ 
4:    $\sigma_j \leftarrow \sqrt{\frac{1}{N} \sum_{i=1}^N (X_{ij} - \mu_j)^2}$ 
5: end for
6: Fase de transformación
7: for  $i = 1$  to  $N$  do
8:   for  $j = 1$  to  $F$  do
9:      $\tilde{X}_{ij} \leftarrow \frac{X_{ij} - \mu_j}{\sigma_j + \varepsilon}$  ▷  $\varepsilon$  evita división por cero
10:   end for
11: end for
12: return  $\tilde{X}$ 

```

Algorithm 2 PCA: reducción de dimensionalidad

Require: Matriz estandarizada $\tilde{X} \in \mathbb{R}^{N \times F}$, número de componentes $k = 8$

Ensure: Representación reducida $Z \in \mathbb{R}^{N \times k}$

```

1: Calcular la matriz de covarianza:  $\Sigma \leftarrow \frac{1}{N-1} \tilde{X}^\top \tilde{X}$ 
2: Obtener descomposición espectral:  $\Sigma \mathbf{w}_j = \lambda_j \mathbf{w}_j, \quad j = 1, \dots, F$ 
3: Ordenar autovalores de forma descendente:  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_F$ 
4: Seleccionar los  $k$  autovectores de mayor varianza:  $\mathbf{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \dots \ \mathbf{w}_k] \in \mathbb{R}^{F \times k}$ 
5: Proyectar los datos:  $Z \leftarrow \tilde{X} \mathbf{W}$ 
6: return  $Z$ 

```

La salida del algoritmo PCA es la entrada del algoritmo de clasificación K-Means. (matrix

$Z \in \mathbb{R}^{N \times 8}$) El algoritmo de K-Means es utilizado con el fin de agrupar los píxeles en 2, 3 o 4 grupos. En este caso 2, su definición es la siguiente:

Algorithm 3 K-Means: agrupamiento no supervisado ($k = 2$)

Require: Matriz PCA $Z \in \mathbb{R}^{N \times 8}$, número de clústeres $k = 2$, inicializaciones $n_{\text{init}} = 10$

Ensure: Vector de etiquetas $\ell \in \{0, 1\}^N$

- 1: **for** cada inicialización $r = 1, \dots, n_{\text{init}}$ **do**
 - 2: Inicializar centroides $\{\mu_1, \mu_2\} \subset Z$ (selección aleatoria)
 - 3: **repeat**
 - 4: **Asignación:** $\ell_i \leftarrow \arg \min_{c \in \{1, 2\}} \|z_i - \mu_c\|_2^2 \quad \forall i$
 - 5: **Actualización:** $\mu_c \leftarrow \frac{1}{|C_c|} \sum_{i \in C_c} z_i \quad \forall c$, donde $C_c = \{i : \ell_i = c\}$
 - 6: **until** los centroides no cambien
 - 7: Registrar inercia $\mathcal{J}_r = \sum_{i=1}^N \|z_i - \mu_{\ell_i}\|_2^2$
 - 8: **end for**
 - 9: Seleccionar la solución con menor $\mathcal{J}_r$
 - 10: **return** ℓ
-

Las pseudo-etiquetas ℓ producidas por K-Means se usan como verdad base para entrenar un clasificador SVM sobre una muestra de hasta 10 000 píxeles, que luego predice la etiqueta de todos los N píxeles.

Algorithm 4 SVM lineal: clasificación sobre pseudo-etiquetas K-Means

Require: Matriz PCA $Z \in \mathbb{R}^{N \times 8}$, pseudo-etiquetas $\ell \in \{0, 1\}^N$, tamaño de muestra $n_s = \min(N, 10\,000)$

Ensure: Mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$

- 1: Seleccionar submuestra aleatoria $\mathcal{S} \subset \{1, \dots, N\}$, $|\mathcal{S}| = n_s$
- 2: Entrenar SVM lineal minimizando:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i \in \mathcal{S}} \max(0, 1 - \ell_i^* (\mathbf{w}^\top z_i + b))$$

donde $\ell_i^* \in \{-1, +1\}$ es la pseudo-etiqueta recodificada

- 3: **Predicción sobre todos los píxeles:** $\hat{y}_i \leftarrow \text{sign}(\mathbf{w}^\top z_i + b) \quad \forall i \in \{1, \dots, N\}$
 - 4: Recodificar a binario: $\hat{y}_i \leftarrow \mathbf{1}[\hat{y}_i > 0]$
 - 5: Reorganizar en mapa $H \times W$
 - 6: **return** $\hat{y}$
-

La salida del algoritmo SVM es un mapa de clasificación $\hat{y} \in \{0, 1\}^{H \times W}$ donde H es el número de filas y W es el número de columnas de la imagen. Aquí se empleó un procedimiento manual

para seleccionar que clase es la mancha urbana y que es la no-urbana. La imagen 2.1 muestra el flujo de preprocesamiento de datos.




Figura 2.1: Flujo de preprocesamiento de datos.

2.2. Autómatas Celulares

Un **Autómata Celular** (AC), en el sentido formalizado por Wolfram (1984), es un sistema dinámico discreto definido sobre una cuadrícula regular de N celdas. Formalmente, un AC queda definido por la cuádrupla $(Q, \mathcal{N}, \delta, q_0)$. El primer elemento, Q , es el conjunto finito de estados posibles de cada celda; en este trabajo $Q = \{0, 1\}$ distingue lo no-urbano de lo urbano. El segundo, $\mathcal{N}$, es la vecindad: el conjunto de celdas adyacentes cuyo estado influye en la transición. El tercero, $\delta : Q^{|\mathcal{N}|} \rightarrow Q$, es la función de transición, que determina el nuevo estado de una celda a partir del estado de sus vecinos. El último, $q_0 : \Omega \rightarrow Q$, fija la configuración inicial del sistema.

En el contexto del crecimiento urbano, el dominio espacial $\Omega \subset \mathbb{Z}^2$ es una cuadrícula discreta de celdas indexadas por pares (i, j) , donde $i \in \{1, \dots, R\}$ indica la fila y $j \in \{1, \dots, C\}$ la columna, con $N = R \times C$ celdas en total.

En los AC probabilísticos, la función de transición δ asigna probabilidades a cada posible nuevo estado, en lugar de determinar el siguiente estado de forma determinista. Esta extensión,

base de los modelos urbanos basados en AC desde White y Engelen (1997) y de marcos calibrados como SLEUTH (Clarke & Gaydos, 1998), resulta adecuada para el modelado urbano, en el que la transición de no-urbano a urbano no está garantizada incluso cuando las condiciones locales son favorables.

Los dos tipos de vecindad más utilizados en modelado urbano son la vecindad de Von Neumann (cuatro celdas ortogonales) y la vecindad de Moore (ocho celdas incluyendo diagonales). En ambos casos, el radio de influencia puede extenderse más allá de la celda inmediatamente adyacente, permitiendo capturar efectos de accesibilidad y proximidad a zonas urbanas existentes.

Para el presente modelo, la influencia de la vecindad se cuantifica mediante la proporción de celdas urbanas en un radio r alrededor de la celda evaluada:

$$\Omega_{i,j}(r) = \frac{1}{|\mathcal{N}_{i,j}(r)|} \sum_{(i',j') \in \mathcal{N}_{i,j}(r)} s_{i',j'} \quad (2.2)$$

donde $s_{i',j'} \in \{0, 1\}$ es el estado urbano de la celda vecina en posición (i', j') y $\mathcal{N}_{i,j}(r)$ es el conjunto de celdas dentro del radio r alrededor de la celda (i, j) . Dicho de otra forma, es la proporción de celdas urbanas en el radio r alrededor de la celda (i, j) , bajo la definición de vecindad.

La probabilidad de que una celda no-urbana en posición (i, j) transite al estado urbano en el paso $t + 1$ se define como una función de tres componentes:

$$P(s_{i,j}^{t+1} = 1 \mid s_{i,j}^t = 0) = f(W_{i,j}, \Omega_{i,j}(r), \varepsilon_{i,j}) \quad (2.3)$$

donde $W_{i,j}$ es la idoneidad espacial asignada por el método WoE (definida a continuación), $\Omega_{i,j}(r)$ es el efecto de vecindad, y $\varepsilon_{i,j}$ es un término estocástico que introduce variabilidad aleatoria en la simulación. La función f combina estos tres factores según parámetros que, en este trabajo, se ajustan mediante el procedimiento de calibración descrito en el Capítulo 5 y en la Sección 5.2. Esta función es la que define la transición de una celda no-urbana a una urbana.

El método de **Pesos de Evidencia** (Weight of Evidence, WoE) es una técnica estadística de origen bayesiano que cuantifica la asociación entre una variable espacial y la ocurrencia de un evento, en este caso la transición de suelo no-urbano a urbano (Bonham-Carter, 1994). Fue desarrollado originalmente en el contexto de la predicción de depósitos minerales y posteriormente adaptado al análisis de cambio de uso de suelo.

Para una variable espacial X discretizada en categorías o intervalos, el peso de evidencia de la categoría b se define como:

$$W^+(b) = \ln \frac{P(X = b \mid \text{transición})}{P(X = b \mid \text{no transición})} \quad (2.4)$$

donde $P(X \in b \mid \text{transición})$ es la proporción de píxeles con transición observada que pertenecen a la categoría b , y $P(X \in b \mid \text{no transición})$ es la proporción equivalente para píxeles sin transición. Los pesos positivos indican que la categoría b favorece la transición; los pesos negativos indican lo contrario. En esta expresión, b no representa la clase urbano/no-urbano, sino una categoría, intervalo o bin de la variable espacial X (por ejemplo, un rango de distancia a la mancha urbana existente o un rango de densidad vecinal). La clase binaria $\{0, 1\}$ corresponde al estado observado o predicho de la celda, mientras que las categorías b pertenecen al espacio de valores de cada variable explicativa.

El peso total para la celda en posición (i, j) se obtiene sumando los pesos de cada variable espacial evaluada en esa celda:

$$W_{i,j} = \sum_{k=1}^V W^+(b_{(i,j)k}) \quad (2.5)$$

donde V es el número de variables espaciales consideradas y $b_{(i,j)k}$ es la categoría o intervalo que toma la variable espacial k en la celda (i, j) . En la implementación de este trabajo, $V = 7$, porque se consideran siete variables espaciales derivadas de la configuración urbana histórica. Por tanto, V no es el número de clases del mapa binario; las clases del estado celular siguen siendo dos (0 para no urbano y 1 para urbano). Este valor $W_{i,j}$ se transforma mediante una función sigmoide para obtener una probabilidad de transición acotada en $[0, 1]$:

$$P_{i,j}^{\text{WoE}} = \frac{1}{1 + e^{-W_{i,j}}} \quad (2.6)$$

Una propiedad relevante del WoE es su interpretabilidad: cada peso $W^+(b)$ puede traducirse en términos geográficos. Por ejemplo, si la variable *distancia a manchas urbanas* tiene un peso negativo para distancias grandes, ello sugiere menor probabilidad de urbanización en celdas alejadas de vías de comunicación. Dicha transparencia puede apoyar la comunicación de resultados a planificadores urbanos, sin sustituir el juicio experto ni las políticas públicas aplicables en cada contexto.

El cálculo de los pesos se realiza sobre datos históricos de transición, lo que hace que las




Figura 2.2: Ejemplo del cálculo de WoE: la variable *distancia al frente urbano* acumula pesos positivos en bins próximos y negativos en bins lejanos. La suma ponderada pasa por la sigmoide y se compara con $\theta = 0,75$.

probabilidades resultantes reflejen empíricamente los patrones observados en el área de estudio, en lugar de depender de supuestos teóricos sobre el comportamiento urbano.

2.3. Métricas de evaluación de modelos predictivos

La evaluación cuantitativa del desempeño del modelo requiere métricas que comparen el mapa predicho con el mapa observado a nivel de píxel y a nivel global. A continuación se presentan las métricas utilizadas en este trabajo, derivadas de la matriz de confusión espacial. La matriz de confusión es una tabla que muestra el número de píxeles correctamente clasificados y los errores de clasificación.

Sea $\Omega \subset \mathbb{R}^2$ el dominio espacial de estudio discretizado en $N = |\Omega|$ píxeles. Para cada píxel $i \in \Omega$, sea $y_i \in \{0, 1\}$ el estado observado real (donde 0 denota no-urbano y 1 denota urbano), y sea $\hat{y}_i \in \{0, 1\}$ el estado predicho por el modelo. En esta notación, i es un índice lineal sobre las $N = R \times C$ celdas de la cuadrícula; cada valor i corresponde a la celda en posición (r, c) con $r \in \{1, \dots, R\}$ filas y $c \in \{1, \dots, C\}$ columnas. Se emplea el índice lineal por claridad en la notación de conjuntos; la equivalencia con la indexación bidimensional (i, j) de las secciones anteriores es $i \leftrightarrow (r, c)$.

La **matriz de confusión** $C \in \mathbb{N}^{2 \times 2}$ cuantifica la concordancia píxel a píxel entre predicción y observación:

$$C = \begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix} \quad (2.7)$$

donde los elementos se definen mediante la función indicadora $\mathbb{K}[\cdot]$ como sigue:

$$TP = \sum_{i \in \Omega} \mathbb{K}[\hat{y}_i = 1 \wedge y_i = 1] \quad (\text{verdaderos positivos: urbano predicho y observado}) \quad (2.8)$$

$$TN = \sum_{i \in \Omega} \mathbb{K}[\hat{y}_i = 0 \wedge y_i = 0] \quad (\text{verdaderos negativos: no-urbano predicho y observado}) \quad (2.9)$$

$$FP = \sum_{i \in \Omega} \mathbb{K}[\hat{y}_i = 1 \wedge y_i = 0] \quad (\text{falsos positivos: sobre-predicción}) \quad (2.10)$$

$$FN = \sum_{i \in \Omega} \mathbb{K}[\hat{y}_i = 0 \wedge y_i = 1] \quad (\text{falsos negativos: sub-predicción}) \quad (2.11)$$

Estos cuatro componentes satisfacen $TP + TN + FP + FN = N$. La magnitud relativa de

FP frente a FN revela el sesgo sistemático del modelo: si $FP > FN$, el modelo sobre-predice urbanización; si $FN > FP$, el modelo es conservador.

La construcción de la matriz requiere correspondencia espacial exacta entre los mapas predicho y observado: idéntica resolución espacial, sistema de proyección cartográfica y extensión geográfica. Los píxeles se clasifican evaluando las condiciones lógicas anteriores sobre todos los píxeles del dominio. La **exactitud global** mide la fracción de píxeles correctamente clasificados:

$$\text{Accuracy} = \frac{TP + TN}{N} \quad (2.12)$$

Esta métrica es sensible al desbalance de clases. En contextos urbanos, donde la mayoría de píxeles no experimenta cambio, un modelo que predice “no cambio” en todos los píxeles obtiene Accuracy muy alta sin capturar ninguna dinámica. Por esta razón, Accuracy debe complementarse con métricas específicas para las transiciones. La **precisión** cuantifica la confiabilidad de las predicciones positivas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.13)$$

Probabilísticamente, Precision estima $P(y_i = 1 \mid \hat{y}_i = 1)$: dado que el modelo predijo urbanización, ¿cuál es la probabilidad de que realmente ocurrió? Precision decrece cuando el modelo genera muchas falsas alarmas (sobre-predicción). Es especialmente relevante cuando el sobre-dimensionamiento de infraestructura tiene costos significativos. El **recall** cuantifica la capacidad de detectar píxeles con transición real:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.14)$$

Recall estima $P(\hat{y}_i = 1 \mid y_i = 1)$: dado que un píxel se urbanizó, ¿cuál es la probabilidad de que el modelo lo detectó? Recall bajo indica que el modelo omite transiciones reales, subestimando la expansión urbana.

Existe una tensión inherente entre Precision y Recall: aumentar el umbral de decisión tiende a incrementar Precision pero disminuye Recall, y viceversa. Esta dualidad motiva la siguiente métrica. El **F1-Score** es la media armónica entre Precision y Recall:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (2.15)$$

La media armónica penaliza más severamente los valores bajos que la media aritmética, de

modo que F1 es bajo cuando cualquiera de las dos métricas es baja, exigiendo buen desempeño en ambas dimensiones simultáneamente. El **coeficiente Kappa de Cohen** (Cohen, 1960) corrige la concordancia observada por la concordancia esperada por azar:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \quad (2.16)$$

donde p_o = Accuracy es la proporción observada de concordancia, y p_e es la proporción esperada por azar:

$$p_e = \frac{(TP + FP)(TP + FN) + (TN + FN)(TN + FP)}{N^2} \quad (2.17)$$

El rango es $\kappa \in [-1, 1]$. Conforme a la escala de interpretación de uso común propuesta por Landis y Koch (1977), $\kappa > 0,81$ indica acuerdo casi perfecto; 0,61–0,80, acuerdo sustancial; 0,41–0,60, acuerdo moderado; 0,21–0,40, acuerdo justo; y $\kappa < 0,20$, acuerdo pobre. La ventaja del coeficiente κ frente a la *Accuracy* es que proporciona una evaluación más realista ante desbalance de clases, al descontar el acuerdo esperado por azar.

Las métricas anteriores evalúan la concordancia global píxel a píxel, incluyendo tanto las transiciones como las permanencias. Sin embargo, en modelación de cambio de uso de suelo interesa específicamente predecir las **transiciones**, no las permanencias. Dado que la clase mayoritaria (píxeles sin cambio) puede inflar artificialmente las métricas globales, el **Figure of Merit** (FoM), propuesto como métrica comparable entre estudios de cambio de uso de suelo por Pontius Jr et al. (2008), aborda esta limitación evaluando exclusivamente la predicción de cambio.

En un sistema urbano consolidado con 95 % de territorio permanente y 5 % con transición, un modelo trivial que predice “no cambio” obtiene *Accuracy* = 0,95 sin capturar ninguna dinámica urbana. El FoM evalúa únicamente el subconjunto de píxeles donde ocurren transiciones, ignorando la clase mayoritaria.

Sea $\mathcal{T}_{obs}$ el conjunto de píxeles con cambio observado y $\mathcal{T}_{pred}$ el conjunto con cambio predicho entre t_0 y t_1 . El FoM es el índice de Jaccard aplicado exclusivamente a las transiciones:

$$\text{FoM} = \frac{|\mathcal{T}_{obs} \cap \mathcal{T}_{pred}|}{|\mathcal{T}_{obs} \cup \mathcal{T}_{pred}|} \quad (2.18)$$

Descomponiendo en componentes:

$$B = |\mathcal{T}_{obs} \cap \mathcal{T}_{pred}| \quad (\text{cambio correctamente predicho}) \quad (2.19)$$

$$C = |\mathcal{T}_{obs} \setminus \mathcal{T}_{pred}| \quad (\text{cambio observado no predicho: omisión}) \quad (2.20)$$

$$A = |\mathcal{T}_{pred} \setminus \mathcal{T}_{obs}| \quad (\text{cambio predicho no observado: comisión}) \quad (2.21)$$

$$\boxed{\text{FoM} = \frac{B}{A + B + C}} \quad (2.22)$$

El denominador contiene exactamente tres términos. No incluye el término D (píxeles sin cambio) porque FoM evalúa exclusivamente las transiciones.

Con esto queda definido el marco teórico necesario para el desarrollo del modelo propuesto en el Cap. 1. El posicionamiento de este trabajo en la literatura especializada es el tema del Cap. 3, donde se realiza una revisión crítica de los enfoques previos y se contrasta el modelo propuesto con ellos.

Capítulo 3

Estado del arte

El modelado computacional del crecimiento urbano ha producido en treinta años una literatura rica pero metodológicamente diferente. Este capítulo no busca ordenar trabajos por autor sino que busca identificar los cuatro problemas metodológicos que siguen abiertos en el campo (calibración por fuerza bruta, validación sobreajustada a una sola ventana temporal, opacidad de la función de transición en los modelos de aprendizaje profundo y dependencia de software propietario) y muestra cómo cada uno justifica una decisión concreta del diseño del modelo WoE-AC propuesto. La discusión concluye con un mapa de la literatura para ciudades mexicanas, donde ningún trabajo publicado satisface simultáneamente los requerimientos R1–R4 de la Tabla 1.1.

3.1. Evolución del modelado urbano computacional

El modelado de la dinámica urbana mediante autómatas celulares empezó con White y Engelen (1997), cuyo trabajo mostró que reglas locales basadas en distancia y vecindad podrían reproducir patrones macroscópicos realistas en ciudades. El siguiente nivel del enfoque fue introducido con SLEUTH en (Clarke & Gaydos, 1998; Silva & Clarke, 2002), que durante dos décadas fue vanguardia y considerado como referencia, y que se aplicó en decenas de ciudades.

Al mismo tiempo, la metodología LUCC (Land Use and Cover Change) introdujo modelos basados en mapas de idoneidad de uso de suelo de base estadística: sistemas como CLUE-S, Dinamica EGO, CA-Markov y, más recientemente, FLUS brindaron arquitecturas alternativas al autómata celular puro en las que la función de transición emerge de regresiones logísticas o pesos bayesianos sobre datos históricos.

Una generación posterior de trabajos sustituyó la regresión por modelos de aprendizaje

automático e híbridos metaheurísticos. Almeida et al. (2008) acopló una red neuronal feedforward a un autómata celular estocástico para Piracicaba, Brasil; años más tarde Wang et al. (2021) combinó un autómata celular con un algoritmo genético para optimizar la forma urbana de Wuhan, a un costo computacional elevado, mientras que Hagenauer y Helbich (2022) introdujo una red neuronal geográficamente ponderada para capturar relaciones espaciales no lineales. Estos enfoques reportan ganancias cuantitativas en precisión, pero sustituyen parámetros legibles por activaciones internas o cromosomas que no admiten una lectura geográfica directa; en esa medida, no son auditables respecto de lo que aprenden.

La decisión central del campo no es en torno a AC y aprendizaje automático, sino entre dos directivas que a priori parecen contrapuestos: maximizar precisión predictiva y mantener la trazabilidad de cada decisión espacial. Las secciones siguientes muestran que esta tensión es resoluble si se cambia la pregunta metodológica.

3.2. Problemas metodológicos persistentes

Los problemas metodológicos mas importantes detectados en la literatura fueron equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software no libre.

3.2.1. Calibración: equifinalidad y costo computacional

SLEUTH calibra cinco coeficientes de crecimiento (*diffusion, breed, spread, slope resistance* y *road gravity*) mediante búsqueda por fuerza bruta sobre un espacio discreto del orden de 10^9 combinaciones, cada una evaluada con simulaciones Monte Carlo de múltiples iteraciones. Clarke y Gaydos (1998) estructuró la búsqueda en tres fases sucesivas (gruesa, fina y final) que estrechan iterativamente el rango de cada coeficiente; aun así, una calibración completa toma días en hardware contemporáneo (Jantz et al., 2003). A esa carga se añaden dos rasgos que agravan la dificultad. Primero, SLEUTH es un autómata *auto-modificable*: los coeficientes de *spread* se reescriben durante la propia corrida en respuesta a la tasa de crecimiento, de modo que el resultado depende de la trayectoria seguida y no solo de los valores iniciales (Clarke & Gaydos, 1998). Segundo, los coeficientes calibrados son sensibles a la resolución espacial de los datos, por lo que un conjunto ajustado a una escala no se transfiere directamente a otra. Sobre esa base aparece el problema metodológico de fondo, que no es solo el costo: es la **equifinalidad**, esto es, la existencia de múltiples combinaciones de coeficientes que producen patrones indistinguibles para la métrica de calibración pero divergen en las proyecciones de largo plazo (Clarke, 2008). Sin un criterio adicional, la elección entre combinaciones equifinales termina dependiendo de

quien realiza la calibración. A ello se suma un riesgo de **sobreajuste de calibración**: como el ajuste se optimiza contra un único intervalo histórico, los coeficientes pueden reproducir muy bien esa ventana y, sin embargo, degradarse al proyectar otro horizonte, sin que la propia métrica de calibración lo advierta (Jantz et al., 2003; Silva & Clarke, 2002). Esta combinación de costo, dependencia de trayectoria y equifinalidad es, precisamente, lo que motiva la estrategia de validación multi-ventana que se adopta más adelante: una sola ventana temporal no basta para distinguir un conjunto de coeficientes robusto de uno meramente equifinal.

El presente trabajo evita el problema redefiniéndolo: en lugar de calibrar coeficientes que controlan reglas geométricas genéricas (diffusion, breed, spread), calibra dos parámetros que controlan la combinación de evidencia espacial empírica (umbral de transición y peso de vecindad). El espacio de búsqueda es de dos dimensiones y la calibración termina en minutos. Más importante aún: cada configuración candidata produce mapas de idoneidad cuyos pesos por variable son directamente auditables, de modo que es posible explicar por qué una celda recibió una probabilidad de transición dada, lo que reduce la ambigüedad asociada a la equifinalidad.

3.2.2. Validación: sobreajuste temporal y métricas no comparables

Pontius Jr et al. (2008) analizó trece simulaciones independientes de nueve modelos de cambio de uso de suelo y propuso el Figure of Merit (FoM) como métrica estándar comparable entre estudios. Su hallazgo es un tanto desmotivante: seis de las trece aplicaciones obtienen FoM inferior al 15 % y solo una supera el 50 %. La dispersión o variabilidad no se explica por la complejidad del modelo sino por la magnitud del cambio neto observado: el FoM crece monótonicamente con el porcentaje de celdas que efectivamente cambian de estado. O dicho de una forma mas sencilla, el FoM es una métrica que penaliza la cantidad de celdas que no cambian de estado.

Esto tiene dos implicaciones que la literatura rara vez confronta. La primera, **validar en una sola ventana temporal es estadísticamente insuficiente**: si el FoM depende de la magnitud del cambio, entonces se puede concluir que una validación única no permite distinguir entre un modelo robusto y uno sobreajustado a una fase específica del crecimiento en el tiempo. Segundo, **reportar métricas como Kappa o Accuracy sin FoM infla artificialmente la calidad del modelo**: en un sistema urbano consolidado donde el 90 % de las celdas permanece sin cambio, un modelo trivial que predice “no cambio” en todas las celdas obtiene Accuracy de 0,90 sin capturar ninguna dinámica, es decir, captura la estabilidad pero no la dinámica de interés.

En consecuencia, la validación del WoE-AC, para el presente trabajo, se realizó en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020), reportando FoM, Kappa e IoU

simultáneamente. La estabilidad del FoM a través de las cinco ventanas, no su valor absoluto en una sola, es lo que permite denotar un modelo que generaliza bien de uno que no lo hace tan bien.

Vale la pena confrontar una contradicción que la literatura rara vez coloca lado a lado. Por un lado, los trabajos de aprendizaje automático y profundo reportan mejoras de exactitud frente a los autómatas celulares clásicos (Almeida et al., 2008; Hagenauer & Helbich, 2022); por otro, el meta-análisis de Pontius Jr et al. (2008) muestra que la dispersión del FoM entre trece aplicaciones no se explica por la sofisticación del modelo, sino por la magnitud del cambio neto del periodo evaluado. Las dos observaciones no se contradicen en abstracto, pero sí en la práctica con que suelen leerse: un FoM de, por ejemplo, 0,40 obtenido en una ciudad con 20 % de cambio neto no es comparable con un 0,20 obtenido en una con 5 %, y aun así ambos se citan como evidencia directa de que un modelo supera a otro. La consecuencia es incómoda pero ineludible: buena parte de los *rankings* de desempeño publicados confunden la dificultad del caso con la calidad del modelo. Algo análogo ocurre con la equifinalidad de SLEUTH (Clarke, 2008): dos calibraciones que empatan en la métrica de ajuste pueden divergir por completo en la proyección a largo plazo, de modo que reportar “el mejor conjunto de coeficientes” sin declarar el conjunto de los equifinales transmite una unicidad que los datos no respaldan. Este trabajo toma postura frente a ese punto: no compara su FoM absoluto contra el de otras ciudades como si fueran intercambiables, sino que evalúa la estabilidad del FoM entre cinco ventanas del mismo sistema urbano, la única comparación que mantiene constante la magnitud del cambio, y reporta el rango completo en lugar de un único valor favorable.

3.2.3. Interpretabilidad: el problema de la caja negra

Almeida et al. (2008) entrenó una red neuronal feedforward con backpropagation sobre variables biofísicas e infraestructurales de Piracicaba (Brasil, 1985–1999); la red aprende pesos sinápticos que alimentan a un CA estocástico. El modelo reporta concordancia espacial superior a los AC clásicos de la época, pero los pesos no son transformables o explicables a una pregunta geográfica, es decir, no se puede afirmar que “la distancia a vialidades contribuyó un X % a la transición de esta celda”. La activación de cada neurona es una combinación no lineal de todas las variables de entrada, sin descomposición legible o dicho de otra forma, no es auditable en cuestión de lo que aprenden.

Trabajos posteriores intensifican esta opacidad por dos vías. La primera es la optimización metaheurística: Wang et al. (2021) integra un autómata celular a un algoritmo genético para generar formas urbanas que maximizan un índice de vitalidad en Wuhan, donde cada

generación produce cromosomas que carecen de lectura geográfica directa. La segunda es el aprendizaje profundo aplicado a teledetección y modelado espacial (Hagenauer & Helbich, 2022; Ma et al., 2019), que requiere GPU y conjuntos de datos masivos para entrenar redes cuyas representaciones internas no son auditables, una vez mas. La ganancia en exactitud es real, pero el costo epistémico es alto: el modelo clasifica sin justificar, y la justificación es exactamente lo que un instrumento de planeación urbana requiere. Un plan municipal sustentado en “el modelo lo predijo” es jurídica y políticamente más débil que uno sustentado en “históricamente, la proximidad al frente urbano contribuye con un Information Value de X a la probabilidad de transición”.

El método de Pesos de Evidencia (WoE) provee exactamente esa descomposición. La elección de WoE en este trabajo no responde a una preferencia estética por la transparencia: responde al requerimiento R4 de la Tabla 1.1, que define la auditabilidad como condición de uso del modelo, no como propiedad accesoria.

3.2.4. Transferibilidad: software propietario y reproducibilidad

Una fracción significativa de los modelos LUCC más citados depende de software propietario, lo que limita en la práctica la reproducibilidad y la transferibilidad de los resultados publicados. Por ejemplo, Dinamica EGO opera bajo licencia académica restringida; IDRISI y TerrSet son comerciales; SLEUTH se distribuye como código en C, pero su instalación en sistemas modernos requiere ajustes no documentados que no son triviales para el usuario. La consecuencia práctica es que la reproducibilidad de los resultados publicados es, en el mejor de los casos, parcial: el lector puede leer el método pero no ejecutarlo sin acceso a infraestructura específica.

Esta dependencia tiene una consecuencia material poco discutida en la literatura metodológica: el acceso a licencias y a hardware especializado introduce una barrera de entrada que condiciona qué grupos académicos pueden reproducir o extender los modelos publicados. En contextos donde estos recursos son limitados, la única alternativa práctica es reescribir el pipeline desde cero o dedicar un esfuerzo considerable a descifrar requerimientos no documentados. El presente trabajo opta por esta vía: se implementa íntegramente en Python con dependencias de código abierto (NumPy, SciPy, scikit-learn) sobre datos públicos (Google Earth Engine), satisfaciendo R3 sin problemas.

3.3. Pesos de Evidencia y modelos probabilísticos espaciales

El método de Pesos de Evidencia, desarrollado por Bonham-Carter (1994) en el contexto de la prospección mineral, se formaliza en el Capítulo 2 (ecuación 2.4): para cada clase de una variable espacial discretizada se calcula un peso bayesiano que cuantifica la asociación entre dicha clase y la ocurrencia del evento de interés, en este trabajo, la transición de suelo no urbano a urbano. El peso total por celda es la suma de los pesos de las variables evaluadas en ella, transformada por la función logística para obtener una probabilidad acotada (ecuación 2.6); el Information Value sintetiza el poder discriminatorio de cada variable. La presente sección no repite la derivación matemática, sino que la sitúa en la literatura LUCC.

La adaptación del WoE al modelado de cambio de uso de suelo se consolidó con Soares-Filho et al. (2002) y la familia de modelos *Dinamica EGO*, que separan dos preguntas que el campo suele tratar de forma confusa: *cuánto* suelo cambia y *dónde* lo hace. La cantidad de transición se fija con una matriz de transición markoviana estimada del cambio histórico, mientras que la asignación espacial la resuelve un autómata celular de dos operadores (*expander*, que ensancha los parches urbanos existentes, y *patcher*, que siembra parches nuevos), alimentado por un mapa de idoneidad WoE. Ese diseño reproduce con fidelidad la distribución de tamaños de parche observada en frentes de deforestación amazónica y expansión agrícola, y en menor medida en crecimiento urbano.

La misma lógica de *demanda* más *asignación* reaparece en otros marcos LUCC ampliamente citados: CLUE-S (Verburg et al., 2002) acopla una idoneidad derivada de regresión logística con una asignación iterativa gobernada por la demanda sectorial de suelo, y FLUS (Liu et al., 2017) sustituye esa idoneidad por la probabilidad de una red neuronal y la asigna mediante un autómata celular con inercia auto-adaptativa y competencia por ruleta. Conviene tomar postura sobre la diferencia con el presente trabajo, porque es deliberada: estos marcos descomponen el problema en un módulo de cantidad (Markov o demanda exógena) y un módulo de localización (CA), y la mayoría se distribuye como software con interfaz gráfica o licencia restringida. Aquí, en cambio, la cantidad no se impone desde fuera, sino que emerge de la propia regla de transición, donde el campo WoE ponderado por IV y la influencia del vecindario de Moore deciden conjuntamente cuántas y cuáles celdas transitan. El esquema de dos módulos ajusta muy bien la cantidad de cambio, esa es su fortaleza documentada, pero paga ese ajuste con una dependencia mayor de software especializado y con una frontera difusa entre lo que decide el modelo de demanda y lo que decide el CA; para un instrumento de planeación, donde importa

poder rastrear por qué una celda concreta se urbaniza, la integración transparente y reproducible que se adopta en este trabajo resulta preferible.

Sin embargo, el WoE tiene tres limitaciones estadísticas reconocidas que conviene explicitar para evitar atribuirle propiedades que no posee:

Independencia condicional. La suma de pesos asume que las variables son condicionalmente independientes dada la ocurrencia del evento. Este supuesto claramente rara vez sucede en variables espaciales urbanas, debido a que es un sistema complejo, donde proximidad a vialidades y proximidad al frente urbano están correlacionadas, por mencionar un ejemplo. El presente trabajo no introduce una corrección formal para esta dependencia; sigue la práctica estándar de la literatura LUCC, que reporta el sesgo derivado mediante el contraste empírico con el cambio observado. Sin embargo, la validación multi-período mitiga parcialmente el problema, esto ya que si el sesgo fuera dominante, el FoM degradaría sistemáticamente entre ventanas.

Sensibilidad a la discretización. Los pesos dependen de cómo se categorice cada variable continua. El presente trabajo adopta una discretización basada en cuantiles uniformes, que es la convención más reproducible aunque no necesariamente la óptima en términos de IV (Information Value).

Multicolinealidad entre drivers. Variables correlacionadas producen pesos redundantes que inflan la magnitud aparente de la evidencia. Este trabajo aplica un análisis de componentes principales sobre el conjunto de variables espaciales antes del cálculo de IV, lo que reduce la redundancia sin sacrificar interpretabilidad.

Sesgo y sensibilidad espacial. Un problema menos discutido en las aplicaciones urbanas del WoE es la autocorrelación espacial: las celdas vecinas no son observaciones independientes, de modo que el tamaño muestral efectivo es menor que el número de píxeles y los pesos pueden estimarse con una precisión aparente mayor que la real (Bonham-Carter, 1994). El efecto se acentúa cuando las variables se derivan de la propia configuración urbana, como ocurre aquí, porque la señal de proximidad y densidad está espacialmente estructurada por construcción. Este trabajo no corrige formalmente la autocorrelación, pero acota su impacto por dos vías: la discretización por cuantiles evita que clases muy pobladas dominen el peso, y la validación en cinco ventanas independientes funciona como prueba de estabilidad, ya que un sesgo espacial dominante se manifestaría como una degradación sistemática del FoM entre períodos, que no se observa.

3.4. Validación espacial en modelos LUCC

La métrica más reportada en LUCC sigue siendo el coeficiente Kappa de Cohen, a pesar de las críticas explícitas a su uso en mapas de cambio. Kappa mezcla dos fuentes de error: desacuerdo en cantidad y desacuerdo en asignación, que tienen significados metodológicos distintos (Pontius Jr et al., 2008). Esta descomposición separa dos situaciones distintas. El **quantity disagreement** ocurre cuando el modelo predice un total de celdas de cambio distinto al observado, sin importar dónde. El **allocation disagreement**, en cambio, aparece cuando el modelo predice el total correcto de cambio pero lo asigna a celdas incorrectas.

Un modelo puede ser perfecto en *quantity* y catastrófico en *allocation*: predice exactamente el área urbana total pero en lugares equivocados. El FoM, definido como el índice de Jaccard restringido a las celdas de cambio, es sensible exactamente a este problema.

La Intersection over Union (IoU) sobre la clase urbana provee información complementaria: mientras el FoM evalúa la calidad de la predicción del cambio, la IoU evalúa la calidad de la predicción del estado urbano final. Reportar ambas evita el sesgo de evaluar solo la dinámica o solo el estado. Dicho de forma sencilla: FoM es una métrica que penaliza la cantidad de celdas que no cambian de estado, mientras que IoU es una métrica que penaliza la cantidad de celdas que se clasifican incorrectamente.

El presente trabajo adopta este protocolo de evaluación: FoM como métrica primaria para el cambio, IoU para el estado, Kappa por compatibilidad con la literatura previa y un análisis explícito de la descomposición quantity vs. allocation cuando el FoM es bajo.

3.5. Vacíos específicos en el contexto mexicano

La literatura mexicana sobre modelado de crecimiento urbano es escasa pero útil y de vanguardia. Suárez y Delgado (2007) construyó el primer estudio de predicción espacial sistemática para la Zona Metropolitana de la Ciudad de México: a partir de proyecciones demográficas de CONAPO al 2020, éste distribuyó hectáreas adicionales en contornos metropolitanos bajo tres escenarios de densidad. El trabajo es relevante por su pionería pero no es un modelo Autómatas Celulares: no hay reglas de vecindad, no hay calibración sobre datos históricos de cambio celular y la validación se hace a nivel de totales de hectáreas, no a nivel de celda, pues se usan agregados y no datos a nivel grano. R1, R4 y la replicabilidad pública no aplican; la única dimensión satisfecha es R2.

Ramírez Hernández (2021), en un libro institucional de IIEc-UNAM, aplica un AC inspirado en SLEUTH a la ZMCM con datos de 1990–2010 y proyecta al 2040. Los parámetros se describen

en el texto pero el código no está disponible y la validación no reporta FoM ni Kappa de forma sistemática. La obra es valiosa como referencia conceptual pero no como benchmark cuantitativo, es decir, no es posible comparar su desempeño con el rango de métricas reportadas en Pontius Jr et al. (2008).

Así pues, García-Ramírez et al. (2023) aplica una cadena SVM + regresión logística + CA-Markov en TerrSet/IDRISI a núcleos urbanos asentados en cinco cuencas hidrológicas del estado de Chihuahua (Laguna Bustillos y de los Mexicanos, río Conchos, Ojinaga, río Conchos, Presa de la Colina, río Conchos, Presa el Granero y río San Pedro), con proyecciones a 2030, 2040 y 2050. La clasificación SVM sobre mapas de uso de suelo 2010–2020 es reproducible y la regresión logística aporta interpretabilidad parcial (pseudo R^2 de McFadden superior a 0,2, ROC aceptable), pero la asignación CA-Markov ocurre dentro del módulo Land Change Modeler de TerrSet, software no libre, y la validación cuantitativa se reporta sobre la regresión logística, no sobre la simulación CA en sí. R4 se cumple parcialmente; R3 no se cumple.

El cuadrante metodológico que estos tres trabajos definen es claro:

Cuadro 3.1: Posicionamiento de la literatura mexicana frente a R1–R4.

Trabajo	R1	R2	R3	R4
Suárez y Delgado (2007)	—	✓	—	—
Ramírez Hernández (2021)	—	✓	—	parcial
García-Ramírez et al. (2023)	parcial	✓	—	parcial
Presente trabajo	✓	✓	✓	✓

Ningún trabajo publicado para una ciudad mexicana cumple simultáneamente con validación multi-período cuantitativa, reproducibilidad abierta e interpretabilidad auditable a nivel de celda. Esa es la brecha que el presente trabajo atiende, y es la razón por la cual la elección de Querétaro como caso de estudio no es sustituible: aplicar el método sobre una ciudad ya estudiada por modelos de caja negra no generaría comparación válida con la literatura existente; aplicarlo sobre una ciudad intermedia sin estudios previos abre el espacio metodológico.

3.6. Síntesis: posicionamiento del presente trabajo

Los cuatro problemas metodológicos analizados (equifinalidad en la calibración, sobreajuste en la validación, opacidad en la función de transición y dependencia de software propietario) se cruzan con la topología espacial del campo. Las revisiones sistemáticas de Santé et al. (2010) y Aburas et al. (2016) muestran que las aplicaciones documentadas se concentran en China,

Europa y Estados Unidos, mientras que la literatura mexicana revisada en la sección anterior avanza con modelos heredados o con herramientas propietarias que limitan la auditoría.

El presente trabajo se ubica en la intersección de tres decisiones: (i) usar WoE como función de transición, lo que satisface R4 sin renunciar a la rigurosidad estadística; (ii) validar en cinco ventanas quinquenales independientes con FoM, Kappa e IoU, lo que satisface R1 y permite distinguir robustez de sobreajuste; (iii) implementar el flujo completo en Python con datos abiertos, lo que satisface R3 y abre la posibilidad de replicación en otras ciudades intermedias mexicanas. R2, la utilidad para planeación urbana, se cumple por construcción: los mapas resultantes son raster celda a celda con probabilidades de transición auditables.

El Capítulo 4 describe el área de estudio, la Zona Metropolitana de Querétaro, y la construcción de la serie histórica de mapas urbano/no-urbano que alimenta el modelo. Ese insumo es el que permite poner a prueba, sobre una ciudad intermedia mexicana aún no modelada con estas herramientas, las decisiones de diseño que este capítulo justificó: una calibración acotada e interpretable frente a la equifinalidad, una validación multi-ventana frente al sobreajuste temporal y una implementación abierta frente a la dependencia de software propietario.

Capítulo 4

Área de estudio

*Este capítulo describe el área de estudio y el conjunto de datos utilizados en la investigación. Se presenta la localización geográfica de la Zona Metropolitana de Querétaro, las características técnicas del conjunto de imágenes (37 años, 1984–2020) obtenidas con **Google Earth** y su **herramienta de imagen histórica (línea de tiempo)**, los criterios de calidad y selección aplicados de forma visual al capturar cada año, y el pipeline de preprocesamiento que transforma las imágenes RGB en mapas binarios urbano/no-urbano mediante clasificación LBP+K-Means+SVM.*

4.1. Localización y características del área de estudio

La Zona Metropolitana de Querétaro se ubica en el centro de México y constituye uno de los polos industriales de mayor crecimiento reciente del país. Según la delimitación oficial de zonas metropolitanas (Consejo Nacional de Población (CONAPO) and SEDATU and INEGI, 2018), agrupa varios municipios en torno a la capital del estado y, de acuerdo con el Censo de Población y Vivienda 2020 (Instituto Nacional de Estadística y Geografía (INEGI), 2020), rebasó el millón y medio de habitantes, tras décadas de expansión sostenida que la convierten en un caso representativo de las ciudades intermedias mexicanas. Su delimitación espacial precisa (centro del encuadre, extensión cubierta y sistema de referencia) se detalla más adelante, dentro de la descripción del conjunto de imágenes.

4.1.1. Descripción y fuente de datos

El estudio utiliza una serie anual de **capturas RGB** (1984–2020, 37 años) sobre la Zona Metropolitana de Querétaro. Las imágenes se obtuvieron con **Google Earth** en escritorio, usando

la **imagen histórica** (línea de tiempo) para elegir, año a año, una fecha con baja nubosidad visible y buen contraste, manteniendo el mismo encuadre. El fondo cartográfico de Google Earth integra, según época, mosaicos que pueden incluir composiciones basadas en sensores tipo Landsat u otras fuentes; en este trabajo **no** se empleó Google Earth Engine (Gorelick et al., 2017) ni descarga masiva por API. La elección de Querétaro se sustenta en su dinámica de crecimiento reciente, bien documentada para la zona metropolitana (Delgado & López, 2018; Huacuz Elías & Vázquez Cruz, 2018), la posibilidad de cubrir 1984–2020 con la misma ventana de visualización y su relevancia como polo industrial en el centro de México, dentro de la expansión urbana que el país arrastra desde los años setenta (Montejano-Escamilla et al., 2023). Dado que el objetivo es modelar la expansión urbana a escala macroscópica (la mancha urbana y su frente de crecimiento) y no una caracterización espectral fina, la fuente se eligió privilegiando la consistencia espacial y temporal del encuadre a lo largo de casi cuatro décadas por encima de la calibración radiométrica absoluta. Esta decisión es coherente con la naturaleza binaria (urbano/no urbano) del problema y con el carácter histórico de la serie, para la cual no existe una alternativa con calibración radiométrica homogénea y acceso libre que cubra desde 1984.

Tras el preprocesamiento, cada año queda como matriz RGB de $1,792 \times 3,024$ píxeles (del orden de $5,4 \times 10^6$ píxeles por imagen) en formato PNG; los metadatos de cobertura y tamaño se resumen más adelante, al conformar la serie.

4.2. Adquisición y conformación del conjunto de imágenes

La adquisición siguió un **protocolo manual replicable** (misma ventana geográfica y criterios visuales de calidad en cada año) orientado a obtener una serie temporal homogénea para estudiar la forma espaciotemporal del crecimiento urbano a partir de percepción remota, en la línea de trabajos que miden esa dinámica desde imágenes (Herold et al., 2003). La herramienta fue **Google Earth** en escritorio, elegida por tres razones prácticas: da acceso a la **imagen histórica** año con año sobre la misma área, ofrece una interfaz visual inmediata para evaluar nubosidad y nitidez antes de capturar, y hace viable construir la serie sin infraestructura de acceso a API ni *scripts* de descarga. La contrapartida es que la repetibilidad depende de mantener la misma escala, orientación y encuadre entre capturas, y de registrar manualmente la fecha elegida en cada año; el procedimiento paso a paso se detalla en el Apéndice A (Algoritmo 5).

La serie se diseñó atendiendo a criterios temporales y de calidad: cobertura completa 1984–2020 (37 años, suficiente para abarcar varios ciclos de crecimiento), una imagen representativa por año sin años omitidos, captura preferente en temporada seca (noviembre–abril) con una meta visual de menos del 10 % de nubes, y consistencia geométrica entre años (mismo zoom,

orientación y región de interés, con ajuste fino a la cuadrícula en el preprocesamiento) sin saturación evidente en los canales RGB.

4.2.1. Criterios de selección y parámetros espaciales

Los parámetros espaciales que guiaron la captura pueden describirse de forma compacta. El área de estudio es la Zona Metropolitana de Querétaro, registrada con Google Earth en escritorio de forma manual mediante la imagen histórica, sin recurrir a Google Earth Engine ni a descarga masiva por API. El encuadre se centró en torno a $20,59^{\circ}$ N y $100,39^{\circ}$ W (equivalente aproximado a $20^{\circ}35'25''$ N, $100^{\circ}23'25''$ W) y cubrió del orden de 25×25 km en el visor, unos 625 km^2 , que sirvieron como referencia operativa para conservar la misma ventana entre años. El visor opera sobre el elipsoide WGS84 (EPSG:4326) y la georreferenciación fina se homogeneizó en el preprocesamiento. La resolución aparente, del orden de 8 a 14 m/píxel ($\sim 115 \text{ m}^2$ por píxel), depende del nivel de zoom y del mosaico cartográfico que Google Earth muestra en cada fecha, por lo que se procuró mantener constantes el zoom y la orientación entre capturas. Las bandas disponibles son únicamente RGB, exportadas o capturadas desde el visor.

A partir de estos parámetros puede estimarse una resolución espacial efectiva aproximada. La ventana operativa de unos 625 km^2 ($\sim 25 \times 25 \text{ km}$) se exporta a una rejilla de $1,792 \times 3,024$ píxeles, de modo que cada píxel cubre del orden de 115 m^2 : un lado equivalente cercano a 11 m/píxel como media geométrica, con un rango por eje aproximado de 8 a 14 m/píxel, ya que la rejilla no es cuadrada. Conviene leer esta cifra como un orden de magnitud y no como una distancia de muestreo calibrada: la extensión es una referencia de encuadre, el nivel de zoom y el mosaico subyacente varían entre fechas, y Google Earth remuestrea internamente las teselas. La resolución resultante basta para discriminar la mancha urbana a escala metropolitana, el objetivo de este trabajo, pero no para distinguir estructuras individuales finas ni para comparaciones submétricas entre años.

En conjunto, la serie reúne 37 imágenes, una por año entre 1984 y 2020, capturadas con una meta visual de cobertura nubosa inferior al 10 % evaluada en el momento de la captura. Cada imagen se homogeneizó en el *pipeline* a $1,792 \times 3,024$ píxeles, y el conjunto completo ocupa del orden de 200 MB.

4.2.2. Control de calidad, limitaciones y mitigación

En la adquisición, el control de calidad fue principalmente **visual** (nubosidad, sombras, nitidez, consistencia del encuadre). Ya conformada la carpeta de imágenes, el **pipeline de preprocesamiento** aplica comprobaciones reproducibles (dimensiones homogéneas, formato




Figura 4.1: Indicadores auxiliares de calidad por década, derivados del preprocesamiento de las capturas. No equivalen a control de calidad radiométrico de productos satelitales oficiales; sirven como apoyo visual para revisar la continuidad de la serie.

RGB, detección de archivos faltantes y reescalado cuando una captura varió en resolución de pantalla) antes de alimentar al clasificador; a ello se suman una validación geométrica (ajuste a la cuadrícula de referencia), una de intensidades (histogramas RGB para detectar anomalías evidentes) y una temporal (continuidad de la serie y sustitución puntual de años claramente anómalos). El conjunto final queda resumido en la descripción anterior del conjunto de imágenes y en la Figura 4.1.

El dataset tiene cuatro limitaciones principales: la resolución y nitidez efectivas dependen del nivel de zoom, del fondo cartográfico de cada fecha y de la compresión al exportar; el operador no controla la corrección atmosférica ni el origen exacto de cada tesela subyacente; la comparabilidad cromática entre años puede variar cuando el proveedor actualiza mosaicos; y el criterio de temporada seca y baja nubosidad es visual, no un filtrado por metadatos de nubes. Para acotar su impacto se fijaron los parámetros de vista (zoom, orientación, región) lo más constantes posible entre años, se homogeneizaron formato y dimensiones en el preprocesamiento, se hizo una revisión cruzada año con año para detectar saltos de contraste o nubosidad residual, y se normalizaron los valores de píxel con vistas a la clasificación binaria, sin pretender una calibración radiométrica entre sensores.

Estas fuentes de error se organizan por tipo, con una estimación cualitativa de su nivel y de su efecto sobre los mapas binarios, en la Tabla A.2 del Apéndice A. Los niveles (bajo, medio, alto) son juicios del autor a partir de la inspección de la serie y no mediciones formales de incertidumbre;

sirven para dar prioridad a las estrategias de mitigación y para acotar honestamente el alcance de los resultados.

4.3. Pipeline de clasificación: de RGB a mapas binarios

El preprocesamiento homogeneiza formato y dimensiones de las capturas RGB y prepara la entrada al clasificador automático (LBP+K-Means+SVM). El *pipeline*, implementado en Python, encadena las etapas que resume la Figura 4.2:

Antes de describirlo conviene justificar por qué se eligió esta cadena y no un enfoque supervisado directo. La razón de fondo es que no se dispone de una verdad terreno etiquetada para los 37 años de la serie: un clasificador supervisado clásico o un *Random Forest* exigiría etiquetar manualmente muestras representativas año por año, y una arquitectura profunda tipo U-Net necesitaría además grandes volúmenes anotados y cómputo en GPU, sin aportar interpretabilidad sobre la decisión urbano/no-urbano. Frente a ello, la cadena combina texturas y color de forma no supervisada: los patrones binarios locales (LBP) describen la rugosidad del tejido construido y son robustos a cambios de iluminación, el agrupamiento K-Means genera pseudoetiquetas sin información previa, y un SVM lineal consolida a partir de ellas una frontera de decisión reproducible y ligera. Dado que el problema es binario y que las imágenes son RGB sin banda infrarroja, este contraste de textura y color basta para separar lo construido de lo no construido; la opción elegida es, además, computacionalmente liviana (sin GPU) y replicable, lo que prioriza la reproducibilidad sobre una exactitud marginalmente mayor que las alternativas más pesadas no garantizan en ausencia de etiquetas.

Pipeline de Procesamiento

Clasificación automática de capturas RGB




Figura 4.2: Pipeline de preprocesamiento implementado

4.3.1. Extracción de características

Para cada píxel se extraen automáticamente 23 características, organizadas en tres categorías. Ocho son básicas y derivan directamente de los canales: rojo, verde y azul, intensidad, brillo y la desviación estándar de cada canal. Seis son texturales: los gradientes Sobel horizontal y vertical, la magnitud del gradiente, el patrón binario local uniforme (LBP con $R = 3$ y $P = 24$) sobre la escala de grises, la entropía local y el contraste local. Las nueve restantes son espectrales y de color: el índice verde-rojo normalizado $(G - R)/(G + R)$, el exceso de verde y el exceso de rojo,

las componentes L , a , b del espacio LAB y H , S , V del HSV. El detalle por característica, con su definición de implementación, se recoge en la Tabla A.1 del Apéndice A.

Sobre la categoría espectral conviene una aclaración. Como las capturas son RGB y no incluyen banda infrarroja, aquí no se calcula un NDVI en sentido estricto: ese índice necesita el infrarrojo cercano, del que estas imágenes carecen. Lo que se usa son índices contruidos únicamente con los canales visibles. El que se reporta como índice verde-rojo normalizado responde a la forma $(G - R)/(G + R)$ y coincide con el NGRDI que la literatura de percepción remota emplea con cámaras RGB; junto con el exceso de verde y de rojo cumple el papel de un proxy cromático de vegetación, suficiente para separar superficies vegetadas de las contruidas a partir del contraste de color, que es lo que requiere la clasificación binaria de este trabajo.

4.3.2. Normalización y reducción dimensional

El preprocesamiento incluye dos etapas adicionales antes del clasificador. La primera es una normalización estadística, que aplica `StandardScaler` para centrar y escalar cada característica. La segunda es una reducción dimensional mediante análisis de componentes principales (PCA), que comprime los 23 descriptores a 8 componentes.

La PCA retiene en promedio cerca del 96 % de la varianza original, una compresión razonable sin pérdida apreciable de información para la clasificación binaria. El preprocesamiento aplicado a toda la serie se resume en la Tabla A.3 del Apéndice A.

La implementación se organiza en una arquitectura modular (rasterización/clasificación de las capturas, cálculo de Pesos de Evidencia y simulación con autómatas celulares) cuyo diagrama de clases UML y rutas de los módulos del repositorio se documentan en el Apéndice A, para no recargar la descripción metodológica.

En este espacio RGB enriquecido con descriptores de textura (en particular los patrones binarios locales [LBP] de Ojala et al. (2002), robustos a cambios de iluminación y útiles para distinguir la rugosidad del tejido contruido), los primeros componentes del PCA reflejan el contraste urbano-vegetación y la variabilidad local, de modo que el SVM trabaja sobre representaciones comprimidas y poco redundantes.

4.4. Análisis de datos procesados y transformación binaria

Esta sección resume la salida del pipeline: mapas binarios anuales urbano/no-urbano listos para alimentar el modelo WoE-AC del capítulo siguiente.

4.4.1. Resultados de la transformación binaria

La Figura 4.3 muestra la evolución temporal del crecimiento urbano de Querétaro capturada mediante la clasificación binaria.




Figura 4.3: Evolución del crecimiento urbano de la Zona Metropolitana de Querétaro (1984–2020), representada mediante mapas binarios urbano/no-urbano obtenidos a partir de la clasificación LBP+K-Means+SVM aplicada a las capturas RGB de la serie.

4.4.2. Calidad interna de la clasificación

La calidad del clasificador LBP+K-Means+SVM se evalúa con un reparto interno *train/test* (20 % para prueba por defecto) sobre las pseudoetiquetas generadas por K-Means, conforme a la rutina de entrenamiento documentada en el Apéndice A. En los experimentos sobre Querétaro, la concordancia del SVM con esas pseudoetiquetas (medida como *accuracy* en el reparto interno, no contra una verdad terreno) se situó en el rango 88–94 %, en línea con lo comentado en el Capítulo 5.

Este porcentaje mide la coherencia interna del clasificador (es decir, qué tan bien el SVM reproduce las etiquetas generadas por K-Means) y no la exactitud respecto a una verdad terreno externa independiente. La validación externa del *pipeline* se realiza, de manera indirecta, a través de la evaluación temporal del modelo AC en el Capítulo 6.

4.4.3. Justificación de la representación binaria

La simplificación del mapa de cobertura de suelo a dos categorías (urbano/no-urbano) responde a tres consideraciones metodológicas. La primera es la compatibilidad con el AC: los autómatas celulares utilizados operan con estados discretos, de modo que la representación binaria elimina una etapa adicional de discretización y hace que las reglas de transición sean directamente interpretables. La segunda es la disponibilidad de datos: las capturas son RGB, sin bandas térmicas ni radar, lo que acota la discriminación fina de usos intraurbanos y hace razonable condensar la salida en dos clases. La tercera es el objetivo del modelo: el interés está en modelar la *expansión* del área urbana y no la composición interna de usos de suelo, y la

clasificación binaria captura precisamente esa variable de salida.

4.4.4. Síntesis del capítulo

La inspección visual de los mapas binarios anuales (Figura 4.3) muestra transiciones graduales y continuas entre años consecutivos, con patrones de expansión congruentes con el crecimiento documentado para la ZMQ, sin artefactos sistemáticos ni discontinuidades espaciales abruptas en la serie.

Este capítulo describió la zona de estudio, la obtención manual de imágenes con Google Earth (línea de tiempo histórica) y el pipeline de clasificación LBP+K-Means+SVM que transforma las imágenes RGB en mapas binarios anuales. La serie resultante de 37 mapas (1984–2020) constituye la entrada principal para el cálculo de los Pesos de Evidencia y la simulación con Autómatas Celulares descritos en el capítulo siguiente.

Capítulo 5

Modelo de crecimiento urbano

Este capítulo muestra una visión exhaustiva del modelo citado a lo largo de todo este trabajo como WoE-AC, se presentan las decisiones explícitas de cada componente del modelo, preprocesamiento y validación. Si bien el segundo capítulo del presente trabajo da una definición a cada concepto utilizado, no hay una argumentación de por qué se utiliza cada una de las componentes del flujo completo que al trabajo presente le compete. Se inicia con un recordatorio breve del preprocesamiento que produce la serie binaria de entrada, cuyo detalle queda en el Capítulo 4, seguido por el modelo que consume esos mapas para calcular la matriz de transiciones históricas, la definición del autómata celular probabilístico y, finalmente, la validación del modelo. Conviene anticipar que la novedad de este trabajo no es el acoplamiento WoE-AC en sí, ampliamente documentado en la literatura, sino su calibración y validación reproducibles sobre cinco ventanas quinquenales independientes, aplicadas a una ciudad intermedia mexicana con código y datos abiertos.

5.1. Del preprocesamiento a la serie binaria de entrada

El modelo WoE-AC no parte de las imágenes crudas, sino de una serie de mapas binarios urbano/no-urbano $\{U_t\}_{t=1984}^{2020}$. Su construcción (la conversión de cada captura RGB de $1,792 \times 3,024$ píxeles en un mapa $U_t(x, y) \in \{0, 1\}$ mediante la cadena LBP + K-Means + SVM) se describe en detalle en el Capítulo 4 y no se reproduce aquí. Basta recordar dos restricciones que ese flujo resuelve: la ausencia de banda infrarroja descarta los índices espectrales habituales (NDVI, NDBI) y obliga a apoyarse en descriptores de textura y color, y la falta de verdad terreno para los 37 años obliga a etiquetar de forma no supervisada.

De ese flujo conviene rescatar, eso sí, la decisión que condiciona todo lo que sigue: el criterio que separa lo urbano de lo no-urbano es **idéntico para todos los años de la serie**. Esa consistencia inter-anual, y no la exactitud cartográfica frente a una verdad terreno, es lo que vuelve comparables las transiciones entre años consecutivos y permite que alimenten el cálculo de Pesos de Evidencia sin sesgos por cambios de criterio. La representación binaria, por su parte, es la entrada natural de un autómata celular, que opera sobre estados discretos, y captura justo la variable de interés: la expansión de la mancha urbana, no la composición interna de usos. Como respaldo de su fiabilidad interna, el clasificador reprodujo entre el 88 % y el 94 % de las pseudoetiquetas en el reparto de prueba (Capítulo 4); su validación externa, de carácter indirecto, se realiza a través del desempeño temporal del propio modelo en el Capítulo 6.




Figura 5.1: Representación binaria $U_t(i, j) \in \{0, 1\}$: celdas oscuras urbanas y claras no urbanas.

5.2. Modelo de crecimiento urbano.




Figura 5.3: Transición $U_t(i, j) = 0 \rightarrow U_{t+1}(i, j) = 1$: la celda con borde rojo transita a urbana cuando $P_{i,j} > \theta$.

y, más adelante, reproducir hacia el futuro.

Conviene distinguir, desde aquí, tres planos que en lo que sigue se exponen de forma entrelazada pero que son conceptualmente distintos. El primero es el **modelo conceptual**: las reglas matemáticas generales del acoplamiento WoE-AC (la cuantificación de evidencia, la

Con la serie de mapas binarios $\{U_t\}_{t=1984}^{2020}$ ya construida, el modelo de crecimiento urbano debe responder a una pregunta distinta de la del preprocesamiento: ya no se trata de decidir qué es urbano, sino de aprender dónde y por qué aparece lo urbano nuevo. El primer paso es, por tanto, definir el objeto de estudio del modelo: la transición. Una transición ocurre cuando una celda que era no-urbana en el año t pasa a urbana en $t + 1$, es decir, $U_t(i, j) = 0$ y $U_{t+1}(i, j) = 1$. Estas transiciones son los eventos que el modelo busca primero explicar a partir de la historia




Figura 5.2: Pipeline completo del modelo WoE-AC: del dato satelital a la validación quinquenal. Las etapas 1–2 producen la serie binaria; la etapa 3 estima los pesos de evidencia sobre 26 pares históricos; la etapa 4 ejecuta el autómata celular de forma iterativa; la etapa 5 evalúa con cinco ventanas temporales independientes.

regla de transición probabilística y la actualización del estado), válidas para cualquier ciudad. El segundo es la **implementación**: el recálculo iterativo del campo de evidencia y de la vecindad sobre el estado actualizado del mapa en cada paso de simulación. El tercero es la **configuración experimental**: los valores concretos fijados para la Zona Metropolitana de Querétaro (el umbral $\theta = 0,75$, el peso de vecindad $\alpha = 0,50$, la ponderación por *Information Value* y las ventanas quinquenales de validación), que son objeto del Capítulo 6. La narración avanza del primero al tercero.

La primera decisión del modelo es cómo cuantificar la evidencia que vincula la configuración espacial de una celda con su probabilidad de transición. La vía más común en la literatura es la regresión logística, pero conlleva un supuesto fuerte: que el logit de la probabilidad es una función lineal de las variables explicativas. Las relaciones espaciales del crecimiento urbano no son lineales; la probabilidad de urbanización cae de forma abrupta en los primeros cientos de metros desde el frente urbano y luego se aplanan. Por eso se elige el método de Pesos de Evidencia (WoE, ecuación 2.4 del Capítulo 2), que no impone ninguna forma funcional: discretiza cada variable en intervalos y estima un peso bayesiano independiente para cada uno, capturando la curvatura real de la relación. Como ventaja adicional, cada peso es interpretable en términos geográficos, lo que satisface el requisito de transparencia que motivó este trabajo y que los enfoques de caja negra no ofrecen.

La segunda decisión es qué variables espaciales alimentan el WoE. Aquí opera de nuevo una restricción de los datos: no se dispone de capas externas homogéneas (vialidades, pendiente, uso de suelo oficial) para los 37 años de la serie. Por tanto, todas las variables deben derivarse de la propia configuración urbana histórica, sin insumos adicionales. Se definen siete: la distancia euclidiana a la celda urbana más cercana, la densidad de vecinos urbanos a tres escalas (ventanas 3×3 , 5×5 y 7×7), la fragmentación local, el tamaño del cluster urbano contiguo más cercano y el gradiente de urbanización. Cada una captura un aspecto distinto del proceso: la proximidad al frente consolidado, la presión del vecindario a múltiples escalas y la morfología del borde urbano. El que las siete provengan únicamente del mapa binario es lo que hace al modelo transferible a cualquier ciudad para la que exista esa serie, sin




Figura 5.4: Las siete variables espaciales derivadas del mapa binario U_t . Todas se calculan exclusivamente a partir de la configuración urbana histórica, sin capas externas.

depender de bases de datos locales.

La tercera decisión es sobre qué datos afinar. En lugar de ajustar el WoE a un único par de años, se agregan (*pooling*) las transiciones de los 26 pares consecutivos del período 1984–2010. El motivo es estadístico: las transiciones de un solo año son escasas y ruidosas, y producirían pesos inestables. Al acumular los 26 períodos se reúnen 8,196,264 transiciones observadas, lo que reduce el error de estimación de cada bin a un nivel en el que los pesos pueden tratarse como constantes del modelo. El período 2011–2020 se reserva deliberadamente, sin tocarlo durante el ajuste, para la validación posterior.

Con los pesos calculados, surge una cuarta decisión: cómo combinarlos. No todas las variables aportan lo mismo. El peso total por celda (ecuación 2.5) no se obtiene como una suma simple, sino ponderando cada variable por su *Information Value* normalizado, de modo que las variables con mayor poder discriminativo pesen más en la decisión final. En el caso de la Zona Metropolitana de Querétaro, esto hace que la distancia al frente urbano domine la combinación, concentra cerca del 28 % del peso total, el *Information Value* más alto de las siete variables, seguida de la densidad de vecinos inmediatos. La suma ponderada se transforma con la función sigmoide (ecuación 2.6) para obtener una probabilidad de transición acotada en $[0, 1]$.

Llegados a este punto aparece la decisión central del modelo, la que lo distingue de una simple regresión espacial: por qué un autómata celular y no usar directamente el mapa de probabilidad WoE como predicción. La razón es que el mapa WoE es estático; describe la idoneidad de cada celda dada la configuración del año inicial, pero no simula cómo el crecimiento se propaga en el tiempo. Una celda muy apta puede no urbanizarse si ningún frente urbano la alcanza dentro del período, y una celda de idoneidad media puede hacerlo si el crecimiento llega a su vecindad. El autómata

celular (Sección 2.2 del Capítulo 2) resuelve esto aplicando la regla de transición de forma iterativa: en cada paso anual se recalculan las siete variables espaciales sobre el estado actualizado del mapa. Así, cuando una celda se urbaniza, incrementa de inmediato la densidad de vecinos de sus celdas contiguas y eleva su probabilidad de transición en el paso siguiente. Este mecanismo de contagio borde a borde es el que genera los patrones de mancha compacta, relleno de huecos




Figura 5.5: Vecindad de Moore (8 celdas) frente a Von Neumann (4 ortogonales). Moore captura frentes diagonales de crecimiento.

y extensión de corredores que se observan empíricamente en la ZMQ; que las dos variables más predictivas sean de proximidad local confirma que el crecimiento de la zona es de tipo contagio y no difusión aleatoria, y por tanto que un autómata celular es su representación natural.




Figura 5.6: Un paso del AC: las celdas candidatas (borde rojo) se evalúan con la regla WoE y transitan a urbanas (relleno rojo) si $P_{i,j} > \theta$.

sobre-predicción masiva; su calibración y la del peso vecinal se detallan en el Capítulo 6. Por último, la transición no es determinista: una celda apta se urbaniza solo si un sorteo aleatorio lo confirma. Esta componente estocástica refleja que, incluso bajo condiciones favorables, la urbanización de una parcela depende de factores no modelados (decisiones de propietarios, permisos, mercado), y es lo que hace que distintas corridas del modelo generen escenarios ligeramente distintos en lugar de una única predicción rígida.

Los tres componentes se condensan en una sola expresión, que constituye el núcleo formal del modelo y coincide con la implementación validada (Sección 5.2). Para una celda no urbana (i, j) , la probabilidad de transición es

$$P_{i,j} = \min\left(1, \sigma\left(\sum_k \omega_k \text{WoE}_k(i, j)\right) + \alpha N_{i,j}\right), \quad \omega_k = \frac{\text{IV}_k}{\sum_l \text{IV}_l}, \quad (5.1)$$

donde $\sigma(\cdot)$ es la función logística; $\text{WoE}_k(i, j)$ es el peso de evidencia de la k -ésima variable espacial, ponderado por su *Information Value* normalizado ω_k (de modo que las variables más discriminativas pesan más); y $N_{i,j} \in [0, 1]$ es la influencia del vecindario, definida como la fracción de vecinos urbanos en la vecindad de Moore (las ocho celdas adyacentes), con peso vecinal α . Nótese que la idoneidad WoE se transforma primero con la sigmoide y la vecindad se suma después, acotando el resultado a $[0, 1]$. La proximidad al frente urbano no aparece como

La regla de transición integra, finalmente, tres componentes. A la probabilidad WoE de cada celda se le añade la influencia del vecindario de Moore (ocho celdas adyacentes, ecuación 2.2), ponderada por un peso vecinal; se elige la vecindad de Moore por ser la mínima que captura tanto adyacencias ortogonales como diagonales del frente urbano. La probabilidad combinada se compara contra un umbral de transición: solo las celdas que lo superan pueden urbanizarse. Este umbral se fijó en 0,75 mediante exploración sistemática, tras observar que valores menores producían

un término separado: la introduce la propia variable de distancia, la de mayor *Information Value*, dentro del campo WoE. En la implementación validada no se incluye un término adicional de decaimiento espacial (por ejemplo, una ponderación por distancia de Chebyshev sobre el vecindario); la distancia al frente urbano actúa únicamente como una variable más dentro del campo WoE, y la vecindad se incorpora como la fracción de vecinos urbanos en la vecindad de Moore. La celda transita a urbana en el paso siguiente solo si $P_{i,j}$ supera el umbral θ y si, además, un sorteo aleatorio $u \sim \mathcal{U}(0, 1)$ lo confirma ($u < P_{i,j}$). La configuración validada en este trabajo fija $\theta = 0,75$ y $\alpha = 0,50$ (Capítulo 6).

Conviene precisar en qué se aparta esta formulación del esquema WoE-AC más habitual. En buena parte de la literatura el WoE entra al autómata como un mapa de idoneidad estático que apenas se recalcula durante la simulación. Aquí, en cambio, el WoE se incorpora como un campo probabilístico continuo ponderado por el *Information Value* normalizado de cada variable, que se recompone en cada paso al recalcular las variables espaciales sobre el estado actualizado del mapa, y se acopla a la vecindad mediante una regla deliberadamente sencilla y auditable. Ahora bien, la aportación metodológica central no reside en el uso del WoE y del AC, que la literatura ya documenta ampliamente, sino en el protocolo de evaluación: la calibración y la validación reproducibles sobre cinco ventanas quinquenales independientes, con código y datos abiertos, que permiten distinguir un desempeño estable de un ajuste a un único período. A ello se suman el contexto poco estudiado, una ciudad intermedia mexicana, y la serie larga de 37 años.

5.3. Validación.

Definido el modelo, queda la pregunta de si sus predicciones son confiables. La primera decisión de la validación ya se tomó al entrenar: el WoE se ajustó únicamente con las transiciones de 1984–2010, dejando intacto el período 2011–2020. Esta separación temporal es lo que hace honesta a la evaluación, pues el modelo se prueba sobre años que nunca vio durante el ajuste, de la misma forma en que tendría que operar al proyectar el futuro. Validar sobre los mismos datos de entrenamiento solo mediría la capacidad de memorizar, no la de predecir.

La segunda decisión, y la que define el aporte metodológico de este trabajo, es no validar sobre una única ventana sino sobre cinco ventanas quinquenales independientes: 2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020. La razón es que una sola ventana puede resultar engañosamente favorable o desfavorable según las particularidades de ese lustro; cinco ventanas que se desplazan año con año permiten distinguir entre un acierto puntual y un comportamiento estable del modelo. Gran parte de la literatura revisada en el Capítulo 3 valida sobre un solo período, lo que impide saber si el desempeño reportado se sostiene en el tiempo.




Figura 5.7: Protocolo de validación: separación temporal entre entrenamiento (WoE, 1984–2010) y las cinco ventanas quinquenales de prueba (2011–2020). Ningún dato del período de prueba interviene en el ajuste del modelo.

El procedimiento es el mismo en cada ventana. Se toma el mapa observado del año inicial como estado de partida, se ejecuta el autómata celular durante cinco pasos anuales recalculando las variables espaciales en cada uno, y el mapa predicho para el año final se compara, celda a celda, contra el mapa observado de ese año. De esa comparación se construye la matriz de confusión (ecuación 2.7) y, a partir de ella, todas las métricas.

Aquí aparece una decisión sobre cómo medir el acierto. Las métricas globales como la exactitud o el coeficiente Kappa (ecuación 2.16) son engañosas en este problema: como la mayoría del territorio no cambia de un año a otro, un modelo que se limitara a copiar el mapa inicial obtendría una exactitud altísima sin predecir crecimiento alguno. Por eso la métrica central de la validación es el *Figure of Merit* (ecuación 2.22), que evalúa exclusivamente las celdas en transición e ignora la clase mayoritaria de permanencia. Se reportan, no obstante, las métricas complementarias (IoU, Precision, Recall, F1 y Kappa) y la descomposición del error en sus componentes de cantidad y de asignación, porque cada una ilumina un aspecto distinto del desempeño.

El resultado sostiene la hipótesis de estabilidad. A lo largo de las cinco ventanas, el *Figure of Merit* se mantiene en el intervalo [0,222, 0,378], con un valor medio cercano a 0,317, un Kappa medio de 0,445 y un IoU medio de 0,633. Ninguna ventana se desploma ni dispara su desempeño respecto de las demás, lo que indica que el modelo captura una dinámica estructural del crecimiento de la Zona Metropolitana de Querétaro y no un patrón sobreajustado a un período concreto. La presentación detallada de estas métricas, ventana por ventana, junto con la discusión de la calibración, se desarrolla en el Capítulo 6.




Figura 5.8: Componentes del *Figure of Merit*: acierto (B), falsa alarma (A) y omisión (C). Solo las celdas en transición entran al cálculo.

Capítulo 6

Resultados y análisis

Este capítulo presenta los resultados obtenidos de la aplicación del modelo WoE-AC para simular el crecimiento urbano de Querétaro. Se analiza la dinámica histórica observada (1984–2020), los resultados del análisis Weight of Evidence, la calibración del modelo, las simulaciones en cinco ventanas quinquenales independientes (2011–2016 a 2015–2020) y la evaluación cuantitativa mediante métricas espaciales (Accuracy, Precision, Recall, F1, Kappa, FoM). Finalmente, se realiza un análisis espacial del error para identificar las fuentes de discrepancia entre predicción y observación.

6.1. Dinámica observada del crecimiento urbano

Antes de evaluar el desempeño del modelo, es pertinente caracterizar el proceso que la simulación busca reproducir. Esta sección describe la evolución histórica de la huella urbana de Querétaro y los patrones espaciales de expansión identificados en la serie temporal 1984–2020.

6.1.1. Evolución temporal 1984–2020

Antes de presentar los resultados de la simulación conviene situarlos en el contexto histórico del crecimiento de Querétaro. Aquí hace falta una advertencia: la magnitud absoluta de la clase “urbano” que devuelve el clasificador no equivale a la mancha urbana real, porque arrastra también suelo desnudo y superficies áridas espectralmente parecidas (véase la nota metodológica al final de esta sección). Por eso, en vez de una tasa de crecimiento compuesta, que la serie clasificada no sostiene, la Tabla 6.1 resume la fracción media de píxeles de esa clase en cuatro tramos de la serie.

Sobre el conjunto de la serie, la fracción clasificada pasa de 44,4 % en 1984 a 52,9 % en 2020,

Cuadro 6.1: Fracción media de píxeles clasificados como “urbano” por tramo de la serie 1984–2020. Las cifras provienen directamente de los mapas binarios y deben leerse como un indicador grueso de la dinámica, no como superficie construida.

Período	Fracción media clasificada	Característica principal
1984–1995	~43 %	Consolidación del centro urbano
1996–2005	~44 %	Expansión hacia zonas industriales
2006–2015	~45 %	Expansión dispersa (norte y este)
2016–2020	~51 %	Consolidación periférica

un incremento neto de 8,4 puntos porcentuales. La variabilidad interanual es alta: hay mínimos como 33,6 % en 1992 y una desviación estándar cercana a 4 puntos a lo largo del período. Un ajuste lineal de la fracción frente al año arroja una pendiente de apenas 0,15 puntos por año, con $R^2 \approx 0,15$; es decir, la tendencia ascendente existe pero es débil y queda dominada por el ruido del clasificador. El único tramo que se separa con nitidez del resto es 2016–2020. Por eso no se reporta una tasa anual compuesta: la serie no la sostiene.




Figura 6.1: Evolución de la fracción clasificada como “urbano” en Querétaro (1984–2020). Se observa una tendencia ascendente con fuerte variabilidad interanual, más marcada en el tramo final de la serie.

6.1.2. Patrones espaciales de expansión

Los mapas binarios generados para cada año revelan tres patrones principales de expansión. El primero es el crecimiento contiguo por difusión, donde la expansión se produce principalmente desde los bordes de áreas urbanas existentes, siguiendo el mecanismo de contagio espacial que los autómatas celulares capturan de manera natural. El segundo corresponde al desarrollo periurbano a lo largo de corredores de transporte, visible en los ejes norte (autopista a San Luis

Potosí) y oeste (autopista a Celaya). El tercero es el desarrollo industrial puntual: la instalación de parques industriales (Aeropuerto Industrial, Querétaro Aerospace) genera núcleos discontinuos en la periferia.

Los mapas binarios muestran crecimiento sostenido de la huella urbana a lo largo del período. Para los años de inicio de los experimentos de validación, los recuentos de píxeles urbanos extraídos directamente de los mapas clasificados son los siguientes: 2011: 2,699,088 px; 2012: 2,140,433 px; 2013: 2,140,627 px; 2014: 2,469,631 px; 2015: 2,145,356 px; 2020 (observado): 2,864,122 px. Estas cifras corresponden directamente a los valores `urban_start` y `urban_end_observed` de los archivos de resultados de validación (`validation_results.json`) y son los insumos directos del Autómata Celular.

Nota metodológica sobre la clase “urbano”: El clasificador K-Means+SVM opera sobre características espectrales y de textura extraídas de las **capturas RGB** de la serie (Google Earth, imagen histórica). En la práctica, el clasificador aprende a separar dos agrupaciones espectrales: *zonas con cubierta vegetal verde y densa* versus *zonas sin cubierta vegetal verde*. Esta segunda clase agrupa el tejido urbano real (edificaciones, vialidades, concreto), pero también suelo desnudo agrícola en temporada seca y superficies áridas periféricas espectralmente similares a las urbanas. Por ello, los recuentos de píxeles de la clase “urbano” son considerablemente mayores que la mancha urbana real de Querétaro.

La validación del modelo se realiza en términos de *consistencia interna*: dado un mapa binario clasificado en el año t (con la definición descrita), el modelo predice qué píxeles habrán cambiado de clase en $t + 5$. La calidad de esa predicción es lo que miden las métricas de la Sección 6.5. Este enfoque es válido mientras la definición de clase se aplique de forma consistente en todos los años de la serie.

6.2. Resultados del análisis Weight of Evidence

Esta sección presenta los resultados del cálculo de Weight of Evidence sobre las transiciones históricas observadas (1984–2010), incluyendo el poder predictivo de cada variable espacial cuantificado mediante el Information Value y la interpretación geográfica de los pesos obtenidos.

6.2.1. Transiciones históricas identificadas

El cálculo de Weight of Evidence se basó en el análisis de 26 períodos anuales consecutivos (1984–2010), identificando los píxeles que cambiaron de estado entre cada par de años. El modelo WoE consolidado está almacenado en `data/processed/woe_pooled_1984_2010.pkl`

y utiliza un total de 8,196,264 píxeles de transición observados a lo largo de los 26 períodos.

6.2.2. Pesos por variable (Information Value)

El modelo utiliza 7 variables espaciales cuya importancia predictiva se cuantifica mediante el Information Value (IV). La Tabla 6.2 presenta los IV calculados sobre el conjunto de entrenamiento 1984–2010, que determinan directamente la ponderación de cada variable en la probabilidad de transición.

Cuadro 6.2: *Information Value* y pesos normalizados de las siete variables WoE, calculados sobre el período de entrenamiento (1984–2010).

Variable	IV	Peso normalizado
Distancia al área urbana (distance_urban)	0,2817	0,2817
Densidad de vecindad 3 × 3 (neighbor_density_3x3)	0,2495	0,2495
Densidad de vecindad 5 × 5 (neighbor_density_5x5)	0,1445	0,1445
Densidad de vecindad 7 × 7 (neighbor_density_7x7)	0,1068	0,1068
Fragmentación local (local_fragmentation)	0,1062	0,1062
Gradiente urbano (urban_gradient)	0,0996	0,0996
Tamaño del <i>cluster</i> más cercano (nearest_cluster_size)	0,0120	0,0120
Total	1,0003	1,000

Estos valores provienen directamente de data/processed/quinquenal_best_config.json. El patrón muestra que la distancia al área urbana y las tres variables de densidad concentran cerca del 75 % del poder predictivo, lo que es **coherente** con un mecanismo de difusión espacial desde las áreas ya urbanizadas, ampliamente documentado en la literatura de expansión urbana. La variable nearest_cluster_size presenta un IV muy bajo (0,012), lo que sugiere que el tamaño del *cluster* urbano más cercano aporta información marginal una vez controlada la distancia.

6.2.3. Interpretación de los pesos WoE

El patrón observado en los pesos es **coherente** con la teoría de difusión urbana: la probabilidad de urbanización de una celda crece con la fracción de vecinos ya urbanizados. Los valores de WoE negativos (*bins* 1–2) corresponden a celdas con vecindad escasamente urbanizada y, en consecuencia, con menor probabilidad de transición que el promedio. Los valores positivos (*bins* 4–8) corresponden a celdas rodeadas por áreas urbanas y, por tanto, con probabilidad de transición varias veces mayor al promedio. El punto de equilibrio (WoE $\approx$ 0) se alcanza en $\rho \approx 0,35$ –0,40.




Figura 6.2: Pesos WoE por bin de densidad de vecindad urbana. La relación monótonica creciente es coherente con un mecanismo de difusión espacial y sitúa a la densidad de vecindad como el predictor de mayor peso entre las variables del modelo, sin que ello implique que sea la única causa del crecimiento.

6.3. Calibración del modelo

A partir de los pesos WoE derivados de los datos históricos, esta sección describe la configuración final del Autómata Celular y el proceso de calibración sistemática de sus parámetros mediante búsqueda en cuadrícula (*grid search*). El marco metodológico que justifica esta elección se discute en el Capítulo 5 (Sección 5.2).

6.3.1. Configuración del autómata celular

El Autómata Celular se configuró con los parámetros especificados en la Tabla 6.3, resultado de la calibración sobre el conjunto de entrenamiento (1984–2010).

Cuadro 6.3: Configuración final del Autómata Celular WoE-AC.

Parámetro	Valor
Espacio celular	1,792 × 3,024 píxeles.
Estados	{0 : no-urbano, 1 : urbano}.
Vecindario	Moore (8 vecinos, radio = 1).
Variables WoE	Siete variables espaciales: distancia al área urbana, densidades de vecindad 3 × 3, 5 × 5 y 7 × 7, fragmentación local, gradiente urbano y tamaño del <i>cluster</i> más cercano.
Ponderación de variables	Proporcional al <i>Information Value</i> (IV) normalizado.
Umbral de urbanización	$\theta = 0,75$ (calibrado sobre la probabilidad combinada).
Peso de vecindad	$\alpha = 0,50$.
Paso temporal	1 año.
Períodos de simulación	5 iteraciones por experimento.

6.3.2. Proceso de calibración

La calibración se centró en el umbral de urbanización (θ) y en la ponderación de las siete variables WoE. El umbral final $\theta = 0,75$ se adoptó porque los valores ensayados en la exploración inicial ($\approx 0,40-0,60$) producían una sobre-predicción excesiva del crecimiento urbano; al fijar $\theta = 0,75$, la sobre-predicción se reduce de manera notable y el Recall se mantiene por encima de 0,91 en las cinco ventanas evaluadas. La ponderación de las siete variables WoE se hizo proporcional al *Information Value* (IV) de cada variable, calculado sobre el conjunto de entrenamiento (1984–2010). La configuración resultante de esta búsqueda (umbral, peso de vecindad y ponderación por IV) queda registrada de forma verificable en el archivo `data/processed/quinquenal_best_config.json` del repositorio, junto con los scripts de calibración que reproducen el barrido.

La probabilidad de urbanización para la celda (i, j) en el paso t es la misma regla de transición definida en el Capítulo 5 (ecuación 5.1): el campo WoE, suma de las siete evidencias ponderadas por su *Information Value* normalizado, se transforma con la sigmoide y se le suma después la influencia del vecindario, acotando el resultado a $[0, 1]$:

$$P_{\text{trans}}(i, j, t) = \min\left(1, \sigma\left(\sum_{k=1}^7 \frac{IV_k}{\sum_l IV_l} \cdot \text{WoE}_k(i, j, t)\right) + \alpha \cdot I_{\text{neigh}}(i, j, t)\right), \quad (6.1)$$

donde $\sigma(\cdot)$ es la función sigmoide; IV_k , el *Information Value* de la k -ésima variable; $\text{WoE}_k(i, j, t)$, el valor de evidencia en la celda; $\alpha = 0,50$, el peso de vecindad; e $I_{\text{neigh}}(i, j, t) \in [0, 1]$, la fracción de vecinos urbanos en la vecindad de Moore. Una celda se urbaniza cuando P_{trans} supera el umbral $\theta = 0,75$ y un sorteo aleatorio lo confirma.

6.4. Simulación del crecimiento urbano

Esta sección describe el protocolo de validación quinquenal múltiple implementado para evaluar el desempeño del modelo de forma independiente al entrenamiento, y presenta los resultados individuales de las simulaciones en cada uno de los cinco períodos evaluados.

6.4.1. Protocolo de validación quinquenal múltiple

Para evaluar el modelo de forma independiente del entrenamiento, se adoptó un esquema de **validación quinquenal múltiple**: el WoE se entrenó exclusivamente con datos del período 1984–2010 y, con esos pesos, el Autómata Celular se simuló en cinco ventanas temporales solapadas de cinco años, con años de inicio sucesivos (2011, 2012, 2013, 2014 y 2015). El diseño garantiza que ningún dato del período de validación interviene en el entrenamiento (*hold-out*

temporal) y permite evaluar la estabilidad del modelo bajo distintas condiciones de partida.

Cuadro 6.4: Configuración del experimento de validación quinquenal múltiple.

Parámetro	Valor
WoE entrenado con	1984–2010 (26 transiciones anuales agregadas por <i>pooling</i>)
Umbral de urbanización	$\theta = 0,75$
Peso de vecindad	$\alpha = 0,50$
Pasos por validación	5 iteraciones (1 año por paso)
Períodos evaluados	2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020

6.5. Evaluación del modelo

A continuación se presentan las métricas de evaluación cuantitativa del modelo en los cinco períodos quinquenales y se contextualizan los resultados frente a valores de referencia reportados en la literatura internacional.

6.5.1. Resumen comparativo – cinco períodos quinquenales

La Tabla 6.5 resume las métricas obtenidas en los cinco períodos evaluados, con los valores tomados directamente de cada archivo `validation_results.json` en las carpetas `data/processed/validation_quinquenal*_v3_weighted/`. El **FoM promedio es de 0,317** (equivalente a 31,7 % en escala porcentual), calculado conforme a la Ecuación 2.22 del marco teórico. Esta magnitud se sitúa en una **banda intermedia** del espectro empírico documentado por Pontius Jr et al. (2008): por encima del subconjunto de aplicaciones con FoM inferior al 15 % y muy por debajo del único caso que supera el 50 % en esa muestra multi-sitio (Capítulo 3). El Kappa promedio de 0,445 corresponde a un acuerdo moderado según la escala de Landis y Koch (cercano al límite superior de ese rango). El Recall alto ($> 0,91$ en todos los períodos) indica que el modelo captura la mayor parte de la urbanización observada, bajo la misma definición operativa de la clase urbana, aunque con sobre-predicción sistemática de la magnitud del crecimiento.

La variación entre períodos refleja diferencias en la dinámica observada. El período 2011–2016 muestra el FoM más bajo (0,222): el área urbana clasificada en 2016 *decreció* levemente respecto a 2011, una anomalía atribuible a la variabilidad de la clasificación binaria RGB año a año, más que a una contracción urbana real. Los períodos 2012–2017, 2013–2018 y 2015–2020, en los que el crecimiento neto observado es positivo, exhiben FoM entre 0,35 y 0,38, con mayor concordancia entre el modelo y los mapas observados.

El FoM promedio obtenido se ubica en una banda intermedia del espectro empírico do-

Cuadro 6.5: Métricas de validación en las cinco ventanas quinquenales (WoE-AC, umbral $\theta = 0,75$).

Período	Acc	IoU	Prec	Recall	F1	κ	FoM
2011–2016	0,665	0,581	0,590	0,975	0,735	0,349	0,222
2012–2017	0,750	0,652	0,688	0,925	0,789	0,499	0,345
2013–2018	0,744	0,648	0,689	0,917	0,787	0,482	0,355
2014–2019	0,697	0,614	0,628	0,965	0,761	0,396	0,287
2015–2020	0,755	0,669	0,701	0,936	0,802	0,498	0,378
Promedio	0,722	0,633	0,659	0,944	0,775	0,445	0,317

Cuadro 6.6: Posicionamiento del modelo WoE-AC en el espectro empírico de Figure of Merit (FoM) documentado en la literatura LUCC. La comparación es cualitativa: los sitios, las definiciones temáticas de las clases y los horizontes temporales difieren entre estudios.

Referencia	Método	FoM reportado / observado
Estudio comparativo multi-sitio (Pontius Jr et al., 2008)	Trece aplicaciones de nueve modelos	Espectro empírico amplio: seis aplicaciones con $\text{FoM} < 15\%$ y una sola ($> 50\%$); el FoM puede variar entre 0% y 100% .
GSA-CA en Urumqi (Tang et al., 2024)	AC con búsqueda gravitacional	$\text{FoM} = 43,03\%$ (2010) y $37,64\%$ (2020); contexto árido con <i>drivers</i> físicos explícitos.
Este trabajo (ZMQ, promedio cinco ventanas)	WoE-AC con <i>grid search</i>	FoM promedio = 0,317 (i.e., 31,7 %); Kappa promedio = 0,445.

cumentado por Pontius Jr et al. (2008): por encima del subconjunto de aplicaciones con FoM inferior al 15 % y por debajo del único caso que supera el 50 % en esa muestra. Comparado con el estudio reciente de Tang et al. (2024) sobre Urumqi, donde el aprovechamiento explícito de *drivers* físicos asociados a la aridez eleva el FoM por encima del 35 %, el modelo WoE-AC propuesto queda por debajo, lo que es coherente con el hecho de que en este trabajo se emplean exclusivamente variables derivadas del propio mapa binario, sin incorporar restricciones topográficas, socioeconómicas ni de infraestructura.




Figura 6.3: Desempeño comparado del modelo WoE-AC en las cinco ventanas quinquenales. Las líneas verticales punteadas señalan el promedio de cada métrica: FoM = 0,317, Kappa = 0,445, IoU = 0,633. La estabilidad entre ventanas indica que el modelo captura una dinámica estructural del crecimiento y no un patrón sobreajustado.

6.5.2. Período 2011–2016

La Tabla 6.7 reúne las métricas de esta ventana y la Figura 6.4 compara el mapa observado con el predicho. Es el período con el FoM más bajo de la serie (0,222), por la razón ya anticipada: el área urbana clasificada en 2016 quedó por debajo de la de 2011.

Cuadro 6.7: Métricas de validación del período 2011→2016. *B* (hits del FoM) es el subconjunto de *TP* que corresponde a transiciones a urbano observadas y predichas simultáneamente; los píxeles permanentes ya urbanizados quedan incluidos en *TP* pero no en *B* (véase Ec. 2.22).

Métricas de píxel		Figure of Merit	
Accuracy	0,665	FoM	0,222
IoU	0,581	Hits (<i>B</i>)	361,614
Precision	0,590	Falsas alarmas (<i>A</i>)	1,203,567
Recall	0,975	Omisiones (<i>C</i>)	64,208
F1	0,735	TP / FP / FN	2,514,806 / 1,749,463 / 64,208
κ	0,349	Crec. obs. / pred.	−4,4 % / +58,0 %




Figura 6.4: Validación quinquenal 2011–2016. De izquierda a derecha: estado inicial (2011), mapa observado 2016 (*ground truth*), mapa predicho 2016 y diferencia (verde=TP, naranja=FP, azul=FN). FoM = 0,222; la anomalía se debe a que el área urbana observada disminuyó levemente por variabilidad en la clasificación binaria RGB año a año.

6.5.3. Período 2012–2017

En esta ventana el desempeño mejora respecto a la anterior. La Tabla 6.8 detalla las métricas y la Figura 6.5 ilustra el resultado espacial, con un FoM de 0,345 sobre un crecimiento observado positivo.

Cuadro 6.8: Métricas de validación del período 2012→2017.

Métricas de píxel		Figure of Merit	
Accuracy	0,750	FoM	0,345
IoU	0,652	Hits (<i>B</i>)	602,889
Precision	0,688	Falsas alarmas (<i>A</i>)	937,345
Recall	0,925	Omisiones (<i>C</i>)	205,308
F1	0,789	TP / FP / FN	2,532,942 / 1,147,725 / 205,308
κ	0,499	Crec. obs. / pred.	+27,9 % / +71,9 %




Figura 6.5: Validación quinquenal 2012–2017. FoM = 0,345; período con crecimiento observado positivo (+27,9 %) y FoM numéricamente superior al de la ventana 2011–2016 bajo el mismo protocolo. Los 602,889 hits (*B*) corresponden a píxeles donde tanto el modelo como la observación registran transición a urbano en el período, asociados a la expansión perimetral visible en el mapa binario.

6.5.4. Período 2013–2018

La Tabla 6.9 y la Figura 6.6 resumen el período, que alcanza un FoM de 0,355, el más alto hasta aquí, en un contexto de expansión sostenida hacia el norte y el este.

Cuadro 6.9: Métricas de validación del período 2013→2018.

Métricas de píxel		Figure of Merit	
Accuracy	0,744	FoM	0,355
IoU	0,648	Hits (<i>B</i>)	641,089
Precision	0,689	Falsas alarmas (<i>A</i>)	934,924
Recall	0,917	Omisiones (<i>C</i>)	231,317
F1	0,787	TP / FP / FN	2,559,805 / 1,156,835 / 231,317
κ	0,482	Crec. obs. / pred.	+30,4 % / +73,6 %




Figura 6.6: Validación quinquenal 2013–2018. FoM = 0,355; valor numéricamente cercano al del período 2012–2017 en un contexto análogo de crecimiento observado positivo. El número de omisiones (231,317 píxeles) sugiere que parte de la expansión hacia el norte y el este no queda recogida en la predicción bajo este experimento.

6.5.5. Período 2014–2019

Este período se aparta de la tendencia: la Tabla 6.10 registra un FoM de 0,287 y la Figura 6.7 deja ver el desajuste entre un crecimiento real modesto y una predicción de expansión más amplia.

Cuadro 6.10: Métricas de validación del período 2014→2019.

Métricas de píxel		Figure of Merit	
Accuracy	0,697	FoM	0,287
IoU	0,614	Hits (<i>B</i>)	511,475
Precision	0,628	Falsas alarmas (<i>A</i>)	1,176,288
Recall	0,965	Omisiones (<i>C</i>)	93,486
F1	0,761	TP / FP / FN	2,611,594 / 1,545,800 / 93,486
κ	0,396	Crec. obs. / pred.	+9,5 % / +68,3 %




Figura 6.7: Validación quinquenal 2014–2019. FoM = 0,287; el crecimiento real modesto (+9,5 %) contrasta con una predicción de expansión más elevada (+68,3 %), lo que se refleja en la proporción de falsas alarmas (1,176,288 píxeles). El Recall alto (0,965) indica que el modelo asigna clase urbana de forma amplia respecto al mapa observado en 2019.

6.5.6. Período 2015–2020

La última ventana es la de mejor desempeño. La Tabla 6.11 consigna un FoM de 0,378 y la Figura 6.8 muestra el mayor número de aciertos de toda la serie, en un año de fuerte crecimiento observado.

Cuadro 6.11: Métricas de validación del período 2015→2020.

Métricas de píxel			Figure of Merit	
Accuracy	0,755	FoM	0,378	
IoU	0,669	Hits (<i>B</i>)	704,983	
Precision	0,701	Falsas alarmas (<i>A</i>)	977,214	
Recall	0,936	Omisiones (<i>C</i>)	181,887	
F1	0,802	TP / FP / FN	2,682,235 / 1,145,318 / 181,887	
κ	0,498	Crec. obs. / pred.	+33,5 % / +78,4 %	




Figura 6.8: Validación quinquenal 2015–2020. FoM = 0,378; entre las cinco ventanas es el valor de FoM numéricamente más alto, en un contexto de fuerte crecimiento observado (+33,5 %). Se registran 704,983 hits y, en términos relativos a este conjunto de corridas, una menor proporción de falsas alarmas que en otras ventanas.

6.6. Análisis espacial del error del modelo




Figura 6.9: Mapa de error para la ventana 2015→2020 (mejor desempeño, $FoM = 0,378$). Las celdas verdes (B) son aciertos —transiciones correctamente predichas—; las ámbar (A) son falsas alarmas; las rojas (C) son omisiones. Solo las celdas en transición entran al cálculo del FoM; las permanencias urbanas y no urbanas aparecen en gris.

Complementando la evaluación cuantitativa, esta sección examina las fuentes de error identificadas en el proceso de simulación y analiza cualitativamente los patrones morfológicos de las predicciones, con el fin de orientar las extensiones metodológicas propuestas en las conclusiones.

6.6.1. Fuentes de error identificadas

El análisis conjunto de los cinco períodos revela tres fuentes principales de error que se propagan desde la clasificación de imágenes hasta la simulación:

Error de clasificación de imágenes

El pipeline de clasificación no supervisada (K-Means + SVM) reporta una concordancia interna de 88–94 % con las pseudoetiquetas en el conjunto de prueba holdout (20 % de los píxeles),

según se describe en el Capítulo 5. Con una imagen de 5,4 millones de píxeles, incluso un 5–10 % de error equivale a 270,000–540,000 píxeles mal clasificados por imagen. Estos errores se manifiestan como confusión espectral (suelo desnudo o techos claros clasificados como urbano) e inconsistencias temporales que introducen “transiciones” espurias en el historial WoE.

Propagación en transiciones históricas

El cálculo de WoE se basa en las transiciones históricas observadas. Los errores de clasificación distorsionan las probabilidades WoE, y el efecto se acumula a lo largo de los 26 años de datos de entrenamiento.

Amplificación en el autómata celular

El AC amplifica errores iniciales: una celda mal clasificada como urbana actúa como “semilla” de crecimiento y genera falsas alarmas en cascada mediante el efecto de vecindad.

Cuadro 6.12: Estimación cualitativa de la contribución de fuentes de error (no cuantificada empíricamente)

Fuente de error	Contribución relativa estimada
Error de clasificación directa (K-Means+SVM)	Alta
Propagación de errores en el historial WoE	Moderada
Amplificación AC (efecto de vecindad cascada)	Alta

Nota metodológica: la tabla anterior refleja una estimación *cualitativa* basada en el análisis del comportamiento del modelo y no un desglose cuantificado de forma empírica. Una cuantificación precisa de la contribución de cada fuente de error requeriría mapas de referencia externos (verdad terreno) para cada año, los cuales no están disponibles para la serie completa 1984–2020.

6.6.2. Análisis morfológico de la predicción

El análisis morfológico cualitativo de los mapas generados muestra que el modelo reproduce patrones estructurales del crecimiento urbano coherentes con el observado: la expansión se concentra en los bordes de áreas ya urbanizadas (mecanismo de difusión), con presencia de fragmentación periférica. El mapa predicho para 2020 tiene un número de celdas urbanizadas mayor al observado (sobre-predicción sistemática), pero la distribución espacial del crecimiento sigue el mismo patrón de contigüidad que el real.

El cálculo formal de métricas de paisaje (FRAGSTATS, Moran’s I) requeriría la ejecución de análisis específicos sobre los mapas predicho y observado. Los archivos de mapa predicho están

disponibles, por ejemplo, en `data/processed/validation_quinquenal_2015_2020_v3_weighted/predicted_2020.npy`, para verificación independiente.

Para la planificación urbana a escala metropolitana, la reproducción cualitativa de los patrones de difusión contigua puede ser tan relevante como la concordancia píxel a píxel en las transiciones, que es lo que el FoM evalúa específicamente y que en este trabajo alcanza un promedio de 0,317.

6.6.3. Fortalezas y debilidades del modelo

Fortalezas identificadas

El modelo exhibe consistencia espacial: las predicciones concentran el crecimiento en los bordes de las áreas urbanas existentes, de forma coherente con el patrón de difusión observado. Su FoM promedio de 0,317 (promedio de los cinco archivos `validation_results.json`) se interpreta frente al espectro multi-sitio documentado por Pontius Jr et al. (2008) (Capítulo 3). El Recall se mantiene superior a 0,91 en todos los períodos, de modo que el modelo recoge la mayor parte de la urbanización real. A esa cobertura se suma su fidelidad morfológica: las comparaciones visuales entre mapas predichos y observados (figuras `summary_XXXX_to_XXXX.png` de cada período) muestran que el crecimiento predicho se concentra consistentemente en los bordes del área urbana existente y reproduce el patrón de difusión contigua observado en los cinco períodos. El enfoque es, además, parsimonioso: siete variables espaciales derivadas del mapa binario –distancia a área urbana, densidades de vecindad $3\times3/5\times5/7\times7$, fragmentación local, gradiente urbano y tamaño de *cluster*– bastan para alcanzar estas métricas sin recurrir a datos socioeconómicos externos.

Debilidades identificadas

Las debilidades parten de una sobre-predicción sistemática: en todos los períodos el crecimiento predicho supera al observado por un factor de entre 2 y 8 veces. Asociada a ella, la *Precision* se mantiene moderada, entre 0,59 y 0,70, lo que indica que muchas predicciones de transición son falsas alarmas. El crecimiento disperso queda sin modelar: el mecanismo de vecindad no captura el desarrollo tipo *leapfrog*. A ello se añade el peso de las variables externas, pues la omisión de factores socioeconómicos o de infraestructura (p. ej. distancia a empleo, precio del suelo) limita la precisión más allá de las siete variables derivadas del mapa binario.

6.6.4. Validación de hipótesis

A continuación se contrasta cada una de las seis hipótesis enunciadas en el Capítulo 1 con la evidencia empírica obtenida en los cinco períodos de validación. Cada hipótesis se reproduce de forma literal (entre comillas) antes de su contraste. El cuadro resumen consolidado se presenta en el Capítulo 7.

H1 (apoyada por la evidencia). «*La integración de WoE como función de transición empírica del AC produce simulaciones con FoM superior a 0,15 en las cinco ventanas de validación quinquenal.*» El criterio se cumple: el FoM se mantiene en el intervalo [0,222, 0,378] en los cinco períodos (Tabla 6.5), con un promedio de 0,317, Accuracy promedio de 0,722 y Kappa promedio de 0,445. Esa magnitud se ubica en una **banda intermedia** respecto al espectro empírico multi-sitio resumido en el Capítulo 3 con base en Pontius Jr et al. (2008).

H2 (apoyada por la evidencia). «*En el espacio de parámetros (umbral de transición, peso de vecindad) existe un óptimo no trivial: la configuración calibrada por búsqueda sistemática supera a una configuración por omisión sin calibrar en el FoM medio de las cinco ventanas, y los umbrales por debajo del calibrado degradan el desempeño por sobre-predicción.*» La configuración calibrada (umbral 0,75, peso de vecindad 0,50 y ponderación por IV) produjo FoM en el intervalo [0,222, 0,378] a lo largo de las cinco ventanas, sin reentrenar el WoE por período. El contraste documentado en el repositorio con configuraciones preliminares, en particular un experimento exploratorio con umbral cercano a 0,60 que generaba sobre-predicción masiva (FoM del orden de 0,17), sostiene la mejora atribuida a la calibración adoptada.

H3 (apoyada por la evidencia). «*Entre las siete variables espaciales evaluadas, las que cuantifican la proximidad al frente urbano y la densidad de vecindad concentran el mayor Information Value (IV), por encima de las variables de fragmentación y de gradiente.*» Las variables de distancia al área urbana y de densidad de vecindad concentran cerca del 75 % del *Information Value* (Tabla 6.2), por encima de la fragmentación local y del gradiente. La relación monotónica creciente entre el WoE y la densidad de vecindad (Figura 6.2) reproduce sobre los datos de Querétaro el patrón de difusión por contagio espacial descrito en la literatura.

H4 (apoyada de forma parcial). «*El modelo mantiene FoM y Kappa estables a lo largo de las cinco ventanas quinquenales, con mayor variación en los períodos donde la extensión de nueva área urbana observada es pequeña.*» El comportamiento morfológico es estable (los patrones de expansión perimetral se reproducen en todos los períodos), pero las métricas pixel-exactas muestran sensibilidad a la dinámica observada: el FoM varía entre 0,222 y 0,378 según el crecimiento neto del período, y el valor más bajo (2011–2016) coincide con la ventana de menor crecimiento neto observado. La omisión del crecimiento disperso (*leapfrog*), reconocida más

adelante como debilidad del modelo, es la principal fuente de degradación pixel-exacta detectada.

H5 (apoyada por la evidencia). «*Restringir la función de transición a siete variables auditables (un modelo de caja blanca) mantiene el FoM medio dentro de la banda intermedia del espectro multi-sitio de Pontius Jr et al. (2008), por encima del subconjunto de aplicaciones con FoM inferior a 0,15, sin recurrir a las representaciones no interpretables propias de los modelos de caja negra (Almeida et al., 2008; García-Ramírez et al., 2023).*» El FoM promedio de 0,317 y el IoU promedio de 0,633 se ubican en esa banda intermedia, por encima del subconjunto con FoM inferior a 0,15, manteniendo pesos auditables (vía *Information Value*) con solo siete variables derivadas del mapa binario. La restricción a un modelo interpretable no hundió el desempeño por debajo de la banda, por lo que la hipótesis se considera apoyada; el contraste con los modelos de caja negra es, eso sí, cualitativo (sitios, clases y horizontes temporales distintos) y no un experimento directo sobre el mismo conjunto de datos.

H6 (apoyada por la evidencia). «*El pipeline completo, desde la adquisición de imágenes hasta la validación quinquenal, se ejecuta en una CPU estándar en un tiempo del orden de horas, sin requerir GPU, software propietario ni hardware especializado.*» Todo el flujo se implementó en Python (NumPy, SciPy, scikit-learn) sobre imágenes de archivo de Google Earth, sin software propietario ni GPU, con un cómputo del orden de horas en una CPU estándar.

6.6.5. Síntesis del desempeño del modelo

Vistas en conjunto, las cinco ventanas dibujan un comportamiento consistente más que un resultado aislado. El FoM se mantiene en una banda intermedia (promedio 0,317, entre 0,222 y 0,378) y el Recall alto en todos los períodos indica que el modelo rara vez deja fuera la urbanización que sí ocurre. El costo de esa cobertura es una sobre-predicción sistemática: el crecimiento simulado supera al observado y la *Precision* se queda en un rango moderado. En otras palabras, el modelo opera en un régimen de alta cobertura predictiva y baja especificidad relativa: acierta dónde crece la ciudad, pero tiende a hacerla crecer de más. Este comportamiento es propagación conservadora en términos de omisión y expansiva en términos de falsos positivos, consecuencia de un campo de probabilidad WoE que favorece la expansión continua del estado urbano ante vecindades parcialmente urbanizadas.

Ese patrón es coherente con la lectura de los pesos WoE. La distancia al área urbana y la densidad de vecindad concentran cerca del 75 % del *Information Value*, de modo que la señal que gobierna la simulación es la difusión por contigüidad. Ahí está, a la vez, la fortaleza y el límite del enfoque: como es un modelo de caja blanca, se puede leer qué lo mueve; pero al apoyarse solo en variables derivadas del propio mapa binario, no captura el desarrollo disperso ni los factores

socioeconómicos que explican parte del crecimiento real. La validación multi-período, más que un número único, es lo que da solidez a esta lectura, porque muestra que el comportamiento se sostiene bajo distintas dinámicas observadas. En términos dinámicos, el sistema no converge a un estado estacionario único, sino que sus trayectorias dependen del estado inicial y se organizan en torno a atractores espaciales locales (los núcleos urbanos consolidados y los corredores de crecimiento) que persisten a lo largo de las cinco simulaciones quinquenales.

Estos resultados son el insumo del capítulo siguiente, donde se consolidan las hipótesis en un cuadro único, se precisan las contribuciones del trabajo y se discuten las líneas para corregir las debilidades aquí identificadas, en particular la sobre-predicción y el crecimiento tipo *leapfrog*.

Capítulo 7

Conclusiones

Este capítulo sintetiza los hallazgos de la investigación, discute las implicaciones para la planificación urbana, identifica las limitaciones del modelo y propone direcciones de trabajo futuro. Se presentan las respuestas a las preguntas de investigación, la validación de hipótesis y las aportaciones del trabajo al campo del modelado urbano, a la luz de los resultados de la validación quinquenal múltiple (cinco períodos, 2011–2020).

7.1. Principales hallazgos

Esta sección sintetiza los resultados centrales de la investigación, presenta las respuestas a las preguntas formuladas en el Capítulo 1 y evalúa el estado de cada hipótesis a la luz de la validación quinquenal múltiple sobre cinco períodos independientes.

7.1.1. Síntesis de la investigación

Esta investigación abordó el problema de modelar el crecimiento urbano de Querétaro (1984–2020) mediante la integración de tres metodologías complementarias: **Weight of Evidence (WoE)** para cuantificar empíricamente la evidencia espacial, **Autómatas Celulares (AC)** para simular dinámicas espaciales locales y una estrategia de **calibración sistemática** para el ajuste de parámetros. La validación quinquenal múltiple sobre cinco períodos independientes (2011–2016, 2012–2017, 2013–2018, 2014–2019 y 2015–2020) sugiere que la metodología WoE-AC, bajo las condiciones de datos y calibración descritas en los capítulos anteriores, presenta varios rasgos consistentes. El *pipeline* LBP+K-Means+SVM clasifica de manera automática las 37 capturas RGB anuales (1984–2020) en mapas binarios urbano/no-urbano, con *accuracy* interno de 88–94 % en el conjunto de prueba. Sobre esa base, el WoE cuantifica empíricamente la evidencia

espacial a partir de las transiciones históricas observadas en 26 años de datos (1984–2010). El modelo obtiene un **FoM promedio de 0,317** sobre cinco períodos de validación independientes, calculado como promedio de los archivos `validation_results.json` en `data/processed/validation_quinquenal_*_v3_weighted/`, equivalente a aproximadamente 31,7 % en la escala porcentual usada por Pontius Jr et al. (2008); interpretado frente al espectro empírico multi-sitio de ese estudio (seis aplicaciones con FoM inferior al 15 % y una sola por encima del 50 %), el resultado se ubica en una **banda intermedia** de dicho marco (Capítulo 3), utilizando únicamente siete variables espaciales derivadas del mapa binario. En conjunto, reproduce los patrones de expansión urbana con *Accuracy* promedio de 0,722, Kappa promedio de 0,445 y FoM promedio de 0,317, y captura el mecanismo de difusión por contagio espacial perimetral de forma coherente con los patrones observados.

7.1.2. Respuestas a las preguntas de investigación

P1: Mejora mediante calibración sistemática

La búsqueda sistemática en cuadrícula y el ajuste manual del umbral, documentados en `quinquenal_best_config.json`, definen la configuración utilizada en los cinco experimentos de validación quinquenal. Los FoM reportados en cada archivo `validation_results.json` (0,222–0,378; promedio 0,317) constituyen la evidencia cuantitativa principal del trabajo. Ensayos preliminares con otras configuraciones (en particular un experimento exploratorio con sobrepredicción masiva y FoM del orden de 0,17, con magnitudes de falsas alarmas del orden de 10^6 píxeles) motivaron el umbral 0,75 y la ponderación por IV finalmente adoptados. No se conserva en el repositorio una tabla A/B período a período contra parámetros puramente heurísticos; la comparación favorable frente a las configuraciones preliminares se sustenta en la trazabilidad de los archivos del repositorio y en la estabilidad de las métricas observada en las cinco ventanas temporales. La integración del WoE como función de transición probabilística incorpora, además, relaciones empíricas no lineales entre vecindad y transición, sin supuestos paramétricos previos sobre la forma funcional.

P2: Configuración adoptada para la validación

La configuración registrada en `quinquenal_best_config.json` (umbral $\theta = 0,75$, peso de vecindad $\alpha = 0,50$ y pesos WoE normalizados por IV) es la empleada en los cinco períodos de validación independientes, en los que se observa un FoM promedio de 0,317 y un Kappa promedio de 0,445 (idénticos a los promedios reportados en la Tabla 6.5 del Capítulo 6), sin reentrenar el WoE por período.

P3: Variables con mayor influencia

El análisis del *Information Value* muestra que las variables **distancia al área urbana** y **densidad de vecindad** (en tres radios) concentran cerca del 75 % del poder predictivo (IV combinado de 0,775 sobre un total normalizado de 1,000), lectura coherente con el mecanismo de difusión por contagio espacial descrito en la literatura de expansión urbana. Los pesos IV provienen directamente de `quinquenal_best_config.json`.

P4: Robustez temporal del modelo

El FoM varía entre 0,222 y 0,378 en función de la dinámica de crecimiento observada en cada período, con valores más altos cuando el crecimiento real observado es positivo y sostenido (períodos 2012–2017, 2013–2018 y 2015–2020). Conviene distinguir dos fuentes de esa variación: por un lado, las diferencias en la magnitud del crecimiento real entre períodos; por otro, una sensibilidad real del desempeño a la calidad de la clasificación binaria y al bajo crecimiento neto, que se hace evidente en 2011–2016. El valor más bajo (FoM 0,222) debe leerse, por tanto, como el límite inferior del desempeño del modelo bajo condiciones de baja señal de cambio, y no minimizarse: el modelo es estable en su comportamiento morfológico, pero sus métricas píxel a píxel sí dependen de la dinámica observada y del ruido del clasificador.

7.1.3. Cumplimiento de los objetivos específicos

Los cinco objetivos específicos planteados en el Capítulo 1 se cumplieron del modo que se describe a continuación. El primero (OE1) condujo a la **serie histórica binaria**: se construyó la serie anual 1984–2020 (37 mapas urbano/no-urbano) a partir de imágenes de archivo de Google Earth, con clasificación no supervisada LBP+K-Means+SVM y sin software propietario (Capítulo 4). El segundo (OE2) abordó las **variables espaciales y el WoE**: se calcularon las siete variables derivadas del mapa binario y se adoptó el WoE como función de transición por su descomposición auditable mediante el *Information Value* (Capítulos 5 y 6). El tercero (OE3) corresponde al **diseño e implementación del WoE-AC**: se implementó el autómata celular que simula la transición no urbano → urbano sobre la ZMQ (Capítulo 5). El cuarto (OE4) cubrió la **calibración y el protocolo de validación**: se calibraron umbral y peso de vecindad por búsqueda en cuadrícula y se validó el modelo en cinco ventanas quinquenales independientes con FoM, Kappa e IoU (Capítulo 6). El quinto (OE5) atendió la **estabilidad temporal y el posicionamiento**: se analizó la estabilidad del desempeño a lo largo de los cinco períodos y se contrastaron los valores de FoM e IoU con los rangos de la literatura de modelos de caja blanca y de caja negra (Capítulos 6 y 3).

7.1.4. Validación de hipótesis

Cuadro 7.1: Resumen de validación de hipótesis

Hip.	Enunciado (Cap. 1)	Estado	Evidencia
H1	La integración de WoE como función de transición empírica del AC produce simulaciones con FoM superior a 0,15 en las cinco ventanas de validación quinquenal (Capítulo 1).	Confirmada	FoM entre 0,222 y 0,378, por encima de 0,15 en las cinco ventanas, en banda intermedia del espectro multi-sitio de Pontius Jr et al. (2008) (Cap. 3); Kappa promedio de 0,445.
H2	En el espacio de parámetros (umbral de transición, peso de vecindad) existe un óptimo no trivial: la configuración calibrada por búsqueda sistemática supera a una configuración por omisión sin calibrar en el FoM medio de las cinco ventanas, y los umbrales por debajo del calibrado degradan el desempeño por sobre-predicción.	Confirmada	FoM medio 0,317 (0,222–0,378 en cinco períodos) frente a una configuración exploratoria previa (FoM $\approx$ 0,17) registrada en el repositorio.
H3	Entre las siete variables espaciales evaluadas, las que cuantifican la proximidad al frente urbano y la densidad de vecindad concentran el mayor Information Value (IV), por encima de las variables de fragmentación y de gradiente.	Confirmada	IV concentrado en distancia al área urbana y densidad de vecindad (en torno al 75 %), por encima de fragmentación y gradiente (Sección WoE, Capítulo 6).

Hip.	Enunciado (Cap. 1)	Estado	Evidencia
H4	El modelo mantiene FoM y Kappa estables a lo largo de las cinco ventanas quinquenales, con mayor variación en los períodos donde la extensión de nueva área urbana observada es pequeña.	Confirmada parcialmente	FoM 0,222–0,378 según el período; el valor más bajo (2011–2016) coincide con la ventana de menor crecimiento neto observado (Capítulo 6).
H5	Restringir la función de transición a siete variables auditables (un modelo de caja blanca) mantiene el FoM medio dentro de la banda intermedia del espectro multisitio de Pontius Jr et al. (2008), por encima del subconjunto con FoM inferior a 0,15, sin recurrir a las representaciones no interpretables propias de los modelos de caja negra.	Confirmada	FoM promedio 0,317 e IoU promedio 0,633 en esa banda intermedia, por encima del subconjunto con FoM inferior a 0,15, con pesos auditables (IV) y solo siete variables; la restricción a un modelo interpretable no hundió el desempeño. El contraste con caja negra es cualitativo (sitios y horizontes distintos), no directo.
H6	El pipeline completo, desde la adquisición de imágenes hasta la validación quinquenal, se ejecuta en una CPU estándar en un tiempo del orden de horas, sin requerir GPU, software propietario ni hardware especializado.	Confirmada	Implementación íntegra en Python (NumPy, SciPy, scikit-learn) sobre imágenes de Google Earth; el cómputo se mantiene del orden de tres horas en CPU estándar, sin GPU (Sección 7.2.3 y Tabla 7.3).

7.1.5. Aportaciones del trabajo

Conviene precisarlo sin sobrevender: el uso del Weight of Evidence y del autómatas celular no constituye, por sí mismo, una novedad metodológica, pues ambos están ampliamente documentados en la literatura. La aportación central de esta investigación reside en el **protocolo de**

evaluación: el acoplamiento WoE-AC **calibrado y validado de forma reproducible sobre cinco ventanas temporales independientes**, con código y datos de acceso libre, aplicado a una ciudad intermedia mexicana poco estudiada. El WoE se incorpora como un campo probabilístico continuo ponderado por el *Information Value*, pero el valor diferenciador está en poder distinguir un desempeño estable de un ajuste a un único período. De esa aportación principal se derivan varias contribuciones específicas. La primera es el **protocolo de validación quinquenal múltiple**, de carácter *metodológico*: la evaluación sobre cinco períodos independientes (2011–2020) con métricas píxel a píxel (FoM, Kappa, IoU) y análisis visual comparativo de patrones morfológicos evalúa la estabilidad temporal del modelo con mayor rigor que la validación en un único período, y es la aportación que sostiene las demás. La segunda, de orden *práctico*, es la **reproducibilidad abierta del pipeline**: un sistema modular en Python que transforma capturas RGB en mapas binarios y en proyecciones de crecimiento urbano (clasificación híbrida, WoE, AC y evaluación), ejecutable con herramientas de código abierto y datos de acceso libre, documentado y publicado. La tercera, también *metodológica*, es el **campo WoE continuo ponderado por Information Value**: una formulación en la que la idoneidad WoE no es un mapa estático, sino un campo probabilístico ponderado por el *Information Value* normalizado de cada variable, que se recalcula en cada paso sobre el estado actualizado del mapa y se acopla a la vecindad de Moore mediante una regla auditable. La cuarta, de naturaleza *metodológica*, es la **aplicación a una ciudad intermedia mexicana**: la adaptación del enfoque WoE-AC al contexto de la Zona Metropolitana de Querétaro, un caso poco estudiado y sin un *benchmark* comparable previo. La quinta, de carácter *empírico*, es la **serie temporal de Querétaro**: un conjunto de datos procesado de 37 años (1984–2020) de mapas binarios urbano/no-urbano, que puede utilizarse como base para investigaciones futuras en la región. La sexta, igualmente *empírica*, es el **posicionamiento frente a la literatura**: el contraste del modelo WoE-AC con estudios internacionales mediante métricas estandarizadas (FoM, IoU), que contextualiza los resultados en el espectro empírico multi-sitio de Pontius Jr et al. (2008).

7.2. Implicaciones para la planificación urbana

Los resultados de la validación sugieren que el modelo puede apoyar la exploración morfológica de escenarios de expansión urbana, sin sustituir los estudios con verdad terreno ni la formulación de política pública calibrada. Bajo esa lectura, esta sección discute las aplicaciones potenciales, los escenarios de política pública conceptualmente simulables y las condiciones de transferibilidad a otras ciudades intermedias mexicanas.

7.2.1. Herramientas para decisión informada

Los resultados sugieren una aplicabilidad potencial en la planificación urbana metropolitana, siempre en un plano hipotético y sujeto a recalibración y validación local previas. Bajo esa salvedad, el modelo podría apoyar distintas tareas. Una sería la **provisión anticipada de infraestructura**: identificar zonas con alta probabilidad de transición a urbano según el modelo WoE-AC, para extender redes de agua, drenaje y electricidad antes de que se materialice la demanda. Otra es la **reserva de suelo para espacios públicos**, esto es, adquirir terrenos en áreas pre-urbanización para parques, equipamiento comunitario y zonas de amortiguamiento ambiental. Una tercera es la **zonificación proactiva**: definir usos de suelo permitidos antes de que la presión inmobiliaria haga inviable la planificación reactiva. La cuarta es la **evaluación de impacto ambiental**, orientada a identificar áreas ecológicamente sensibles en la trayectoria de expansión urbana proyectada.

7.2.2. Escenarios de política pública

La estructura del modelo admite simular, de forma conceptual, el impacto de distintas intervenciones de política urbana. A partir del estado calibrado, pueden proyectarse escenarios alternativos ajustando los parámetros del AC, como se ilustra de manera cualitativa en la Tabla 7.2:

Cuadro 7.2: Escenarios de política pública *conceptualmente* simulables con el modelo WoE-AC mediante ajuste de parámetros o máscaras de probabilidad. Las direcciones de efecto son cualitativas; **este trabajo no calibró corridas contrafactuales por política** ni cuantificó impactos en métricas de dispersión para Querétaro.

Política	Implementación en el modelo (ejemplos)	Efecto esperado (cualitativo)
Tendencial (BAU)	Sin cambios de parámetros	Línea base de referencia
Densificación	Aumentar peso WoE en zonas intraurbanas predefinidas	Reducción esperada de expansión periférica relativa al BAU
Contención urbana	Reducir probabilidad de transición en anillo exterior	Menor crecimiento en borde; mayor presión intraurbano
Corredores TOD	Amplificar probabilidad a lo largo de ejes de transporte prioritarios	Crecimiento más concentrado en corredores

7.2.3. Accesibilidad computacional

El pipeline completo (clasificación + WoE + simulación + validación) se ejecuta en aproximadamente 3 horas en CPU estándar, sin requerir GPU. Esto lo distingue de enfoques de aprendizaje profundo que típicamente necesitan hardware especializado y tiempos de entrenamiento mayores (Ma et al., 2019). La Tabla 7.3 resume las características operativas del enfoque adoptado en comparación con modelos de aprendizaje profundo.

Cuadro 7.3: Características operativas del enfoque WoE-AC frente a modelos de aprendizaje profundo

Característica	WoE-AC (este trabajo)	Aprendizaje profundo
Datos de entrenamiento requeridos	Series multitemporales locales (en este trabajo, 26 transiciones anuales agregadas por <i>pooling</i>).	Conjuntos de datos etiquetados a gran escala, habitualmente con decenas de imágenes anotadas.
Hardware mínimo	CPU estándar.	GPU recomendada.
Interpretabilidad de resultados	Alta (pesos WoE explicables).	Baja (modelo de caja negra).
Tiempo de ejecución	Del orden de tres horas en CPU.	Del orden de ocho a doce horas o más en GPU.
Transferibilidad	Requiere recalibración WoE.	Requiere reentrenamiento.

7.2.4. Relevancia para ciudades intermedias mexicanas

Los hallazgos son **potencialmente transferibles** a ciudades mexicanas con características similares a Querétaro: población del orden de 500,000 a 2,000,000 de habitantes, economía industrial y de servicios, tasas de crecimiento sostenidas y topografía de valle. Ciudades como León, Aguascalientes, San Luis Potosí, Saltillo o Hermosillo son candidatas razonables para una réplica metodológica, siempre que se recalibre el modelo WoE con los datos locales correspondientes y se verifique empíricamente su desempeño antes de utilizarlo con fines de planificación.

El protocolo de aplicación que se desprende de este trabajo es el siguiente: (1) construir una serie anual de imágenes con la misma extensión geográfica para el área objetivo (en este trabajo se utilizó Google Earth en modo *imagen histórica*); (2) generar la clasificación binaria urbano/no-urbano con un *pipeline* reproducible; (3) calcular el WoE con las transiciones históricas locales; (4) calibrar los parámetros del AC con los datos del área objetivo; y (5) ejecutar la simulación y la evaluación con métricas espaciales estándar. El cómputo propiamente dicho (clasificación, WoE, simulación y validación) se mantiene del orden de tres horas en CPU estándar, como se indicó arriba; el tiempo de calendario total de una réplica completa es mayor, principalmente

por la adquisición manual de imágenes y por la revisión visual de la serie, y se sitúa en una ventana de trabajo de algunos días a una semana.

7.3. Limitaciones del modelo

El rigor académico exige reconocer los límites del enfoque adoptado. Esta sección describe las limitaciones conceptuales, empíricas y de transferibilidad del modelo, e identifica las extensiones metodológicas que permitirían superarlas en investigaciones futuras.

7.3.1. Limitaciones conceptuales

En el plano conceptual, la primera limitación atañe a la **definición operativa de “urbano”**. El clasificador K-Means+SVM, al operar sobre imágenes RGB sin banda infrarroja, aprende a separar zonas con cubierta vegetal verde de zonas sin ella. La clase “urbano” incluye, por tanto, tejido urbano real pero también suelo desnudo agrícola en temporada seca y superficies áridas. Una clasificación más precisa requeriría imágenes con banda NIR para calcular NDVI real, o muestras de campo geolocalizadas como ground truth. Esta limitación no invalida la validación interna del modelo (que evalúa la consistencia predictiva dentro de la misma clasificación), pero sí acota la interpretación de los resultados en términos de área urbana absoluta. Una segunda limitación es el **vecindario estático**: el vecindario de Moore (3×3 píxeles) captura interacciones locales pero puede ser insuficiente para modelar influencias de largo alcance como distancia a centros de empleo o nodos de transporte. A ella se suma la **ausencia de retroalimentación dinámica**, ya que las variables explicativas (densidad de vecindad) no se actualizan durante la simulación en respuesta al crecimiento predicho, lo que reduce el realismo en simulaciones de largo plazo. Por último, la **asunción de estacionariedad**: las relaciones WoE calibradas con datos de 1984–2010 se asumen válidas en las cinco ventanas de validación posteriores, supuesto que puede no sostenerse ante transformaciones económicas o políticas disruptivas.

7.3.2. Limitaciones empíricas

En el plano empírico, la primera limitación se relaciona con la **calidad de los datos**: la clasificación no supervisada (K-Means + SVM) tiene una *accuracy* interna del 88 al 94 %, lo que equivale a un error nominal del 6 al 12 % por imagen (del orden de 325,000 a 650,000 píxeles sobre $5,4 \times 10^6$). Estos errores se propagan al cálculo WoE y pueden amplificarse en la simulación del AC mediante el efecto de vecindad. La segunda es la **resolución espectral**: las imágenes contienen únicamente bandas RGB, sin información infrarroja, y el índice de vegetación aproximado $(G - R)/(G + R)$ es menos discriminativo que el NDVI real $(NIR - R)/(NIR + R)$. La tercera concierne

a las **variables internas**: el modelo usa 7 variables espaciales derivadas del propio mapa binario (densidades, distancias, fragmentación, gradiente) y no incorpora variables externas potencialmente relevantes como distancia a vialidades, pendiente topográfica, zonificación oficial o variables socioeconómicas. La cuarta es el **crecimiento disperso no modelado**: el mecanismo de difusión por vecindad no captura el desarrollo tipo leapfrog (saltos discontinuos de urbanización), que representa una fracción significativa del crecimiento real observado.

7.3.3. Limitaciones de transferibilidad

En cuanto a la transferibilidad, una primera limitación es la **especificidad contextual**: los pesos WoE son específicos al patrón histórico de Querétaro y requieren recalibración para su aplicación en otras ciudades. La segunda es la **dependencia de la resolución**: los resultados están ligados a la grilla de los mapas binarios derivada de las capturas homogeneizadas ($1,792 \times 3,024$ píxeles), de modo que modificar la extensión, el tamaño de celda o la fuente de imágenes implica reentrenar el WoE y recalibrar los parámetros del AC. La tercera es el **horizonte temporal**: la aplicabilidad del modelo para horizontes mayores a 15 años es incierta sin recalibración periódica, dado que las dinámicas urbanas pueden cambiar estructuralmente.

7.3.4. Trabajo futuro

Con base en las limitaciones identificadas, se proponen las siguientes extensiones prioritarias:

Corto plazo (1-2 años)

A corto plazo destacan tres líneas. La primera es la incorporación de **variables adicionales**: distancia a vialidades principales, distancia a centros de empleo y pendiente topográfica mediante análisis WoE multi-variable. La segunda es la **optimización metaheurística**, esto es, explorar metaheurísticas alternativas al grid exhaustivo (p. ej. optimización por enjambre de partículas o procedimientos bayesianos de búsqueda) para la calibración de parámetros, comparando su desempeño con el procedimiento empleado en esta investigación. La tercera es la **validación en más ciudades**: aplicar la metodología a Aguascalientes, León y San Luis Potosí para evaluar la transferibilidad geográfica.

Mediano plazo (3-5 años)

A mediano plazo se perfilan cuatro extensiones. El **WoE temporal** consistiría en desarrollar pesos que evolucionan dinámicamente para capturar cambios en las dinámicas de crecimiento a lo largo del tiempo. La **integración multi-escala** acoplaría el modelo AC con modelos económicos regionales que proporcionen demanda agregada de urbanización. Los **datos de**

movilidad permitirían incorporar patrones de origen-destino de viajes (disponibles vía telefonía móvil) como variable explicativa. La **calibración multiobjetivo**, por su parte, extendería el grid search para optimizar simultáneamente FoM, similitud morfológica y compacidad urbana como criterios de sostenibilidad.

Largo plazo (5-10 años)

A largo plazo, la **integración con cambio climático** adaptaría el modelo para incorporar escenarios de cambio climático (temperatura, precipitación) como restricciones o drivers de urbanización. El **transfer learning** buscaría desarrollar pre-entrenamiento en múltiples ciudades para reducir los datos requeridos en nuevas aplicaciones. Finalmente, las **métricas complementarias de validación** pasarían por adoptar de forma sistemática métricas espaciales adicionales (FRAGSTATS, índice de Moran, *Fuzzy Accuracy*) para complementar las métricas píxel a píxel ya empleadas, en línea con buenas prácticas reconocidas en la literatura LUCC.

7.4. Mensaje central

El mensaje central de esta investigación es que **un modelo parsimonioso e interpretable, validado empíricamente en varios períodos independientes, puede reproducir de forma razonable la dinámica morfológica del crecimiento urbano y servir como herramienta de exploración**. Su utilidad para la planificación es indirecta: ofrece una primera lectura de hacia dónde tiende a expandirse la ciudad, no una predicción operativa lista para sustituir el análisis técnico, que exigiría recalibración local y validación adicional antes de cualquier uso real.

Los resultados del modelo WoE-AC apuntan en tres direcciones. Con siete variables espaciales derivadas del mapa binario y la serie de capturas RGB procesadas en el *pipeline* descrito, el FoM promedio de 0,317 sobre cinco períodos quinquenales independientes (archivos `validation_results.json`), equivalente a aproximadamente 31,7 % en la escala porcentual usada por Pontius Jr et al. (2008), se interpreta como un desempeño en **banda intermedia** respecto al espectro empírico multi-sitio resumido en el Capítulo 3, sin equiparar sitio ni modelo con aquella muestra. El mecanismo de difusión/contagio espacial se reproduce cualitativamente con razonable fidelidad: la expansión predicha se concentra en los bordes de áreas urbanas, coherente con los patrones observados, sin requerir variables socioeconómicas ni hardware especializado. Por último, la implementación en Python de acceso abierto hace que el pipeline sea reproducible y potencialmente transferible a otros contextos urbanos con características similares.

La presente investigación constituye un punto de partida documentado para el modelado de crecimiento urbano en ciudades intermedias mexicanas. Sus limitaciones (ausencia de variables socioeconómicas, datos RGB sin infrarrojo, clasificación binaria) señalan las extensiones prioritarias para trabajo futuro.

7.5. Palabras finales

El aporte concreto de este trabajo es un modelo WoE-AC para la Zona Metropolitana de Querétaro, construido sobre una serie de 37 años (1984–2020) de imágenes de acceso libre y evaluado con un protocolo de validación quinquenal reproducible. Ese protocolo, más que un valor de desempeño aislado, es lo que distingue la propuesta: permite separar un comportamiento espacial estable de un ajuste a un único período, en un contexto, las ciudades intermedias mexicanas, donde rara vez se documenta esa distinción.

La metodología desarrollada no es un fin en sí misma, sino una base reproducible, construida con datos de acceso libre y validada en cinco ventanas temporales, sobre la cual otros trabajos pueden mejorar la clasificación, incorporar variables socioeconómicas y extender la validación a otras ciudades intermedias mexicanas.

Apéndice A

Arquitectura e implementación del software

Este apéndice reúne los detalles de implementación del *framework* WoE-AC —el diagrama de clases y las rutas de los módulos en el repositorio— que complementan la descripción metodológica del Capítulo 4 sin recargar su narrativa. El repositorio organiza el trabajo en una arquitectura modular que integra la rasterización/clasificación de las capturas, el cálculo de Pesos de Evidencia y la simulación con autómatas celulares; la Figura A.1 muestra el diagrama de clases UML (generado con PlantUML; véase `diagramas/architecture.puml`).




Figura A.1: Arquitectura del framework WoE-AC para modelado de crecimiento urbano. Diagrama UML mostrando las clases del sistema organizadas en paquetes: Configuración (configuración), Data/IO (manejo de datos históricos), Feature & Spatial (extracción de características), Weight of Evidence (cálculo de pesos), Cellular Automaton (simulación AC) y Orchestrator (pipeline y calibración de parámetros). El diagrama se genera desde el código fuente usando PlantUML (ver diagramas/architecture.puml).

En la rama de **imágenes**, el flujo opera sobre matrices RGB ya homogeneizadas. El módulo FeatureExtractor (paquete tesis_ac/pipeline/feature_extraction) construye las 23 variables resumidas en la Tabla A.1. La clase FeaturePreprocessor aplica StandardScaler y PCA (ocho componentes por defecto). El componente SatelliteImageProcessor (nombre

heredado en el código; procesa matrices RGB de las capturas, véase `tesis_ac/pipeline/clustering.py`) agrupa `ImageClusterer` e `ImageClassifier`: K-means para $k \in \{2, 3, 4\}$ y SVM lineal entrenado con pseudoetiquetas. La varianza acumulada explicada por PCA se consulta con `get_variance_explained` del preprocesador. La orquestación de alto nivel está en `SatelliteImagePipeline` (`tesis_ac/pipeline/main\_pipeline.py`).

En la cadena **WoE-AC** usada en la validación quinquenal de la tesis intervienen `WoE Calculator`, `WoECellularAutomaton` y la simulación implementada en los módulos `tesis_ac/woe/` y `tesis_ac/ca/`. La configuración efectiva —umbral, peso de vecindad y ponderación por IV— se encuentra registrada en `data/processed/quinquenal\_best\_config.json`. Los experimentos son reproducibles desde la raíz del repositorio con los scripts `validate\_quinquenal\_*.py`, que leen los mapas en `data/processed/standardized\_maps/` y el modelo WoE entrenado `data/processed/woe\_pooled\_1984\_2010.pkl`; el entrenamiento agregado del WoE se obtiene con `train\_woe\_pooled.py`. El repositorio conserva, además, un pipeline experimental más amplio en `tesis_ac/run\_classify\_and\_grid.py`, que no forma parte de la narrativa defendida en esta tesis (la cual se centra en la búsqueda en cuadrícula y el ajuste manual del umbral descritos en el Capítulo 5).

A.1. Procedimiento de adquisición manual de imágenes

El conjunto de imágenes descrito en el Capítulo 4 se construyó con el procedimiento manual reproducible que resume el Algoritmo 5, sobre Google Earth en escritorio y su herramienta de imagen histórica.

Algorithm 5 Procedimiento de adquisición manual con Google Earth

- 1: Centrar el visor en la Zona Metropolitana de Querétaro y ajustar zoom, orientación y ángulo que se mantendrán fijos para toda la serie
 - 2: Para cada año y de 1984 a 2020:
 - 3: Abrir la herramienta de *imagen histórica* y seleccionar el año y
 - 4: Desplazarse dentro del año hasta una fecha con cobertura nubosa baja (criterio visual)
 - 5: Verificar que el encuadre coincide con el resto de la serie (sin desplazamientos accidentales)
 - 6: Exportar o capturar la imagen y guardarla con nomenclatura estandarizada (p. ej. YYYY.png)
 - 7: Revisar visualmente la continuidad de la serie (saltos bruscos, años atípicos) y repetir la captura solo cuando una escena resulte claramente inutilizable
-

A.2. Cuadros complementarios del conjunto de datos

El conjunto de imágenes descrito en el Capítulo 4 se complementa con tres cuadros de referencia: el detalle de las 23 características extraídas por píxel (Tabla A.1), la estimación cualitativa de las principales fuentes de error y su mitigación (Tabla A.2) y el resumen agregado del preprocesamiento aplicado a toda la serie (Tabla A.3).

Cuadro A.1: Características extraídas por píxel a partir de cada captura RGB.

Categoría	Cantidad	Características específicas
Básicas	8	Canales R, G, B; intensidad; brillo; desviación estándar de R, G y B.
Texturales	6	Sobel horizontal y vertical; magnitud del gradiente; LBP uniforme ($R = 3$, $P = 24$) sobre escala de grises; entropía local; contraste local.
Espectrales / color	9	Índice verde-rojo normalizado $(G - R)/(G + R)$; exceso de verde y exceso de rojo; componentes L, a, b (LAB); H, S, V (HSV).
Total	23	

Cuadro A.2: Estimación cualitativa de las principales fuentes de error del conjunto de imágenes, su efecto sobre los mapas binarios y su mitigación. Los niveles son apreciaciones del autor, no medidas formales de incertidumbre.

Tipo de error	Nivel	Efecto sobre los mapas	Mitigación aplicada
Georreferenciación / encuadre	Bajo-medio	Pequeños desplazamientos entre capturas por reposicionamiento manual del visor; desalineación píxel a píxel entre años.	Mismo zoom, orientación y región; ajuste a la cuadrícula de referencia en el preprocesamiento.
Temporal (fecha intra-anual)	Medio	La fecha exacta varía dentro de cada año; cambios fenológicos y estacionales alteran la respuesta de la vegetación.	Captura preferente en temporada seca (nov.-abr.) y revisión de continuidad de la serie.
Mosaico / composición del proveedor	Medio-alto	Google Earth actualiza mosaicos y mezcla fuentes y fechas; discontinuidades de textura y color no atribuibles a cambio real.	Revisión cruzada año con año y sustitución puntual de escenas claramente anómalas.
Cromático / radiométrico	Medio	Sin corrección atmosférica; diferencias de balance de color e iluminación que sesgan los índices de color (NGRDI).	Normalización y estandarización por imagen; descriptores de textura (LBP) robustos a la iluminación.
Compresión / exportación	Bajo-medio	Las capturas se exportan como imágenes comprimidas (JPEG/PNG); aparecen artefactos de bloque y suavizado de bordes que pueden alterar píxeles de frontera urbano/no-urbano.	Exportación a la máxima resolución disponible del visor y descriptores de textura locales menos sensibles al artefacto puntual.
Clasificación (LBP+K-Means+SVM)	Medio	Pseudoetiquetas no supervisadas, sin verdad terreno; ruido binario y sobre o subestimación local de lo urbano.	Validación interna <i>train/test</i> y evaluación temporal indirecta del modelo AC (Capítulo 6).

Cuadro A.3: Resumen agregado del preprocesamiento aplicado a la serie 1984–2020.

Métrica	Valor
Varianza retenida por PCA (promedio de la serie)	Cerca del 96 %.
Componentes finales por píxel	8 (a partir de los 23 descriptores originales).
Características válidas por imagen	23 de 23 (ningún descriptor se descarta).
Píxeles procesados por imagen	5,419,008 ($1,792 \times 3,024$).

Bibliografía

- Aburas, M. M., Ho, Y. M., Ramli, M. F., & Ash'aari, Z. H. (2016). The simulation and prediction of spatio-temporal urban growth trends using cellular automata models: A review. *International Journal of Applied Earth Observation and Geoinformation*, 52, 380-389. <https://doi.org/10.1016/j.jag.2016.07.007>
- Almeida, C. M., Gleriani, J. M., Castejon, E. F., & Soares-Filho, B. S. (2008). Using neural networks and cellular automata for modelling intra-urban land-use dynamics. *International Journal of Geographical Information Science*, 22(9), 943-963. <https://doi.org/10.1080/13658810701731168>
- Bonham-Carter, G. F. (1994). *Geographic Information Systems for Geoscientists: Modelling with GIS* (Vol. 13). Pergamon.
- Clarke, K. C. (2008). A Decade of Cellular Urban Modeling with SLEUTH: Unresolved Issues and Problems. En R. K. Brail (Ed.), *Planning Support Systems for Cities and Regions* (pp. 47-60). Lincoln Institute of Land Policy.
- Clarke, K. C., & Gaydos, L. J. (1998). Loose-coupling a Cellular Automaton Model and GIS: Long-term Urban Growth Prediction for San Francisco and Washington/Baltimore. *International Journal of Geographical Information Science*, 12(7), 699-714. <https://doi.org/10.1080/136588198241617>
- Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37-46. <https://doi.org/10.1177/001316446002000104>
- Consejo Nacional de Población (CONAPO) and SEDATU and INEGI. (2018). *Delimitación de las zonas metropolitanas de México 2015*. Consultado el 7 de junio de 2026, desde <https://www.gob.mx/conapo/documentos/delimitacion-de-las-zonas-metropolitanas-de-mexico-2015>
- Delgado, J., & López, A. (2018). Tendencias recientes del crecimiento urbano en la Zona Metropolitana de Querétaro [DOI no localizado en el repositorio de Estudios Demográficos y

- Urbanos (El Colegio de México)]. *Estudios Demográficos y Urbanos*, 33(1), 173-205. <https://estudiosdemograficosyurbanos.colmex.mx/index.php/edu/issue/view/EDU.v33i1>
- García-Ramírez, P., Alatorre-Cejudo, L. C., & Bravo-Peña, L. C. (2023). Detección, modelización y proyección del crecimiento urbano de núcleos de población en diferentes cuencas hidrológicas de Chihuahua, México. *Investigación y Ciencia de la Universidad Autónoma de Aguascalientes*, 31(90), 1-19. <https://doi.org/10.33064/iycuaa2023904103>
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18-27. <https://doi.org/10.1016/j.rse.2017.06.031>
- Hagenauer, J., & Helbich, M. (2022). A geographically weighted artificial neural network. *International Journal of Geographical Information Science*, 36(2), 215-235. <https://doi.org/10.1080/13658816.2021.1871618>
- Herold, M., Goldstein, N. C., & Clarke, K. C. (2003). The Spatiotemporal Form of Urban Growth: Measurement, Analysis and Modeling. *Remote Sensing of Environment*, 86(3), 286-302. [https://doi.org/10.1016/S0034-4257\(03\)00075-0](https://doi.org/10.1016/S0034-4257(03)00075-0)
- Huacuz Elías, R. d. J., & Vázquez Cruz, R. d. R. (2018). El proceso de metropolización en Querétaro 1990–2010. *Contexto. Revista de la Facultad de Arquitectura de la Universidad Autónoma de Nuevo León*, 12(16), 79-91. <https://doi.org/10.29105/contexto12.16-6>
- Instituto Nacional de Estadística y Geografía (INEGI). (2020). *Censo de Población y Vivienda 2020*. Consultado el 7 de junio de 2026, desde <https://www.inegi.org.mx/programas/ccpv/2020/>
- Jantz, C. A., Goetz, S. J., & Shelley, M. K. (2003). Using the SLEUTH Urban Growth Model to Simulate the Impacts of Future Policy Scenarios on Urban Land Use in the Baltimore-Washington Metropolitan Area. *Environment and Planning B: Planning and Design*, 30(2), 251-271. <https://doi.org/10.1068/b2983>
- Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, 33(1), 159-174. <https://doi.org/10.2307/2529310>
- Liu, X., Liang, X., Li, X., Xu, X., Ou, J., Chen, Y., Li, S., Wang, S., & Pei, F. (2017). A future land use simulation model (FLUS) for simulating multiple land use scenarios by coupling human and natural effects. *Landscape and Urban Planning*, 168, 94-116. <https://doi.org/10.1016/j.landurbplan.2017.09.019>
- Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. (2019). Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166-177.

- Montejano-Escamilla, J. A., Caudillo-Cos, C. A., Ávila-Jiménez, F. G., Tapia-McClung, R., & Barrera-Alarcón, I. G. (2023). Expansión y crecimiento urbanos en México, 1975–2020. *Región y Sociedad*, 35(e1734). <https://doi.org/10.22198/rys2023/35/1734>
- Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7), 971-987. <https://doi.org/10.1109/TPAMI.2002.1017623>
- Pontius Jr, R. G., Boersma, W., Castella, J.-C., Clarke, K., de Nijs, T., Dietzel, C., Duan, Z., Fotsing, E., Goldstein, N., Kok, K., Koomen, E., Lippitt, C. D., McConnell, W., Mohd Sood, A., Pijanowski, B., Pithadia, S., Sweeney, S., Trung, T. N., Veldkamp, A. T., & Verburg, P. H. (2008). Comparing the input, output, and validation maps for several models of land change. *The Annals of Regional Science*, 42(1), 11-37. <https://doi.org/10.1007/s00168-007-0138-2>
- Ramírez Hernández, R. (2021). *Zona Metropolitana de la Ciudad de México: crecimiento y expansión al 2040. Prospectiva territorial usando modelos de simulación urbana*. Universidad Nacional Autónoma de México, Instituto de Investigaciones Económicas. <https://doi.org/10.22201/iiec.9786073044349e.2021>
- Santé, I., García, A. M., Miranda, D., & Crecente, R. (2010). Cellular automata models for the simulation of real-world urban processes: A review and analysis. *Landscape and Urban Planning*, 96(2), 108-122. <https://doi.org/10.1016/j.landurbplan.2010.03.001>
- Silva, E. A., & Clarke, K. C. (2002). Calibration of the SLEUTH urban growth model for Lisbon and Porto, Portugal. *Computers, Environment and Urban Systems*, 26(6), 525-552. [https://doi.org/10.1016/S0198-9715\(01\)00014-X](https://doi.org/10.1016/S0198-9715(01)00014-X)
- Soares-Filho, B. S., Cerqueira, G. C., & Pennachin, C. L. (2002). DINAMICA—a stochastic cellular automata model designed to simulate the landscape dynamics in an Amazonian colonization frontier. *Ecological Modelling*, 154(3), 217-235. [https://doi.org/10.1016/S0304-3800\(02\)00059-5](https://doi.org/10.1016/S0304-3800(02)00059-5)
- Suárez, M., & Delgado, J. (2007). La expansión urbana probable de la Ciudad de México. Un escenario pesimista y dos alternativos para el año 2020. *Estudios Demográficos y Urbanos*, 22(1), 101-142. <https://doi.org/10.24201/edu.v22i1.1295>
- Tang, X., Liu, F., & Hu, X. (2024). Urban growth simulation and scenario projection for the arid regions using heuristic cellular automata. *Scientific Reports*, 14(1), 21106. <https://doi.org/10.1038/s41598-024-71709-4>

- Verburg, P. H., Soepboer, W., Veldkamp, A., Limpiada, R., Espaldon, V., & Mastura, S. S. A. (2002). Modeling the spatial dynamics of regional land use: the CLUE-S model. *Environmental Management*, 30(3), 391-405. <https://doi.org/10.1007/s00267-002-2630-x>
- Wang, R., He, Q., Zhang, L., & Wang, H. (2021). Coupling Cellular Automata and a Genetic Algorithm to Generate a Vibrant Urban Form—A Case Study of Wuhan, China. *International Journal of Environmental Research and Public Health*, 18(21), 11013. <https://doi.org/10.3390/ijerph182111013>
- White, R., & Engelen, G. (1997). Cellular Automata as the Basis of Integrated Dynamic Regional Modelling. *Environment and Planning B: Planning and Design*, 24, 235-246. <https://doi.org/10.1068/b240235>
- Wolfram, S. (1984). Cellular Automata as Models of Complexity. *Nature*, 311(5985), 419-424. <https://doi.org/10.1038/311419a0>